

Syntesöversikten

Grammatiken i Governance as Engineerings fjorton arbetsdokument — vad den hävdar, hur starkt, och vad den inte gör

Björn Kenneth Holmström · Juni 2026

Anspråk märks [R] rigorös, [IP] i princip, eller [H] heuristisk.

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/syntheses/brief>

En kompakt karta över en serie på fjorton teoretiska arbetsdokument, skriven för läsare inom teknik och politik. Den anger vad ramverket hävdar, markerar hur starkt det hävdar det, redovisar den första förutsägelsen som prövats mot data, och pekar ut det arbete som ännu inte är gjort.

Vad detta är, och vad det inte är

Detta är en syntes av *Governance as Engineering*, en serie på fjorton arbetsdokument som behandlar styrsystem som återkopplingssystem och frågar vad reglerteori, cybernetik och informationsteori har att säga om varför de misslyckas. Premissen ryms i en mening: styrsystem observerar, beslutar, agerar och observerar igen, och återkopplingssystem har strukturella egenskaper — latens, signaltrohet, dimensionalitet, förstärkningstak — som begränsar deras beteende oavsett avsikterna hos dem som driver dem.

Det är **inte ett manifest**, och det är inte en färdig teori. Arbetet är nyligen gjort, utvecklat av en enskild författare som arbetat snabbt och med omfattande AI-samarbete. Dess centrala diagnostiska anspråk — att många styrningsmisslyckanden är *arkitektoniska* snarare än *beteendemässiga* — är avsett att vara tillräckligt precist för att kunna ha fel på identifierbara sätt, och därmed kunna förbättras. Poängen med denna översikt är att göra ramverket läsbart för dem som kan pröva det, bryta det, utvidga det eller bygga med det. En läsare som vill veta om anspråken är att lita på tittar först på hur de reserveras, så reservationerna placeras främst snarare än begravs.

Hur du läser anspråken

Varje bärande anspråk i serien bär en av tre tillförlitlighetsetiketter. De används i denna översikt och genomgående i arbetsdokumenten.

- **[R] Rigorös** — bevisad inom en formell modell, eller en direkt följd av ett etablerat resultat i reglerteori eller informationsteori.
- **[IP] I princip** — den formella kärnan är solid, men dess översättning till institutioner är en tolkande motsvarighet, inte en härledning. De flesta av seriens styrningsanspråk ligger här: matematiken är verklig; överföringen från matematik till ministerier är ett argument, inte ett teorem.

- **[H] Heuristisk** — uppskattad, illustrerande eller löst tillämpad. Användbar för orientering, inte för avgörande. Indexvikter, varietetskvotens kortform och flera analogier mellan fall är uttryckligen av detta slag.

Distinktionen är viktig eftersom ramverkets mest förföriska felläge är att låta ett rigoröst formellt resultat låna ut auktoritet till en heuristisk politisk läsning. Att namnge nivån på varje anspråk är den disciplin som förhindrar detta. Där ett arbetsdokuments formella inre är rigoröst men dess styrningsläsning är i princip, anges båda etiketterna.

Tesen i ett enda steg

Betrakta varje styrsystem som en kontrollant i en loop med den värld det styr. Det observerar världens tillstånd genom en kanal som väljer ut vissa dimensioner och släpper andra, beslutar utifrån det det observerar, agerar, och observerar resultatet. Tre strukturella storheter sätter då hårda gränser, oberoende av kompetens eller vilja: **latens** (den döda tiden mellan störning och svar, som sätter ett tak för hur snabbt systemet kan reagera), **signaltröhet** (hur exakt information når beslutsskiktet, vilket avgör om besluten följer verkligheten eller en förvrängd bild av den) och **dimensionalitet** (hur många oberoende aspekter av världen systemet kan uppfatta, vilket fastställer gränsen mellan det som kan styras och det som anländer som en överraskning). **[IP]**

Ur dimensionaliteten kommer seriens organiserande resultat, **Goodhart–Ashby-syntesen**: en målfunktion med lägre dimensionalitet än systemet den styr optimerar med tiden bort sin egen förmåga att uppfatta det systemet. Ashbys lag om nödvändig variation säger att en kontrollant bara kan absorbera den variation av störningar den kan matcha; Goodharts lag säger att ett mått som blir ett mål upphör att mäta det det följde. Tillsammans: de dimensioner ett system inte värdesätter är de dimensioner det upphör att se, och de slutar inte verka — de ackumuleras som externaliteter tills de framtvingar en uppgörelse som systemets egna kanaler inte kunde förutse. Gapet mellan miljöns dimensionalitet och observationsarkitekturs dimensionalitet är **varietetsgapet**, G , den storhet hela serien är organiserad kring. **[IP]** (*Det statistiska villkoret — att den uppfattade variationen måste vara minst störningsvariationen minus målfunktionens räckvidd — är [R] inom modellen; dess likställande med verklig institutionell blindhet är [IP].*)

Följden är att de flesta reformer ändrar människorna, rutinerna eller resurserna *inom* en arkitektur utan att ändra arkitekturen, och därmed lämnar taket på plats. Misslyckandet är strukturellt, och det är strukturen serien försöker ge en grammatik.

Hur diagnosen ser ut i ett fall

Betrakta ett hälsosystem som försöker upptäcka en framväxande epidemi. Om det ser klustrade sjukhusinläggningar i realtid eller nationell dödlighetsstatistik månader senare är dess *observationskanal* och dess *latens*. Om en frontlinjeklinikers rapport om ett ovanligt fall når beslutsskiktet intakt, eller

medelvärdesbildas in i en regional sammanställning som löser upp klustret i medelvärdet, är dess *signaltrohet* och dess *representationskedja*. Om det modellerar smittspridning i grannjurisdiktioner eller behandlar dem som externa chocker är dess *gräns*. Inget av detta är en fråga om kompetens eller anslag; var och en är en strukturell egenskap som ramverket namnger, och tillsammans avgör de vad systemet kan och inte kan se innan någon fattar ett beslut. Grammatiken nedan är katalogen över sådana egenskaper.

Grammatiken: två teoricykler

De fjorton arbetsdokumenten faller i två cykler. Den första fastställer den **statiska arkitekturen** — de strukturella primitiv ett styrsystem har oavsett om det förändras eller ej. Den andra fastställer **anpassningens dynamik** — hur en arkitektur förändras, lär sig och förblir livsduglig, eller misslyckas med det. Tabellen anger varje arbetsdokument i de termer dess egen slutsats använder, med nivån på dess styrningsanspråk.

Rapport	Vad den fastställde	Cykel	Nivå
I	Latens och signaltrohet sätter hårda tak för responsivitet; centraliserade kontrollanter svarar på medelvärdet, inte fördelningen (medelvärdesproblemet).	Ett	IP
II	Störningar anländer med många frekvenser; en arkitektur med en enda hastighet är strukturellt felanpassad till de flesta av dem.	Ett	IP
III	Representationskedjor dämpar medborgarpreferenssignalen; bortom ett kritiskt djup kan beslutsskiktet inte längre tillförlitligt rekonstruera den (konstitutionell oobserverbarhet).	Ett	IP
IV	Nödvändig variation finns vid kontaktpunkten; närhet är ett tekniskt krav innan det är en politisk preferens.	Ett	IP
V	Begränsningarna i I–IV adderas inte — de förvärras multiplikativt (samordningsmisslyckandets skatt).	Ett	R / IP
VI	Målfunktioner är observationsarkitekturer; det ett system inte värdesätter upphör det att se (varietetsgapet).	Ett	IP
VII	Över femton landstudier sviker reformer strukturellt — genom det institutionella immunförsvaret, förbifartsfällan och läsbarhetsproblemet; det konvergerande första steget är det skyddade experimentutrymmet.	Ett	H
VIII	Varietetsgapet gjort uppskattbart: strukturella primitiv, proxyvariabler och ett sammansatt index G med angiven osäkerhet.	Ett	IP (index); H (vikter)
IX	Arkitektonisk förändring som omtvistad reglering: latensasymmetrin mellan reformatörer och etablerade intressen, och <i>övergångsbandbredd</i> som ett lopp som kan förloras innan det syns.	Två	IP (Ω -kvot: H)

Rapport	Vad den fastställde	Cykel	Nivå
X	Distribuerad avkänning misslyckas genom korrelation, inte enskilt fel: ensemblevariansen skalar som $\sigma^2 \cdot [(1-p)/N + p]$. Dess centrala förutsägelse — att en population samtida AI-observatörer är nära perfekt korrelerad — har nu förregistrerats och prövats (Studie 1, nedan).	Två	R (varians); empiriskt prövad
XI	Aktueringskanalen: delegeringskedjor förlorar en dimension per bristfälligt skikt (ett teorem), och regleransträngningen växer superlinjärt med djupet — vilket ger <i>konstitutionell ostyrbarhet</i> som den exakta dualen till III:s oobserverbarhet.	Två	R (kodimension); IP (energi)
XII	Gränsdraging som en oberoende designvariabel; small-gain-teoremet anger när omodellerad dynamik över gränsen destabiliserar en välskött kontrollant; poolningsparadoxen gör avvägningen oundviklig för varje enskild gräns.	Ett/Två	IP
XIII	Legitimitet som det första <i>endogena kopplingstillståndet</i> : den multiplicerar aktivering och dividerar observationsbrus, kan inte sättas direkt, och — när den är lånad snarare än byggd — kollapsar med hysteres.	Två	IP
XIV	Stabilt lärande som det tredje anpassningskravet: dual styrning (dual control), spänningen mellan utforskning och exploatering, och persistent excitation som det rigorösa innehållet i "antiskörhet".	Två	IP

Några resultat förtjänar **[R]**-etiketten direkt. Den multiplikativa förvärringen av felmoder i V är aritmetik. Ensemblevariansresultatet i X är en ren följd av hur korrelerade fel kombineras, och det är den formella kärnan i anspråket att en enda allseende modell är farligare än många ofullkomliga. Kodimensionslagen i XI — att en delegeringskedja förlorar exakt en rent överförd dimension per bristfälligt skikt — är ett teorem, inte en numerisk observation. Det mesta övriga är **[IP]**: reglerteorin är solid, och läsningen av institutioner genom den är ett disciplinerat argument som en skeptisk läsare bör behandla som sådant.

Den andra cykeln löses upp i en enda sekvens, **anpassningstriaden**:

Avkänna
↓
Lära
↓
Verkställa

Avkänna (Rapport X) är att hålla observatörer tillräckligt dekorrelerade för att fånga det fel de delar; *Lära* (Rapport XIV) är att utforska tillräckligt för att hålla modellen identifierbar; *Verkställa* (Rapport IX) är att behålla tillräcklig övergångsbandbredd för att ändra arkitekturen i tid. Ett system som inte kan avkänna verkligheten kan inte lära; ett som inte kan lära kan inte anpassa sig; ett som inte kan verkställa sin anpassning kan inte överleva. Avkänna → Lära → Verkställa är seriens svar på hur ett styrsystem förblir tillräckligt för en miljö som genererar nyheter snabbare än arkitekturer vanligen omkonstrueras.

Den reflexiva vändningen

Lästa tillsammans konvergerar den andra cykelns arbetsdokument mot något serien inte satte sig för att bevisa men ständigt återupptäckte: en livsduglig styrarkitektur måste upprätthålla villkoren för sin egen fortsatta anpassning. Övergångsbandbredd (IX), observatörsångfald (X), legitimitet (XIII) och förmågan att lära (XIV) är inte fyra orelaterade krav; de är fyra sidor av ett. Rapport XIV namnger det direkt — en kontrollant som inte bara reglerar systemet utan reglerar sin egen reglering, cybernetikens andra ordningens drag. Detta erbjuds som ett framväxande mönster, inte ett nytt primitiv; att lägga till det i katalogen vore teoriinflation. [IP]

Det har en följd värd att ange tydligt, eftersom den faller ut ur ingenjörskonsten snarare än ur något tidigare ställningstagande. De aktiviteter som upprätthåller en kontrollants modell av en föränderlig värld — utforskning, olikttänkande, oberoende observation — är lokalt ineffektiva och globalt nödvändiga. Persistent excitation (XIV) är det formella påståendet att ett system som undertrycker all varians inte kan identifiera sina egna parametrar; observatörsdekorrelation (X) är det formella påståendet att enighet bland identiska observatörer inte är bevis. Att skydda sådana aktiviteter är, enligt denna läsning, ett designkrav för att hålla modellen kalibrerad, inte en smaksak. Ramverket gör kravet synligt; det låtsas inte härleda ur det någon särskild uppfattning om vilka ändamål styrning bör tjäna.

Den tredje cykeln: från teori till test, och sedan till byggande

De första två cyklerna är teori. De diagnostiserar, formaliserar och mäter i prototyp. Mellan den teorin och all ingenjörskonst ligger en **empirisk grind**: ett ramverk som vägrar konfronteras med data förtjänar ännu inte namnet ingenjörskonst. Seriens stående regel, sedan mätdokumentet, är att ett dokumenterat nollresultat är mer värdefullt än en oprövad utvidgning.

Den första förutsägelsen har nu passerat grinden. Rapport X förutsäger att samtida AI-system, i allt högre grad använda som styrningsobservatörer, är nära perfekt korrelerade — att rådfråga fler av dem ger nästan ingen av den felreducering som oberoende observatörer skulle ge. Studie 1 prövade detta under ett fryst, förregistrerat protokoll (frågebatteriet publicerat före insamling; en blind extern granskning avgjord; nollresultat utlovade i förväg). Sex AI-konsumentssystem skattade vart och ett femtio styrningsrelevanta storheter dragna ur offentliga databaser, bedömda mot sanningsvärden. Den effektiva felkorrelationen var $\rho_{\text{eff}} \approx 0,97$ (95 % konfidensintervall ungefär [0,95, 0,99]): en ensemble av sex modeller låg nästan exakt på en enskild modells felnivå, där oberoende skulle ha skurit den ungefär sexfaldigt. Den primära förutsägelsen höll, avgörande. Den sekundära förutsägelsen — att korrelationen skulle vara starkast i svansarna — fick **inte** stöd, och redovisas som sådan. Begränsningarna anges i protokollet och spelar roll: sex system, konsumentgränssnitt snarare än kontrollerade instrument, poster begränsade till storheter som föregår modellernas träningsgräns, och protokolldesignern bland försökspersonerna (redovisat, och mildrat genom att flytta posturvalet till slumpdragningar med fröade frön ur offentliga databaser). Ett ekologiskt

komplement med färskor återstår på färdplanen. **Det anspråk detta medger är smalt och starkt: korrelationsskattemekanismen är verklig för dagens AI-observatörer — inte att ramverket som helhet är validerat.**

Det är en förutsägelse. Resten av det empiriska programmet är specificerat och öppet: en pilotgranskning av varietetsgapet i en villig institution; studien av delegeringsdjup mot implementeringstrohet i tillräcklig urvalsstorlek; en prospektiv varietetsgapspanel över tjugo till trettio styrsystem; legitimitetsskattningsprotokollet tillämpat på ett representativt urval. Bortom den empiriska fasen ligger ingenjörskonsten i egentlig mening — de skyddade experimentutrymmena, de oberoende observatörsensemblerna, legitimitetssensorerna och kretsbytarna som designprinciperna pekar mot. Inget av det har byggts.

Det anges här som en **öppen inbjudan**, och av ett skäl som överensstämmer med ramverkets egen logik. Serien hävdar att ingen enskild integratör bör vara flaskhalsen i ett system som är tänkt att uppfatta mer än någon enskild utsiktspunkt kan; Rapport X gör poängen formellt, och ett projekt utvecklat genom ett enda redaktionellt omdöme är ett uppriktigt exempel på just den begränsningen. Den jämförande styrkan i detta arbete har varit diagnostisk och formell. Utbyggnaden — piloter, instrument, institutionell design, ihållande empirisk prövning — är en annan disciplin, och den är öppen för medarbetare vars styrkor ligger där att ta upp, ändra och förbättra. Primitiven är definierade tillräckligt precist för att kunna operationaliseras; diagnosdiagrammet kan fyllas i för vilket nytt fall som helst som en övning; protokollen, simuleringarna och Studie 1:s frysta analyskript är reproducerbara.

Vad ramverket inte hävdar

Den ärliga gränsen är lika viktig som anspråken.

Det tillhandahåller inte *inhållet* i god styrning. Det specificerar strukturella villkor för livsdugliga styrarkitekturer; det avgör inte de etiska ändamål dessa arkitekturer bör eftersträva. Med Habermas distinktion talar det om institutioners facticitet, inte deras giltighet. Ingenjörskonst kan konstruera ett sjövärdigt skepp; den kan inte avgöra vart skeppet bör segla.

Flera storheter som läses som precisa är det inte. Det sammansatta indexet G är strukturellt motiverat **[IP]**, men dess nivåvikter och dess kritiska tröskel är **[H]** — parametriseringar kalibrerade mot fallsamlingen, inte härledda från första principer, och redovisade med känslighetsanalys av det skälet. Övergångsdokumentets varietetskvotkortform är en heuristik och hålls utanför det publika materialet. Översättningen av aktueringsdokumentets energilag till "politiskt kapital" är i princip, aldrig rigorös, och dess falsifierbara förutsägelser anges medvetet i trohet och djup, som kan kodas, snarare än i energi, som ännu inte kan det. Vissa axlar — särskilt var en verklig delegeringskedja ligger mellan sina idealiserade poler — saknar helt ett fältinstrument.

Och härkomsten är vad den är. Detta är ett nyligen gjort, ensamt, AI-assisterat projekt, inte ett långvarigt forskningsprogram. Mönstren mellan fall är tillräckligt samstämmiga över radikalt olika domäner för att osannolikt vara brus, och de formella kärnorna är kontrollerbara. Studie 1:s fynd berör projektets egen metod lika mycket som någon annans: serien sattes samman med hjälp av flera av samma system som studien mätte, så deras enighet kan inte läsas som bekräftelse. Det processen förlitade sig på var inte deras medelvärdesbildade skattningar utan de oenigheter den kunde lyfta fram och en redaktörs integrering av dem — och den förlitan är ett anspråk att kontrollera, inte ett försvar att ta för givet. Korpusen är en utgångspunkt byggd av en arkitektur med en enda redaktör i centrum, och dess mest användbara framtid är att utvidgas av människor som kan inta positioner som dess författare inte kan.

Inbjudan

Ramverket är ett levande diagnostiskt instrument, inte en privat metod. De användbara svaren på det är att pröva det mot fall det inte har sett, att utmana primitiven där de inte passar, att utvidga de formella grunderna där de är tunna, och — i den tredje cykeln som knappt har börjat — att mäta och att bygga. En förutsägelse har överlevt kontakten med data. Arbetet med att bygga återstår. Arkitekturen för att bygga är åtminstone specificerad tillräckligt väl för att börja.