

Syntesöversikten

Grammatiken i Styrning som ingenjörkonsts fjorton arbetsdokument — vad den hävdar, hur starkt, och vad den inte gör

Björn Kenneth Holmström · Juni 2026

Anspråk märks [R] rigorös, [IP] i princip, eller [H] heuristisk.

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/syntheses/brief>

En kompakt karta över en serie på tjugioåtta teoretiska arbetsdokument, skriven för läsare inom teknik och politik. Den anger vad ramverket hävdar, markerar hur starkt det hävdar det, redovisar den första förutsägelsen som prövats mot data, och pekar ut det arbete som ännu inte är gjort.

Vad detta är, och vad det inte är

Detta är en syntes av *Styrning som ingenjörskonst* (*Governance as Engineering*), en serie på tjugioåtta arbetsdokument som behandlar samhällets styrsystem — stater, myndigheter, institutioner — som återkopplingssystem, och frågar vad reglerteori, cybernetik och informationsteori har att säga om varför de misslyckas. Med *styrsystem* avses här samhällsstyrning, inte reglersystem i teknisk mening: reglertekniken är linsen, inte föremålet. Premissen ryms i en mening: styrsystem observerar, beslutar, agerar och observerar igen, och återkopplingssystem har strukturella egenskaper — latens, signaltrohet, dimensionalitet, förstärkningstak — som begränsar deras beteende oavsett avsikterna hos dem som driver dem.

Det är **inte ett manifest**, och det är inte en färdig teori. Arbetet är nyligen gjort, utvecklat av en enskild författare som arbetat snabbt och med omfattande AI-samarbete. Dess centrala diagnostiska anspråk — att många styrningsmisslyckanden är *arkitektoniska* snarare än *beteendemässiga* — är avsett att vara tillräckligt precist för att kunna ha fel på identifierbara sätt, och därmed kunna förbättras. Poängen med denna översikt är att göra ramverket läsbart för dem som kan pröva det, bryta det, utvidga det eller bygga med det. En läsare som vill veta om anspråken är att lita på tittar först på hur de reserveras, så reservationerna placeras främst snarare än begravs.

Hur du läser anspråken

Varje bärande anspråk i serien bär en av tre tillförlitlighetsetiketter. De används i denna översikt och genomgående i arbetsdokumenten.

- **[R] Rigorös** — bevisad inom en formell modell, eller en direkt följd av ett etablerat resultat i reglerteori eller informationsteori.
- **[IP] I princip** — den formella kärnan är solid, men dess översättning till institutioner är en tolkande motsvarighet, inte en härledning. De flesta av seriens styrningsanspråk ligger här: matematiken är

verklig; överföringen från matematik till ministerier är ett argument, inte ett teorem.

- **[H] Heuristisk** — uppskattad, illustrerande eller löst tillämpad. Användbar för orientering, inte för avgörande. Indexvikter, varietetskvotens kortform och flera analogier mellan fall är uttryckligen av detta slag.

Distinktionen är viktig eftersom ramverkets mest förföriska felläge är att låta ett rigoröst formellt resultat låna ut auktoritet till en heuristisk politisk läsning. Att namnge nivån på varje anspråk är den disciplin som förhindrar detta. Där ett arbetsdokuments formella inre är rigoröst men dess styrningsläsning är i princip, anges båda etiketterna.

Tesen i ett enda steg

Betrakta varje styrsystem som en regulator i en loop med den värld det styr. Det observerar världens tillstånd genom en kanal som väljer ut vissa dimensioner och släpper andra, beslutar utifrån det det observerar, agerar, och observerar resultatet. Tre strukturella storheter sätter då hårda gränser, oberoende av kompetens eller vilja: **latens** (den döda tiden mellan störning och svar, som sätter ett tak för hur snabbt systemet kan reagera), **signaltröhet** (hur exakt information når beslutsskiktet, vilket avgör om besluten följer verkligheten eller en förvrängd bild av den) och **dimensionalitet** (hur många oberoende aspekter av världen systemet kan uppfatta, vilket fastställer gränsen mellan det som kan styras och det som anländer som en överraskning).

[IP]

Ur dimensionaliteten kommer seriens organiserande resultat, **Goodhart–Ashby-syntesen**. Anspråket är *inte* att en regulator måste matcha sin omgivnings komplexitet — det behöver den inte, och kan den inte: all reglering bygger på reducerade modeller, och en väl vald modell av låg ordning är det normala och riktiga tillståndet. Anspråket är smalare, och det gäller *vilka* störningsdimensioner en regulator överhuvudtaget kan uppfatta. Ashbys lag om nödvändig variation, i sin störningsrelativa form, säger att en regulator bara kan avvisa den variation av störningar den kan matcha; Goodharts lag säger att ett mått som blir ett mål upphör att mäta det det följde. Tillsammans: målfunktionen väljer vilka dimensioner systemet observerar, och optimeringstrycket eroderar sedan dess avkänning av de dimensioner den inte värdesätter — så reduktionen är inte ett fritt ingenjörssval gjort med full sikt, utan ett som regulatorn inte kan granska, eftersom den inte kan se vad den har släppt. Dessa icke värdesatta dimensioner slutar inte verka; de ackumuleras som externaliteter tills de framtvingar en uppgörelse som systemets egna kanaler inte kunde förutse. **Varietetsgapet**, G , är denna målrelativa brist — den störningsvariation som arkitekturen lämnar oobserverad — inte det alltid stora, alltid harmlösa gapet mellan miljöns råa komplexitet och modellen. **[IP]** (*Det statistiska villkoret — att den uppfattade variationen måste vara minst störningsvariationen minus målfunktionens räckvidd — är $[R]$ inom modellen; dess likställande med verklig institutionell blindhet är $[IP]$.*)

Följden är att de flesta reformer ändrar människorna, rutinerna eller resurserna *inom* en arkitektur utan att ändra arkitekturen, och därmed lämnar taket på plats. Misslyckandet är strukturellt, och det är strukturen serien försöker ge en grammatik.

Hur diagnosen ser ut i ett fall

Betrakta ett hälsosystem som försöker upptäcka en framväxande epidemi. Om det ser klustrade sjukhusinläggningar i realtid eller nationell dödlighetsstatistik månader senare är dess *observationskanal* och dess *latens*. Om en frontlinjeklinikers rapport om ett ovanligt fall når beslutsskiktet intakt, eller medelvärdesbildas in i en regional sammanställning som löser upp klustret i medelvärdet, är dess *signalstrohet* och dess *representationskedja*. Om det modellerar smittspridning i grannjurisdiktioner eller behandlar dem som externa chocker är dess *gräns*. Inget av detta är en fråga om kompetens eller anslag; var och en är en strukturell egenskap som ramverket namnger, och tillsammans avgör de vad systemet kan och inte kan se innan någon fattar ett beslut. Grammatiken nedan är katalogen över sådana egenskaper.

Under grammatiken: Observationskanalens ursprung (Artikel 0)

Teserna ovan, och varje artikel som följer på dem, börjar efter att ett steg redan har inträffat: världens kontinuerliga flöde har skurits till en ändlig mängd variabler — *dess* räknas, *de där* gör det inte — och regulatören resonerar i *dem*. Den tillskrifningen är **faktoriseringen**, själva observationskanalen, och grammatiken nedan tar den som given. Artikel 0, skriven sent men avsedd att läsas först, tillhandahåller den saknade grunden genom att fråga var den kommer ifrån, och argumenterar för att faktorisering inte är primitiv utan *härledd*: två ingredienser — avgränsad representationskapacitet och ett naket temporalt prediktionsmål — räcker för att tvinga fram den, utan något krav på handling, belöning eller överlevnadstryck, så att en passiv prediktor redan skär världen vid fogar som följer dess struktur. En minimal modell uppvisar tre registrerade egenskaper [**R inom modellen**]: en flaskhalsad prediktor återvinner latent kausala variabler den aldrig informerades om (*emergens*); under kapacitetsbrist suddar den inte jämnt utan offrar ett sammanhängande kausalt underrum i sin helhet, och blir en *statisk observatör* som ser var saker är men inte vart de är på väg (*strukturell blindhet* — Artikel VI:s varietetsgap visat som en mekanism snarare än en stipulation); och vid kapacitetsmarginalen förbinder den sig diskret till en av ett konkurrerande par av variabler, där valet görs genom träningstillfällighet där världen är symmetrisk (*icke-unikt, symmetribrutet urval*). Två konsekvenser grundar det som de senare klustren bygger på: faktoriseringar bildar stora beteendemässigt ekvivalenta klasser, så institutionell samordning är *urval* inom en klass snarare än upptäckt av en unik sanning — men inom den friheten är klasser som bevarar miljöns kausala variabler objektivt bättre på robusthet, sampleffektivitet och överföring, så världen begränsar valet utan att fastställa det. Två-ingredients-argumentet är [**IP**]; mekanismen är [**R inom modellen**], och dess första registrerade operationalisering av strukturell blindhet misslyckades och korrigerades under en andra förhandsregistrering, rapporterad som en del av resultatet.

Grammatiken: två teoricykler

Rapport 0, skriven sent men avsedd att läsas först, ligger under hela strukturen som dess grundplan (märkt **Grund.** i tabellen) och inleder den. Av de tjugosju arbetsdokument som bygger på den faller femton i två cykler. Den första fastställer den **statiska arkitekturen** — de strukturella primitiv ett styrsystem har oavsett om det förändras eller ej. Den andra fastställer **anpassningens dynamik** — hur en arkitektur förändras, lär sig och förblir livsduglig, eller misslyckas med det. Tabellen anger varje arbetsdokument i de termer dess egen slutsats använder, med nivån på dess styrningsanspråk. De två cyklerna möts nu i en symmetri: den första cykelns statiska brister förvärras multiplikativt (V), medan den andra cykelns dynamiska förmågor begränsas av sitt minimum (XV) — de två sätt på vilka delarna i en flerdelad arkitektur misslyckas med att vara oberoende. De återstående tolv arbetsdokumenten bildar två senare kluster, beskrivna efter de två cyklerna: ett *kluster av uppfattningsgränser* (XVI–XVIII), som frågar ut de grunder cyklerna bygger på, och ett *faktoriseringskluster* (XIX–XXVII, märkt **Fakt.** i tabellen), som arbetar ut följderna av avgränsad representation. Bådas evidentiella karaktär skiljer sig från cyklernas och diskuteras med vart och ett.

Rapport	Vad den fastställde	Cykel	Nivå
0	Faktorisering — den observationskanal varje senare dokument tar för given — är inte primitiv utan <i>härledd</i> : avgränsad representationskapacitet plus ett rent mål om temporal prediktion räcker för att framtvinga den, utan handling, belöning eller överlevnadstryck. En flaskhalsad prediktor återvinner latent kausala variabler den aldrig fått veta att de finns (framväxt); under kapacitetssvält offerar den ett sammanhängande kausalt delrum helt snarare än att brytas ned jämnt (strukturerad blindhet — varietetsgapet mekaniserat); vid marginalen binder den sig vid en av ett konkurrerande par genom träningstillfällighet, inte världen (icke-unikt, symmetribrutet urval). Faktoriseringar bildar stora beteendemässigt ekvivalenta klasser, så samordning är urval inom en klass, inte upptäckt av en unik sanning — men klasser som bevarar miljöns kausala variabler är objektivt bättre.	Grund.	R (inom modellen) / IP
I	Latens och signaltrohet sätter hårda tak för responsivitet; centraliserade regulatorer svarar på medelvärdet, inte fördelningen (medelvärdesproblemet).	Ett	IP
II	Störningar anländer med många frekvenser; en arkitektur med en enda hastighet är strukturellt felanpassad till de flesta av dem.	Ett	IP
III	Representationskedjor dämpar medborgarpreferenssignalen; bortom ett kritiskt djup kan beslutsskiktet inte längre tillförlitligt rekonstruera den (konstitutionell oobserverbarhet).	Ett	IP
IV	Nödvändig variation finns vid kontaktpunkten; närhet är ett tekniskt krav innan det är en politisk preferens.	Ett	IP
V	Begränsningarna i I–IV adderas inte — de förvärras multiplikativt (samordningsmisslyckandets skatt).	Ett	R / IP

Rapport	Vad den fastställde	Cykel	Nivå
VI	Målfunktioner är observationsarkitekturer; det ett system inte värdesätter upphör det att se (varietetsgapet).	Ett	IP
VII	Över femton landstudier sviker reformer strukturellt — genom det institutionella immunförsvaret, förbifartsfällan och läsbarhetsproblemet; det konvergerande första steget är det skyddade experimentutrymmet.	Ett	H
VIII	Varietetsgapet gjort uppskattbart: strukturella primitiv, proxyvariabler och ett sammansatt index G med angiven osäkerhet.	Ett	IP (index); H (vikter)
IX	Arkitektonisk förändring som omtvistad reglering: latensasymmetrin mellan reformatörer och etablerade intressen, och <i>övergångsbandbredd</i> som ett lopp som kan förloras innan det syns.	Två	IP (Ω -kvot: H)
X	Distribuerad avkänning misslyckas genom korrelation, inte enskilt fel: ensemblevariansen skalar som $\sigma^2 \cdot [(1-p)/N + p]$. Dess centrala förutsägelse — att en population samtida AI-observatörer är nära perfekt korrelerad — har nu förregistrerats och prövats (Studie 1, nedan).	Två	R (varians); empiriskt prövad
XI	Aktueringskanalen: delegeringskedjor förlorar en dimension per bristfälligt skikt (ett teorem), och regleransträngningen växer superlinjärt med djupet — vilket ger <i>konstitutionell ostyrbarhet</i> som den exakta dualen till III:s oobserverbarhet.	Två	R (kodimension); IP (energi)
XII	Gränsdragning som en oberoende designvariabel; small-gain-teoremet anger när omodellerad dynamik över gränsen destabiliserar en välskött regulator; poolningsparadoxen gör avvägningen oundviklig för varje enskild gräns.	Ett/Två	IP
XIII	Legitimitet som det första <i>endogena kopplingstillståndet</i> : den multiplicerar aktivering och dividerar observationsbrus, kan inte sättas direkt, och — när den är lånad snarare än byggd — kollapsar med hysteres.	Två	IP
XIV	Stabilt lärande som det tredje anpassningskravet: dual styrning (dual control), spänningen mellan utforskning och exploatering, och persistent excitation som det rigorösa innehållet i "antiskörhet".	Två	IP
XV	Anpassningstriaden har ändlig genomströmning: avkänning, lärande och verkställande delar en rekursiv slinga vars anpassningstakt begränsas av dess långsammaste steg (<i>anpassningsflaskhalsen</i>), den dynamiska dualen till V:s förvärring; informations-, innovations- och verklighetseftersläpningarna är dess felsignaturer.	Två	R (flaskhals) / IP
XVI	Bevarande av utforskning motstår formalisering: över fyra discipliner avtar en storhet som representerar oanvända alternativ under optimering och kvarstår endast genom en <i>källterm optimeraren själv inte sätter</i> . Ordningsparametern är <i>källtermens lokalitet</i> — inom eller utom optimerarens kontrollmängd — inte optimerarens "räckvidd". Ett medvetet avgränsat, negativt resultat.	Gräns	IP

Rapport	Vad den fastställde	Cykel	Nivå
XVII	Bearbetning kan göras godtyckligt verifierbar; <i>certifiering av verkligheten</i> kan inte göras självverifierande. Att automatisera en gräns omlokaliserar dess oreducerbara världscertifieringslänk uppströms men raderar den inte (<i>omlokaliseringsinvarianten</i>) — för världskopplad samordning, vilket styrning är per konstruktion; ren konvention undslipper den.	Gräns	IP
XVIII	Gränser driver under regulatorns eget lärande: när anpassning verkar genom kanaler som också bär koppling över gränsen överlever <i>ingen fast uppdelning i jurisdiktion och miljö lärandet</i> (icke-faktoriserbarhetsteoremet). En <i>kritisk lärandebandbredd</i> — för långsam förlorar systemet, för snabb löser upp gränsen — sluter sig över en del av parameterrummet (<i>dekomponerbarhetsfronten</i>). Det förregistrerade förvarningsindexet misslyckades som definierat och redovisas så.	Gräns	R (inom modellen) / IP
XIX	En bevarad faktorisering bär tre särskiljbara slags värde — att <i>styra väl, varna</i> tidigt (sentinel), eller <i>överbrygga</i> ekologin — och styrförmåga förutsäger inget av de andra två; vinnaren-tar-allt-urval faller varnings- och förbindelsevärde som bieffekt. Replikerad över tjugo omtränade ekologier.	Fakt.	R (inom modellen) / IP
XX	Ashby, Goodhart och certifieringskostnad är en och samma gräns sedd under tre operationer — att hålla, optimera, upprätthålla. Den skärpta Goodhart: optimering eroderar målet endast när projektionen släpper en målrelevant dimension som optimeraren kan <i>nå</i> . Sökandet efter en bevarandelag redovisas som misslyckat.	Fakt.	R (inom modellen) / IP
XXI	Den avgränsade regulatorns livscykel genom tre separationer — lärande $\neq$ anpassning, metalärande $\neq$ gratis, fortlevnad $\neq$ syfte — var och en en glidning från en intern framgång till den yttre den finns till för.	Fakt.	R (regress) / IP
XXII	Tre slags försäkran en institution vill ha — inifrån, utifrån, inför världen — misslyckas alla, men från <i>tre olika källor</i> ; symmetrin "tre gränser ur en gräns" avvisas. En institution kan inte övervaka sin egen certifieringskärna med instrument som beror av den.	Fakt.	R (teorem) / IP
XXIII	Den utlovade geometrin för faktoriseringsrummet existerar mestadels inte (tre registrerade misslyckanden): stress skalar om det snarare än omformar det. Det som består: beteendavstånd är ett symmetriskt mått, men <i>reformkostnad är riktad</i> — asymmetrisk, icke-komponerbar, billigast via en sned väg genom målets närområde.	Fakt.	R (inom modellen) / IP
XXIV	En mångfaldsproxy följer räckvidden till värdesatta alternativ när den observeras passivt men frikopplas när den optimeras: den optimerade agenten maxar proxyn men förlorar räckvidden. Ett persistent excitation-misslyckande inneslutet i ett mål.	Fakt.	R (inom modellen) / IP

Rapport	Vad den fastställde	Cykel	Nivå
XXV	Bodes känslighetsintegral importerad som bevarandelagen bakom "undertryckt tryck omlokaliseras", med sina gränser markerade: bevarad log-area avgör inte realiserad förlust, som en strategisk motståndare läser av från den övre svansen. Utnyttjande kräver koncentration, åtkomlighet och upptäckt — inget av det följer av bevarandet.	Fakt.	R (Bode) / IP
XXVI	Rapport X:s fasta placeholder för flyktsannolikhet ersatt av ett kompetenstillstånd: flykt från epistemisk monokultur <i>nukleeras</i> av den bäst bevarade kanalen och <i>sprids</i> genom en stegkaskad; institutionell tid träder in som ackumulerad flyktmöjlighet.	Fakt.	R (inom modellen) / IP
XXVII	Nödvändig variation är nödvändig men inte tillräcklig. I ett exakt löst reglerproblem förlorar återkoppling som bär full information om tillståndet men löser ett systematiskt <i>förskjutet</i> mål betydande beslutsvärde (dämpning i 82 % av de prövade förhållandena, ingen <i>berikning</i>). Två förskjutningar som bär identisk information medför olika kostnader, och ordningen kastas om när förskjutningen fördjupas — så <i>nödvändig samstämmighet</i> (vilken distinktion signalen löser, inte hur många) är en andra, geometriskt strukturerad begränsning som Goodhart–Ashby-syntesen inte namngav. Seriens första beräkningsmekanistiska artikel.	Fakt.	R / R (inom modellen) / IP

Några resultat förtjänar **[R]**-etiketten direkt. Den multiplikativa förvärringen av felmoder i V är aritmetik. Ensemblevariansresultatet i X är en ren följd av hur korrelerade fel kombineras, och det är den formella kärnan i anspråket att en enda allseende modell är farligare än många ofullkomliga. Kodimensionslagen i XI — att en delegeringskedja förlorar exakt en rent överförd dimension per bristfälligt skikt — är ett teorem, inte en numerisk observation. Och anpassningsflaskhalsen i XV — att en rekursiv slingas anpassningstakt är minimum av dess stegtakter — är likaledes aritmetik, den dynamiska dualen till V:s förvärring. Det mesta övriga är **[IP]**: reglerteorin är solid, och läsningen av institutioner genom den är ett disciplinerat argument som en skeptisk läsare bör behandla som sådant.

Den andra cykeln löses upp i en enda sekvens, **anpassningstriaden**:

Avkänna



Lära



Verkställa

Avkänna (Rapport X) är att hålla observatörer tillräckligt dekorrelerade för att fånga det fel de delar; *Lära* (Rapport XIV) är att utforska tillräckligt för att hålla modellen identifierbar; *Verkställa* (Rapport IX) är att behålla tillräcklig övergångsbandbredd för att ändra arkitekturen i tid. Ett system som inte kan avkänna

verkligheten kan inte lära; ett som inte kan lära kan inte anpassa sig; ett som inte kan verkställa sin anpassning kan inte överleva. Avkänna → Lära → Verkställa är seriens svar på hur ett styrsystem förblir tillräckligt för en miljö som genererar nyheter snabbare än arkitekturer vanligen omkonstrueras.

Den reflexiva vändningen

Lästa tillsammans konvergerar den andra cykelns arbetsdokument mot något serien inte satte sig för att bevisa men ständigt återupptäckte: en livsduglig styrarkitektur måste upprätthålla villkoren för sin egen fortsatta anpassning. Övergångsbandbredd (IX), observatörmångfald (X), legitimitet (XIII) och förmågan att lära (XIV) är inte fyra orelaterade krav; de är fyra sidor av ett. Rapport XIV namnger det direkt — en regulator som inte bara reglerar systemet utan reglerar sin egen reglering, cybernetikens andra ordningens drag. Detta erbjuds som ett framväxande mönster, inte ett nytt primitiv; att lägga till det i katalogen vore teoriinflation. [IP]

Det har en följd värd att ange tydligt, eftersom den faller ut ur ingenjörskonsten snarare än ur något tidigare ställningstagande. De aktiviteter som upprätthåller en regulators modell av en föränderlig värld — utforskning, oliktänkande, oberoende observation — är lokalt ineffektiva och globalt nödvändiga. Persistent excitation (XIV) är det formella påståendet att ett system som undertrycker all varians inte kan identifiera sina egna parametrar; observatörsdekorrelation (X) är det formella påståendet att enighet bland identiska observatörer inte är bevis. Att skydda sådana aktiviteter är, enligt denna läsning, ett designkrav för att hålla modellen kalibrerad, inte en smaksak. Ramverket gör kravet synligt; det låtsas inte härleda ur det någon särskild uppfattning om vilka ändamål styrning bör tjäna.

Gränserna-för-uppfattning-klustret (XVI–XVIII)

Tre senare arbetsdokument bildar en distinkt grupp. Där de två cyklerna bygger ramverket, frågar detta kluster ut de grunder som den andra cykelns anpassningsförmåga vilar på: om utforskning kan bevaras mot den optimering som eroderar den (XVI), om de gränser en styrenhet litar på kan göras hållbara mot den optimerare som tjänar på att flytta dem (XVII), och om en jurisdiktion förblir avskiljbar från sin omgivning när styrenhetens eget lärande omformar kopplingen (XVIII). Dess karaktär är medvetet annorlunda än de konstruktiva arbetsdokumentens – fynden är avgränsade, flera är negativa, och den högsta tillförlitlighetsetiketten hålls tillbaka avsiktligt. Varje dokument togs fram genom ett adversativt flermodellsprotokoll: en hypotes skickades genom flera avancerade språkmodeller som användes som dekorrelerade observatörer och snävades in under ihållande kritik tills endast det påstående som överlevde kontakten återstod. Varje dokument noterar att dess evidens är stark i att ”flera discipliner formaliserar samma struktur” och svag i att ”strukturen är sann om världen”, eftersom observatörerna själva är korrelerade språkmodeller – samma försiktighet som Studie 1 mätte, nu riktad mot klustrets egen metod.

Arbetsdokument XVI frågar om de många domänspecifika varningarna att framgång eroderar anpassningsförmåga namnger ett enda objekt eller bara rimmar. Fyra discipliner – reglerteknik, evolutionsbiologi, institutionell ekonomi, beslutsteori – ställdes var och en samma strukturella fråga i strikt inhemsk vokabulär, med de gemensamma termerna förbjudna och svaret undanhållet. De oberoende formella utsagorna delar ett skelett: en storhet som representerar för närvarande oanvända alternativ avtar under det primära målet och består endast genom en *källterm som optimeringsprocessen själv inte sätter*. Den korrigerade ordningsparametern är **källtermens lokalitet** – huruvida den termen ligger inom eller utanför optimerarens kontrollmängd. Två linser placerar den strikt utanför (en regulator kan inte berika sin egen referens; en etablerad aktör kan inte sätta ett tak för sina egna inträdesbarriärer), två i ett omstritt område som fältet inte har stängt. Arbetsdokumentet vägrar uttryckligen en enhetlig teori, ett mätbart index och ett no-go-teorem; det tillåtna anspråket är den delade avtagande-plus-källtermsstrukturen och den enda axel längs vilken de fyra skiljer sig. [IP]

Arbetsdokument XVII isolerar varför en sådan extern källterm kan vara oreducerbar. Kärnan är en asymmetri: **bearbetning** – huruvida ett system beräknar det det påstår – kan göras godtyckligt verifierbar, men **verklighetscertifiering** – huruvida det yttre faktum som en regel beror av faktiskt inträffade – kan inte göras självverifierande, eftersom en verifierare av ett världsfaktum i sin tur behöver en verifierare, och regressen avslutas endast genom att man litar på ett ankare som inte är verifierat. Ur detta följer **omlokaliseringsinvarianten**: att automatisera en samordningsgräns omlokaliserar dess oreducerbara världscertifieringslänk uppströms men raderar den inte – ett oföränderligt smart kontrakt stänger exekveringslänken och återöppnar samma beroende vid specifikationslänken (vad tokenen representerar, vad förslaget betyder). Invarianten är räckviddsavgränsad: den binder *världskopplad* samordning, som måste svara mot något faktum utanför sig själv, och misslyckas bevisligen för *självrefererande* samordning (ren konvention), där regel och praktik är samma sak. Styrning är per konstruktion världskopplad, så invarianten gäller den. Designspaken är inte att eliminera tillit utan att minimera kedjan till en enda diskret certifieringslänk och kostnadshärda den – och att lägga märke till att hårdning av *registret* (en manipulationssäker liggare) inte är hårdning av *certifieringen* (den människa eller sensor som intygar att det registrerade faktumet inträffade, fortfarande den mjukaste punkten). [IP]

Arbetsdokument XVIII återför klustret till ett ingenjörsmässigt register genom att ta bort ett antagande från gränsanalysen i arbetsdokument XII. XII behandlade koppling över gränser som exogen – ett landskap som styrenheten jagar. XVIII behandlar fallet där styrenhetens eget lärande omformar kopplingen, och bevisar **icke-faktoriserbarhetsteoremet [R inom modellen]**: under generiskt ihållande lärande överlever ingen tidsinvariant uppdelning av världen i jurisdiktion och miljö – den gräns som var korrekt vid designtillfället blir okorrigerad av den anpassning den innesluter. En minimal modell uppvisar konsekvensen som en cykel av faktoriserbart lugn, dold ackumulation av koppling, icke-faktoriserbar kollaps och felkalibrerad återhämtning, vilken bortom en reflexivitetströskel slutar i ett *låst* tillstånd där gränsen svetsas igen. En **kritisk lärandebandbredd** begränsar inläringstakten från båda hållen – för långsam förlorar systemet (arbetsdokument XV:s gräns i lokal form), för snabb löser upp gränsen – och de två gränserna klämmer endogent, så att de stänger helt över en betydande region av parameterutrymmet: **dekomponerbarhetsfronten**,

en avvägning med en ogenomförbar sida. Omramningen är att styrningens gränsproblem inte är att välja rätt gräns utan att upprätthålla en dekomponerbarhetsmarginal under den drift som lärande oundvikligen inducerar. **[R inom modellen] / [IP]**

XVIII producerade också seriens tydligaste registrerade nollresultat. Det band sig i förväg vid ett förvarningsindex – stigande korrelation av *prediktionsfel* över gränsen skulle flagga gränsupplösning innan den syntes i utfall – med den bindande konsekvensen att misslyckande skulle kosta de relevanta avsnitten deras stöd. Det misslyckades: vid en strikt budget för falsklarm fångade indexet som det var registrerat ungefär en kollaps av fem. Mekanismen är resultatet. Lokal anpassning absorberar gränsöverskridande koppling i intern förstärkning och tvättar därmed bevisen på upplösning ur just de residualer som en välskött institution övervakar – Goodharts lag tillämpad på själva diagnostiken, och en ny instans av XVI:s källtermslokalitet som nu konsumerar informativiteten hos en signal. Kopplingen överlever endast där inget lokalt mål skrubbar den, i gränsöverskridande *tillståndskovarians*, och även där är upptäckten ledtidsbegränsad. Indexet skrevs om på tillståndskovarians och nedgraderades till **[H]** i väntan på fältdata. Att en serie om gränserna för institutionell perception fann sitt eget föreslagna instrument underkastat dem, och att disciplinen med registrerad förutsägelse fångade det, erbjuds som att metoden fungerade som avsett.

Faktoriseringsklustret (XIX–XXVII): Avgränsad representation och dess konsekvenser

En tredje grupp om nio artiklar utgår från en premiss som de tidigare cyklerna lämnade implicit och som en grundläggande not (genomgående refererad till som *Artikel 0*) gör explicit: en avgränsad regulator kan inte representera sin värld i dess helhet, så den måste *faktorisera* — skära världen i en ändlig mängd uppgiftsrelevanta distinktioner — och den faktorisering den landar i är icke-unik och regimberoende, privilegierad av omgivningen snarare än fastställd av den. Klustret frågar vad som följer när den premissen väl tas på allvar: vad en regulator bör göra med de flera faktoriseringar den skulle kunna hålla, vilka av seriens lånade lagar som är konsekvenser av gränsen snarare än oberoende postulat, hur en avgränsad arkitektur åldras, vilka garantier den aldrig kan ge sig själv, vad faktoriseringsrummets geometri gör och inte gör, och om det ens räcker att bära tillräcklig variation för att en observation ska vara värd att agera på. Dess karaktär fortsätter gränsklustrets disciplin och skärper den: nästan varje påstående bärs av en förhandsregistrerad simulering med fastställda trösklar och fastställda nollhypoteser, omtränad över många frön så att ett resultat bara räknas om det överlever att modellerna regenereras under det. De empiriska påståendena märks **[R inom modellen]** — exakta för det angivna systemet, och gör inga anspråk direkt på någon institution — med styrningsläsningarna hållna vid **[IP]**. Klustrets mest utmärkande drag är tätheten av dess ärliga nollresultat: flera artiklar leds av förutsägelser som misslyckades, utifrån den stående uppfattningen att en registrerad falsifiering är ett bidrag, inte en pinsamhet.

Artiklarna XIX och XXIII är ett empiriskt par om den portfölj av faktoriseringar en regulator håller. XIX frågar vad vinnaren-tar-allt-urval förkastar när det bara behåller den för tillfället bäst styrande modellen. Över tjugo oberoende omtränade modellekologier finner den att en faktorisering bär åtminstone tre

särskiljbara slags värde — den kan *styra* väl, *varna* tidigt (en vaktpost som ser det fel den aktiva guvernören inte kan), eller *överbrygga* ekologin (hålla öppna översättningsvägar mellan faktoriseringar som annars skulle driva utom räckhåll) — och att styrningsskicklighet inte förutsäger något av de andra två. En adaptiv revision som bevarar alla faktoriseringar för avkänning men förbinder sig till en för handling, och återöppnar vid evidens, följer ett ouppnåeligt orakel och slår en monokultur i alla tjugo ekologierna; den främsta guvernören skiljer sig från den främsta bron i samtliga tjugo och från den främsta vaktposten i sjutton (även om guvernör–vaktpost-korrelationen, vid $\rho = 0,48$, gör den dissociationen verklig men svag). Två registrerade påståenden misslyckades och rapporteras som misslyckanden, och disciplinerar pilotens överanspråk. Resultatet ger XVI:s källtermer en mekanism — optimering gör sig av med tidig varningskapacitet, inte för att varning är kostsam utan för att den är okorrelerad med styrningsskicklighet — och tillför ett felmod som de tidigare artiklarna saknade: styrning kan misslyckas genom fragmentering av faktoriseringsrummet, vilket ingen förbättring av den aktiva guvernören reparerar. XXIII, det utlovade geometriska syskonet, inleder med att rapportera att det objekt den skulle beskriva mestadels inte existerar: en falsifierbarhetsgranskning före textförfattande och registrerad replikation fann att stress *omskalar* faktoriseringsrummet snarare än omformar det, att den anslutningströskel XIX hade lutat sig mot bevisligen bara är en omformulering av avståndsmagnitud, och att ingen topologisk övergång framträder under en kontinuerlig stressvepning. Det som överlever är skarpare för misslyckandena: beteendemässigt avstånd är en symmetrisk metrik, men *reformkostnad är riktad* — starkt asymmetrisk (vad en arkitektur kostar att lämna är inte vad den kostar att återvända till), icke-komponerande, och bara svagt förutsagd av beteendemässigt avstånd. Att rutta en reform genom ett mellansteg sänker dess kostnad, men en registrerad kontroll visar att detta inte är geodetiskt: det bästa mellansteget beror på reformens destination, inte dess ursprung — reform är billigast via en sned ansats genom målets grannskap. **[R inom modellen] / [IP]**

Artiklarna XX och XXII är ett formellt par om vad gränsen implicerar och, uttryckligen, vad den inte gör. XX visar att tre av de lagar serien har lutat sig mot — Ashbys nödvändiga variation, Goodharts lag och XVII:s certifieringskostnad — inte är oberoende postulat utan en och samma gräns sedd under tre operationer: att hålla en faktorisering (Ashby, ett fakteorem, nästan definitionsmässigt och flaggat som grunt), att optimera genom den (Goodhart), och att upprätthålla dess passform över tid (certifieringskostnad, en monoton redovisningsolikhet). Det enda substantiellt nya resultatet är en skärpt Goodhart: optimering eroderar målet *precis när* den förlustbringande projektionen förkastar en målrelevant dimension som optimeraren kan *nå* — den förkastade dimensionens nåbarhet är diskriminatoren, vilket säger vilka proxyvariabler som är säkra och vilka som inte är det (demonstrerat över trettio registrerade världar, **[R inom modellen]**). Artikeln rapporterar också ett misslyckat sökande efter en *konserveringslag*: representationskomplexitet kan stiga eller falla; endast kostnaden för att förbli i linje är monoton, och det negativa resultatet anges snarare än slätas över. XXII vägrar den frestande parallellen — "tre gränser från en gräns" — och visar att den är falsk. Tre garantier en institution kan vilja ha misslyckas från tre olika källor: reformers oavgörbarhet kräver beräkningsmässig *universalitet* (negationen av avgränsad representation, eftersom en ändlig regulator har ett avgörbart konvergensproblem); No Free Lunch-gränsen kräver endast frånvaron av en fördelning över miljöer och binder avgränsade och oavgränsade regulatorer lika; endast certifieringsoförmågan spåras till gränsen. I denna terräng, observerar XXII, löper stringens och intresse i

motsatta riktningar — de två rena teoremen är grunda, det enda resultatet med verkligt innehåll är inte ett teorem. Dess empiriska demonstration misslyckades på alla fyra registrerade förutsägelser, och vad som ersatte dem (återregistrerat, bekräftat på tjugo nya frön) är klustrets skarpaste praktiska påstående: att invertera en institutions behovsdetektkanal svälter inte den felidentifierade parten utan *översvämmar* dem, så ouppfyllt behov avläses som en perfekt nolla och misslyckandet är osynligt inifrån — en institution kan inte övervaka sin egen certifieringskärna med instrument som är beroende av den kärnan, och en sviktande institutions hälsoindikatorer kan *förbättras*. **[R inom modellen] / [IP]**

Artikel XXI behandlar den avgränsade arkitekturs livscykel genom tre separationer, var och en en plats där en regulator misstar en intern framgång för den externa den finns till för att tjäna. *Lärande är inte anpassning*: att förbättra modelltrohet och att upprätthålla koppling till världen kan motverka varandra, och en registrerad minimal modell visar den snabbaste inläraren hålla den bästa modellen och det sämsta greppet — koppling når en topp vid en mellanhög inlärningshastighet och försämras sedan, grindad av en absorptionskapacitetsolikhet (**[R inom modellen]** för separationen). *Meta-lärande är inte gratis*: stegen av att lära-sig-lära kan inte regrediera i det oändliga i ett avgränsat system, så den måste stängas på en liten uppsättning invarianter som hålls stilla — identitetsgräns, certifieringskärna, minne, tidsskaleseparation, en plural reserv — och konstitutionell ingenjörskonst är, i denna läsning, valet av vad som ska hållas fast. *Fortlevnad är inte syfte*: en institutions terminala adaptiva handling kan vara att avsluta eller överföra sin koppling snarare än att fortsätta, och det karakteristiska misslyckandet är regulatorn som bevarar sig själv i stället för den koppling den byggdes för att upprätthålla. De sista två är argumenterade, inte demonstrerade, och markerade som sådana. **[R] (regress) / [IP]**

Artikel XXIV isolerar en skarpare form av Goodhart-som-sensorkorruption i ett minimalt adaptivt system. En mångfaldsproxy byggd på en grovkornig observatör följer en agents genuina räckvidd till värdefulla perifera optioner *när utforskning varierar passivt*, men frikopplas helt så snart proxyn blir ett optimeringsmål: den optimerade agenten driver proxyn till sitt tak samtidigt som den inte behåller någon förmåga att nå periferin. Perifer räckvidd bevaras endast när observatören löser upp periferin tillräckligt fint i förhållande till dess åtkomstkostnad, där upplösning och kostnad verkar additivt. Och snedvridningen behöver inte påtvingas — en representation inlärd från uppgiftscentrerad erfarenhet lägger sin upplösning på det ofta besökta centrumet och komprimerar periferin av sig själv, och hamnar i frikopplingsregimen; bredare utforskning reparerar inte detta, men strukturell exponering som samplar periferin gör det. Mekanismen är ett persisterande exciteringsfel inbyggt i ett mål: att optimera observatören undertrycker den excitering som skulle låta den se vad den är avsedd att mäta. Miljön är en enda deterministisk rutvärld utan strategiska agenter; bidraget är en mekanism och en falsifierbar förutsägelse för administrativ mätning, angiven som hypotes, inte som en styrningslag. **[R inom modellen] / [IP]**

Artikel XXV ger seriens återkommande påstående att "undertryckt tryck omlokaliseras" den formella grund det vanligtvis saknar, och är noggrann med var grunden slutar. Den importerar Bodes känslighetsintegral — en genuin konserveringslag: för en stabil slinga med relativt gradtal minst två konserveras log-känsligheten, så undertryckning i ett övervakat band är en nedre gräns för förstärkning någon annanstans (**[R]**, inom de

linjära, fast-regulator-, icke-strategiska villkor som inte bokstavligen gäller i styrning). Dess konceptuella innehåll är en geometrisk mismatchning: konservering verkar på den positiva delen av $\log|S|$, medan en strategisk motståndares realiserade förlust verkar på den övre svansen av $|S|^2$ (CVaR av responsen över en nåbar mängd). Eftersom dessa är olika funktionaler av samma profil, bestämmer konserverat tryck inte realiserad skada, och den tillgängliga förstärkta *arean* bestämmer inte den tillgängliga *förlusten*. Exploatering licensieras av tre separerbara kapaciteter — koncentration, tillgänglighet, upptäckt — varav ingen impliceras av konservering. En konvex-syntesstudie visar sedan att köp av djupare övervakad-band-undertryckning höjer exploaterbarhetsgolvet, och att en lösare tillåtelse för komplementär känslighet sänker det endast tills undertryckningen är maximal, där designfriheten kollapsar. Artikeln är en explicit övning i att *inte* begå seriens namngivna fel om lånad auktoritet: konserveringslagen är importerad för exakt vad den licensierar och inget mer. [R] / [IP]

Artikel XXVI avlägsnar en plathållare från Artikel X. X representerade svårigheten att fly från en epistemisk monokultur med en enda fast nära-noll-sannolikhet att återgå till oberoende; XXVI ersätter den med ett explicit kompetenstillstånd som återuppbyggs under oberoende drift och avklingar under användning av delade system. En homogen medelfältsreduktion löses i slutet form, och delar upp hysteresen mellan konsolidering och återgång i en konsensusterm, en kompetensavklingningsterm och en ansvarsterm — där kompetensavklingning bevisligen flyttar *återgång*ströskeln men inte *inträde*ströskeln. Den heterogena populationen avviker från den reduktionen på ett strukturerat sätt som är artikelns huvudobjekt: flykt från full konsolidering *nukleeras* av den bäst bevarade kanalen och *propageras* av en kaskad vars genomförbarhet är ett stegvillkor på de ordnade straffen (den k-te billigaste kanalen måste vara livskraftig efter k-1 avhopp). Den resulterande flyktstege-satsen ger ett ändlig-populations-kvantilkriterium — ingen anpassad fasgräns — som klassificerar femtiofem av femtiosex celler i ett fruset rutnät, dess enda miss på själva gränsen, och ett stokastiskt lager visar flyktfaror som sammansätts till de observerade utträdeströsklarna så att institutionell tid kommer in som ackumulerad flyktmöjlighet. Flera registrerade förutsägelser misslyckades längs vägen och ersattes; uppdelningen och stegsatsen är exakta inom modellen, överföringen till verklig epistemisk infrastruktur [IP] i bästa fall. [R inom modellen] / [IP]

Den tredje cykeln: från teori till test, och sedan till byggande

De första två cyklerna är teori. De diagnostiserar, formaliserar och mäter i prototyp. Mellan den teorin och all ingenjörskonst ligger en **empirisk grind**: ett ramverk som vägrar konfronteras med data förtjänar ännu inte namnet ingenjörskonst. Seriens stående regel, sedan mätdokumentet, är att ett dokumenterat nollresultat är mer värdefullt än en oprövad utvidgning.

Den första förutsägelsen har nu passerat grinden. Rapport X förutsäger att samtida AI-system, i allt högre grad använda som styrningsobservatörer, är nära perfekt korrelerade — att rådfråga fler av dem ger nästan ingen av den felreducering som oberoende observatörer skulle ge. Studie 1 prövade detta under ett fryst, förregistrerat protokoll (frågebatteriet publicerat före insamling; en blind extern granskning avgjord; nollresultat utlovade i förväg). Sex AI-konsumentssystem skattade vart och ett femtio styrningsrelevanta

storheter draga ur offentliga databaser, bedömda mot sanningsvärden. Den effektiva felkorrelationen var $p_{\text{eff}} \approx 0,97$ (95 % konfidensintervall ungefär [0,95, 0,99]): en ensemble av sex modeller låg nästan exakt på en enskild modells felnivå, där oberoende skulle ha skurit den ungefär sexfaldigt. Den primära förutsägelsen höll, avgörande. Den sekundära förutsägelsen — att korrelationen skulle vara starkast i svansarna — fick **inte** stöd, och redovisas som sådan. Begränsningarna anges i protokollet och spelar roll: sex system, konsumentgränssnitt snarare än kontrollerade instrument, poster begränsade till storheter som föregår modellernas träningsgräns, och protokolldesignern bland försökspersonerna (redovisat, och mildrat genom att flytta posturvalet till slumpdragningar med fröade frön ur offentliga databaser). Ett ekologiskt komplement med färsk storheter återstår på färdplanen. **Det anspråk detta medger är smalt och starkt: korrelationsskattemekanismen är verklig för dagens AI-observatörer — inte att ramverket som helhet är validerat.**

Det är en förutsägelse. Resten av det empiriska programmet är specificerat och öppet: en pilotgranskning av varietetsgapet i en villig institution; studien av delegeringsdjup mot implementeringstrohet i tillräcklig urvalsstorlek; en prospektiv varietetsgapspanel över tjugo till trettio styrsystem; legitimitetsskattningsprotokollet tillämpat på ett representativt urval. Bortom den empiriska fasen ligger ingenjörskonsten i egentlig mening — de skyddade experimentutrymmena, de oberoende observatörsensemblerna, legitimitetssensorerna och kretsbytarna som designprinciperna pekar mot. Inget av det har byggts.

Det anges här som en **öppen inbjudan**, och av ett skäl som överensstämmer med ramverkets egen logik. Serien hävdar att ingen enskild integratör bör vara flaskhalsen i ett system som är tänkt att uppfatta mer än någon enskild utsiktspunkt kan; Rapport X gör poängen formellt, och ett projekt utvecklat genom ett enda redaktionellt omdöme är ett uppriktigt exempel på just den begränsningen. Den jämförande styrkan i detta arbete har varit diagnostisk och formell. Utbyggnaden — piloter, instrument, institutionell design, ihållande empirisk prövning — är en annan disciplin, och den är öppen för medarbetare vars styrkor ligger där att ta upp, ändra och förbättra. Primitiven är definierade tillräckligt precist för att kunna operationaliseras; diagnosdiagrammet kan fyllas i för vilket nytt fall som helst som en övning; protokollen, simuleringarna och Studie 1:s frysta analyskript är reproducerbara.

Vad ramverket inte hävdar

Den ärliga gränsen är lika viktig som anspråken.

Det tillhandahåller inte *inhållet* i god styrning. Det specificerar strukturella villkor för livsdugliga styrarkitekturer; det avgör inte de etiska ändamål dessa arkitekturer bör eftersträva. Med Habermas distinktion talar det om institutioners facticitet, inte deras giltighet. Ingenjörskonst kan konstruera ett sjövärdigt skepp; den kan inte avgöra vart skeppet bör segla.

Det är inte en allmän systemteori. Mitten av nittonhundratalets försök att skapa en sådan — von Bertalanffys allmänna systemteori och dess efterföljare — lovade mer än de höll, och kritiken av den överambitionen är befogad (Berlinski, *On Systems Analysis*, MIT Press, 1976). Disciplinen som dras ur den historien är medvetet blygsam: reglertekniska begrepp gör nytta som diagnostiska linser på specifika problem, i kombination med ingående områdeskännedom, inte som en enhetlig teori ur vilken styrningsutfall kan härledas. Där denna översikt använder ordet *grammatik* avses en katalog av strukturella egenskaper att pröva fall för fall — inte ett generativt system som förklarar institutioner på egen hand.

Inte heller är kärnobservationen — att ett enskilt lågdimensionellt mått förvränger — i sig ny: Goodharts lag, Ridgways "what gets measured gets done" och ekonomins decennielånga vändning mot flerdimensionella mått på utveckling och välfärd säger alla detsamma. Bidraget här är den strukturella mekanismen — målfunktionen som observationsarkitektur, och dess erosion under optimering — inte observationen att mått förvränger.

Flera storheter som läses som precisa är det inte. Det sammansatta indexet G är strukturellt motiverat **[IP]**, men dess nivåvikter och dess kritiska tröskel är **[H]** — parametriseringar kalibrerade mot fallsamlingen, inte härledda från första principer, och redovisade med känslighetsanalys av det skälet. Övergångsdokumentets varietetskvotkortform är en heuristik och hålls utanför det publika materialet. Översättningen av aktueringsdokumentets energilag till "politiskt kapital" är i princip, aldrig rigorös, och dess falsifierbara förutsägelser anges medvetet i trohet och djup, som kan kodas, snarare än i energi, som ännu inte kan det. Vissa axlar — särskilt var en verklig delegeringskedja ligger mellan sina idealiserade poler — saknar helt ett fältinstrument.

Och härkomsten är vad den är. Detta är ett nyligen gjort, ensamt, AI-assisterat projekt, inte ett långvarigt forskningsprogram. Mönstren mellan fall är tillräckligt samstämmiga över radikalt olika domäner för att osannolikt vara brus, och de formella kärnorna är kontrollerbara. Studie 1:s fynd berör projektets egen metod lika mycket som någon annans: serien sattes samman med hjälp av flera av samma system som studien mätte, så deras enighet kan inte läsas som bekräftelse. Det processen förlitade sig på var inte deras medelvärdesbildade skattningar utan de oenigheter den kunde lyfta fram och en redaktörs integrering av dem — och den förlitan är ett anspråk att kontrollera, inte ett försvar att ta för givet. Korpusen är en utgångspunkt byggd av en arkitektur med en enda redaktör i centrum, och dess mest användbara framtid är att utvidgas av människor som kan inta positioner som dess författare inte kan.

Inbjudan

Ramverket är ett levande diagnostiskt instrument, inte en privat metod. De användbara svaren på det är att pröva det mot fall det inte har sett, att utmana primitiven där de inte passar, att utvidga de formella grunderna där de är tunna, och — i den tredje cykeln som knappt har börjat — att mäta och att bygga. En förutsägelse har överlevt kontakten med data. Arbetet med att bygga återstår. Arkitekturen för att bygga är åtminstone specificerad tillräckligt väl för att börja.