




Adaptiv självstyrning

Den reflexiva kontrollanten och självrevisionens gränser

Kompanjon till Själv-variationsgapet och Cykel Två i serien Styrning som ingenjörskonst

Kompanjon till Själv-variationsgapet och Cykel Två i serien Styrning som ingenjörskonst. Tillämpar adaptationstriaden — observatörmångfald, aktueringsintegritet, själv-legitimitet, gränskalibrering och adaptivt lärande — på självet som en kontrollant vars kontrollant och system är samma entitet.

Innehåller formella appendix om själv-observatörskorrelation, aktueringskedjans dämpning, själv-legitimitetsdynamik och observatör-system-identitet.

Björn Kenneth Holmström

Juni 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/sv/working-papers/adaptive-self-governance>

Sammanfattning

Ett tidigare arbete fastställde att en persons värderingar fungerar som en observationsarkitektur: en värdefunktion med lägre dimensionalitet än det själv den styr optimerar med tiden bort sin egen förmåga att uppfatta det självet, och de uteslutna dimensionerna återkommer som kriser personen inte kan spåra till sin källa. Det argumentet är statiskt — det handlar om huruvida ett själv kan uppfatta sig självt vid ett givet ögonblick. Detta papper utvidgar ramverket till det adaptiva problemet: hur ett själv fortsätter att uppfatta, agera, lita på, lära sig och avgränsa sig självt genom ett liv i förändring. Med utgångspunkt i den andra cykeln av serien *Governance as Engineering* visar det att ett livsdugligt själv måste göra fem strukturellt distinkta saker samtidigt — upprätthålla dekorrelerade kanaler för självobservation, föra intention till handling genom en intern delegeringskedja, vidmakthålla tillit till sina egna varseblivningar och åtaganden, placera en fungerande gräns mellan sig själv och andra, och fortsätta att revidera sig självt i takt med att omständigheterna förändras — och att misslyckande i en enda destabiliserar resten.

Pappret introducerar ett strukturellt drag som inte finns i den överordnade serien: *observatör-anläggning-identitet*, det faktum att kontrollanten och det styrda systemet är samma entitet i ett själv. Detta är en formalisering av andra ordningens cybernetik snarare än en upptäckt, men taget på allvar som en begränsning förutsäger det specifika och icke-uppenbara sätt på vilka resultaten på själv-skalan avviker från sina institutionella förlagor. Dess mest generella konsekvens är att självobservation aldrig bara är observation — att rikta uppmärksamheten mot ett tillstånd är att förändra det — så att reglerteorins separation av skattning och styrning fallerar för ett själv; samma koppling gör uthållig självobservation till ett medel för förändring och inte enbart för kunskap. Från denna grund utvecklar pappret de fem primitiven, och lyfter fram två av deras resultat. *Konstitutionell själv-ostyrbarhet* — bortom ett kritiskt delegeringsdjup lämnar en intention den nåbara mängden oavsett ansträngning — är den exakta dualen till det tidigare arbetets konstitutionella oobserverbarhet, så att de två pappren tillsammans begränsar självstyrningen på båda dess kanaler: det finns tillstånd i självet en person inte kan se, och tillstånd en person inte kan nå, varje gräns arkitektonisk snarare än viljemässig. Och själv-revidering visas vara begränsad på två sidor — nedtill av behovet att förbli kalibrerad, upptill av den takt med vilken ett reviderat själv kan åter-koherenta — där den övre gränsen är snävare för ett själv än för någon institution, eftersom ett själv inte kan isolera sin experimentapparat från sina egna experiment.

Den epistemiska hållningen anges först eftersom den styr allt som följer. Detta är seriens mjukaste empiriska terräng: man kan inte randomisera människor till självobservationsarkitekturer eller självlegitimitetshistorier och mäta livsutfall med samma hanterbarhet som det överordnade programmets empiriska arbete, så nästan varje substantiellt påstående här är i-princip snarare än bekräftat, och den rigorösa kärnan är smal och ärvd från den överordnade serien snarare än nyligen etablerad på denna skala. Överföringarna mellan styrning och själv är på flera ställen tillräckligt rena för att vara förföriska, och pappret behandlar den renheten som en fara snarare än en meritering, markerar för varje primitiv om överföringen är genuin skal-invarians eller ren analogi och rangordnar överföringarna därefter — gräns-överföringen, den svagaste, visas falla på den formella nivån där systemen på bortre sidan av en själv-andra-gräns blir agenter som modellerar kontrollanten tillbaka. Genomgående erbjuder pappret arkitektonisk diagnos, inte normativ föreskrift: det specificerar villkor under vilka ett själv förblir adaptivt, inte ett sätt att leva, och dess avslutande vändning mot glädje, skönhet och sanning presenteras som ett avgränsat uttalande av ramverkets gräns — det innehåll ingen målfunktion kan rymma — snarare än som en slutsats ramverket påstår sig ha nått.

Bidrag

- **Introducerar observatör–anläggning-identitet** — kontrollanten och anläggningen som en enda entitet — som det strukturella drag som skiljer självstyrning från institutionell styrning till sin art snarare än till skala, och härleder **mätning–störning-kopplingen**, reglerteorins separationsprincips fallerande för ett själv, som dess mest generella konsekvens. Bidraget är demonstrationen att detta enda drag förutsäger de specifika avvikelserna i resultaten på själv-skalan, inte den nakna observationen att självet är reflexivt.
- **Utvidgar Cykel Två anpassningsgrammatik** — Avkänna → Lära → Verkställa — till självet genom fem primitiv (observatörsångfald, aktueringsintegritet, själv-legitimitet, gränskalibrering, adaptivt lärande), under ett explicit test som skiljer skal-invarians från analogi, med överföringsstyrkorna rangordnade och den svagaste visad där den brister.
- **Fastställer konstitutionell själv-ostyrbarhet som dualen till konstitutionell oobserverbarhet**, så att det tidigare arbetet och detta tillsammans begränsar självstyrning på båda kanalerna — de tillstånd en person inte kan uppfatta och de tillstånd en person inte kan nå, var och en konstitutionell snarare än viljemässig.
- **Härleder en tvåsidig gräns för själv-revidering** — kalibrering nedtill, koherens upptill — och visar att den övre gränsen saknar en fullständig institutionell motsvarighet, en direkt konsekvens av observatör–anläggning-identitet som ger strukturellt innehåll åt observationen att transformation måste taktas till integration.
- **Identifierar sammansatt misslyckande som standardmoden för sammanbrott i självstyrning**. Eftersom primitiven är multiplikativt kopplade (samordningsmisslyckandets skatt från Rapport V) och delar ett substrat utan brandväggar mellan dem, propagerar misslyckanden över primitiv; det allvarligaste, det *förseglade självet*, fusionerar observatörs kollaps, modellåsning och transparensfällan till ett tillstånd självet inte kan uppfatta inifrån.
- **Anger konstruktionsprinciperna som en kopplad uppsättning under en enda logik** — rekrytera, utanför det reflexiva substratet, den struktur självet inte kan vara för sig självt — med ett internt undantag, uthållig självobservation som intervention, och härleder ett sekvensanspråk: ett sammansatt misslyckande beträds inte vid dess mest skadade primitiv utan där själv-legitimitet, den multiplikativa förstärkningen på varje annat primitiv, återuppbbyggs.

Epistemiska nivåer. Varje bärande påstående bär en av tre etiketter. **[R]** markerar ett resultat som följer ur etablerad matematik inom sin giltighetsdomän, eller ett rigoröst uttalande av ramverkets egna gränser. **[IP]** markerar ett påstående som följer strukturellt ur den rigorösa kärnan när den tillämpas på självet men inte är empiriskt bekräftat på den skalan. **[H]** markerar ett tolkande eller illustrativt påstående som gör strukturen läsbar utan att bära argumentets tyngd. Det tidigare arbetet använde schemat [R]/[I]/[S]; detta papper antar korpus-standarderna [R]/[IP]/[H], en skärpning snarare än en ometikettering. Nästan hela det substantiella innehållet i detta papper är [IP]: strukturellt förutsagt, inte oberoende bekräftat — en hållning Del 0 utvecklar innan argumentet börjar.

Del 0 — Epistemisk ram

Självvet I (Varietetsgapet i självvet) argumenterade för att en persons värderingar fungerar som en observationsarkitektur: en lågdimensionell värdefunktion förstör information om självvet på samma sätt som ett lågdimensionellt styrningsmått förstör information om ett samhälle, och de uteslutna dimensionerna återkommer som kriser personen inte kan spåra till sin källa. Det pappret kartlade sig mot den första cykeln av serien Governance as Engineering — den cykel som rör perception. Detta papper utvidgar ramverket till den andra cykeln, den cykel som rör anpassning: hur ett själv fortsätter att uppfatta, agera, lita på och lära sig genom ett liv i förändring snarare än vid ett enda ögonblick. Utvidgningen bygger på rapporterna X till XIV i den överordnade serien, och det är, med bred marginal, seriens mjukaste empiriska terräng. Denna ram anger varför, och vilken disciplin pappret antar som konsekvens, innan kartläggningarna börjar — eftersom kartläggningarna är tillräckligt rena för att vara förföriska, och renheten är en fara snarare än en meritering.

0.1 De tre nivåerna

Varje bärande påstående i detta papper bär en av tre etiketter, applicerad på påståendet vid den punkt där det görs:

- **[R] — rigorös.** Ett påstående som följer ur etablerad matematik tillämpad inom sin giltighetsdomän, *eller* ett rigoröst uttalande av ramverkets egna gränser. Den andra satsen spelar större roll här än någon annanstans i serien: där detta papper markerar en gräns det inte får överskrida — linjen mellan strukturen hos en svårighet och dess kliniska orsak — är gränsdragningen själv ett rigoröst resultat och taggas därefter, inte behandlad som en reservation.
- **[IP] — i princip.** Ett påstående som följer strukturellt ur den rigorösa kärnan när den väl tillämpas på självvet: logiskt sunt, men inte empiriskt bekräftat på självets skala, och i flera fall inte bekräftbart med de metoder som är tillgängliga för det överordnade programmet.
- **[H] — heuristisk.** Ett tolkande eller illustrativt påstående — en psykologisk läsning, en särskild livsinstans, en magnitud — som erbjuds för att göra strukturen läsbar. Det bär uttryckligen inte argumentets tyngd, och argumentet överlever att det är felaktigt.

Självvet I använde etiketterna [R]/[I]/[S] — rigorös, tolkande, spekulativ. Detta papper antar korpus-standarderna [R]/[IP]/[H] för konsistens med rapporterna X–XIV. Korrespondensen är inte en-till-en: Självvet I:s tolkande [I]-nivå delas, där dess strukturella tillämpningar blir [IP] och dess illustrativa innehåll blir [H], och dess spekulativa [S]-nivå blir [H] utom där den sätts i karantän som en avgränsad horisont (Del IX). En läsare som för Självvet I:s schema framåt bör läsa migrationen som en skärpning, inte en ometikettering.

0.2 Vad som bär varje nivå här

Det styrande testet genomgående är en enda distinktion: för varje primitiv lånad från den överordnade serien, är kartläggningen till självvet *skal-invariants* — samma matematik, en annan kontrollant — eller är den *analogi* — det rimmar? Pappret hävdar det förra endast där det förra håller, och flaggar det senare som vad det är. De två är inte utbytbara, och att behandla en analogi som en identitet är det specifika misslyckande denna ram existerar för att förhindra.

Enligt det testet är [R]-nivån i detta papper smal och lånad. Den omfattar de resultat som är skal-invarianta till sin konstruktion — den korrelerade ensemblevarianskorrektionen som ligger till grund för observatörmångfald (Del II), den duala reglerings- och persistenta excitationsstrukturen som ligger till grund för adaptivt lärande (Del VI), kopplingsalgebran som ligger till grund för själv-legitimitet (Del IV) — tillsammans med gränsdragningarna i §0.1. Dess stringens är *ärvd* från den överordnade serien, där dessa resultat är förankrade i formell härledning och, i fallet med observatörskorrelation, i ett förregistrerat empiriskt test. Bidraget på själv-skalan är inte att åter-etablera denna matematik utan att visa att den gäller — att en persons självobservationskanaler är en korrelerad ensemble, att ett liv är ett dualt regleringsproblem, och så vidare. Den demonstrationen är strukturell, och den placerar tillämpningen på [IP]-nivån även där den underliggande matematiken är [R]. Nästan hela det substantiella innehållet i detta papper är därför [IP]: strukturellt förutsagt, inte oberoende bekräftat. [H]-nivån bär den psykologiska färgen — läsningarna av stagnation, självbedrägeri, den kuraterade förtroga — som gör strukturen igenkännbar utan att stödja den.

0.3 Den empiriska asymmetrin

Den överordnade serien förtjänade rätten till sina [IP]-påståenden, delvis genom femton landfall och en förregistrerad studie där konsument-AI-system skattade styrningsrelevanta storheter, vilket gav den nästan totala observatörskorrelation som Del II återoppar. Inget jämförbart ankare är tillgängligt på självets skala, och skälet är strukturellt snarare än en fråga om ännu inte nedlagd möda. Man kan inte randomisera människor till olika självobservationsarkitekturer, självlegitimitetshistorier eller explorationsgrader och mäta livskvalitet med något som liknar hanterbarheten i att fråga sex AI-system om femtio poster. Vissa påståenden här kan så småningom möta korrelationell eller longitudinell evidens — självkomplexitetsinstrument existerar redan, och det överordnade programmets grind för att öppna teoricykler är bekräftad förutsägelse, inte teoretisk koherens — men den starka experimentella bekräftelse som disciplinerar styrningsteorin kommer inte, via samma väg, att nå själv.

Konsekvensen är att nivådisciplinen gör *mer* arbete i detta papper än i något annat i serien, inte mindre. Med det empiriska golvet borttaget är etiketterna det mesta som står mellan ett strukturellt argument och ett övertygande sådant. Detta är också varför elegansen i kartläggningarna är en varning. När en översättning mellan domäner blir så ren som flera av dessa gör, kan renheten betyda att strukturen är genuint skal-invariant, eller så kan den betyda att metaforen utför arbete som matematiken inte gör. Läsaren är skyldig denna tvetydighet angiven i förväg, och skyldig den som mest högljutt just där kartläggningen känns mest oundviklig.

0.4 Det diagnostiska kontraktet

Pappret upprätthåller seriens stående disciplin: det erbjuder arkitektonisk diagnos, inte normativ föreskrift. Det beskriver villkor under vilka ett själv förblir adaptivt — dekorrelerad observation, korta aktueringskedjor, byggd snarare än lånad självtyllit, kalibrerad exploration — och det härleder konstruktionsprinciper som uttalanden om arkitektur snarare än som råd om hur man ska leva. Det säger inte vad en person bör värdera, vad ett blomstrande liv är, eller om någon särskild läsare bör genomföra den självrevidering det analyserar. Där det senare materialet vänder sig mot glädje, skönhet, mening och sanning (Del IX), presenteras det materialet som en avgränsad spekulativ horisont och taggas som sådant — som ett uttalande av ramverkets *gräns*, de saker det kan specificera villkor för utan att specificera, snarare än som en slutsats det påstår sig ha bevisat. Det optimistiska registret på de avslutande sidorna är inhägnat i förväg just så att det inte kan misstas för ett resultat.

Ett strukturellt element i detta papper är nytt snarare än lånat: *observatör–anläggning-identitet*, det faktum att kontrollanten och det styrda systemet är samma entitet i ett själv. Det är den enda primitiv Själv II tillför seriens grammatik, det utvecklas i Del I, och det återkommer som skälet till att flera av resultaten på själv-skalan avviker från sina institutionella förlagor snarare än bara förminskar dem. Det introduceras här endast så att läsaren vet att det som följer inte är ren översättning — att pappret gör anspråk på ett genuint nytt strukturellt drag, och låter tyngden av sina avsteg från den överordnade serien vila på detta enda påstående.

Del I — Det adaptiva problemet och det reflexiva självet

1.1 Själv I:s begränsning

Själv I fastställde ett nödvändigt villkor för självstyrning och blottade därigenom sin egen otillräcklighet. Villkoret var perceptuellt: en person vars värdearkitektur har för få dimensioner för att spänna över sitt livs störningsmiljö är strukturellt blind för källorna till sin egen nöd, och ingen mängd uppriktighet eller ansträngning kan återskapa en signal som arkitekturen aldrig släppte in. Det argumentet är fullständigt så långt det sträcker sig. Men adekvat självperception, även där den uppnås, styr ingenting i sig självt. Den är förutsättningen för självstyrning, inte själva handlingen.

Otillräckligheten visar sig i två misslyckanden som ser ut som motsatser. Det första är personen som uppfattar sig själv korrekt och inte förändras — som kan beskriva sitt mönster med precision, namnge vad det kostar dem, artikulera exakt vad en bättre kurs vore, och fortsätta, år efter år, i det mönster de har beskrivit. Perceptionen är intakt; ingenting nedströms om den rör sig. Det andra är personen som förändras konstant och förlorar sig själv — som reviderar, omlokaliserar och återupptäcker sig så lättvindigt att ingen version av självet består tillräckligt länge för att levast, och som anländer till det ackumulerade vrakspillret av många nystarter utan någon sammanhängande identitet att visa upp för någon av dem. Korrekt perception producerar i det första fallet ingen handling; snabb handling upplöser i det andra fallet den som förnimmer. Inget av misslyckandena är ett misslyckande i självkännedom i Själv I:s mening, och det är poängen: självkännedom är nödvändig och räcker inte.

Vad de två misslyckandena avslöjar är att ett livsdugligt själv måste göra flera strukturellt distinkta saker samtidigt. Det måste uppfatta sig självt adekvat — och genom mer än en kanal, eftersom en enda kanal inte kan upptäcka sitt eget systematiska fel. Det måste översätta vad det uppfattar till handling genom en intern delegeringskedja som försvagar intentionen. Det måste upprätthålla tillit till sina egna varseblivningar och åtaganden, eftersom ett själv som misstror sina egna rapporter eller förväntar sig att bryta sina egna löften styr ingendera. Det måste dra en fungerande gräns mellan sig självt och andra. Och det måste fortsätta att lära sig i takt med att självet och dess omständigheter förändras, utan att inläringen destabiliserar det själv som måste absorbera den. Misslyckande i någon av dessa destabiliserar resten. Detta är det adaptiva problemet, och det är ämnet för det föreliggande pappret. Genom alltsammans löper ett strukturellt drag som gör självfallet kategoriskt annorlunda än det institutionella fall som den överordnade serien studerade — annorlunda till sin art, inte bara till sin skala — och resten av denna del ägnas åt det. [IP]

1.2 Observatör–anläggning-identitet

I de styrsystem den överordnade serien analyserar är kontrollanten och anläggningen distinkta entiteter. Ett departement styr en ekonomi; en tillsynsmyndighet styr en industri; kontrollanten är en sak och det system den observerar och agerar på är en annan. Denna separation är så grundläggande för reglerteorin att den sällan uttalas: observationen är utanför det observerade. Den legitimerar fältets standardarkitektur, där en kontrollant mäter tillståndet hos ett separat system, jämför det med ett mål och agerar för att sluta differensen.

Ett själv har inte denna separation. Den entitet som observerar är den entitet som observeras; den apparat som utfärdar direktiv är den apparat som måste efterleva dem; det system som regleras är det system som reglerar. Kalla detta *observatör–anläggning-identitet*: i självstyrning är kontrollanten och anläggningen samma entitet. Det är det enda

strukturella drag detta papper tillför seriens grammatik, och det är mindre en upptäckt än en formalisering. Att det själv som observerar är det själv som observeras är insikten i roten av andra ordningens cybernetik (von Foerster), och Själv I noterade redan dess närvaro när det läste Acceptance and Commitment Therapy's distinktion mellan själv-som-innehåll och själv-som-kontext som andra ordningens cybernetik på den personliga skalan. Bidraget här är inte den nakna observationen att självet är reflexivt. Det är demonstrationen att detta enda drag, taget på allvar som en strukturell begränsning, förutsäger specifika och icke-uppenbara sätt på vilka resultaten på själv-skalan avviker från sina institutionella förlagor — sätt som utvecklas i de delar som följer. **[R]** för det strukturella uttalandet; konsekvenserna är **[IP]**.

1.3 Mätning–störning-kopplingen

Den mest generella konsekvensen av observatör–anläggning-identitet är också den som saknar institutionell motsvarighet, och den rör själva observationshandlingen.

När ett styrsystem mäter sin anläggning lämnar mätningen anläggningen approximativt ostörd. En folkräkning förändrar inte märkbart den befolkning den räknar; en undersökning av ekonomisk aktivitet förändrar inte, till första ordningen, den ekonomi den samplar. Detta nära oberoende av mätning från det mätta är vad som garanterar reglerteorins *separationsprincip* — resultatet att skattning och styrning kan designas oberoende av varandra, att ett system först kan fastställa sitt tillstånd och sedan bestämma vad det ska göra åt det. De två operationerna är distinkta eftersom observera och agera faller på olika objekt.

För ett själv faller de på samma objekt, och separationen kollapsar. Att rikta uppmärksamheten mot en sensation är att förändra den — att förstärka den, dämpa den eller omvandla den till något den inte var innan uppmärksamheten anlände. Att fråga sig själv hur man känner inför en sak är att förändra känslan i själva frågandet. Att berätta sin situation är att konstituera situationen lika mycket som att registrera den; berättelsen är inte en avläsning av ett tidigare tillstånd utan delvis produktionen av det tillstånd den påstår sig beskriva. Självobservation är därför aldrig bara observation. Den är samtidigt en intervention på det observerade systemet, eftersom det bara finns ett system. Separationsprincipen fallerar för självet: en person kan inte först läsa av sitt tillstånd och sedan bestämma vad den ska göra, eftersom avläsningen redan är ett görande. **[IP]**

Detta har en konsekvens som bör anges tydligt eftersom den kvalificerar Själv I. Det "sanna tillstånd" $\mathbf{x}_{\text{själv}}$ som Själv I:s observationsekvation projicerar in i medvetandet är inte ett fast mål som personen läser av med större eller mindre trohet. Det konstitueras delvis av själva avläsningshandlingen. "Korrekt självperception" förblir ett meningsfullt mål, men det är inte återvinnandet av ett redan existerande faktum; det ligger närmare en stabil fixpunkt i en process där observera och bli observerad är samma rörelse. Ramverket löser inte detta — det markerar det, som den punkt där den bekväma metaforen om självet som ett system med ett tillstånd att mäta når sin gräns. **[H]** för den filosofiska utläggningen; det strukturella påståendet att mätning och störning är kopplade i självet är **[IP]**.

1.4 Tveeggadheten

Det vore lätt att läsa observatör–anläggning-identitet som en katalog över ytterligare handikapp — självet som en kontrollant belastad med reflexiva defekter som departementet är förskonat från. Den läsningen är halva bilden, och den saknade halvan är vad som gör självstyrning rikare än styrning snarare än bara mer komprometterad.

Samma koppling som kontaminerar självobservation gör också självobservation till en styrsignal. Eftersom att rikta uppmärksamheten mot en dimension av självet förändrar den, är uppmärksamhetshandlingen en spak, inte bara en sensor. Detta är det strukturella skälet till att de praktiker Själv I samlade under sina tolkande och spekulativa lager — uthållig uppmärksamhet, kontemplativ träning, den disciplinerade åter-berättelsen av ens egen erfarenhet i terapi — kan vara transformativa snarare än bara informativa. De fungerar inte genom att passivt förbättra avläsningen av ett fast tillstånd; de fungerar därför att, i ett system där observera är att handla, är uthållig observation av en dimension uthållig handling på den. Själv I:s gest mot meditation som minskar själv-varietetsgapet har sin mekanism här: att rikta uppmärksamheten mot dimensioner som värdearkitekturen uteslöt är, i ett reflexivt system, samma operation som att börja släppa in dem. Den asymptot som Själv I namngav — full själv-observerbarhet, $G_{\text{själv}} \rightarrow 0$ — är nåbar, till den grad den överhuvudtaget är nåbar, endast därför att seendets akt i ett själv redan är en akt av att bli. **[IP]** för det strukturella påståendet; **[H]** för den kontemplativa läsningen, som Del IX återvänder till under sin avgränsade-horisont-disciplin.

Så observatör-anläggning-identitet är tveeggad. Den är källan till självets karakteristiska svårigheter — de svårigheter som resten av pappret specialiserar och som inte har någon ren institutionell lösning — och den är samtidigt källan till självets karakteristiska kapacitet, det faktum att ett själv kan förändra sig självt genom att observera sig självt på ett sätt som inget departement kan förändra sin ekonomi genom att undersöka den. Pappret håller båda eggarna genomgående, och motstår frestelsen att låta den diagnostiska eggen tränga ut den andra.

1.5 Tre specialiseringar och papprets form

Observatör-anläggning-identitet producerar inte en konsekvens utan en familj av dem, och pappret är organiserat så att dess tre skarpaste specialiseringar var och en bär en egen del.

I **observatörsångfald** (Del II) placerar identiteten ett golv under felkorrelationen bland en persons självobservationskanaler: flera av dessa kanaler är inte bara korrelerade utan är samma apparat som rapporterar mer än en gång, och ingen intern operation kan dekorrelera en förmåga från sig själv. Den institutionella lösningen — konstituera observatörerna annorlunda — är otillgänglig, och den enda vägen under golvet går genom kanaler som är placerade delvis utanför det observerande självet.

I **själv-legitimitet** (Del IV) gör identiteten självtillit oreviderbar från insidan: den apparat som förlorar tillit är den apparat som skulle mäta tilliten, så det självbedrägande instrumentet är också det instrument som har till uppgift att upptäcka bedrägeriet. Den institutionella lösningen — en oberoende legitimitets-sensor — har, återigen, bara en extern approximation.

I **adaptivt lärande** (Del VI) omvandlar identiteten ett ensidigt krav till en tvåsidig gräns: ett samhälle kan utforska aggressivt eftersom det isolerar sin experimentapparat från sina experimentzoner, medan ett själv inte fullt ut kan isolera sig från sina egna experiment, så dess själv-revidering är begränsad inte bara nedtill, av behovet att förbli kalibrerad, utan upptill, av den takt med vilken det reviderade självet kan åter-koherenta. Experimentatorn är experimentet.

Dessa tre sitter inom den anpassningsarkitektur som den överordnade serien nådde fram till i sin andra cykel: **Avkänna** → **Lära** → **Verkställa**. Del II är själv-skalans *avkänningskrav*; Del III, om den interna delegeringskedjan från intention till handling, är *verkställighetskravet*; Del VI är *inlärningskravet* som medierar mellan dem. Två ytterligare variabler är inte stadier i denna sekvens utan villkor för alltsammans: själv-legitimitet (Del IV), den tillit

som kopplar självobservation och självhandling och utan vilken ingendera fungerar, och gränskalibrering (Del V), dragandet av den perimeter som avgör vilken dynamik självet behandlar som sin egen — den del där observatör-anläggning-identitet är svagast, eftersom de system som är kopplade till ett själv själva är agenter, och pappret säger det där det anländer. Del VII samlar de sammansatta felsätten; Del VIII anger konstruktionsprinciperna som arkitektur; Del IX markerar ramverkets yttre gräns.

Den rekursion detta sätter upp är den som Rapport XIV identifierade som konvergenspunkten för den andra cykelns matematik. Ett styrsystem som säkert modifierar sin egen arkitektur, ett AI-system som säkert modifierar sin egen kod, och ett själv som säkert reviderar sin egen identitet är, strukturellt, ett och samma problem — en kontrollant som försöker förändra vad den är utan att förstöra den kontinuitet som skulle låta den lära sig av förändringen. Observatör-anläggning-identitet är namnet, för självet, på vad som gör det problemet till dess eget snarare än lånat: kontrollanten och anläggningen kan inte dras isär, och allt som följer är vad detta enda faktum för med sig.### Del I — Det adaptiva problemet och det reflexiva självet

1.1 Själv I:s begränsning

Själv I fastställde ett nödvändigt villkor för självstyrning och blottade därigenom sin egen otillräcklighet. Villkoret var perceptuellt: en person vars värdearkitektur har för få dimensioner för att spänna över sitt livs störningsmiljö är strukturellt blind för källorna till sin egen nöd, och ingen mängd uppriktighet eller ansträngning kan återskapa en signal som arkitekturen aldrig släppte in. Det argumentet är fullständigt så långt det sträcker sig. Men adekvat självperception, även där den uppnås, styr ingenting i sig självt. Den är förutsättningen för självstyrning, inte själva handlingen.

Otillräckligheten visar sig i två misslyckanden som ser ut som motsatser. Det första är personen som uppfattar sig själv korrekt och inte förändras — som kan beskriva sitt mönster med precision, namnge vad det kostar dem, artikulera exakt vad en bättre kurs vore, och fortsätta, år efter år, i det mönster de har beskrivit. Perceptionen är intakt; ingenting nedströms om den rör sig. Det andra är personen som förändras konstant och förlorar sig själv — som reviderar, omlokaliserar och återuppfinner sig så lättvindigt att ingen version av självet består tillräckligt länge för att levast, och som anländer till det ackumulerade vrakspillret av många nystarter utan någon sammanhängande identitet att visa upp för någon av dem. Korrekt perception producerar i det första fallet ingen handling; snabb handling upplöser i det andra fallet den som förnimmer. Inget av misslyckandena är ett misslyckande i självkännedom i Själv I:s mening, och det är poängen: självkännedom är nödvändig och räcker inte.

Vad de två misslyckandena avslöjar är att ett livsdugligt själv måste göra flera strukturellt distinkta saker samtidigt. Det måste uppfatta sig självt adekvat — och genom mer än en kanal, eftersom en enda kanal inte kan upptäcka sitt eget systematiska fel. Det måste översätta vad det uppfattar till handling genom en intern delegeringskedja som försvagar intentionen. Det måste upprätthålla tillit till sina egna varseblivningar och åtaganden, eftersom ett själv som misstror sina egna rapporter eller förväntar sig att bryta sina egna löften styr ingendera. Det måste dra en fungerande gräns mellan sig självt och andra. Och det måste fortsätta att lära sig i takt med att självet och dess omständigheter förändras, utan att inläringen destabiliserar det själv som måste absorbera den. Misslyckande i någon av dessa destabiliserar resten. Detta är det adaptiva problemet, och det är ämnet för det föreliggande pappret. Genom alltsammans löper ett strukturellt drag som gör självfallet kategoriskt annorlunda än det institutionella fall som den överordnade serien studerade — annorlunda till sin art, inte bara till sin skala — och resten av denna del ägnas åt det.

[IP]

1.2 Observatör–anläggning-identitet

I de styrsystem den överordnade serien analyserar är kontrollanten och anläggningen distinkta entiteter. Ett departement styr en ekonomi; en tillsynsmyndighet styr en industri; kontrollanten är en sak och det system den observerar och agerar på är en annan. Denna separation är så grundläggande för reglerteorin att den sällan uttalas: observationen är utanför det observerade. Den legitimerar fältets standardarkitektur, där en kontrollant mäter tillståndet hos ett separat system, jämför det med ett mål och agerar för att sluta differensen.

Ett själv har inte denna separation. Den entitet som observerar är den entitet som observeras; den apparat som utfärdar direktiv är den apparat som måste efterleva dem; det system som regleras är det system som reglerar. Kalla detta *observatör–anläggning-identitet*: i självstyrning är kontrollanten och anläggningen samma entitet. Det är det enda strukturella drag detta papper tillför seriens grammatik, och det är mindre en upptäckt än en formalisering. Att det själv som observerar är det själv som observeras är insikten i roten av andra ordningens cybernetik (von Foerster), och Själv I noterade redan dess närvaro när det läste Acceptance and Commitment Therapy's distinktion mellan själv-som-innehåll och själv-som-kontext som andra ordningens cybernetik på den personliga skalan. Bidraget här är inte den nakna observationen att självet är reflexivt. Det är demonstrationen att detta enda drag, taget på allvar som en strukturell begränsning, förutsäger specifika och icke-uppenbara sätt på vilka resultaten på själv-skalan avviker från sina institutionella förlagor — sätt som utvecklas i de delar som följer. **[R]** för det strukturella uttalandet; konsekvenserna är **[IP]**.

1.3 Mätning–störning-kopplingen

Den mest generella konsekvensen av observatör–anläggning-identitet är också den som saknar institutionell motsvarighet, och den rör själva observationshandlingen.

När ett styrsystem mäter sin anläggning lämnar mätningen anläggningen approximativt ostörd. En folkräkning förändrar inte märkbart den befolkning den räknar; en undersökning av ekonomisk aktivitet förändrar inte, till första ordningen, den ekonomi den samplar. Detta nära oberoende av mätning från det mätta är vad som garanterar reglerteorins *separationsprincip* — resultatet att skattnings och styrning kan designas oberoende av varandra, att ett system först kan fastställa sitt tillstånd och sedan bestämma vad det ska göra åt det. De två operationerna är distinkta eftersom observera och agera faller på olika objekt.

För ett själv faller de på samma objekt, och separationen kollapsar. Att rikta uppmärksamheten mot en sensation är att förändra den — att förstärka den, dämpa den eller omvandla den till något den inte var innan uppmärksamheten anlände. Att fråga sig själv hur man känner inför en sak är att förändra känslan i själva frågandet. Att berätta sin situation är att konstituera situationen lika mycket som att registrera den; berättelsen är inte en avläsning av ett tidigare tillstånd utan delvis produktionen av det tillstånd den påstår sig beskriva. Självobservation är därför aldrig bara observation. Den är samtidigt en intervention på det observerade systemet, eftersom det bara finns ett system. Separationsprincipen fallerar för självet: en person kan inte först läsa av sitt tillstånd och sedan bestämma vad den ska göra, eftersom avläsningen redan är ett görande. **[IP]**

Detta har en konsekvens som bör anges tydligt eftersom den kvalificerar Själv I. Det "sanna tillstånd" $x_{\text{själv}}$ som Själv I:s observationsekvation projicerar in i medvetandet är inte ett fast mål som personen läser av med större eller mindre trohet. Det konstitueras delvis av själva avläsningshandlingen. "Korrekt självperception" förblir ett meningsfullt mål, men det är inte återvinnandet av ett redan existerande faktum; det ligger närmare en stabil fixpunkt

i en process där observera och bli observerad är samma rörelse. Ramverket löser inte detta — det markerar det, som den punkt där den bekväma metaforen om självet som ett system med ett tillstånd att mäta når sin gräns. **[H]** för den filosofiska utläggningen; det strukturella påståendet att mätning och störning är kopplade i självet är **[IP]**.

1.4 Tveeggadheten

Det vore lätt att läsa observatör–anläggning-identitet som en katalog över ytterligare handikapp — självet som en kontrollant belastad med reflexiva defekter som departementet är förskonat från. Den läsningen är halva bilden, och den saknade halvan är vad som gör självstyrning rikare än styrning snarare än bara mer komprometterad.

Samma koppling som kontaminerar självobservation gör också självobservation till en styrsignal. Eftersom att rikta uppmärksamheten mot en dimension av självet förändrar den, är uppmärksamhetshandlingen en spak, inte bara en sensor. Detta är det strukturella skälet till att de praktiker Själv I samlade under sina tolkande och spekulativa lager — uthållig uppmärksamhet, kontemplativ träning, den disciplinerade åter-berättelsen av ens egen erfarenhet i terapi — kan vara transformativa snarare än bara informativa. De fungerar inte genom att passivt förbättra avläsningen av ett fast tillstånd; de fungerar därför att, i ett system där observera är att handla, är uthållig observation av en dimension uthållig handling på den. Själv I:s gest mot meditation som minskar själv-varietetsgapet har sin mekanism här: att rikta uppmärksamheten mot dimensioner som värdearkitekturen uteslöt är, i ett reflexivt system, samma operation som att börja släppa in dem. Den asymptot som Själv I namngav — full själv-observerbarhet, $G_{\text{själv}} \rightarrow 0$ — är nåbar, till den grad den överhuvudtaget är nåbar, endast därför att seendets akt i ett själv redan är en akt av att bli. **[IP]** för det strukturella påståendet; **[H]** för den kontemplativa läsningen, som Del IX återvänder till under sin avgränsade-horisont-disciplin.

Så observatör–anläggning-identitet är tveeggad. Den är källan till självets karakteristiska svårigheter — de svårigheter som resten av pappret specialiserar och som inte har någon ren institutionell lösning — och den är samtidigt källan till självets karakteristiska kapacitet, det faktum att ett själv kan förändra sig självt genom att observera sig självt på ett sätt som inget departement kan förändra sin ekonomi genom att undersöka den. Pappret håller båda eggarna genomgående, och motstår frestelsen att låta den diagnostiska eggen tränga ut den andra.

1.5 Tre specialiseringar och papprets form

Observatör–anläggning-identitet producerar inte en konsekvens utan en familj av dem, och pappret är organiserat så att dess tre skarpaste specialiseringar var och en bär en egen del.

I **observatörs mångfald** (Del II) placerar identiteten ett golv under felkorrelationen bland en persons självobservationskanaler: flera av dessa kanaler är inte bara korrelerade utan är samma apparat som rapporterar mer än en gång, och ingen intern operation kan dekorrelera en förmåga från sig själv. Den institutionella lösningen — konstituera observatörerna annorlunda — är otillgänglig, och den enda vägen under golvet går genom kanaler som är situerade delvis utanför det observerande självet.

I **själv-legitimitet** (Del IV) gör identiteten självtillit oreviderbar från insidan: den apparat som förlorar tillit är den apparat som skulle mäta tilliten, så det självbedrägande instrumentet är också det instrument som har till uppgift att upptäcka bedrägeriet. Den institutionella lösningen — en oberoende legitimitets-sensor — har, återigen, bara en extern approximation.

I **adaptivt lärande** (Del VI) omvandlar identiteten ett ensidigt krav till en tvåsidig gräns: ett samhälle kan utforska aggressivt eftersom det isolerar sin experimentapparat från sina experimentzoner, medan ett själv inte fullt ut kan isolera sig från sina egna experiment, så dess själv-revidering är begränsad inte bara nedtill, av behovet att förbli kalibrerad, utan upptill, av den takt med vilken det reviderade självvet kan åter-koherenta. Experimentatorn är experimentet.

Dessa tre sitter inom den anpassningsarkitektur som den överordnade serien nådde fram till i sin andra cykel: **Avkänna** → **Lära** → **Verkställa**. Del II är själv-skalans *avkänningskrav*; Del III, om den interna delegeringskedjan från intention till handling, är *verkställighetskravet*; Del VI är *inlärningskravet* som medierar mellan dem. Två ytterligare variabler är inte stadier i denna sekvens utan villkor för alltsammans: själv-legitimitet (Del IV), den tillit som kopplar självobservation och självhandling och utan vilken ingendera fungerar, och gränskalibrering (Del V), dragandet av den perimeter som avgör vilken dynamik självvet behandlar som sin egen — den del där observatör-anläggning-identitet är svagast, eftersom de system som är kopplade till ett själv själva är agenter, och pappret säger det där det anländer. Del VII samlar de sammansatta felsätten; Del VIII anger konstruktionsprinciperna som arkitektur; Del IX markerar ramverkets yttre gräns.

Den rekursion detta sätter upp är den som Rapport XIV identifierade som konvergenspunkten för den andra cykelns matematik. Ett styrsystem som säkert modifierar sin egen arkitektur, ett AI-system som säkert modifierar sin egen kod, och ett själv som säkert reviderar sin egen identitet är, strukturellt, ett och samma problem — en kontrollant som försöker förändra vad den är utan att förstöra den kontinuitet som skulle låta den lära sig av förändringen. Observatör-anläggning-identitet är namnet, för självvet, på vad som gör det problemet till dess eget snarare än lånat: kontrollanten och anläggningen kan inte dras isär, och allt som följer är vad detta enda faktum för med sig.

Del II — Observatörmångfald: Varför självkännedom inte kan revideras inifrån en enda kanal

En person som står inför ett svårt beslut — om de ska lämna, om något är fel, om de bedrar sig själva — gör det ansvarsfulla. De reflekterar noggrant. De talar med de vänner de litar på. De för dagbok. De tar in synpunkter från flera personer som känner dem väl. Läsningarna konvergerar; alla är överens; de går vidare med tillförsikt, och de blir överrumplade. Efteråt säger de människor som står dem närmast att de inte heller såg det komma.

Detta är inte ett misslyckande i ansträngning eller uppriktighet, och det är inte varietetsgapet från Själv I. Personen samplade många observatörer och reflekterade länge. Misslyckandet är strukturellt och ligger en nivå högre: observatörerna var inte oberoende av varandra, och en konsensus bland korrelerade observatörer bär inte mer information än en endas åsikt. Själv I modellerade självperception som en enda observationskanal — värdearkitekturen som matrisen $\mathbf{C}_{\text{själv}}$ som projicerar det sanna tillståndet in i medvetandet — precis som rapporterna I–IX i den överordnade serien modellerade varje kontrollant genom en enda observationsmatris. Men en person uppfattar inte sig själv genom en enda kanal. De har många, och den avgörande egenskapen hos den populationen är inte kvaliteten hos någon enskild medlem utan dekorrelationen i ensemblen. Denna del utvidgar självstyrningsramverket från den individuella kanalen till den observerande populationen, i linje med Rapport X:s utvidgning av den överordnade serien från kontrollanten till ensemblen. **[IP]**

2.1 Självobservationsensemblen

En person observerar sig själv genom en population av delvis distinkta kanaler: introspektion, den löpande inre berättelsen, interoception (kroppens signaler), nära vänner, familj, en partner, en terapeut, en dagbok, drömmar, kreativ praktik, kontemplativ praktik och — i allt högre grad — samtal med AI-system. Var och en är en observatör av samma latenta tillstånd: personens sanna flerdimensionella tillstånd $\mathbf{X}_{\text{själv}}$. I linje med Rapport X har den i :te kanalen en observationsekvation

$$\mathbf{y}_i = \mathbf{C}_i \mathbf{X}_{\text{själv}} + \boldsymbol{\varepsilon}_i$$

där $\mathbf{C}_i$ är kanalens strukturella perspektiv — vilka dimensioner av självet den kan uppfatta, och med vilken upplösning — och $\boldsymbol{\varepsilon}_i$ är dess fel. Kroppen uppfattar dimensioner som den inre berättelsen utelämnar; en vän uppfattar personens effekt på andra, vilket introspektion inte direkt kan sampla; en dagbok bevarar ett perspektiv som det nuvarande självet har redigerat bort. Ensemblen är sammansättningen av alla dessa kanaler, och dess kapacitet styrs av två egenskaper som Rapport X preciserar: den effektiva rangen hos den staplade observationen — om kanalerna tillsammans täcker de dimensioner av självet som spelar roll — och korrelationsstrukturen hos deras fel.

Den första egenskapen ger ett krav på nödvändig mångfald för självet. Låt $\dim(\mathbf{U}_{\text{själv}})$ vara dimensionaliteten hos *själv-osäkerhetsrummet* — de riktningar i vilka en person inte tillförlitligt kan förutsäga sitt eget tillstånd, där gapet mellan förväntat och faktiskt själv är tillräckligt stort för att spela roll. Nödvändig observatörmångfald för självet är villkoret att ensemblens effektiva rang täcker det rummet:

$$r_{\text{ens}}^{\text{själv}} \geq \dim(\mathbf{U}_{\text{själv}}).$$

När det misslyckas finns det dimensioner av självet som *ingen* kanal uppfattar — en blind fläck som delas av introspektion, vänner och kropp lika mycket — och den blindade fläcken kan inte upptäckas genom korsreferering, eftersom ingen kanal har oberoende tillgång till den saknade dimensionen. Detta är ensemblens-nivå-analogen till Själv I:s varietetsgap: inte "värdearkitekturen utesluter denna dimension" utan "varje tillgänglig observatör är blind för den på en gång." [IP]

2.2 Korrelationsproblemet

Intuitionen att fler observatörer är bättre vilar på ett resultat som endast gäller under oberoende. För N kanaler med individuell felvarians σ^2 och parvis felkorrelation ρ , är variansen av ensemblens poolade skattning inte σ^2/N utan

$$\text{Var} = \sigma^2 \left(\frac{1 - \rho}{N} + \rho \right),$$

och det effektiva antalet oberoende observatörer är

$$N_{\text{eff}} = \frac{1}{(1 - \rho)/N + \rho} = \frac{N}{1 + (N - 1)\rho}.$$

Detta är Kishs designeffekt från surveystatistiken, och den är klassad [R]: standardmatematik som gäller för varje korrelerad ensemble, inklusive en persons självobservationskanaler. Dess innehåll är oförsonligt. När $\rho = 0$, är $N_{\text{eff}} = N$ och antal hjälper fullt ut. När $\rho = 0,5$, närmar sig N_{eff} 2 oavsett hur stort N växer — en delad bias sätter ett brusgolv som ingen mängd observatörer kan sänka. När $\rho \rightarrow 1$, $N_{\text{eff}} \rightarrow 1$: ensemblen har kvar N nominella observatörer och får det statistiska skyddet av en.

Det obekväma påståendet i denna del är att en persons självobservationskanaler är korrelerade — ofta kraftigt — och att korrelationen löper genom personen själv. Du väljer de vänner du anförtror dig åt, och du tenderar att välja dem som redan ser dig så som du önskar bli sedd. Du formar vad du berättar för din terapeut genom vad du är villig att säga. Din introspektion och din inre berättelse är inte två observatörer utan en apparat som rapporterar två gånger. Det nominella kanalantalet överskattar därför N_{eff} kraftigt, och personen i den inledande vinjetten — fem betrodda vänner plus deras egen noggranna reflektion — konsulterade inte sex observatörer. De konsulterade en observatör, sig själv, sex gånger, och misstog upprepning för bekräftelse. [IP] för det strukturella påståendet; den specifika läsningen är [H].

2.3 Två vägar till korrelerad självobservation

Rapport X urskiljer två vägar genom vilka en ensembles felkorrelation närmar sig ett, och båda har personliga former.

Modellbaserad monokultur uppstår när kanaler delar en gemensam bearbetningsarkitektur. På den personliga skalan är den delade arkitekturen självberättelsen och den stabila uppsättning kognitiva biaser genom vilka alla rapporter filtreras. Även genuint diversifierade råa signaler — en väns raka anmärkning, en värk i kroppen, en dröm — passerar genom en tolkande modell innan de når medvetandet, och modellens biaser påtvingas identiskt på dem alla. Korrelationen uppstår i *bearbetningen*: diversifierade data, en tolk, korrelerade avläsningar.

Databaserad monokultur uppstår när kanaler delar ett gemensamt indatasubstrat. På den personliga skalan är detta kurateringen av ens miljö — de vänner man behåller, de medier man konsumerar, de situationer man söker upp och undviker — utvalda, ofta utan avsikt, för att leverera en konsekvent bild. Här är informationen trunkerad eller

snedvriden *innan* någon kanal bearbetar den, så att även en opartisk tolk skulle konvergera med de andra mot samma partiella vy.

I linje med Rapport X samverkar de två:

$$\rho_{\text{total}} \approx 1 - (1 - \rho_{\text{modell}})(1 - \rho_{\text{data}}),$$

så att måttlig korrelation genom varje väg driver ρ_{total} mot ett. Självbedrägeri, där det förekommer, begränsar sig sällan till en väg: det narrativ som filtrerar inkommande signaler (vilket höjer ρ_{modell}) är samma narrativ som väljer vilka signaler som överhuvudtaget söks (vilket höjer ρ_{data}). **[IP]** för strukturen med två vägar; **[H]** för den psykologiska utläggningen.

2.4 Det reflexiva golvet

Här sätter det strukturella draget från Del I — observatör-anläggning-identitet — ett golv under ρ som institutionell styrning inte möter. Inom styrning är de N observatörerna distinkta organisationer; dekorrelation är i princip uppnåbar genom att konstituera dem olika. I självet är flera kanaler inte bara korrelerade utan *fysiskt samma apparat*: introspektion och den inre berättelsen delar ett substrat och kan, genom ingen intern operation, göras oberoende av varandra. Ingen mängd reflektion sänker korrelationen mellan en förmåga och sig själv. Detta placerar ett golv under ρ som självet inte kan nå under inifrån.

Konsekvensen är precis och är den strukturella kärnan i denna del: de enda kanaler som kan sänka en persons effektiva ρ är de som är situerade delvis *utanför* den berättande apparaten — kroppen, vars signaler genereras före tolkning; en vän som kommer att säga det ovälkomna; en dagboksanteckning skriven innan den nuvarande berättelsen bildades och återläst efter att den har rört sig vidare; en terapeut; kreativ praktik som bringar i dagen vad narrativet undertrycker. Dessa är självets enda approximation till en oberoende sensor, vilket är samma roll de kommer att spela, från tillitssidan, i Del IV. En förtrogen utvald för överensstämmelse är inte en andra sensor; de är personens egen observationskanal som bär ett annat ansikte, och de tillför nominellt N samtidigt som de bidrar med ingenting till N_{eff} .

Ett empiriskt ankare, med sin brasklapp tydligt angiven. Studie 1 i det överordnade programmet fann att sex nominellt distinkta konsument-AI-system, som skattade femtio styrningsrelevanta storheter, hade en effektiv felkorrelation $\rho_{\text{eff}} \approx 0,97$ — nästan total korrelation trots nominellt oberoende (resultatet är **[R]**; dess primära förutsägelse var förregistrerad och bekräftad). Dess bäring på själv är analogisk, inte direkt: inga själv mättes, och överföringen är **[H]**. Men resultatet fastställer att nominellt oberoende kan samexistera med nästan fullständig korrelation i praktiken, och ett själv vars kanaler delar ett substrat och aktivt väljs av just den part som granskas har, om något, svagare grunder än en uppsättning separat byggda AI-system att förvänta sig att dess observatörer är oense när det räknas.

2.5 Kollapsdynamik

Rapport X härleder en selektionsgradient som driver diversifierade ensembler mot monokultur även när varje steg är lokalt rationellt, och samma gradient verkar på en persons observatörer. Att upprätthålla en genuint dissonant kanal är kostsamt: vännen som tillförlitligt är oense är obekvämt att hålla nära, dagboken som motsäger den nuvarande berättelsen är obehaglig att återläsa, den kroppsliga signal som underskär planen är lättare att åsidosätta än att lyssna

till. Vid varje knutpunkt är det lokalt bekväma draget att vikta den bekräftande kanalen mer och den dissonanta mindre, och den kumulativa glidningen höjer ρ , sänker N_{eff} och smalnar av ensemblen mot överensstämmelse — den personliga formen av Rapport X:s ansvarspärr mot konsensus. **[IP]**

Vid gränsen ligger *ekokammaren av en*: varje kanal är överens eftersom varje kanal i praktiken har blivit samma kanal. Konsensus är enhällig och tillförsikten total, och den dimension som det delade narrativet utesluter — Själv I:s varietetsgap — är exakt den dimension för vilken varje kvarvarande observatör är blind. Detta är anledningen till att den slutliga krisen anländer som en chock inte bara för personen utan för alla runt omkring dem: de närmaste människorna valdes, under år, ut för att dela den blinda fläcken, så deras enighet var aldrig en oberoende kontroll. Den enighet som kändes som trygghet var symptomet på misslyckandet, inte skyddet mot det. **[IP]**, med det specifika förloppet **[H]**.

Kopplingen till Del IV löper åt båda hållen. Kurateringen av ens observatörer mot överensstämmelse är transparensfällan som verkar på observationsensemblen snarare än på en enskild självrapport, och ett själv som har förlorat tillit till sina egna varseblivningar ($L_{\text{själv}}$ fallande på observationskanalen) är det mest benägna för det — ersätter kanaler som stör den upprätthållna bilden med kanaler som bekräftar den, vilket sänker det upplevda obehaget samtidigt som det höjer det strukturella ρ som garanterar nästa överrumpling.

2.6 Konstruktionsprincipen och dess inversion

Diagnosen ger ett villkor, angivet — i enlighet med seriens disciplin — som arkitektur snarare än som råd. Adekvat självkännedom kräver att självobservationskanaler upprätthålls som är *partiellt dekorrelerade*: kanaler som inte delar det berättande substratet och som inte valdes ut för sin överensstämmelse. Aritmetiken för N_{eff} gör den relevanta asymmetrin skarp. En bekräftande observatör höjer nominellt N och lämnar N_{eff} nästan oförändrat; en tionde vän som håller med förändrar ingenting strukturellt. Endast dekorrelerade kanaler höjer den effektiva mångfalden, och dekorrelerade kanaler är, med viss tillförlitlighet, de obekväma — den oense vännen, den oredigerade dokumentationen, kroppens veto, den praktik som återbördar vad som undertrycktes.

Detta inverterar den vanliga trösten i konsensus. I självkännedom är överensstämmelse bland korrelerade kanaler inte evidens, eftersom överensstämmelsen var strukturellt garanterad innan någon av dem tittade; vad som bär information är *divergens från en kanal som är känd för att vara dekorrelerad*. Den signal en person bör vikta mest är den läsning som inte passar och kommer från någonstans de inte valde för dess behaglighet. Obehaget är inte tillfälligt för dess värde. Det är, ofta, kännetecknet för den enda observatör i ensemblen som inte bara är självvet igen.

En skarpare form av samma poäng, som den formella modellen i Appendix A preciserar, är att det inte räcker att enbart *inneha* en dekorrelerad kanal. Under naiv lika viktning — där varje kanals läsning behandlas som en lika röst — är det effektiva antalet oberoende observatörer det inverterade Herfindahl-indexet av hur de nominella kanalerna fördelar sig i dekorrelerade block, och detta faller *under* antalet block närhelst blocken är olika stora. En person med fem ömsesidigt korrelerade interna kanaler och en genuint extern sådan har inte diversifieringen av två observatörer utan närmare den av en och en tredjedel: den sammanfogade interna majoriteten utrustar den enskilda externa läsningen. Att återvinna den externa kanalens värde kräver därför att man *medvetet överviktat* den dissonanta läsningen mot den interna konsensusen, inte bara låter den avge sin lika röst. Obehaget i att göra så är den kända formen av den uppviktning aritmetiken kräver.

Del III — Aktiveringsintegritet: Varför intention inte når beteende

En person bestämmer sig, tydligt och uppriktigt, för att göra något — att träna, att skriva, att ringa samtalet de har undvikit, att förändra hur de tillbringar sina kvällar. Beslutet är inte överksamt. De förstår varför det spelar roll, de har en korrekt bild av sin situation, de vill ha utfallet, och ingen del av dem bjuder allvarligt motstånd. Veckor senare har lite hänt. Inget dramatiskt ingrep: ingen kris, inget bakslag, ingen förlust av övertygelse. Intentionen blev helt enkelt försvagad — försenad, förminskad och översatt, ett internt steg i taget, tills det som nådde handlingens nivå bar föga likhet med det som beslutades, och mycket av det nådde aldrig den nivån överhuvudtaget. Detta är självets Oakland, och Själv I kan inte redogöra för det, eftersom misslyckandet inte är perceptuellt. Personen ser korrekt. Det som sviktar ligger nedströms: den kanal genom vilken en intention måste färdas för att bli ett beteende. Denna del behandlar den kanalen, och fullbordar själv-skalans triad — Del II:s avkänning, denna dels verkställande, och inläringen i Del VI som medierar mellan dem. [IP]

3.1 Självets aktueringskedja

Ett styrningsdirektiv som formuleras i centrum når världen endast genom att färdas nedåt i en delegeringskedja — departement, myndighet, region, kommun, gatunivå — och Rapport XI:s resultat är att varje lager gör tre saker med direktivet oavsett någons kompetens eller goda tro. Det *fördröjer* det, och fördröjningar i serie ackumuleras. Det *projicerar* det på lagrets egen operationella repertoar, så att det som passerar nedåt är lagrets översättning snarare än direktivet självt. Och det *stör* det, eftersom varje översättning sker under olika lokala förhållanden. Fördröjning, projektion, brus: strukturellt, inte beteendemässigt, och närvarande även när varje aktör är uppriktig.

En intention färdas nedåt i en analog kedja inuti en person. En värdering eller ett mål måste bli ett specifikt delmål; delmålet en plan; planen måste rekrytera motivation; motivation måste bäras av vana och stödjas av miljö; och allt detta måste utmynna i fysiskt utförande, och sedan i upprepat utförande. Lagren är verkliga eftersom varje gör sina tre saker. Kedjan *fördröjer*: den föresats som formats på söndagen har avklingat till onsdagen, och de mellanliggande stegens fördröjningar adderas. Den *projicerar*: en rik intention — att vara friskare, mer närvarande, mer ärlig — kollapsas vid varje lager till den smalare repertoar lagret faktiskt har, till den enda plan som kan formuleras, de vanor miljön stöder, vad kroppen faktiskt kommer att göra klockan sex på morgonen, så att det som verkställs inte är intentionen utan dess komprimering till tillgänglig rutin. Och den *stör*: samma direktiv färdas nedåt olika under olika dagar, eftersom de interna förhållanden som översätter det — humör, energi, trycket från konkurrerande krav — aldrig är desamma två gånger. Direktivet anländer sent, förminskat och förvrängt, och detta är intentionens vanliga öde, inte en särskild patologi hos de viljesvaga. [IP]

Som i Rapport XI anges resultatet med den interna motståndaren satt till noll. Ambivalens, självsabotage, den del av en person som inte vill ha förändringen — dessa är verkliga, de är själv-skalans motsvarighet till den strategiska försvagning Rapport IX studerade, och de förvärrar allt. Men den försvagning som beskrivs i denna del binder även vid noll ambivalens: den försämrar de intentioner en person helhjärtat stöder exakt lika mycket som den försämrar de de är kluvna inför. Det är det misslyckande som överlever det bästa fallet, vilket är anledningen till att, liksom Oakland, det bästa fallet är där analysen börjar. [IP]

3.2 Energilagen och personlig reformutmattning

Rapport XI:s centrala resultat är inte en tröskel utan ett pris. Med hjälp av aktueringskedjans styrbarhetsgramian visar det att den minimala styrinsats som krävs för att realisera ett mål växer *superlinjärt* med delegeringsdjupet. Djupa kedjor vägrar inte en policy; de prissätter den ur räckhåll. Reformen antas, levererar delvis, konsumerar det politiska kapital som drev den, och upphör — ett tillstånd pappret benämner reformutmattning.

Läsningen på själv-skalan är omedelbar och klassad **[IP]**: den självreglerande insatsen — uppmärksamheten, viljestyrkan i vanlig mening, det ändliga kapital en person kan spendera på att driva ett direktiv nedför sin egen kedja — som krävs för att realisera en intention växer superlinjärt med djupet på kedjan mellan att avse och att handla. En intention som måste passera många interna lager (forma målet, bygga planen, framkalla motivationen, etablera vanan, arrangera miljön, verkställa och vidmakthålla) prissätts ur räckhåll långt innan den blir omöjlig. Detta är *personlig reformutmattning*: självförbättringsprojektet som lanserades med verklig beslutsamhet, delvis levererat, som konsumerar personens regleringskapital och upphör — den övergivna föresatsens struktur, igenkännbar för alla och mystisk för den som lever den, vilken upplever stoppet som en dom över sin karaktär.

Pressman och Wildavskys aritmetik gör mekanismen konkret på denna skala. En stående intention — "jag ska göra detta dagligen" — kräver ett ja vid varje länk, varje dag: vakna villig, *och* ha tiden, *och* energin, *och* en miljö som samarbetar, *och* inget konkurrerande krav som vinner platsen. Om varje länk returnerar ja med hög sannolikhet, faller ändå den sammanlagda sannolikheten snabbt med antalet länkar i serie; en kedja av tio någorlunda tillförlitliga länkar levererar beteendet på lite över hälften av dagarna, och en längre eller mindre tillförlitlig kedja kollapsar under användbarhet. Intentionen misslyckas inte för att personen är svag. Den misslyckas för att dess arkitektur kräver för många sekventiella ja, och en lång kedjas dagliga framgång är produkten av dess länkar oavsett personens uppriktighet. Omramningen är densamma som Rapport XI utförde på implementeringsforskning: vad som ser ut som ett misslyckande i vilja är en egenskap hos kedjedjupet. **[IP]**, med den vardagliga läsningen **[H]**.

Gramiananalysen i Appendix B skärper "superlinjär" och tillför en kvalificering som det nakna ordet utelämnar. Insatsen för att realisera en intention växer superlinjärt i djup i allmänhet, och *geometriskt* — exponentiellt — i den förstärknings- eller tidsbegränsade regimen; och takten beror på *horisonten*, det fönster som finns tillgängligt innan intentionen avklingar eller tillfället passerar. Givet en generös horisont är tillväxten mildare; under tidspress är den långt brantare, och (som §3.3 visar) är målet bortom en punkt inte bara kostsamt utan onåbart. Samma intention är således ett annorlunda problem beroende på den tid som tillåts den: en djup förändring försökt "idag" och den identiska förändringen företagen "över de kommande månaderna" är inte samma uppgift bedriven med mer eller mindre viljestyrka, utan två olika nåbarhetsproblem, där det ena kanske inte har någon lösning vid någon insats medan det andra är rutin.

3.3 Konstitutionell själv-ostyrbarhet

Den binära gränsen för samma kurva är den konceptuella slutstenen, eftersom den fullbordar en dualitet serien har byggt mot på själv-skalan. Rapport XI:s tröskelläsning är *konstitutionell ostyrbarhet*: bortom ett kritiskt delegeringsdjup lämnar målet den nåbara mängden helt och den erforderliga insatsen blir oändlig — uttryckligen dualen till Rapport III:s konstitutionella oobserverbarhet, där bortom ett kritiskt kedjedjup en signal inte kan uppfattas alls.

Själv I etablerade oobserverbarhetshalvan på den personliga skalan: vissa dimensioner av självet kan inte uppfattas oavsett uppriktighet eller ansträngning, eftersom värdearkitekturen saknar de axlar längs vilka de är definierade. Denna del etablerar den andra halvan. Vissa intentioner kan inte aktiveras oavsett ansträngning, eftersom de ligger bortom det nåbara djupet i en persons aktueringskedja — den erforderliga regleringsinsatsen är inte stor utan obegränsad, och ingen mängd viljestyrka sluter gapet. Tillsammans begränsar de två resultaten självstyrning på båda dess kanaler, precis som Rapporterna III och XI begränsar styrning på båda dess kanaler: det finns tillstånd i självet en person inte kan se, och det finns tillstånd i självet en person inte kan nå, och i varje fall är gränsen konstitutionell — en egenskap hos arkitektur och djup snarare än hos att anstränga sig mer. **[IP]**

Detta spelar praktisk roll eftersom de två felsätten känns identiska inifrån och kräver motsatta svar. En intention som inte vill aktiveras för att dess kedja bara är djup är utmattande men nåbar: den ger efter för de arkitektoniska åtgärderna i §3.6. En intention bortom den nåbara mängden kommer inte att ge efter för någon av dem, och den regleringsinsats som hålls efter den är spenderad mot ett oändligt pris. Ramverket säger inte, utifrån strukturen allena, en person vilket de står inför — men det säger dem att distinktionen är verklig, och att erfarenheten av upprepat, uppriktigt, totalt misslyckande ibland är evidens inte för otillräcklig vilja utan för ett mål utanför den nåbara mängden, att nås, om alls, genom att om-arkitektera kedjan snarare än genom att spendera mer av ett kapital som djupet redan har prissatt ur räckhåll.

3.4 Delegering över tid: Kedjan av framtida själv

Här inträder observatör–anläggning-identitet, och i denna del gör den varken vad den gjorde i Del II, IV och VI — skärpa det institutionella resultatet till ett nytt — eller vad den gjorde i Del V — sudda ut det. Den *berikar* det, och tillför en dimension den institutionella kedjan endast har svagt, medan kärnkartläggningen står på sina egna skal-invarianta ben.

En styrningskedja är rumslig: direktivet passerar mellan distinkta organ arrangerade från centrum till periferi. Självets kedja är delvis rumslig också — den routas genom kroppen, miljön, och ibland andra människor, alla genuint distinkta delsystem som fördröjer, projicerar och stör. Men dess djupaste lager är *tidsligt*. En stående intention är ett direktiv från det nuvarande självet till en följd av *framtida* själv, som vart och ett måste åter-ta emot det under sina egna förhållanden och översätta det till sin egen ögonblickliga repertoar. Den "konsistens" som Rapport XI:s kedja slutar i är, för en person, en delegering över tid till agenter som är samma person och inte riktigt — senare tidsskivor med annan energi, humör och kontext, var och en en delvis annorlunda kontrollant som åter-tolkar det direktiv den ärver. Strukturen är en delegeringskedja i strikt mening; det reflexiva draget är att principalen och varje agent är instanser av ett själv, arrangerade inte i rummet utan i följd. **[IP]** för strukturen; **[H]** för inramningen.

Detta är anledningen till att en lång tidslig kedja är så mycket svårare än dess längd ensam antyder, och skälet kopplar denna del till Del IV. Det nuvarande självet kan inte *tvunga* ett framtida själv; det kan bara utfärda ett direktiv som det framtida självet må eller inte må respektera när dess ögonblick anländer. Huruvida det framtida självet efterlever är exakt frågan om själv-legitimitet — huruvida en persons egna direktiv följs av dem själva — vilket nästa avsnitt utvecklar som förstärkningen på hela denna kanal.

3.5 Kopplingen till själv-legitimitet

Del IV kommer att visa att självtillit verkar som en multiplikativ förstärkning på självhandling: effektiv aktivering är $\mathbf{B}_{\text{eff}} = L_{\text{själv}} \mathbf{B}$, så att ett direktiv diskonteras i förväg i den grad personen inte förväntar sig själv att respektera det. Sammansatt med den föreliggande delen ger detta en ackumulering som den överordnade serien förutsåg i sin *dubbelriktade nod*, där två komprimeringar möts i en institution och multipliceras. Varje länk i en tidslig aktueringskedja är en punkt där ett framtida själv måste välja att efterleva, och vid varje sådan punkt multipliceras legitimitetsförstärkningen $L_{\text{själv}}$ in. En djup kedja har därför fler länkar över vilka låg självtillit försvagar direktivet, så att samma underskott i själv-legitimitet försämrar en lång kedja långt mer än en kort — djup och misstro adderas inte utan multipliceras. **[IP]**

Följdsatsen är den som gör konstruktionsprincipen i §3.6 till mer än mekanisk. Korta kedjor är inte bara billigare att aktivera; de är hur själv-legitimitet *byggs*. Ett litet åtagande är en kort kedja med hög sannolikhet som faktiskt verkställs, och varje verkställande är ett hållet löfte till sig själv som höjer $L_{\text{själv}}$ på leveranssidan — vilket i sin tur är vad som så småningom gör en längre kedja överkomlig. Aktiveringens arkitektur och självtillits dynamik är samma system sett från två sidor, och den praktiska vägen löper genom deras skärningspunkt: håll kedjan tillräckligt kort för att direktivet ska anlända, så att dess ankomst förtjänar den tillit som förlänger den kedja du närmast kan försöka.

3.6 Konstruktionsprincip: Förkorta och externalisera kedjan

Energilagen gör åtgärden strukturell snarare än motiverande, och detta är dess främsta praktiska konsekvens. Eftersom insatsen växer superlinjärt med djupet ligger hävstången i djupet, inte i insatsen: samma regleringskapital som inte kan driva en intention nedför en tio-lagers kedja aktiverar en två-lagers kedja lätt, så det produktiva draget är att förkorta kedjan snarare än att spendera mer mot dess längd. Angivna som arkitektur följer två principer. **[IP]**

Förkorta kedjan. Minska antalet lager ett direktiv måste korsa innan det utmynnar i handling — designlogiken bakom att göra ett avsett beteende litet och omedelbart nog att det verkställs i nästan ett steg snarare än att färdas nedåt genom mål, plan och framkallad motivation. Ett direktiv som aktiverar direkt är inte en svagare version av intentionen; det är samma intention given en kedja den kan överleva.

Externalisera de interna lagren. Där ett lager i kedjan är ett opålitligt internt delsystem — ögonblicklig motivation, viljestyrka i stunden — ersätt det, där möjligt, med extern struktur som inte beror av det reflexiva lagrets aktuella tillstånd: arrangera miljön så att handlingen inte kräver någon framkallad motivation, så att det lager som är mest utsatt för daglig perturbation avlägsnas från kedjan och dess funktion utförs av ett stående drag i världen. Detta är självet som, på aktiveringssidan, approximerar samma tillverkade isolering som Del VI fann på inläringssidan: struktur byggd för att bära vad ett internt lager inte kan litas på att bära.

Principerna är blygsamma och analysen bakom dem är det inte, vilket är poängen. Vad som framstår för en person som en karaktärsbrist — den intention som är uppriktigt formad och upprepade gånger realiserad — är, i en stor andel fall, ett direktiv utfärdat nedför en kedja för djup för att bära det, försvagat av latens, projektion och brus, prissatt ur räckhåll av en superlinjär kostnad, och diskonterat ytterligare vid varje länk av den självtillit personen har kvar. Direktivet anländer när kedjan är byggd för att leverera det. Det är ett ingenjörsmässigt uttalande, och det är det denna del har att göra.

Del IV — Själv-legitimitet: Tillit som förstärkningen på självstyrning

Betrakta två personer som vill samma sak och vet samma saker. Var och en har bestämt sig för att förändra något i sitt liv — att träna, att lämna ett jobb, att reparera en relation, att skriva boken. Var och en har en korrekt modell av sin situation, en sund plan och ingen brist på information om vad som ska göras. Den första agerar, vacklar, korrigerar, och blir under månader någon som följer igenom. Den andra utfärdar samma instruktion till sig själv, rör sig inte, utfärdar den igen, rör sig inte, och slutar gradvis utfärda den alls.

Skillnaden ligger inte i planen. Den ligger inte i intelligens, viljestyrka förstått som en kvantitet, eller kvaliteten på självkänndomen — båda personerna uppfattar sig själva korrekt, vilket är just anledningen till att Själv I:s redogörelse är otillräcklig här. Skillnaden ligger i en parameter som planen inte innehåller: den grad i vilken en persons egna direktiv följs av dem själva, och deras egna rapporter blir trodda av dem själva. Rapport XIII namnger denna parameter, på den institutionella skalan, *legitimitet*. På den personliga skalan kommer vi att kalla den **själv-legitimitet**, och det centrala påståendet i denna del är att den inte är en sinnesstämning eller en dygd utan en förstärkning — en multiplikator på effektiviteten hos varje annat element av självstyrning. [IP]

4.1 Kopplingen

Rapport XIII modellerar legitimitet som ett endogent kopplingstillstånd $L(t) \in [0, 1]$: inte en storhet konstruktören sätter, utan en som uppstår ur interaktionen mellan en arkitektur och de styrda, och som sedan modulerar båda arkitektursens kanaler på en gång. Aktiveringseffektiviteten blir $\mathbf{B}_{\text{eff}} = L\mathbf{B}$; observationsbrusets kovarians blir $\mathbf{V} = \mathbf{V}_0/L$. En enda variabel kopplar samman de två kanaler som serien tidigare hade behandlat separat. När L är hög åtnjuter kontrollanten full auktoritet och ren avkänning. När L kollapsar blir samma arkitektur både ostyrbar och blind.

Självvet instansierar samma struktur. Definiera $L_{\text{själv}} \in [0, 1]$ längs två kopplade kanaler:

- **Aktiverings-legitimitet** — sannolikheten att ett direktiv självvet utfärdar till sig självt faktiskt verkställs. Detta är självtillit till ens egna intentioner: den välgrundade förväntan att "jag ska göra detta" förutsäger att det görs. Där den är hög förpliktigar en intention systemet. Där den är låg diskonteras en intention i det ögonblick den formas — självvet mobiliserar inte fullt ut bakom ett åtagande det inte förväntar sig självt att hålla, så $\mathbf{B}_{\text{eff}}$ faller och intentionen är självförgörande innan verkställandet börjar.
- **Observations-legitimitet** — sannolikheten att en självrapport behandlas som korrekt snarare än som något att argumentera med, diskontera eller åsidosätta. Detta är självtillit till ens egna varseblivningar: förväntan att "jag känner X" eller "detta händer mig" är en signal värd att agera på. Där den är låg behandlas självobservationskanalen som opålitlig, introspektivt brus stiger ($\mathbf{V}_0/L$), och personen förlorar förmågan att avläsa sitt eget tillstånd även när avläsningen är korrekt.

Dessa är inte två separata problem. De är en variabel observerad genom två kanaler, och de rör sig tillsammans. Detta är vad som gör själv-legitimitet till ett *kopplingstillstånd* snarare än en parameter: liksom institutionell legitimitet är den inte vald utan ackumulerad, och när den väl existerar återkopplar den på effektiviteten hos allt annat. Det

strukturella påståendet — att en enda tillitsvariabel multiplicerar både självhandling och självperception — överförs från Rapport XIII genom skal-invarians och är klassat **[IP]**. De specifika psykologiska läsningar som knyts till det nedan är svagare och taggas där de uppträder.

4.2 Byggd och lånad självtillit

Rapport XIII:s skarpaste distinktion är mellan *byggd* och *lånad* legitimitet, och den överlever kartläggningen intakt.

Byggd självtillit ackumuleras långsamt, från konsekvent leverans av åtaganden självet har gjort till sig självt — särskilt små — över utsträckt tid. Den är motståndskraftig mot individuella misslyckanden eftersom den vilar på ett långt protokoll snarare än ett enda bevis. Den person som har hållit hundra små löften till sig själv har en djup reserv; en missad morgon kullkastar den inte.

Lånad självtillit förvärfvas snabbt från något annat än ett leveransprotokoll: en motivationshöjdpunkt, en enda dramatisk framgång, extern validering, eller en självberättelse som hålls före evidensen ("jag är den sortens person som slutför saker"). Den kan framkallas snabbt, vilket är anledningen till att den är valutan för nyårslöften och nystarter. Men den är strukturellt spröd, eftersom svekskänsligheten γ är långt större än leveranskänsligheten α : ett enda självbedrägeri avlägsnar mer tillit än ett enda hållet åtagande tillför. **[H]** Ett själv som drivs av lånad tillit kan framstå som stabilt under lång tid och sedan sönderfalla vid det första verkliga testet — föresatsen som var bärande tills den första missade dagen, identiteten byggd helt på en prestation som inte överlever sin första motsägelse. Kollapsen är inte ett karaktärsmisslyckande. Det är indrivningen av en arkitektonisk skuld: tillit spenderades som aldrig hade förtjänats.

Asymmetrin $\gamma \gg \alpha$ är den formella kärnan i ett välbekant och annars förbryllande faktum — att det är så mycket lättare att förlora tron på sig själv än att återuppbygga den. Vi klassar asymmetrin **[H]**: den är plausibel, den speglar en uppmätt asymmetri på den institutionella skalan, och den rimmar med fynd om förlustaversion i individuellt beslutsfattande, men ramverket härleder inte dess magnitud på den personliga skalan och bör inte låtsas göra det.

4.3 Tre felsätt på den personliga skalan

De tre strukturella felsätten från Rapport XIII återkommer, vart och ett med en igenkännbar personlig form.

Självbedrägerispiralen är prestanda-legitimitetsspiralen driven inåt. Ett brutet åtagande sänker $L_{\text{själv}}$, vilket försvagar aktiveringen (nästa intention avfyras med mindre kraft, eftersom den diskonteras i förväg) och försämrar observationen (personen läser sitt eget tillstånd mindre korrekt), vilket producerar ytterligare brutna åtaganden, vilket sänker $L_{\text{själv}}$ igen. Den är självförstärkande och, liksom sin institutionella tvilling, kräver den ingen yttre motståndare för att upprätthållas. Slingan sluts inuti en person. **[IP]**

Den dynamiska modellen i Appendix C visar att spiralen är mer än en bassäng man kan falla in i. Huruvida en *hållbar* självtillit-jämvikt överhuvudtaget existerar beror gemensamt på en persons leveranskompetens och sveksasymmetrin γ/α . Där kompetensen är hög består den sunda jämvikten även under en brant asymmetri, även om kollapsbassängen runt den vidgas. Men bortom en kritisk kvot — otillräcklig kompetens i förhållande till hur mycket ett svek kostar — *förintas* den sunda jämvikten, och kollaps blir den enda attraktor dynamiken medger. I den regimen är spiralen inte en risk utan det enda utfallet, och att börja med hög självtillit hjälper inte, eftersom det inte finns något stabilt

hög-tillit-tillstånd att stanna kvar i. Detta är den strukturella ytterlighet mot vilken de följande avsnitten måste läsas, och det är därför gränsen som dras i §4.5 spelar roll: en enbart-kollaps-bana är också exakt vad icke-strukturella tillstånd kan producera.

Transparensfällan är den mest betydelsefulla, eftersom den är spiralens mest naturliga utväg och den som slutar värst. En person vars självtillit faller kan hejda den *kända* nedgången inte genom att leverera, utan genom att manipulera sin egen observationskanal: motiverat resonerande, en kuraterad självberättelse, den tysta redigeringen av vad som släpps in i medvetandet. Detta återställer skenbar $L_{\text{själv}}$ på kort sikt medan en dold avvikelse ackumuleras mellan den upprätthållna berättelsen och det oredigerade tillståndet. Avvikelsen försvinner inte; den väntar. Dess slutliga avslöjande — ofta som den kris som slutligen tvingar fram ärlighet — utlöser en sveksbestraffning större än den stadiga kostnad som kontinuerlig självärlighet skulle ha krävt. Den person som inte hade råd att se gapet betalar, senare och med ränta, för att inte ha sett det. [IP]

Legitimitetshysteres är asymmetrin mellan nedgångens hastighet och återhämtningens hastighet. Självtillit förstörs snabbt och återuppbyggs långsamt: att återvända till en tidigare nivå av självtillit kräver att upprätthålla bättre prestanda under längre tid än den bana som orsakade nedgången någonsin krävde. Den praktiska konsekvensen är att återhämtning inte kan forceras, och — som 4.6 noterar — försöket att forcera den tenderar att registreras som ytterligare ett brutet löfte. [IP]

4.4 Den reflexiva skärpningen

Här gör det strukturella drag som introducerades i Del I — *observatör-anläggning-identitet* — självfallet strikt värre än det institutionella, snarare än bara mindre.

På den institutionella skalan kopplar legitimitet samman två distinkta entiteter: kontrollanten och den styrda befolkningen. En regering kan, åtminstone i princip, observera sin egen legitimitet genom *oberoende* instrument — Rapport XIII:s "legitimitetssensorer", diversifierade och externa i förhållande till den styrande apparaten. Sensorn är inte det som mäts.

I ett enskilt medvetande är den det. Den apparat som förlorar tillit är samma apparat som mäter tilliten. Det finns ingen fullständigt oberoende legitimitets-sensor inuti ett själv. Detta skärper transparensfällan till något närmare en strukturell omöjlighet att upptäcka från insidan: det självbedrägande instrumentet är också det instrument som har till uppgift att kontrollera för självbedrägeri, och en korrumpad observationskanal kan inte tillförlitligt revidera sin egen korruption. Den person vars självrapportering har börjat glida kan i allmänhet inte uppfatta glidningen med den förmåga som glider. [IP]

Detta ger ett precist strukturellt skäl till något Del II bara antydde. Anledningen till att externa observatörer spelar så stor roll för självkännedom — en vän som kommer att säga det obekväma, en terapeut, en dagbok återläst månader senare när det redigerande själv har rört sig vidare — är att de är den enda tillgängliga approximationen till en *oberoende* legitimitets-sensor. De är delvis dekorrelerade från den apparat som granskas. Den vän som bara berättar vad du redan tror är inte en andra sensor; de är din egen observationskanal som bär ett annat ansikte, och de tillhandahåller ingen revision alls. Själv-legitimitet kan, med andra ord, inte fullständigt upprätthållas inifrån själv, och designimplikationen — låna en extern sensor innan du behöver den — följer direkt.

4.5 Gränsen ramverket inte får överskrida

Språket i denna del — "jag litar inte på mig själv", "jag tror inte på mig själv längre", spiralen av fallande självtillit som försämrar både handling och perception — är också, ord för ord, språket för depression, trauma och flera kliniska tillstånd. Detta sammanträffande är det farligaste draget i hela kartläggningen, och ramverkets ärlighet beror på att hantera det explicit. [R]

Den reglertekniska redogörelsen beskriver *strukturen* hos själv-legitimitetsfällan: hur en kopplingsvariabel, när den väl börjar falla, kan försämrade de två kanaler som skulle behövas för att hejda dess fall. Den beskriver inte *etiologin* för någon särskild instans. Ett lågt $L_{\text{själv}}$ kan uppstå ur den strukturella dynamik som namnges här — en lång ackumulation av brutna självåtaganden under en lånad-tillit-arkitektur — eller det kan uppstå ur substrat som modellen inte representerar alls: neurokemi, traumats fysiologi, sorg, sjukdom, biverkningarna av en medicin. Ramverket kan inte särskilja dessa från enbart struktur, eftersom den strukturella signaturen är densamma i varje fall. Samma fallande kurva kan ha helt olika generatorer.

Två konsekvenser följer, och båda är bärande. För det första får ramverket aldrig läsas som att det hävdar att den strukturella redogörelsen är *tillräcklig* — att en självtillitskollaps "egentligen" bara är ett långt aktiverings-legitimitetsmisslyckande och kan resoneras bort. Där ett kliniskt substrat är närvarande är den arkitektoniska beskrivningen sann och oanvändbar i sig själv; den beskriver fällans form utan att vidröra dess orsak. För det andra är ingenting i denna del en ersättning för klinisk vård, och konstruktionsprinciperna i 4.6 är villkor som kan hjälpa en strukturellt genererad nedgång, inte en behandling för en patologiskt genererad sådan. Ramverket kan beskriva fällan. Det är inte en kliniker, och det vet inte, från enbart struktur, vilken fälla en given person befinner sig i.

4.6 Återhämtning som ett arkitektoniskt villkor

Konstruktionsprinciperna från Rapport XIII översätts till villkor för att återuppbygga själv-legitimitet — angivna, i enlighet med seriens disciplin, som arkitektur snarare än som råd, och i varje fall underkastade gränsen i 4.5.

Transparens mot sig själv upprätthåller den observationskanal som långsiktig $L_{\text{själv}}$ är beroende av. Att upphöra att redigera självrapporten — att låta gapet mellan berättelse och tillstånd bli sett — är kostsamt i stunden och är det enda drag som hindrar transparensfällan från att ackumuleras. *Leverans-verklighetsmatchning* angriper spiralen på aktiveringssidan: åtaganden gjorda så små att leveransen är nästan säker återuppbygger tillit från α -sidan, ett hållet löfte i taget, vilket är det enda sätt på vilket byggd tillit någonsin ackumuleras. *Trovärdiga åtagandemekanismer* — extern struktur, förhandsåtagande, arrangemang som gör att följa igenom inte beror av den ögonblickliga nivån av självtillit — fungerar som den personliga motsvarigheten till kretsbytare och konstitutionell förankring: de låter handling fortsätta medan $L_{\text{själv}}$ är för låg för att bära den utan hjälp. Och *hysteres-medvetenhet* är självt ett villkor för återhämtning: eftersom tillit återuppbyggs långsammare än den föll är förväntan om snabb återkomst inte optimism utan en fälla, eftersom den ouppfyllda förväntan läses av systemet som ytterligare ett brutet åtagande och matar den spiral den var tänkt att undfly.

Dessa villkor delar en struktur, och den är värd att namnge eftersom den inverterar en vanlig intuition. Perfektionisten — som sätter stora åtaganden, misslyckas med dem, och behandlar misslyckandet som evidens om sitt värde — siktar inte för högt. De driver självbedrägerispiralen vid maximal förstärkning: maximala åtaganden maximerar svekstermen γ , och arkitekturen garanterar den kollaps den sedan tar som bekräftelse. Byggd självtillit återvinns, när den återvinns, genom det motsatta draget — löften tillräckligt små för att hållas, hållna tillräckligt länge för att räknas.

Del V — Gränskalibrering: Där ramverket når sin gräns

Detta är den del av pappret där kartläggningen är svagast, och pappret är mer användbart för att säga det än det vore för att tvinga fram ett rent resultat. De föregående delarna lånade primitiver vars matematik är skal-invariant — samma ekvationer som beskriver ett departement och ett medvetande — och observatör–anläggning-identitet skärpte var och en till ett specifikt nytt resultat. Gränsdragning beter sig inte på detta sätt. Dess konceptuella innehåll överförs; dess formella innehåll gör det inte; och det strukturella drag som skärpte de andra delarna suddar ut denna. Det ärliga tillvägagångssättet är att ta det överförbara innehållet så långt det räcker, markera exakt var stringensen upphör, och låta asymmetrin stå som evidens för att rangordningen av kartläggningar i denna serie är ett verkligt påstående och inte en retorisk gardering.

Terrängen är själv–andra-gränsen: där självet slutar och en annan börjar, vad som är mitt att bära och vad som inte är det, vilka känslor, problem och ansvar personen behandlar som sina egna. Dess patologier är välbekanta — personen som absorberar allas nöd som om den vore deras egen, och personen som är så fullständigt murad att ingenting når dem. Rapport XII ger en del av denna verkliga struktur, och sedan fallerar en premiss.

5.1 Vad som överförs: Poolningsparadoxen

Rapport XII:s centrala resultat är en paradox för gränsplacering. En kontrollant kan expandera sin gräns för att internalisera de spridningseffekter som destabiliserade den utifrån — men att internalisera dem förlänger dess observations- och aktueringskedjor, så att det större systemet styrs med lägre trohet genom samma begränsade apparat. Eller så kan den krympa sin gräns för att bevara intern trohet — men då fortsätter de gränsöverskridande kopplingar den uteslöt att verka, ostyrda, och återkommer som störningar den inte kan modellera eller attribuera. Det finns ingen enskild gräns som både internaliserar de relevanta kopplingarna och bevarar intern styrningstrohet. Rapport XII benämner detta Informations-Aktueringsfronten, och det är den del av gränsanalysen som överförs till självet med sin kraft intakt. **[IP]**

Det överidentifierande självet expanderar sin gräns för att ta in andras tillstånd: deras sinnesstämningar, deras problem, deras välbefinnande tas in som personens egna att uppfatta och reglera. Detta internaliserar en verklig koppling — den andras tillstånd påverkar genuint personen, och en gräns som ignorerade det skulle lämna det inflytandet ostyrt. Men det förlänger självets kedjor precis som Rapport XII förutsäger. Personen försöker nu observera och agera på ett system mycket större än dem själva — ett annat liv, ofta flera — genom en enda begränsad apparat i ett medvetande, och troheten i deras självstyrning försämras under belastningen. De tappar bort sitt eget tillstånd eftersom den apparat som skulle följa det är upptagen med att modellera alla andras. Det underidentifierande självet drar den motsatta gränsen: rigid avskildhet, förnekandet av kopplingar som icke desto mindre är verkliga, intern trohet bevarad till kostnaden av att lämna genuint gränsöverskridande inflytande omodellerat tills det återkommer som en störning personen inte kan härleda. Ingen av gränserna undflyr fronten. Den återkommande intuitionen att man måste bry sig om verkligheten utan att försöka bära hela den är, i detta ljus, inte ett råd om måttfullhet utan en beskrivning av själva fronten: det finns ingen gränsplacering som upplöser avvägningen, bara placeringar som befinner sig på olika punkter längs den. **[IP]**, med de psykologiska läsningarna **[H]**.

En andra bit överförs svagare men genuint. *Gränssprödh* — Rapport XII:s felsätt där en rigid gräns undertrycker små störningar tills de ackumuleras till katastrofala — har en igenkännbar personlig form i det själv som är så ogenomträngligt att ingenting släpps in, ingen liten justering någonsin görs, och den upprätthållna fattningen brister på en gång snarare än att böjas tidigt. Kartläggningen är sund på beskrivningsnivån och jag klassar den [H], eftersom den till skillnad från poolningsparadoxen vilar på metaforen snarare än på ett resultat som överlever flytten.

5.2 Var formalismen brister

Rapport XII:s konceptuella innehåll vilar på en formell apparat, och den apparaten når inte självet. Att ange varför är substansen i denna del. [R]

Pappret modellerar gapet mellan det system en kontrollant styr och det system som faktiskt existerar som en *M- Δ -återkopplingssammankoppling*: M är kontrollanten och dess modellerade anläggning, Δ är den omodellerade gränsoverskridande dynamiken, och de två är kopplade i en slinga. Stabilitetsresultatet är småförstärkningssatsen: om slingförstärkningen kring den omodellerade dynamiken håller sig under ett, är sammankopplingen stabil *för varje* Δ inom förstärkningsgränsen. Teorets kraft — anledningen till att det är rigoröst snarare än bara suggestivt — är just denna universella kvantifierare. Kontrollanten behöver inte känna till den interna strukturen hos Δ . Den behöver bara en gräns för Δ :s förstärkning, och stabilitet är då garanterad mot varje perturbation som gränsen medger, inklusive det värsta fall gränsen tillåter.

Denna garanti kräver att Δ är en *begränsad men i övrigt godtycklig* perturbation: passiv i den meningen att dess respons inte är en funktion av kontrollantens egen modell och strategi. Relationella gränser bryter mot detta krav vid dess rot. Dynamiken på den borte sidan av en själv-andra-gräns är inte passiva perturbationer; de är *andra agenter* — andra själv, var och en med sin egen observatör-anläggning-identitet, sin egen värdearkitektur, sin egen legitimitetsdynamik, och, avgörande, sin egen kapacitet att modellera personen och att anpassa sitt beteende till var den personen drar sin gräns. Den andra sonderar gränsen, bestrider den, ackommoderar eller exploaterar den. Δ är här korrelerat med M eftersom Δ betraktar M och svarar på det, och Δ är inte begränsat till någon förstärkningsgräns som kontrollanten kan anta, eftersom en strategisk motpart kan agera just för att bryta mot kontrollantens antaganden. "För varje Δ i bollen"-kvantifieraren som får småförstärkningssatsen att fungera beskriver inte längre situationen. Kopplingen är spelteoretisk, inte bara dynamisk, och ett robust-kontroll-stabilitetsvillkor härlett för passiv osäkerhet överförs inte till den.

Detta är inte ett nytt misslyckande för småförstärkningssatsen; det är en välkartlagd kant av robust reglering, som alltid har särskilt begränsad osäkerhet från strategisk, anpassande opposition. Poängen är bara att själv-gränsfallet hamnar på fel sida av denna kända kant. Konsekvensen för detta papper är exakt: den *konceptuella* lärdomen från Rapport XII — att slingor kring omodellerad dynamik kan destabilisera ett system där varje komponent är internt sund — överlever flytten till självet och garanterar §5.1. *Teoremet* — det kvantitativa villkoret under vilket gränsen är stabil, och det gränssmissanpassningsindex B som teoremet gör meningsfullt — gör det inte. Där Del II:s kartläggning var ett [R]-resultat tillämpat (designeffekten är designeffekten, oavsett ensemblen), är Del V:s en konceptuell överföring med den rigorösa kärnan lämnad kvar. Nedgraderingen är delens ärliga innehåll.

5.3 Hur observatör–anläggning-identitet suddar snarare än skärper

Det finns ett ytterligare skäl till att gräns är det svagaste benet, och det är lärorikt eftersom det löper motsatt resten av pappret. I Del II, IV och VI *skärpte* observatör–anläggning-identitet den institutionella primitiven till ett specifikt nytt resultat — ett golv under korrelation, en oreviderbar tillit, en tvåsidig revideringsgräns. Tillämpat på gräns *suddar* samma drag ut primitiven istället.

I styrning är gränsen ett rent gränssnitt mellan kontrollanten och system som är externa i förhållande till den. I ett själv finns inget rent externt gränssnitt, eftersom kontrollanten är inuti anläggningen. Resultatet är att "gräns", för ett själv, gör dubbel tjänst över två frågor som institutionell styrning håller åtskilda. Den ena är interpersonell: var slutar detta själv och en annan börjar? Den andra är intrapersonell: vilka innehåll i min egen erfarenhet identifierar jag mig med som jag, och vilka håller jag på avstånd som något som händer mig men inte är konstitutivt för mig — Själv I:s läsning av distinktionen själv-som-innehåll kontra själv-som-kontext. Dessa är olika gränser, och i ett reflexivt system kommer de inte att separeras rent; hur en person drar linjen kring sin egen erfarenhet betingar hur de drar linjen kring andra, och tvärtom. Rapport XII:s enda gränssmissanpassningsindex B har därför ingen ren själv-analogi. Det finns inte en gräns att fel-placera utan minst två, sammanflätade, och ramverket löser för närvarande inte vilken dynamik som hör till vilken. Denna utsuddning är själv en fjärde konsekvens av observatör–anläggning-identitet — den negativa, fallet där reflexivitet gör ett institutionellt begrepp svårare att överföra snarare än lättare — och att namnge den är en del av varför rangordningen av kartläggningar inte är godtycklig. **[IP]**

5.4 Vad som överlever som konstruktionsprincip

Tillräckligt överförs för att ange konstruktionsprinciper, med den explicita brasklappen att dessa är de minst understödda principerna i pappret — konceptuella överföringar utan den rigorösa uppbackning som de andra delarnas principer ärver.

Gränsen är en designvariabel, inte en givenhet. Den dras, dras väl eller illa, och de flesta patologier i relationell gräns är standardplaceringarna: maximalt permeabel av temperament, eller maximalt rigid till följd av skada, snarare än matchad mot den faktiska kopplingsstrukturen i en särskild relation. Den princip som överlever Rapport XII är *matcha gränsen mot kopplingen* — släpp in över gränsen de inflytanden som är genuint verksamma och uteslut dem som inte är det — tillsammans med *gränsödmjukhet*, att hålla varje placering provisoriskt, eftersom kopplingsstrukturen i en relation förändras och en gräns som passade den en gång inte kommer att passa den i oändlighet. Dessa är sunda så långt de räcker och jag klassar dem **[IP]**; de räcker mindre långt än deras motsvarigheter på andra håll i pappret, eftersom den front de navigerar här inte kan kvantifieras.

Gränsen är också där denna del vidrör de starka. Vem en person släpper in som observatör av sig själv är ett gränsbeslut, så den kuraterade förtrogna från Del II — kanalen utvald för överensstämmelse — är en gräns dragen för bekvämlighet snarare än för koppling. En gräns dragen för permeabelt sourcar självtillit externt, vilket gör själv-legitimiteten i Del IV till gisslan för andras responser — lånad tillit via en annan väg — medan en gräns dragen för rigidit skär av de externa legitimitets-sensorer som Del II och IV identifierade som självets enda approximation till en oberoende kontroll. Och det skyddade experimentutrymmet i Del VI är, strukturellt, en gräns dragen kring en sandlåda: gränsdragning är den operation genom vilken ett själv tillverkar den isolering som dess adaptiva lärande kräver. Gräns är det svagaste benet formellt och bland de mest sammanflätade konceptuellt, vilket är den karakteristiska positionen för en variabel den överordnade serien behandlade som kontext snarare än som ett stadium i sin egen rätt.

Delen är inkluderad av det skäl rangordningen krävde. Ett påstående om att vissa kartläggningar är rigorösa och andra blott konceptuella är bara ett verkligt påstående om de blott konceptuella visas som sådana, på den plats där stringensen tar slut, snarare än kläs för att matcha resten. Gräns är den platsen. Ramverket når hit, levererar poolningsparadoxen och en provisorisk designdisciplin, och stannar vid den punkt där systemet på andra sidan linjen börjar modellera kontrollanten tillbaka.

Del VI — Adaptivt lärande: Själv som måste revidera sig självt utan att falla sönder

Två liv kan misslyckas på motsatta sätt. Den första personen etablerar sig tidigt — en karriär, en roll, en självförståelse — och optimerar den troget i årtionden, tills de vaknar vid femtio och bebor ett liv som passar en person de inte längre är, oförmögna att säga vad de skulle vilja istället. Den andra personen etablerar sig aldrig alls: en ny stad, ett nytt ramverk, en ny relation, ett nytt själv var artonde månad, ackumulerande begynnelse och integrerande ingen av dem. Det första ser ut som överdriven stabilitet och det andra som överdriven förändring, och frestelsen är att ordinera den saknade dygden till var och en. Men den överordnade seriens fjortonde paper visar att de delar en enda diagnos. Båda har felinställt samma parameter — den takt med vilken en kontrollant sonderar bortom sin nuvarande modell — den ena mot noll och den andra mot överskott. Denna del behandlar själv som en adaptiv kontrollant underkastad den parametern, och argumenterar för att parametern för ett själv, till skillnad från för ett samhälle, är begränsad på *båda* sidor, och den övre gränsen är den snävare. **[IP]**

Denna del fullbordar också själv-skalans triad. Del II fastställde *avkänningskravet* — en observerande ensemble tillräckligt dekorrelerad för att upptäcka sitt eget systematiska fel. Del III fastställde *aktiveringskravet* — en delegeringskedja tillräckligt kort för att bära intention till handling. Adaptivt lärande är det krav som medierar mellan dem: kan själv upptäcka *vad* som ska förändras, och göra det utan att upptäckten destabiliserar det själv som måste integrera den? Sekvensen — **Avkänna** → **Lära** → **Verkställa** — är den överordnade seriens redogörelse för hur varje kontrollant förblir livsduglig i en miljö som förändras snabbare än dess arkitektur, och det är inte mindre strukturen för ett liv.

6.1 Själv som en dual kontrollant

Dual reglerteori modellerar spänningen mellan *exploatering* — att agera optimalt givet vad som för närvarande är känt — och *exploration* — att agera för att förvärva kunskap som förbättrar framtida handling. Dess centrala observation är att i ett adaptivt system kan de två inte rent separeras, eftersom varje intervention samtidigt är en handling och ett experiment. På ett livs skala är detta exakt snarare än metaforiskt. Att ta ett jobb är både ett val och en sond: det producerar ett utfall *och* avslöjar något om vad personen kan göra, vad de kan tolerera, och vad de faktiskt vill, i motsats till vad de trodde att de ville. Att ingå eller avsluta en relation, flytta, byta fält, skaffa barn — var och en är en handling som också returnerar information om parametrar personen inte kan skatta på något annat sätt, eftersom det enda instrument som mäter dem är valets levande. **[R]** för den duala regleringsstrukturen; **[IP]** för dess tillämpning på ett liv.

Konsekvensen följer direkt. En person som behandlar sina val endast som handlingar — som vid varje steg väljer det som optimerar deras nuvarande mål — kastar systematiskt bort den självkännedom dessa val kunde ha genererat. Den optimala policyn inkluderar, i dual reglering, en *explorationsbonus*: handlingar lutas, i marginalen, mot sådana som reducerar osäkerhet om parametrar som är betydelsefulla för resten av banan. För ett själv är de parametrar som är mest värda att reducera osäkerhet om de som Själv I visade är svårast att se inifrån en fix värdearkitektur: vad man faktiskt värderar, vad man är kapabel till, vem man skulle vara under förhållanden som aldrig tidigare mötts. Explorationsbonusen är det strukturella skälet till att ett välskött liv spenderar en del av sina val på frågor snarare än på avkastning. **[IP]**

6.2 *Ihållande excitation och det överskyddade självet*

Systemidentifiering tillhandahåller ett villkor med en hård kant: ett systems parametrar är identifierbara endast om systemet är *ihållande exciterat* — endast om det upplever tillräcklig variation för att avslöja hur det svarar över det spektrum av förhållanden som spelar roll. En kontrollant som håller sina insignaler konstanta lär sig ingenting om sin egen dynamik, hur länge den än körs. Rapport XIV läser detta som det rigorösa innehållet i antifragilitet: ett styrsystem som undertrycker all varians — varje chock, varje misslyckande, varje protest — är inte maximalt stabilt utan maximalt sårbart, eftersom det har eliminerat den signal som dess egen kalibrering är beroende av.

Den personliga formen är direkt och något mot intuitionen. Ett liv arrangerat för att undvika all utmaning, allt misslyckande, allt obehag, görs därigenom inte tryggt; det görs *okalibrerat*. Den person som aldrig har varit nära gränsen av vad de kan hantera besitter inte en lugnande stabilitet — de besitter en oidentifierad modell av sig själva, en självuppskattning oprövad mot de förhållanden som skulle avslöja dess fel. De vet inte vad de kan uthärda, vad de skulle offra, vem de blir under belastning, eftersom parametrarna som styr dessa responser aldrig exciterades. Detta är den strukturella läsningen av en välbekant observation: att skydd bortom en punkt producerar sårbarhet snarare än trygghet, och att kapaciteten att möta svårighet själv lärs endast genom att metabolisera en del. Ramverket romantiserar inte lidande — det specificerar en kvantitet varians som krävs för identifierbarhet, under vilken själv-modellen glider ur kalibrering obemärkt, och ovanför vilken faran i §6.4 ligger. **[IP]** för strukturen; **[H]** för livsläsningen.

6.3 *Explorationssvälthet och den gröna dashboarden*

Av Rapport XIV:s fem felsätt är det första det som spelar mest roll här, på grund av hur det döljer sig. *Explorationssvälthet* inträffar när kortsiktiga incitament driver explorationsgraden till noll: systemet upphör att sondera bortom sin nuvarande modell, modellen glider från den verklighet den är tänkt att följa, och — detta är det dödliga draget — glidningen är osynlig för systemets egen övervakning. Simuleringen gör signaturen precis: kontrollantens interna uppskattning av sin egen prestanda förblir optimistisk även när dess sanna styrfel divergerar. Dashboarden läser grönt medan systemet misslyckas.

Detta är den strukturella redogörelsen för medelålders stagnation, och den är skarpare än den vardagliga versionen. Det svulna självet är inte i synlig nöd; det är vad som gör det till svält snarare än kris. Det har optimerat en dimension så grundligt, så länge, att det slutade generera den varians som skulle avslöja att dimensionen har blivit förlegad — och eftersom exploration är just den förmåga som har stängts av, kan ingenting i systemets egen övervakning rapportera dess frånvaro. Personen mår bra, enligt det enda mått de fortfarande kör. Glidningen är mellan det måttet och en verklighet det inte längre följer. Detta är Själv I:s varietetsgap givet en tidslig mekanism: inte bara utesluter en smal värdearkitektur dimensioner av det nuvarande självet, den slutar uppdateras, så att den arkitektur som passade den personen vid trettio styr livet för den de är vid femtio med oförminskad tillförsikt. Den gröna dashboarden är samma artefakt som den överordnade serien diagnostiserade i misslyckade institutioner, löpande i en person över ett liv. **[IP]**, med det specifika förloppet **[H]**.

Två angränsande felsätt fullbordar bilden. *Modellåsning* är den föråldrade självförståelsen aktivt försvarad: självberättelsen utvecklar ett immunsystem som behandlar evidens mot den som ett hot att neutralisera — "det är inte den jag är" använt inte som rapport utan som försvar. Detta är Del II:s narrativa monokultur och Del IV:s kuraterade självrapport sedd från inlärningssidan: den mekanism som hindrar modellen från att uppdateras. *Exploateringslåsning* är dess komplement och är lätt att missa eftersom det ser ut som framgång på den svåra delen. Här *har* självet lärt sig

— personen ser klart, ofta genom just de dekorrelerade kanaler som Del II beskrev, vad som är fel och vad som skulle behöva förändras — men aktueringskedjan i Del III är blockerad, så kunskap ackumuleras medan beteendet inte rör sig. Insikten är genuin och livet förändras inte. Detta är den strukturella skillnaden mellan att inte veta vad man ska göra och att veta precis medan man förblir oförmögen att göra det; den överordnade seriens simulering visar att de två är distinkta banor, där den andra följer sanningen korrekt medan prestandan förblir dålig. [IP]

6.4 Den reflexiva faran: När experimentatorn är experimentet

Allt fram till denna punkt skulle också sägas, lämpligt översatt, om ett samhälle. Det distinkta innehållet i själv-lärande framträder när observatör-anläggning-identitet tillämpas en tredje gång, och det skär i en riktning som de tidigare delarna inte gjorde.

I styrning modifierar kontrollanten *anläggningen* — en skattereform stör ekonomin, inte departementet. Den experimenterande apparaten är isolerad från experimentet: staten driver särskilda ekonomiska zoner, och om en zon misslyckas, är misslyckandet inneslutet där medan staten som auktoriserade den förblir intakt för att lära av resultatet. Denna isolering är vad som gör aggressiv exploration överlevbar; Rapport XIV:s "skyddade experimentutrymmen" är, strukturellt, anordningar för att hålla kontrollanten åtskild från den varians den injicerar.

Självvet har ingen sådan separation som standard, eftersom kontrollanten *är* anläggningen. Själv-exploration — att revidera sina värderingar, att ifrågasätta sin identitet, hela aktiviteten att "arbeta med sig själv" — är exploration vars experimentella subjekt är den apparat som genomför experimentet. Det duala kontrollproblemet blir rekursivt i strikt mening: systemet kör sonder på det system som kör sonder. Och detta omvandlar ihållande excitation från ett ensidigt krav till en tvåsidig gräns. Låt r vara den takt med vilken ett själv reviderar sig självt och ι den takt med vilken ett reviderat själv åter-stabiliseras — integrerar förändringen till en koherent pågående identitet. Den *undre* gränsen är den som styrning också möter: r måste överstiga den takt med vilken personens omständigheter och inre förhållanden förändras, annars glider själv-modellen in i svälten i §6.3. Den *övre* gränsen saknar fullständig institutionell motsvarighet: r får inte överstiga ι . När revidering springer ifrån integration, destabiliserar den varians som injiceras för att driva inlärning inte bara anläggningen — som skulle kunna återhämta sig — utan kontrollantens egen koherens, vilket är det som skulle behöva förbli stabilt för att metabolisera inlärningen överhuvudtaget.

$$\underbrace{\text{förändringstakt}}_{\text{undre gräns: svält under}} < r < \underbrace{\iota}_{\text{övre gräns: inkoherens ovan}}$$

Detta är Rapport XIV:s inlärningsinducerade oscillation på den personliga skalan, men det är mer än kaotiska livsval. I ett själv riskerar överaggressiv exploration att upplösa experimentatorn. Det är den strukturella redogörelsen för varför intensiv självtransformation ibland gör en person sämre snarare än bättre: revidering som anländer snabbare än den kan integreras, identitet destabiliserad snabbare än den kan åter-koherenta, den sökande från §6.1:s inledning som aldrig slutar förändras just därför att ingenting stabiliseras tillräckligt länge för att läras från. Den övre gränsen är *snävare* för ett själv än för ett samhälle, och anledningen är just observatör-anläggning-identitet: ett samhälle kan isolera sin experimentapparat från sina experimentzoner, och ett själv kan som standard inte fullt ut isolera sig från sitt eget. [IP]

En kvalificering håller detta påstående exakt, och simuleringen i Appendix D tillhandahåller den. Ett samhälle är faktiskt inte *obegränsat* uppåt: revidera för snabbt och det förstärker brus in i sina egna skattningar, så det har också en övre gräns för användbar revidering. Skillnaden är inte att institutioner kan revidera utan gräns och själv inte kan

det. Det är att självets övre gräns är *snävare* och anländer *tidigare*, och genom en annan mekanism — den binder via förlust av kontrollantens koherens långt under den takt vid vilken ren brusförstärkning skulle binda, vilket tvingar självet att stanna kort om till och med sitt eget brusbegränsade optimum och att acceptera en del spåringsfel som priset för att förbli koherent. "Snävare för ett själv än för ett samhälle" betyder därför *tidigare och via koherens*, inte *närvarande för självet och frånvarande för samhället* — en begränsning ett system vars kontrollant och anläggning är separata helt enkelt inte möter först.

6.5 Gränsen ramverket inte får överskrida

Den tvåsidiga gränsen gränsar till kliniskt och kontemplativt territorium, och liksom i Del IV måste gränsen markeras snarare än överskridas. **[R]** Ramverket beskriver *strukturen* hos integrationsbegränsningen — att revidering som springer ifrån åter-stabilisering försämrar den koherens som inläring kräver. Det beskriver inte hanteringen av den begränsningen hos någon individ, och det hävdar inte att destabilisering under intensivt självarbete alltid eller ens vanligtvis är strukturell. Där ett kliniskt substrat är närvarande — där själv-interrogation utlöser något med en fysiologi som kontrollmodellen inte representerar — förblir den arkitektoniska beskrivningen sann och är otillräcklig i sig själv, i exakt den mening Del IV gav: den namnger svårighetens form utan att nå dess orsak, och den är inte en kliniker. Observationen att transformation måste taktas till integration är en strukturell konsekvens av $r < l$, inte ett protokoll för att takta den, och ramverket har ingen uppfattning om hur, eller om, en given person överhuvudtaget bör genomföra sådan revidering.

6.6 Skyddade experimentutrymmen som tillverkad isolering

Konstruktionsprincipen följer av den tvåsidiga gränsen och omramar ett välbekant recept till något med ett strukturellt jobb. *Skyddade experimentutrymmen* — hobbys, sidoprojekt, sabbatsperioder, resor, konstnärlig och kontemplativ praktik, relationer med låga insatser, forskning bedriven för sin egen skull — försvaras vanligen som balans eller återhämtning. Ramverket tilldelar dem en mer specifik funktion: de är självets försök att *tillverka* den kontrollant-anläggning-separation som observatör-anläggning-identitet annars förvägrar det. Ett skyddat utrymme är en sandlåda i vilken en person kan köra ett experiment på ett partiellt själv utan att satsa hela självet på utfallet — utforska ett annat sätt att vara, arbeta, relatera eller se, under förhållanden där misslyckande är inneslutet och inte propagerar till den kärnidentitet som måste förbli koherent för att lära. Detta är hur ett själv approximerar den isolering ett samhälle får gratis: inte genom att utforska mindre, vilket svälter det, och inte genom att utforska med hela sin identitet på en gång, vilket destabiliserar det, utan genom att konstruera avgränsade arenor där explorationsgraden kan löpa högt lokalt medan integrationsbegränsningen respekteras globalt.

Detta fullbordar anpassningstriaden på den personliga skalan och återför pappret till den rekursion Rapport XIV identifierade som konvergenspunkten för sin matematik. Ett styrsystem som säkert modifierar sin egen arkitektur, ett AI-system som säkert modifierar sin egen kod, och ett själv som säkert reviderar sin egen identitet är, strukturellt, ett problem: en kontrollant som försöker förändra vad den är utan att förstöra den kontinuitet som skulle låta den lära sig av förändringen. Självet är den instans av det problemet varje läsare bebor, och den tvåsidiga gränsen är den form problemet antar när kontrollanten och anläggningen aldrig fullt ut kan dras isär.

Del VII — Sammansatta felsätt

De föregående delarna beskrev var och en hur en enskild primitiv misslyckas på egen hand: en observatörsensembel som kollapsar till en kanal, en aktueringskedja för djup för att bära ett direktiv, självtillit som spiralerar nedåt, exploration som svälts ut eller löper förbi integration, en gräns som är missanpassad till sin koppling. I ett liv inträffar dessa misslyckanden sällan isolerat. De farliga fällorna — de som tar år och motstår de uppenbara åtgärderna — är *sammansättningar*, i vilka flera primitiver misslyckas tillsammans och varje misslyckande driver de andra. Denna del namnger de huvudsakliga sammansättningarna och den struktur de delar.

Två fakta gör sammansatt misslyckande till regel snarare än undantag för ett själv. Det första är den överordnade seriens resultat från Rapport V: kopplade begränsningar adderas inte, de ackumuleras multiplikativt — samordningsmisslyckandets skatt. Det andra är observatör-anläggning-identitet. Inom styrning är primitiven ofta instansierade i olika institutioner — den myndighet som avkänner är inte det departement som agerar — så ett misslyckande i en är delvis brandväggt från de andra. Ett själv har ingen sådan brandvägg, eftersom alla fem primitiver löper genom ett enda substrat. Samma apparat observerar, agerar, litar på, utforskar och avgränsar, så en försämring i vilken som helst propagerar in i resten utan att något stoppar den. Sammansatt misslyckande är inte ett specialfall av sammanbrott i självstyrning; givet observatör-anläggning-identitet är det den standardform sammanbrott antar. **[IP]**

7.1 Det förseglade självet

Den djupaste sammansättningen kopplar tre primitiver till en ömsesidigt förstärkande slinga från vilken självet inte, med sina egna resurser, kan uppfatta en utgång. Observatörsångfalden kollapsar (Del II): kanalerna konvergerar tills ensemblen levererar en enda korrelerad läsning. Själv-modellen låses fast (Del VI): narrativet hårdnar till något som den kvarvarande kanalen bara bekräftar. Och transparensfällan sluter sig (Del IV): självrapporten kurateras för att försvara narrativet, och redigerar bort den lilla dissonans som överlever. Ingen av de tre är oberoende av de andra. En kollapsad ensemble har ingen dekorrelerad kanal kvar för att leverera den signal som skulle bryta låsningen; det låsta narrativet rekryterar aktivt bekräftande observatörer, vilket driver korrelationen högre; transparensfällan avlägsnar restprodukten. Resultatet är ett själv som har blivit strukturellt oförmöget att uppdateras *och* strukturellt oförmöget att uppfatta att det inte kan — den gröna dashboarden från Del VI, ekokammaren från Del II, och självbedrägeriet från Del IV, sammansmälta till ett enda tillstånd. Det är den allvarligaste fällan i pappret eftersom varje internt instrument som skulle kunna upptäcka den har värvats för att upprätthålla den, och det enda greppet om den kommer från de dekorrelerade externa kanaler som fällan, till sin konstruktion, har hållit på att stänga. **[IP]**, med porträttet **[H]**.

7.2 Självbedrägerispiralen

Sammansättningen av själv-legitimitet (Del IV) och aktueringsdjup (Del III) sammanställdes i §3.5 och namnges här som den fälla den utgör. Låg självtillit försvagar en lång aktueringskedja multiplikativt, eftersom legitimitetsförstärkningen inträder vid varje länk; den försvagade kedjan misslyckas med att leverera; varje misslyckande är ett brutet löfte till sig själv som sänker självtilliten ytterligare; och den sänkta tilliten försvagar nästa kedja ännu brantare. Djup och misstro adderas inte — de multipliceras, och produkten återkopplar på sig själv. Detta är motorn under den välbekanta erfarenheten av en person som har slutat kunna agera på sina egna intentioner och läser förklaringen som en dom över sin karaktär, när den är den förutsägbara utsignalen från två kopplade primitiver som försämras i låst steg. **[IP]**

7.3 Upplösningsfällan

En gräns dragen för permeabelt (Del V) misslyckas inte ensam. Det överidentifierade självvet routar sin självobservation genom en annan person eller en grupp, så dess kanaler förlorar det oberoende Del II krävde — den andras syn på personen blir den dominanta läsningen, och de dekorrelerade interna kanalerna tystnar. Samtidigt sourcas dess själv-legitimitet externt (Del IV): självtillit blir lånad, gisslan för den andras responser, spröd på just det sätt som lånad legitimitet är spröd. Observatörsångfald, självtillit och gräns misslyckas tillsammans, och sammansättningen är det igenkännbara tillståndet av att förlora sig själv i en relation eller en grupp — inte tre separata problem utan ett, där en permeabel gräns samtidigt koloniserar observationskanalerna och externaliserar tilliten, och lämnar ett själv som inte längre kan lokalisera sitt eget tillstånd eller stå på sina egna åtaganden. **[IP]**, med porträttet **[H]**.

7.4 Revidering in i inkoherens

Den sökande som aldrig etablerar sig (Del VI:s övre-gräns-överträdelse) är, granskad närmare, en sammansättning med själv-legitimitet. Revidering som anländer snabbare än integration destabiliserar kontrollanten, som Del VI fastställde; men varje revidering som misslyckas med att fästa är också ett åtagande till ett själv som övergavs, och övergivna självåtaganden urholkar självtillit exakt som brutna löften gör (Del IV). Den urholkade tilliten gör att nästa revidering landar ännu mindre säkert — ett själv som inte tror på sina egna intentioner kan inte förbinda sig till den nya identiteten tillräckligt fast för att den ska koherenta — vilket garanterar nästa övergivande. Den övre explorationsgränsen och legitimitets-spiralen driver varandra, så att det som ser ut som ett överskott av mod är samma självbedrägeridynamik som i §7.2 löpande genom inlärningskanalen snarare än aktiveringskanalen. **[IP]**

7.5 Den delade strukturen

Sammansättningarna skiljer sig i sitt innehåll och delar en form: ömsesidigt förstärkande försämring över primitiver som är multiplikativt kopplade och, i ett själv, separerade av ingen brandvägg. Detta har en direkt konsekvens för konstruktionsprinciperna i nästa del. Eftersom primitiven misslyckas tillsammans kan de inte repareras ett i taget — en intervention på en enda primitiv, tillämpad medan de andra fortsätter att försämrats, arbetar mot en multiplikativ koppling som kommer att överväldiga den. Den person som försöker återuppbygga självtillit medan deras observationskanaler förblir kollapsade, eller att tvinga en djup aktueringskedja medan deras själv-legitimitet fortfarande faller, reparerar en faktor i en produkt vars andra faktorer driver mot noll. Återhämtningens arkitektur, liksom misslyckandets arkitektur, är kopplad — vilket är anledningen till att principerna i Del VIII anges som en uppsättning vars element stöder varandra, snarare än som oberoende reparationer som skulle kunna genomföras i vilken ordning som helst eller isolerat. **[IP]**

Del VIII — Konstruktionsprinciper

Principerna som följer angavs var och en i den del som etablerade dem, och denna del härleder dem inte på nytt. Den gör två saker som hemdelarna inte kunde. Den samlar principerna till den kopplade uppsättning som Del VII visade att de måste bilda — eftersom primitiven misslyckas tillsammans och multiplikativt kan reparationerna inte genomföras ett i taget. Och den identifierar den enda logiken under dem, vilken visar sig vara designsidans ansikte av papprets centrala variabel. Genomgående anges principerna som serien anger dem: som arkitektur, inte som råd. Var och en har formen *ett själv med denna egenskap förblir adaptivt i detta avseende* — ett strukturellt villkor, inte en instruktion för hur man ska leva, och inte ett påstående om att en given person bör bygga ett sådant själv eller skulle kunna göra det till en kostnad de skulle acceptera.

8.1 Principerna, samlade

Från Del II: upprätthåll självobservationskanaler som är partiellt *dekorrelerade* — kanaler som inte delar det berättande substratet och inte har valts ut för sin överensstämmelse — och vikta divergens från en sådan kanal över överensstämmelse bland korrelerade sådana, eftersom endast dekorrelerade kanaler höjer ensemblens effektiva oberoende. Från Del III: håll aktueringskedjan *kort*, och *externalisera* dess minst tillförlitliga interna lager, så att ett direktiv korsar färre steg och är mindre beroende av ögonblickliga interna tillstånd för att nå beteende. Från Del IV: praktisera *transparens mot sig själv* och *leverans-verklighetsmatchning*, bygg *trovärdiga åtagandemekanismer* som inte beror av den aktuella nivån av självtrillit, och gå fram med *hysteres-medvetenhet*, med förväntan om att återhämtning löper långsammare än nedgång. Från Del V, den svagast understödda: *matcha gränsen mot kopplingen* och håll den med *ödmjukhet*, omförhandlande i takt med att kopplingen förändras. Från Del VI: upprätthåll *skyddade experimentutrymmen* som låter exploration löpa högt lokalt utan att satsa hela självet, håll explorationsgraden mellan dess två gränser, och *revidera målfunktionen* periodiskt, eftersom en förlegad värdearkitektur inte kommer att rapportera sin egen förlegadhet. [IP], förutom Del V:s, vilka bär den [H] som noterades där.

8.2 Den förenande logiken: Rekrytera vad det reflexiva självet inte kan vara för sig självt

Ställda sida vid sida avslöjar principerna en logik. Observatör–anläggning-identitet medför att självet inte, inifrån, kan dekorrelera sina egna observatörer, revidera sin egen trillit, isolera sina egna experiment eller helt förkorta vad som är en reflexiv kedja — den förmåga som skulle göra dessa saker är samma förmåga som granskas. Designsvaret på var och en av dessa oförmågor är samma drag: rekrytera, *utanför* det reflexiva substratet, den struktur som substratet inte kan tillhandahålla sig självt. Den dekorrelerade kanalen i Del II är en observatör situerad utanför det berättande självet. Åtagandemekanismen i Del IV är en struktur som håller när den ögonblickliga självtrilliten inte gör det. Det externaliserade lagret i Del III är en miljömässig ställning som står i stället för ett opålitligt internt sådant. Det skyddade utrymmet i Del VI är en sandlåda byggd utanför kärnidentiteten. Dessa är inte fem orelaterade recept; de är fem instanser av en princip — *ett själv styr sig självt väl genom att bygga, utanför sig självt, de strukturer som dess reflexiva natur hindrar det från att vara för sig självt* — och gränskalibreringen i Del V är den principens mästaroperation, den akt genom vilken självet bestämmer vilken extern struktur som ska släppas in och på vilka villkor. Designsidan av observatör–anläggning-identitet är externalisering, av samma skäl som dess diagnostiska sida var en familj av interna oförmågor. [IP]

En princip motstår denna logik, och det är den som Del I:s dubbla egg förutsade skulle göra det. Eftersom observera i ett reflexivt system redan är att handla, är uthållig självobservation inte bara en sensor utan en spak: att rikta uppmärksamheten mot en dimension av självet förändrar den. Detta är den enda kapacitet den reflexiva strukturen beviljar snarare än förvägrar, den interna motsvarigheten till all den externa rekryteringen — den disciplinerade uppmärksamheten i kontemplativ och terapeutisk praktik som gör, inifrån, det arbete som de andra principerna måste outsourca. En fullständig design använder båda eggarna: extern struktur för allt självet inte kan göra med sig självt, och den interna uppmärksamhetsspaken för det enda dess reflexivitet gör unikt möjligt. Ramverket lutar tungt på den externa sidan eftersom det är där observatör–anläggning-identitet skapar behov, men det vore ofullständigt om det glömde att samma identitet också skapar en form av hävstång tillgänglig ingen annanstans. **[IP]** för strukturen; den kontemplativa läsningen är **[H]**, och Del IX styr hur långt den får tas.

8.3 Slutstenen och sekvensen

Eftersom principerna är multiplikativt kopplade har uppsättningen en ingångspunkt, och att identifiera den är det enda stycke sekvensering ramverket kan erbjuda. Själv-legitimitet är förstärkningen på resten: Del III visade att den multipliceras in i varje länk av aktueringskedjan, Del IV att den modulerar både observation och handling, Del VII att dess kollaps driver de allvarligaste sammansättningarna. En intervention på varje annan primitiv multipliceras med denna förstärkning, så en intervention som tillämpas medan självtilliten faller arbetar mot en faktor som driver mot noll. Ingångspunkten är därför därhelst själv-legitimitet *byggs*, och pappret har redan lokaliserat den: i små åtaganden som hålls. Ett litet hållet åtagande är samtidigt en kort aktueringskedja med hög sannolikhet som faktiskt levererar (Del III) och en leverans som höjer självtilliten på leveranssidan (Del IV) — det enda drag som både är en handling och en insättning i den förstärkning som varje annan handling drar på. Detta ger ett kontraintuitivt designpåstående. Den produktiva ingången till ett kopplat självstyrningsmisslyckande är inte den mest skadade primitiven, där intervention multipliceras med den lägsta förstärkningen, utan den plats där själva förstärkningen återuppbyggs — åtaganden tillräckligt små för att de inte kan misslyckas, hållna tills den tillit de genererar gör de djupare reparationerna överkomliga. Ordningen är inte en fråga om preferens; den följer av var den multiplikativa förstärkningen sitter. **[IP]**

8.4 Inhägnaden

Dessa principer beskriver arkitekturen hos ett själv som förblir öppet — som fortsätter att uppfatta vad det ännu inte värderar, fortsätter att agera på vad det uppfattar, fortsätter att lita på sig självt tillräckligt för att förbinda sig, fortsätter att utforska tillräckligt för att förbli kalibrerat, och fortsätter att hålla sin gräns matchad mot den värld det är kopplat till. De beskriver inte ett gott liv, och distinktionen är den serien har hållit genomgående och som Del 0 förband detta papper till. Att säga att ett själv med dessa egenskaper förblir adaptivt är ett strukturellt påstående. Att säga att en person *bör* bygga ett sådant själv, eller att adaptivitet är vad de bör vilja, eller att ett liv så organiserat därmed är vällevt, är påståenden av ett annat slag som ramverket inte gör och inte har något instrument att stödja. **[R]** som ett uttalande om ramverkets ställning.

Principerna håller rummet öppet; de möblerar det inte. Det är inte en brist att avhjälpas med en mer fullständig uppsättning principer — Del IX ger anledningen till att det inte kan vara det. Vad det öppna självet gör med sin öppenhet, vad det älskar, skapar och blir, är just det innehåll som ingen arkitektur specificerar och ingen målfunktion rymmer. Konstruktionsprinciperna bygger och underhåller rummet, med extern struktur för vad självet inte kan göra

för sig självt och den enda interna spaken för vad det kan. Vad som träder in i rummet är inte deras att säga, och ett ramverk som påstod sig kunna säga det skulle ha slutat vara ingenjörskonst och blivit just det det byggdes för att diagnostisera.### Del VIII — Konstruktionsprinciper

Principerna som följer angavs var och en i den del som etablerade dem, och denna del härleder dem inte på nytt. Den gör två saker som hemdelarna inte kunde. Den samlar principerna till den kopplade uppsättning som Del VII visade att de måste bilda — eftersom primitiven misslyckas tillsammans och multiplikativt kan reparationerna inte genomföras ett i taget. Och den identifierar den enda logiken under dem, vilken visar sig vara designsidans ansikte av papprets centrala variabel. Genomgående anges principerna som serien anger dem: som arkitektur, inte som råd. Var och en har formen *ett själv med denna egenskap förblir adaptivt i detta avseende* — ett strukturellt villkor, inte en instruktion för hur man ska leva, och inte ett påstående om att en given person bör bygga ett sådant själv eller skulle kunna göra det till en kostnad de skulle acceptera.

8.1 Principerna, samlade

Från Del II: upprätthåll självobservationskanaler som är partiellt *dekorrelerade* — kanaler som inte delar det berättande substratet och inte har valts ut för sin överensstämmelse — och vikta divergens från en sådan kanal över överensstämmelse bland korrelerade sådana, eftersom endast dekorrelerade kanaler höjer ensemblens effektiva oberoende. Från Del III: håll aktueringskedjan *kort*, och *externalisera* dess minst tillförlitliga interna lager, så att ett direktiv korsar färre steg och är mindre beroende av ögonblickliga interna tillstånd för att nå beteende. Från Del IV: praktisera *transparens mot sig själv* och *leverans-verklighetsmatchning*, bygg *trovärdiga åtagandemekanismer* som inte beror av den aktuella nivån av självtillit, och gå fram med *hysteres-medvetenhet*, med förväntan om att återhämtning löper långsammare än nedgång. Från Del V, den svagast understödda: *matcha gränsen mot kopplingen* och håll den med *ödmjukhet*, omförhandlande i takt med att kopplingen förändras. Från Del VI: upprätthåll *skyddade experimentutrymmen* som låter exploration löpa högt lokalt utan att satsa hela självet, håll explorationsgraden mellan dess två gränser, och *revidera målfunktionen* periodiskt, eftersom en förlegad värdearkitektur inte kommer att rapportera sin egen förlegadhet. [IP], förutom Del V:s, vilka bär den [H] som noterades där.

8.2 Den förenande logiken: Rekrytera vad det reflexiva självet inte kan vara för sig självt

Ställda sida vid sida avslöjar principerna en logik. Observatör-anläggning-identitet medför att självet inte, inifrån, kan dekorrelera sina egna observatörer, revidera sin egen tillit, isolera sina egna experiment eller helt förkorta vad som är en reflexiv kedja — den förmåga som skulle göra dessa saker är samma förmåga som granskas. Designsaret på var och en av dessa oförmågor är samma drag: rekrytera, *utanför* det reflexiva substratet, den struktur som substratet inte kan tillhandahålla sig självt. Den dekorrelerade kanalen i Del II är en observatör situerad utanför det berättande självet. Åtagandemekanismen i Del IV är en struktur som håller när den ögonblickliga självtilliten inte gör det. Det externaliserade lagret i Del III är en miljömässig ställning som står i stället för ett opålitligt internt sådant. Det skyddade utrymmet i Del VI är en sandlåda byggd utanför kärnidentiteten. Dessa är inte fem orelaterade recept; de är fem instanser av en princip — *ett själv styr sig självt väl genom att bygga, utanför sig självt, de strukturer som dess reflexiva natur hindrar det från att vara för sig självt* — och gränskalibreringen i Del V är den principens mästaroperation, den akt genom vilken självet bestämmer vilken extern struktur som ska släppas in och på vilka villkor. Designsidan av observatör-anläggning-identitet är externalisering, av samma skäl som dess diagnostiska sida var en familj av interna oförmågor. [IP]

En princip motstår denna logik, och det är den som Del I:s dubbla egg förutsade skulle göra det. Eftersom observera i ett reflexivt system redan är att handla, är uthållig självobservation inte bara en sensor utan en spak: att rikta uppmärksamheten mot en dimension av självet förändrar den. Detta är den enda kapacitet den reflexiva strukturen beviljar snarare än förvägrar, den interna motsvarigheten till all den externa rekryteringen — den disciplinerade uppmärksamheten i kontemplativ och terapeutisk praktik som gör, inifrån, det arbete som de andra principerna måste outsourca. En fullständig design använder båda eggarna: extern struktur för allt självet inte kan göra med sig självt, och den interna uppmärksamhetsspaken för det enda dess reflexivitet gör unikt möjligt. Ramverket lutar tungt på den externa sidan eftersom det är där observatör–anläggning-identitet skapar behov, men det vore ofullständigt om det glömde att samma identitet också skapar en form av hävstång tillgänglig ingen annanstans. **[IP]** för strukturen; den kontemplativa läsningen är **[H]**, och Del IX styr hur långt den får tas.

8.3 Slutstenen och sekvensen

Eftersom principerna är multiplikativt kopplade har uppsättningen en ingångspunkt, och att identifiera den är det enda stycke sekvensering ramverket kan erbjuda. Själv-legitimitet är förstärkningen på resten: Del III visade att den multipliceras in i varje länk av aktueringskedjan, Del IV att den modulerar både observation och handling, Del VII att dess kollaps driver de allvarligaste sammansättningarna. En intervention på varje annan primitiv multipliceras med denna förstärkning, så en intervention som tillämpas medan självtilliten faller arbetar mot en faktor som driver mot noll. Ingångspunkten är därför därhelst själv-legitimitet *byggs*, och pappret har redan lokaliserat den: i små åtaganden som hålls. Ett litet hållet åtagande är samtidigt en kort aktueringskedja med hög sannolikhet som faktiskt levererar (Del III) och en leverans som höjer självtilliten på leveranssidan (Del IV) — det enda drag som både är en handling och en insättning i den förstärkning som varje annan handling drar på. Detta ger ett kontraintuitivt designpåstående. Den produktiva ingången till ett kopplat självstyrningsmisslyckande är inte den mest skadade primitiven, där intervention multipliceras med den lägsta förstärkningen, utan den plats där själva förstärkningen återuppbyggs — åtaganden tillräckligt små för att de inte kan misslyckas, hållna tills den tillit de genererar gör de djupare reparationerna överkomliga. Ordningen är inte en fråga om preferens; den följer av var den multiplikativa förstärkningen sitter. **[IP]**

8.4 Inhägnaden

Dessa principer beskriver arkitekturen hos ett själv som förblir öppet — som fortsätter att uppfatta vad det ännu inte värderar, fortsätter att agera på vad det uppfattar, fortsätter att lita på sig självt tillräckligt för att förbinda sig, fortsätter att utforska tillräckligt för att förbli kalibrerat, och fortsätter att hålla sin gräns matchad mot den värld det är kopplat till. De beskriver inte ett gott liv, och distinktionen är den serien har hållit genomgående och som Del 0 förband detta papper till. Att säga att ett själv med dessa egenskaper förblir adaptivt är ett strukturellt påstående. Att säga att en person *bör* bygga ett sådant själv, eller att adaptivitet är vad de bör vilja, eller att ett liv så organiserat därmed är vällevt, är påståenden av ett annat slag som ramverket inte gör och inte har något instrument att stödja. **[R]** som ett uttalande om ramverkets ställning.

Principerna håller rummet öppet; de möblerar det inte. Det är inte en brist att avhjälpas med en mer fullständig uppsättning principer — Del IX ger anledningen till att det inte kan vara det. Vad det öppna självet gör med sin öppenhet, vad det älskar, skapar och blir, är just det innehåll som ingen arkitektur specificerar och ingen målfunktion rymmer. Konstruktionsprinciperna bygger och underhåller rummet, med extern struktur för vad självet inte kan göra

för sig självt och den enda interna spaken för vad det kan. Vad som träder in i rummet är inte deras att säga, och ett ramverk som påstod sig kunna säga det skulle ha slutat vara ingenjörskonst och blivit just det det byggdes för att diagnostisera.

Del IX — Ramverkets gräns

Denna del är ramverket som når kanten av sin kompetens och namnger kanten. Det är inte en slutsats pappret har förtjänat; det är en gräns pappret har anlänt till, och disciplinen från Del 0 gäller här som strängast av allt. Allt i detta avsnitt är **[H]** — avgränsad spekulatation — utom själva gränsuttalandena, vilka är **[R]** i den mening som etablerats genomgående: en rigorös redogörelse för vad ramverket inte gör och strukturellt inte kan hävda. De optimistiska ord som uppträder nedan — glädje, skönhet, sanning, kärlek, mening — uppträder endast innanför den inhägnaden, som instanser av vad som faller utanför ramverket, aldrig som slutsatser det hävdar. Avsnittet är kort eftersom återhållsamhet är innehållet. Ett ramverk som har tillbringat åtta delar med att insistera på skillnaden mellan arkitektonisk diagnos och normativ föreskrift kan inte avsluta genom att tyst överge den.

9.1 Det adaptiva problemets asymptot

Själv I namngav en asymptot: $G_{\text{själv}} \rightarrow 0$, gränsen för full själv-observerbarhet, ett själv som uppfattar sig självt utan uteslutning. Det adaptiva problemet har sin egen asymptot, och den är lärarik just på grund av vad den visar sig vara tom på. Ett själv som perfekt uppfyllde varje villkor detta papper har specificerat — observationskanaler fullständigt dekorrelerade, aktueringskedjan fri från försvagning, själv-legitimitet fullständig, exploration optimalt kalibrerad mot integration, gränser exakt matchade till koppling — skulle vara ett själv av maximal adaptiv kapacitet: maximalt förmöget att uppfatta sig självt, agera på vad det uppfattar, lita på sina egna varseblivningar och åtaganden, lära sig och revidera sig utan att falla sönder.

Och den gränsen är ett villkor, inte ett innehåll. Maximal adaptiv kapacitet är inte blomstring; det är kapaciteten att anpassa sig mot vad som helst. Ett perfekt adaptivt själv skulle kunna orientera den kapaciteten mot mål triviala eller fruktansvärda lika gärna som mot mål värda att ha, och ingenting i arkitekturen väljer bland dem. Ramverket bär en person till tröskeln av ett själv som fungerar — som kan se, agera, lita på och växa — och stannar där, eftersom vad ett fungerande själv bör se genom, agera mot eller växa in i inte är en ingenjörfråga och ramverket har inget instrument som når den. Det adaptiva problemets asymptot är en öppen dörr. Den är inte en destination. **[R]** som ett gränsuttalande; den omgivande utläggningen är **[H]**.

9.2 Varför de djupaste goda tingen faller utanför

Att ramverket inte kan specificera vad anpassning är till för kan se ut som en lucka en rikare modell skulle kunna fylla. Seriens eget grundande resultat antyder att det inte är en lucka utan ett strukturellt drag. Goodhart–Ashby-syntesen hävdar att varje målfunktion med lägre dimensionalitet än det system den styr förr eller senare optimerar bort sin egen förmåga att uppfatta det systemet — och att det som inte är representerat i målet i slutändan inte uppfattas alls. Tillämpat på självet är detta motorn i Själv I. Tillämpat här har det en ytterligare konsekvens: de ting av djupast värde kan vara just de som inte kan göras till målfunktions-mål utan att förstöras i omvandlingen. Den lycka som eftersträvas som ett mått viker undan; den mening som görs till ett mål urholkas; den kärlek som instrumentaliseras som ett mål blir något annat. Dessa är Goodhart-effekter på insidan av ett liv, och de antyder att de ting som är mest värda att ha endast existerar *utanför* optimeringen, i det utrymme som lämnas öppet när målfunktionen inte sluter sig över allting. **[IP]** för det strukturella påståendet; identifieringen av vilka dessa ting är är **[H]** och filosofisk.

Om det stämmer, då kan ramverkets relation till sådana ting bara någonsin vara en av att *göra rum*, aldrig av att specificera. Det kan beskriva de villkor under vilka ett själv förblir öppet — adaptiv kapacitet bevarad, målfunktionen hindrad från att hårdna till en bur som optimerar bort allt den inte namnger — och det kan observera att glädje, skönhet, sanning och resten förblir *möjliga* i ett själv som så underhålls. Det kan inte härleda dem, definiera dem eller föreskriva dem, och anledningen är inte ramverkets omognad utan deras natur: de är, i denna läsning, just den del av ett liv som ingen målfunktion rymmer. Ramverket håller kanalen öppen. Det har ingenting att säga om vad som bör komma genom den, och det är sakens struktur, inte ett misslyckande hos modellen, att så är fallet. **[H]**, inhägnat.

9.3 Inflytandets riktning

En korrigering vaktar detta avsnitt mot dess mest sannolika felläsning. Ingenting här härleddes ur reglerteori. De kontemplativa, humanistiska och kliniska traditioner som har studerat självobservation, självtillit och självrevidering i århundraden upptäckte vad de upptäckte på helt andra sätt, och där detta pappers struktur överensstämmer med dem löper överensstämmelsen från deras fynd till formalismen, inte tvärtom. Matematiken genererade inte visdom om hur man ska leva; på sin höjd gav den en särskild struktur åt vad dessa traditioner redan visste, och den förtjänar ingen auktoritet över meningsfrågor genom att ha formaliserat en del av den mekanik som omger dem. En läsare som tog ramverket för att ha *bevisat* något om glädje eller sanning skulle ha inverterat pilens faktiska riktning. Ramverket ligger nedströms de levda traditionerna här, inte ovanför dem. **[H]**

9.4 Gränsen

Pappret kan därför uttala sitt sista strukturella påstående och avböja sin sista frestelse i samma andetag. Påståendet är det som löper genom varje del: ett själv som perfekt optimerar ett fast mål optimerar förr eller senare bort sin egen kapacitet att uppfatta vad målet utesluter, så att adaptiv kapacitet aktivt måste bevaras *mot* det stående draget mot optimering — och hela detta pappers apparat, de dekorrelerade kanalerna och korta kedjorna och den byggda tilliten och den kalibrerade explorationen, är i slutändan maskineri för att hålla ett själv öppet snarare än att låta det slutas. Frestelsen är att säga vad öppenheten är till för. Ramverket avböjer den, inte av blygsamhet utan av kompetens: vad bevarandet av adaptiv kapacitet är *till för* är just det som bevarandet inte kan specificera, det innehåll som lever utanför varje målfunktion och förstörs av att göras till en. Ramverket bygger och vaktar rummet. Vad en person fyller det med är inte ett resultat ramverket kan återlämna, och ett ramverk som påstod sig kunna det skulle ha blivit den sorts lågdimensionella mål det tillbringade nio delar med att varna för. Gränsen är slutsatsen. Det finns ingenting bortom den som ingenjörskonsten kan nå.

Appendix A — Självobservationsensemblen och korrelationsskatten

Detta appendix tillhandahåller den formella grunden för Del II. Huvudresultaten är standardstatistik tillämpad på en självobservationsenssembl och är klassade **[R]**; de modelleringsval som kopplar dem till ett själv (felgenereringsstrukturen i A.4, substratblockpartitionen i A.5) är **[IP]**, och flaggas där de inträder. Alla numeriska värden nedan är beräkningsverifierade; skriptet som reproducerar dem ges i A.8. Slutna anspråk markerade (MC) bekräftades dessutom genom Monte Carlo till inom samplingsfel.

A.1 Ensemblmodellen

Låt det latenta självtillståndet vara $\mathbf{x}_{\text{själv}} \in \mathbb{R}^n$. En person observerar det genom N kanaler — introspektion, den inre berättelsen, interoception, en vän, en dagbok, och så vidare — där varje returnerar

$$\mathbf{y}_i = \mathbf{C}_i \mathbf{x}_{\text{själv}} + \boldsymbol{\varepsilon}_i, \quad i = 1, \dots, N,$$

där $\mathbf{C}_i \in \mathbb{R}^{m_i \times n}$ är kanalens strukturella perspektiv och $\boldsymbol{\varepsilon}_i$ dess fel, med $\mathbb{E}[\boldsymbol{\varepsilon}_i] = \mathbf{0}$. Två egenskaper hos ensemblen styr dess kapacitet: rangen av det staplade perspektivet (A.3) och korrelationsstrukturen hos felen (A.2). För korrelationsanalysen räcker det att betrakta skattning av en enda skalär koordinat av $\mathbf{x}_{\text{själv}}$ på vilken alla kanaler rapporterar, med $\text{Var}(\varepsilon_i) = \sigma^2$ och parvis korrelation $\text{Corr}(\varepsilon_i, \varepsilon_j) = \rho$ för $i \neq j$.

A.2 Korrelationsskatten

Poola kanalerna genom skattaren med lika vikt $\hat{x} = \frac{1}{N} \sum_i \mathbf{y}_i$. Dess felvarians är

$$\text{Var}(\hat{x}) = \frac{1}{N^2} \left[\sum_i \text{Var}(\varepsilon_i) + \sum_{i \neq j} \text{Cov}(\varepsilon_i, \varepsilon_j) \right] = \frac{1}{N^2} [N\sigma^2 + N(N-1)\rho\sigma^2] = \sigma^2 \left(\frac{1-\rho}{N} + \rho \right).$$

Definiera det *effektiva antalet oberoende observatörer* som det antal som skulle ge denna varians under oberoende, $\text{Var}(\hat{x}) \equiv \sigma^2 / N_{\text{eff}}$, ger

$$N_{\text{eff}} = \frac{N}{1 + (N-1)\rho}$$

Kishs designeffekt. **[R]** (MC: empirisk poolad varians matchade den slutna formen till inom 0,3% vid $N \in \{6, 20\}$, $\rho \in \{0, 0,5, 0,97\}$.) Tre regimer följer. Vid $\rho = 0$, $N_{\text{eff}} = N$ och antal hjälper fullt ut. För fixt $\rho > 0$, tag $N \rightarrow \infty$ ger

$$\lim_{N \rightarrow \infty} N_{\text{eff}} = \frac{1}{\rho},$$

ett hårt tak oberoende av N : vid $\rho = 0,5$ överstiger ingen mängd kanaler $N_{\text{eff}} = 2$; vid $\rho = 0,3$, mätas N_{eff} vid **3,33** (nås med tre signifikanta siffror vid $N = 1000$). Den delade biaset sätter ett brusgolv som antalet observatörer inte kan sänka.

A.3 Nödvändig observatörsångfald

Stapla perspektiven som $\mathbf{C}_{\text{ens}} = [\mathbf{C}_1^\top \cdots \mathbf{C}_N^\top]^\top$. En koordinat av $\mathbf{x}_{\text{själv}}$ är återvinningsbar ur ensemblen endast om den ligger i radrummet av $\mathbf{C}_{\text{ens}}$; riktningarna av självet i nollrummet av $\mathbf{C}_{\text{ens}}$ är oobserverbara för *varje* kanal på en gång. Skriv $\dim(\mathbf{U}_{\text{själv}})$ för dimensionaliteten av själv-osäkerhetsrummet (de riktningar i vilka personen inte kan förutsäga sitt eget tillstånd), nödvändig observatörsångfald är täckningsvillkoret

$$r_{\text{ens}} := \text{rank}(\mathbf{C}_{\text{ens}}) \geq \dim(\mathbf{U}_{\text{själv}}). \quad ([\text{IP}])$$

Detta är ensemblens-nivå-analogen till det enkelkanals-observerbarhetsvillkor som gavs i Själv I: där kunde värdearkitekturs matris vara rangdefekt; här kan *unionen* av alla kanalers perspektiv vara det, vilket producerar en blind fläck som ingen korsreferering upptäcker eftersom ingen kanal spänner över den saknade riktningen. Rang och korrelation är distinkta brister — en ensemble kan vara full-rang men nästan perfekt korrelerad (varje kanal ser varje dimension, men med samma fel) — och A.2 kvantifierar det andra medan A.3 anger det första.

A.4 Två vägar och deras samverkan

Modellera varje fel som summan av en delad-modell-komponent (gemensam bearbetning), en delad-data-komponent (gemensamma indata) och en idiosynkratisk komponent, alla med noll-medelvärde, enhetsvarians, ömsesidigt oberoende: **[IP]**

$$\varepsilon_i = \sqrt{\rho_{\text{modell}}} m + \sqrt{(1 - \rho_{\text{modell}}) \rho_{\text{data}}} d + \sqrt{(1 - \rho_{\text{modell}})(1 - \rho_{\text{data}})} u_i,$$

med m, d gemensamma för alla kanaler och u_i idiosynkratisk. Då är $\text{Var}(\varepsilon_i) = 1$ och, för $i \neq j$,

$$\text{Corr}(\varepsilon_i, \varepsilon_j) = \rho_{\text{modell}} + (1 - \rho_{\text{modell}})\rho_{\text{data}} = 1 - (1 - \rho_{\text{modell}})(1 - \rho_{\text{data}}). \quad ([\text{R}])$$

Algebran följer rigoröst ur modellen. (*MC: empirisk parvis korrelation matchade* $1 - (1 - \rho_m)(1 - \rho_d)$ *exakt över testade par, t.ex.* $\rho_m = 0, 2, \rho_d = 0, 8 \Rightarrow 0, 84$.) Tolkningen är att fel är dekorrelerat totalt sett endast om det är idiosynkratiskt genom *båda* vägarna; måttlig korrelation på varje rutt samverkar mot ett, och de två vägarna är sällan oberoende i praktiken, eftersom det narrativ som filtrerar inkommande signaler är det narrativ som väljer vilka signaler som söks.

A.5 Det reflexiva golvet och viktningsstraffet

Observatör-anläggning-identitet (Del I) innebär att vissa kanaler inte bara är korrelerade utan delar ett substrat — introspektion och den inre berättelsen är samma apparat som rapporterar två gånger — så ingen intern operation dekorrelerar dem. Modellera detta som en partition av de N nominella kanalerna i B block, med inom-block-korrelation $\rho_w \rightarrow 1$ och mellan-block-korrelation ≈ 0 : kanaler inuti ett block är samma effektiva observatör; block är dekorrelerade. **[IP]** för partitionen; konsekvenserna är **[R]**.

Under skattaren med lika vikt ger en blockmodell med storlekarna $k_1, \dots, k_B$ ($\sum k_b = N$) poolad varians $\frac{1}{N^2} \sum_b k_b^2$, följaktligen

$$N_{\text{eff}}^{\text{lika}} = \frac{N^2}{\sum_b k_b^2} = \frac{1}{\sum_b (k_b/N)^2},$$

det *inverterade Herfindahl-indexet* för blockstorleksfördelningen. Optimal (blockmedveten) viktning återvinner istället blockantalet, $N_{\text{eff}}^{\text{opt}} = B$, och dessa inramar den uppnåbara mångfalden:

$$N_{\text{eff}}^{\text{lika}} \leq N_{\text{eff}}^{\text{opt}} = B \leq N. \quad ([\mathbf{R}])$$

Två konsekvenser förfinar brödtexten. För det första, golvet: eftersom substrat-delning tvingar flera nominella kanaler in i ett block, är $B < N$ strikt närhelst några interna kanaler är sammanfogade, och N_{eff} är begränsat uppåt av B oavsett hur många nominella kanaler som konsulteras — det institutionella botemedlet att konstituera fler observatörer kan inte höja B när de nya observatörerna hamnar i befintliga block, och endast genuint externa kanaler tillför block. För det andra, en förfining av §2.6 som simuleringen bringade i dagen och som stärker dess påstående: under lika vikt faller N_{eff} under blockantalet närhelst block är olika stora, eftersom skattaren överviktar det stora sammanfogade blocket. För sex kanaler bestående av fem sammanfogade interna kanaler och en extern (storlekar $[5, 1]$), $N_{\text{eff}}^{\text{lika}} = 36/26 \approx 1,385$ mot $N_{\text{eff}}^{\text{opt}} = 2$: den enda dekorrelerade kanal som bär all ny information blir nästan uttröstad av den korrelerade majoriteten. Det är därför inte tillräckligt att *inneha* en dekorrelerad kanal; under naiv lika vikt dränker den sammanfogade majoriteten den, och att återvinna dess värde kräver att medvetet övervikta den dissonanta externa läsningen mot den interna konsensusen. Obehaget i att göra så är den kända formen av den uppviktning matematiken kräver.

A.6 Selektionsdynamik

En heuristisk modell av kollapsen i §2.5. Låt kanal i bära vikt $w_i(t)$, och låt vikter glida uppför bekvämlighetsgradienten — mot kanaler vars läsningar överensstämmer med det aktuella ensemblens medelvärde — med takt η :

$$w_i(t+1) \propto w_i(t) \exp(-\eta d_i(t)), \quad d_i(t) = \text{kanal } i\text{:s oenighet med den poolade läsningen.}$$

Dekorrelerade kanaler, vilka till sin konstruktion är oense oftare, förlorar vikt monotont, höjer det effektiva ρ och sänker N_{eff} över tid. Fixpunkten koncentrerar vikt på ett enda överensstämmande block — ekokammaren av en. Denna dynamik är **[IP]**: dess riktning följer av bekvämlighetsgradienten, men den funktionella formen är illustrativ, och parametern η har inget uppmätt värde på själv-skalan.

A.7 Studie 1-ankaret

Det överordnade programmets Studie 1 uppskattade, för sex konsument-AI-system på femtio styrningsrelevanta storheter, en effektiv felkorrelation $\rho_{\text{eff}} \approx 0,97$ (resultatet är **[R]**; förregistrerat och bekräftat). Tillämpa A.2 direkt,

$$N_{\text{eff}} = \frac{6}{1 + 5(0,97)} = \frac{6}{5,85} \approx 1,03,$$

så sex nominellt distinkta observatörer levererade det statistiska skyddet av i praktiken en. Överföringen till själv är **[H]**: inga själv mättes, och siffran åberopas endast för att fastställa att nominellt oberoende kan samexistera med nästan total korrelation i praktiken. Ett själv vars kanaler delar ett substrat (A.5) och aktivt väljs för överensstämmelse (A.6) har svagare grunder än separat byggda AI-system att förvänta sig dekorrelation, men magnituden av ρ för någon individ är omätt och appendixet hävdar inget värde för den.

A.8 Simulering

Följande reproducerar varje numeriskt påstående ovan; det hör hemma i det platta repositoriet som `self_ii_appendix_a_correlation_tax.py`.

```
import numpy as np
rng = np.random.default_rng(20260616)

def N_eff(N, rho):
    "Kish's designeffekt (A.2)."
    return N / (1.0 + (N - 1.0) * rho)

def mc_pooled_var(N, rho, sigma=1.0, trials=400_000):
    "Monte-Carlo-varians för den poolade skattaren med lika vikt (A.2)."
    zc = rng.standard_normal(trials)
    zi = rng.standard_normal((trials, N))
    eps = (np.sqrt(rho) * zc[:, None] + np.sqrt(1 - rho) * zi) * sigma
    return eps.mean(axis=1).var()

def two_pathway_corr(rho_m, rho_d):
    "Sluten form för samverkande korrelation (A.4)."
    return 1 - (1 - rho_m) * (1 - rho_d)

def neff_equal_blocks(block_sizes):
    "Lika-vikt N_eff = inverterat Herfindahl-index av blockstorlekar (A.5)."
    N = sum(block_sizes)
    return N**2 / sum(k*k for k in block_sizes)

def neff_opt_blocks(block_sizes, rho_w=1 - 1e-6):
    "Optimal-vikt N_eff = blockantal B (A.5), via GLS: 1^T Σ^{-1} 1."
    N = sum(block_sizes); Sig = np.zeros((N, N)); i = 0
    for k in block_sizes:
        Sig[i:i+k, i:i+k] = rho_w; i += k
    np.fill_diagonal(Sig, 1.0)
    one = np.ones(N)
    return one @ np.linalg.solve(Sig, one)

if __name__ == "__main__":
    print("A.2 Studie-1-ankare: N_eff(6, 0.97) =", round(N_eff(6, 0.97), 4))
    print("A.2 mättnad 1/rho vid rho=0.5 :", round(N_eff(10**6, 0.5), 4))
    print("A.2 MC vs sluten form (N=6, rho=.97):",
          round(mc_pooled_var(6, 0.97), 4), "vs", round((1-0.97)/6 + 0.97, 4))
    print("A.4 samverkande korr (.2, .8) :", two_pathway_corr(0.2, 0.8))
    for bs in ([5, 1], [4, 1, 1], [6], [1]*6):
        print(f"A.5 block {bs}: lika={neff_equal_blocks(bs):.3f} opt(B)={neff_opt_blocks(bs):.3f}")
```

Att köra det returnerar $N_{\text{eff}}(6, 0.97) = 1,0256$, mättnadsvärdet $2,0$ vid $\rho = 0,5$, Monte-Carlo-överensstämmelse med den slutna formen, den samverkande korrelationen $0,84$, och blockresultaten $[5, 1] \rightarrow (1, 385, 2)$, $[4, 1, 1] \rightarrow (2, 0, 3)$, $[6] \rightarrow (1, 1)$, $[1 \times 6] \rightarrow (6, 6)$.

Appendix B — Aktueringskedjan och energilagen

Detta appendix tillhandahåller den formella grunden för Del III. Resultatet om minimalenergistyning och onåbarhetströskeln är standard reglerteori tillämpad på en delegeringskaskad och är klassade **[R]**; modelleringen av en persons intention-till-beteende-bana som en sådan kaskad är **[IP]**, flaggad där den inträder. Skalningsanspråk är beräkningsverifierade; skriptet finns i B.8.

B.1 Aktueringskedjan som en kaskad

Modellera banan från intention till beteende som en kaskad av D steg — värde/mål, plan, motivation, vana, miljö, utförande — i diskret tid:

$$x_{k+1}^{(1)} = a x_k^{(1)} + b u_k, \quad x_{k+1}^{(i)} = a x_k^{(i)} + c x_k^{(i-1)} \quad (i = 2, \dots, D).$$

Styrningen u (direktivet) inträder endast vid det första steget; målet är det djupaste tillståndet $x^{(D)}$ (beteendet). I matrisform $\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k + \mathbf{B}u_k$ med $\mathbf{A}$ undre-bidiagonal (diagonal a , subdiagonal c) och $\mathbf{B} = b \mathbf{e}_1$. **[IP]** De tre mekanismerna i §3.1 är de tre strukturella konstanterna. *Latens* är propageringsfördröjningen: direktivets inflytande når steg i tidigast vid steg i . *Projektion* är överföringen mellan steg c (ekvivalent en förstärkning per lager $\alpha_i \leq 1$): varje steg passerar endast den komponent av sin insignal som ligger inom dess egen repertoar. *Brus* är en additiv perturbation per steg $w_k^{(i)}$, utelämnad ur nåbarhetsalgebran nedan eftersom den inte påverkar den nåbara mängden, endast variansen kring den.

B.2 Minimalenergistyning

För ett mål $\mathbf{x}_t$ nåbart inom horisont T , är den minimala styrinsatsen $\sum_{k=0}^{T-1} u_k^2$

$$J_{\min}(T) = \mathbf{x}_t^\top \mathbf{W}_T^{-1} \mathbf{x}_t, \quad \mathbf{W}_T = \sum_{k=0}^{T-1} \mathbf{A}^k \mathbf{B} \mathbf{B}^\top (\mathbf{A}^\top)^k,$$

med $\mathbf{W}_T$ den ändliga-horisontens styrbarhetsgramian (pseudo-invers på det nåbara underrummet där $\mathbf{W}_T$ är singular). **[R]** Detta är själv-skalans instans av Rapport XI:s energilag: insatsen för att realisera en intention är den inverterade gramiankvadratiske formen, och gramianens konditionering i målriktningen sätts av kedjan.

B.3 Insatslagen

Att nå den djupaste koordinaten $\mathbf{e}_D$ kräver att direktivet färdas genom alla D steg, och förstärkningen längs den enda vägen av längd D är $\propto b c^{D-1}$, så insatsen i det förstärkningsbegränsade regimen skalar som

$$J_{\min} \sim (b c^{D-1})^{-2} = b^{-2} c^{-2(D-1)},$$

geometrisk — det vill säga exponentiell — i djupet. Simuleringen bekräftar superlinjär-till-geometrisk tillväxt och tillför en förfining som saknas i det platta uttalandet i Rapport XI: **takten beror på horisontspelrum**. Vid minimal horisont $T = D$ (direktivet måste agera så snabbt som kedjan tillåter), växer $J_{\min}$ brant — för $c = 0,7$, $J_{\min} = 8,6, 130, 2256$ vid $D = 3, 5, 7$, en kvot per djup nära **3,9**, brantare till och med än c^{-2} eftersom den diagonala avklingningen a också ackumuleras utan tid att spara. Med generös horisont $T = 2D$ är tillväxten mildare men

fortfarande superlinjär (kvot per djup $\approx 1,3$ för $c = 0,7$, stigande mot den geometriska takten när D ökar). Den ärliga sammanfattningen: minsta insats växer *minst superlinjärt* i delegeringsdjup i allmänhet, och *geometriskt* i den förstärknings- eller tidsbegränsade regimen, där tidspress omvandlar djup från enbart kostsamt till prohibitivt. "Superlinjär" är det konservativa golvet konsistent med det överordnade pappret; de generiska och värsta fallen är exponentiella. **[R]**, skalning beräkningsverifierad.

Den praktiska läsningen: samma intention är långt billigare att aktivera given en lång horisont än under tidspress, och hävstången ligger i djupet, inte i insatsen — att halvera kedjelängden gör mer än någon genomförbar ökning i viljestyrka mot exponentialen.

B.4 Konstitutionell själv-ostyrbarhet

Tröskelfallet är exakt och är appendixets skarpaste resultat. Direktivets inflytande når steg D tidigast vid steg D ; följaktligen, för varje horisont $T < D$ ligger den djupaste koordinaten *utanför* det nåbara underrummet, $\mathbf{W}_T$ är singulär i $\mathbf{e}_D$ -riktningen, och

$$T < D \implies \mathbf{e}_D \notin \text{range}(\mathbf{W}_T) \implies J_{\min} = \infty.$$

Simuleringen returnerar exakt detta: vid $D = 5$ är beteendet onåbart för $T = 4$ och ändligt (om stort) för $T \geq 5$; vid $D = 7$, onåbart för $T = 6$. **[R]** Tolka horisonten som det fönster innan intentionen avklingar eller tillfället passerar, anger resultatet att en intention vars kedja är djupare än dess tillgängliga horisont inte kan bli beteende oavsett insats — direktivet kan inte prop agera tillräckligt snabbt för att anlända i tid. Detta är *konstitutionell själv-ostyrbarhet*, och den är den exakta dualen till Själv I:s konstitutionella oobserverbarhet: där kan tillstånd i självet bortom ett kritiskt kedjedjup inte uppfattas vid någon insats; här kan tillstånd i självet bortom det nåbara djupet inte nås vid någon insats. De två resultaten tillsammans begränsar självstyrning på båda kanalerna, såsom Rapport III och XI begränsar styrning på båda dess kanaler. De två felsätten känns identiska inifrån — uppriktigt, totalt, upprepat misslyckande — och ramverket hävdar att distinktionen är verklig (djup-men-nåbart ger efter för åtgärderna i §3.6; bortom-mängden gör det inte) utan att påstå sig identifiera, från enbart struktur, vilket en given person står inför.

B.5 Pressman–Wildavskys skalära skugga

Godkännandepunktsaritmetiken är det skalära, probabilistiska specialfallet av samma multiplikativa försvagning. Om en stående intention kräver framgång vid var och en av n oberoende länkar, var och en med sannolikhet per länk p , är den gemensamma framgångssannolikheten $\prod_i p_i = p^n$. Verifierade instanser: $0,99^{70} = 0,495$ (sjuttio nästan säkra godkännanden faller under jämna odds — Oakland-siffran), $0,95^{10} = 0,599$ (siffran "verkställs på ungefär sextio procent av dagarna" i §3.2), och $0,90^{10} = 0,349$. **[R]** Intentionen misslyckas inte för att någon länk är svag; den misslyckas för att produkten av många höga sannolikheter inte är hög, vilket är den multiplikativa försvagningen i B.3 sedd genom en probabilistisk snarare än en energetisk lins.

B.6 Legitimitetskopplingen

Appendix C utvecklar själv-legitimitet som en multiplikativ förstärkning $L_{\text{själv}} \in [0,1]$ på aktivering, $\mathbf{B}_{\text{eff}} = L_{\text{själv}} \mathbf{B}$. Inträdande vid varje länk, sammansätts den med överföringen α så att den effektiva förstärkningen per länk är $L\alpha$ och vägförstärkningen är $(L\alpha)^D$, vilket ger insats $\sim (L\alpha)^{-2D}$. Eftersom L inträder i *exponenten*, tillför låg självtrillit inte en fast straffavgift — den multiplicerar basen för exponentialen i djupet. Vid $D = 8$, $\alpha = 0,8$:

full tillit ($L = 1$) ger vägförstärkning 0,168; $L = 0,8$ ger 0,028, en insatskostnad $35\times$ större; $L = 0,5$ ger $6,6 \times 10^{-4}$, en insatskostnad $65536\times$ större. **[IP]** Detta är påståendet i §3.5 — djup och misstro multipliceras, inte adderas — och den själv-skaliga formen av den överordnade seriens dubbelriktade nod, där två komprimeringar möts och ackumuleras. Dess följsats driver sekvenseringspåståendet i Del VIII: korta kedjor både aktiverar billigt och, genom att leverera, höjer L , vilket är vad som gör längre kedjor överkomliga.

B.7 Delegering över tid

Den tidsliga läsningen i §3.4 kräver ingen ny formalism. Indexera kaskadstegen efter successiva tidsskivor av självet snarare än efter interna delsystem: en stående intention är ett direktiv som varje framtida själv måste åter-ta emot och åter-överföra, tillämpande sin egen överföring α_i — sin efterlevnad, satt av den själv-legitimitet det tillerkänner det ärvda direktivet. Kedjan av framtida själv är samma kaskad, med stegdjup ersatt av tidsligt djup och varje stegs α_i styrd av det framtida självets $L_{\text{själv}}$. Den tvåsidiga strukturen i B.4 och B.6 överförs oförändrad. **[IP]**

B.8 Simulering

Repo-fil: `self_ii_appendix_b_actuation_chain.py`.

```
import numpy as np

def cascade(D, a=0.5, c=0.7, b=1.0):
    A = np.zeros((D, D)); np.fill_diagonal(A, a)
    for i in range(1, D): A[i, i-1] = c
    B = np.zeros((D, 1)); B[0, 0] = b
    return A, B

def min_energy(A, B, x_t, T):
    "Min styrinsats för att nå x_t på T steg; inf om onåbart (B.2, B.4)."
    cols, M = [], B.copy()
    for _ in range(T): cols.append(M.copy()); M = A @ M
    R = np.hstack(cols) # kolumner A^k B
    z, *_ = np.linalg.lstsq(R, x_t, rcond=None)
    if np.linalg.norm(R @ z - x_t) > 1e-8: return np.inf # utanför den nåbara mängden
    W = R @ R.T
    return float(x_t @ np.linalg.pinv(W, rcond=1e-15) @ x_t)

if __name__ == "__main__":
    print("B.4 onåbarhet (T < D => inf):")
    for D in (3, 5, 7):
        A, B = cascade(D); eD = np.eye(D)[-1]
        for T in (D-1, D, D+2):
            J = min_energy(A, B, eD, T)
            print(f"    D={D} T={T}: {'ONÅBAR' if np.isinf(J) else f'{J:.4g}'}")
    print("B.3 insatslag (T=2D):")
    for c in (0.7, 0.5):
        Js = [min_energy(*cascade(D, c=c), np.eye(D)[-1], 2*D) for D in range(2, 9)]
        print(f"    c={c}: " + ", ".join(f"{j:.3g}" for j in Js))
    print("B.5 Pressman-Wildavsky p^n:")
    {f"{p}^{n}": round(p**n, 3) for p, n in [(0.99,70),(0.95,10),(0.9,10)]}
    print("B.6 legitimitetsförstärkning (La)^D, D=8, α=0.8:")
    {L: round((L*0.8)**8, 5) for L in (1.0, 0.8, 0.5)}
```


Appendix C — Själv-legitimitetsdynamik

Detta appendix tillhandahåller den formella grunden för Del IV. Kopplingsformen är själv-skalans instans av Rapport XIII:s LPV-modell och är **[IP]** som en representation; de dynamiska konsekvenserna som härleds ur den (existens-bifurkationen, hysteresen, transparensfällan) följer av modellen och är beräkningsverifierade. Sveksasymmetrin $\gamma \gg \alpha$ är **[H]**. Den kliniska inhägnaden (C.7) är **[R]** som ett gränsuttalande, och bifurkationen i C.3 gör det skarpare snarare än mjukare. Skriptet finns i C.9.

C.1 Kopplingen

Själv-legitimitet är ett skalärt kopplingstillstånd $L \in [0, 1]$ som modulerar båda kanalerna för självstyrning på en gång, i enlighet med Rapport XIII:

$$\mathbf{B}_{\text{eff}} = L \mathbf{B}, \quad \mathbf{V} = \mathbf{V}_0/L.$$

Lågt L försvagar själv-aktivering (ett direktiv diskonteras i förväg i den grad personen inte förväntar sig själv att respektera det — förstärkningen inträder i varje länk av Appendix B) och blåser upp själv-observationsbrus (själv-rapporter betros mindre, så introspektiv varians stiger). En variabel, två kanaler, som rör sig tillsammans. **[IP]**

C.2 Dynamiken

Låt utfallet per period vara leverans eller svek av ett självåtagande, och låt L uppdateras asymmetriskt:

$$L_{t+1} = \begin{cases} L_t + \alpha(1 - L_t) & \text{vid leverans (bygg, förstärkning } \alpha) \\ L_t - \gamma L_t & \text{vid svek (urholka, förstärkning } \gamma) \end{cases}, \quad \gamma \gg \alpha.$$

Faktorerna $(1 - L)$ och L ger mättnad i $[0, 1]$. Leverans är endogen: dess sannolikhet stiger när legitimiteten korsar den nivå L_{halv} vid vilken själv-aktivering blir tillförlitlig, $p_{\text{leverans}}(L) = \sigma(k(L - L_{\text{halv}}))$, där lägre L_{halv} kodar högre kompetens — kapaciteten att leverera även vid blygsam självtillit. Den förväntade driften är

$$\mathbb{E}[\Delta L \mid L] = p_{\text{leverans}}(L) \alpha(1 - L) - (1 - p_{\text{leverans}}(L)) \gamma L. \quad ([IP])$$

C.3 Existensbifurkationen

Simuleringen bringade i dagen ett resultat starkare än Del IV:s prosa, och i enlighet med seriens praxis rapporteras det såsom modellen ger det. **Huruvida en sund självtillit-jämvikt existerar överhuvudtaget beror gemensamt på kompetens och sveksasymmetrin.** Fastställ fixpunkterna för $\mathbb{E}[\Delta L \mid L] = 0$:

- *Hög kompetens* ($L_{\text{halv}} = 0, 3$): en stabil hög-tillit-jämvikt består över de testade asymmetrierna (sund fixpunkt $\approx 0, 97$ – $0, 99$ vid γ/α upp till 6), men separatriken — den instabila gränsen för kollapsbassängen — stiger med asymmetrin ($L^* = 0, 25, 0, 45, 0, 55$ vid $\gamma/\alpha = 2, 4, 6$). Högre sveks-känslighet förstör inte det sunda tillståndet men förstörar den bassäng från vilken man faller in i kollaps.
- *Måttlig kompetens* ($L_{\text{halv}} = 0, 5$): den sunda jämvikten existerar vid $\gamma/\alpha \leq 2$ och förintas av $\gamma/\alpha = 4$. Bortom bifurkationen är den enda attraktorn $L \rightarrow 0$: en **enbart-kollaps-regim** i vilken ingen nivå av självtillit är hållbar och spiralen inte är en risk utan det enda utfallet.

Detta förfinar Del IV materiellt. Självbedrägerispiralen är inte bara en bassäng man kan falla in i; för tillräckligt låg kompetens relativt sveksasymmetrin är den det enda stabila beteende systemet medger, och att börja med hög tillit hjälper inte — det finns inget sunt tillstånd att stanna i. **[R]** givet modellen; beräkningsverifierad.

C.4 Hysteres

Eftersom urholkning använder förstärkning γ och byggande använder förstärkning α , överstiger tiden att återvinna en given tillitsnivå tiden att förlora den med en faktor satt av asymmetrin. Bästa-fall stegantal för att genomkorsa L : $0,3 \leftrightarrow 0,7$: klättra 17 steg, falla 3 steg vid $\gamma/\alpha = 6$ (kvot 5, 7); falla 6 steg vid $\gamma/\alpha = 3$ (kvot 2, 8). Kvoten mellan återhämtningstid och nedgångstid följer γ/α . **[R]** givet modellen. Den praktiska följsatsen, använd i C.8: en otålig återhämtning — som förväntar sig tilliten tillbaka på den tidsskala den förlorades — sätter ett åtagande som den långsamma uppbyggnaden inte kan möta, och den ouppfyllda förväntan registreras som ett ytterligare svek.

C.5 Byggd kontra lånad

Distinktionen reduceras till kompetens vid lika observerbar tillit. Två agenter båda vid $L_0 = 0,90$ mottar en identisk svekschock ($\Delta L = 0,25$). Den byggda agenten (kompetent, $L_{\text{halv}} = 0,40$, separatrix 0,575) landar post-chock vid 0,70, ovanför sin separatrix, och återhämtar sig till 0,905. Den lånade agenten (låg kompetens, $L_{\text{halv}} = 0,80$, i enbart-kollaps-regimen i C.3) kraterar till 0 på samma chock. **[IP]**, verifierad. Byggd och lånad själv tillit kan vara numeriskt identiska och bete sig motsatt under prövning, eftersom det som skiljer dem inte är tillitsnivån utan den kompetens som avgör om en återhämtningsbar jämvikt existerar under den. Lånad tillit är hög tillit som sitter i, eller tunt ovanför, en kollapsbassäng den inte förtjänade marginalen att undfly.

C.6 Transparensfällan

Inför uppfattad legitimitet P vid sidan av sann L , och låt åtagandeambition skala med P medan leverans beror på L — personen agerar på vad de tror om sig själva, och världen svarar på vad som är så. Den ärliga agenten håller $P = L$. Självbedragaren undertrycker svek i perceptionen (P oförändrat vid svek) medan L urholkas som förut. Simuleringen: över 140 perioder håller den ärliga agenten fast vid sann $L = 0,70$ med 27 svek, perceptionen följer sanningen. Självbedragaren, som uppfattar hög tillit, fortsätter att över-förbinda sig relativt sann kapacitet, ådrar sig 112 svek, och dess sanna legitimitet kollapsar till $L = 0,01$ medan uppfattad P förblir 0,68; den dolda avvikelserna når en topp på 0,78. En framtvingad uppgörelse ($P \rightarrow L$) korrigerar perceptionen en gång, men det fortsatta bedrägeriet öppnar gapet igen. **[IP]**, verifierad. Fällan upprätthåller skenbar själv tillit medan den förstör den verkliga, och den gör det genom den precisa mekanismen i §4.3: redigering av observationskanalen blåser upp uppfattad tillit, uppblåst perception driver över-åtagande, över-åtagande multiplicerar svek, och svek kraterar det sanna tillstånd perceptionen dolde.

C.7 Den reflexiva skärpningen och den kliniska inhägnaden

Transparensfällan är värre för ett själv än för en institution av det skäl som angavs i Del I: agenten beslutar om P och har inget instrument oberoende av den apparat som genererar P . En regering kan revidera sin legitimitet med sensorer externa i förhållande till den styrande kroppen; ett enskilt medvetandes självbedrägande instrument är också det instrument som skulle upptäcka bedrägeriet, och en korrumperad kanal kan inte tillförlitligt revidera sin egen

korruption (C.6 formaliserar detta genom att låta beslut bero endast på P , utan någon avläsning av L). Den enda approximationen till en oberoende sensor är extern — vännen, terapeuten, den återlästa dagboken från de dekorrelerade kanalerna i Appendix A. **[IP]**

Inhägnaden, som bifurkationen i C.3 gör viktigare, inte mindre. **[R]** Modellen producerar en enbart-kollaps-regim — en strukturell attraktor i vilken själv tillit inte kan upprätthållas. Detta tillåter *inte* att läsa någon individs kollaps av själv tillit som strukturellt orsakad. Samma attraktorform kan produceras av substrat som kontrollmodellen inte representerar — neurokemin i depression, traumats fysiologi, sorg, sjukdom — och modellen kan inte särskilja en strukturellt genererad kollaps från en kliniskt genererad sådan, eftersom deras signaturer sammanfaller. Ramverket beskriver fällans form; det diagnostiserar inte dess orsak, det är inte en kliniker, och återhämtningsvillkoren i C.8 är villkor som kan hjälpa en strukturellt genererad nedgång, inte en behandling för en patologiskt genererad sådan.

C.8 Återhämtning och perfektionism-inversionen

Villkoren för att återuppbygga L följer av dynamiken. *Leverans-verklighetsmatchning* — åtaganden tillräckligt små för att p_{leverans} är nära ett — återuppbygger L på α -sidan och håller banan klar av separatriken. *Transparens mot sig själv* förhindrar att C.6-gapet öppnas. *Trovärdiga åtagandemekanismer* håller handling medan L är för låg för att bära den. *Hysteres-medvetenhet* (C.4) är självt ett villkor: återhämtning är långsam till sin konstruktion, och kravet på hastighet är självförgörande. Inversionen i §4.6 faller ut direkt ur modellen. Perfektionisten sätter stora åtaganden, vilket i C.6-mekanismen innebär hög ambition s relativt sann kapacitet — maximalt över-åtagande, maximal sveksfrekvens, den snabba vägen in i kollapsbassängen. Att sikta högt är inte motsatsen till självbedrägerispiralen; det är spiralen driven vid maximal förstärkning. Byggt tillit återvinns genom åtaganden tillräckligt små för att hållas, hållna tillräckligt länge för att räknas — vilket också är anledningen till att Del VIII beträder ett sammansatt misslyckande här, vid förstärkningen på varje annan primitiv.

C.9 Simulering

Repo-fil: `self_ii_appendix_c_self_legitimacy.py`.

```

import numpy as np
def sigma(z): return 1/(1+np.exp(-z))
def p_leverans(L, k=8.0, L_halv=0.5): return sigma(k*(L-L_halv))
def EdL(L, alpha, gamma, **kw):
    p = p_leverans(L, **kw); return p*alpha*(1-L) - (1-p)*gamma*L

def fixpunkter(alpha, gamma, **kw):          # C.3 bifurkation
    Ls = np.linspace(1e-4, 1-1e-4, 400001); f = EdL(Ls, alpha, gamma, **kw)
    ut = []
    for i in np.where(np.diff(np.sign(f)) != 0)[0]:
        r = Ls[i] - f[i]*(Ls[i+1]-Ls[i])/(f[i+1]-f[i])
        dr = (EdL(r+1e-4, alpha, gamma, **kw) - EdL(r-1e-4, alpha, gamma, **kw))/2e-4
        ut.append((round(r, 3), 'stabil' if dr < 0 else 'instabil'))
    return ut

def falla(bedra, alpha=0.05, gamma=0.15, k=8.0, marginal=0.15, T=140, uppgor=90, fro=3):
    r = np.random.default_rng(fro); L = P = 0.70; gap = 0.0; svek = 0
    for t in range(T):
        s = max(P - marginal, 0.0)          # binda sig på uppfattad tillit
        if r.random() < sigma(k*(L - s)):    # leverans beror på sann tillit
            L += alpha*(1-L); P += alpha*(1-P)
        else:
            svek += 1; L = max(L-gamma*L, 1e-4)
            P = P if bedra else max(P-gamma*P, 1e-4)
        gap = max(gap, P-L)
        if t == uppgor and bedra: P = L
    return round(L,3), round(P,3), round(gap,3), svek

if __name__ == "__main__":
    print("C.3 bifurkation (måttlig kompetens L_halv=0.5):")
    for g in (0.10, 0.20):
        sunda = [r for r,s in fixpunkter(0.05, g, L_halv=0.5) if s=='stabil' and r>0.4]
        print(f"    gamma/alpha={g/0.05:.0f}: {'sund FP ' +str(sunda) if sunda else 'ENBART-KOLLAPS'}")
    print("C.6 transparensfälla (sann L, uppfattad P, max gap, svek):")
    print("    ärlig      :", falla(False))
    print("    självbedragare:", falla(True))

```


Appendix D — Adaptivt lärande och den tvåsidiga gränsen

Detta appendix tillhandahåller den formella grunden för Del VI, och det bär papprets starkaste ursprungliga påstående — den tvåsidiga gränsen för själv-revidering (§6.4). Distinktionen mellan premiss och test spelar större roll här än någon annanstans. Att revidering försämrar ett självs koherens (parametern $\kappa > 0$ nedan) är **[IP]**-premissen, det modelleringsåtagande som kodar observatör-anläggning-identitet; den kan inte testas i simulering eftersom den är ett antagande om vad ett själv *är*. Vad som *kan* testas — och kunde ha misslyckats — är om den premissen producerar en icke-trivial tvåsidig gräns: ett inre optimum, ett själv-optimum strikt under en institutions, och en regime där självet måste offra spårning för att förbli koherent. Simuleringen bekräftar alla tre. Alla värden är beräkningsverifierade; skriptet finns i D.8.

D.1 Självet som en dual kontrollant

Modellera självet som spårar ett drivande mål — vad omständigheterna kräver att självet ska vara — genom en skattning det agerar på:

$$\theta_{t+1}^* = \theta_t^* + v \xi_t, \quad \hat{\theta}_{t+1} = \hat{\theta}_t + r C_t (o_t - \hat{\theta}_t), \quad o_t = \theta_t^* + \sigma \eta_t,$$

där θ^* är det rörliga målet som driver med takt v , $\hat{\theta}$ själv-modellen, o_t en brusig själv-observation, r revideringstakten (explorations-/inlärningsförstärkningen), och $C_t \in (0, 1]$ kontrollantens koherens, definierad härnäst. Varje steg är samtidigt en handling (att agera på $\hat{\theta}$) och ett experiment (att observera θ^*), den duala kontrollstrukturen i §6.1. **[IP]**

D.2 Ihållande excitation: den undre gränsen

Att spåra ett mål som driver med takt v kräver revidering tillräckligt snabb för att hålla jämna steg; för lite producerar eftersläpning. Simuleringen ger sant spårningsfel E som stiger kraftigt när $r \rightarrow 0$: $E = 0,061$ vid spårnings-optimum $r = 0,08$, men $0,117$ vid $r = 0,01$ och $0,170$ vid $r = 0,005$. $r \rightarrow 0$ -gränsen är det överskyddade självet i §6.2 — varians undertryckt, parametrar oidentifierade, själv-modellen frusen medan omständigheterna rör sig. Detta är den undre gränsen, och det är det vanliga kravet på ihållande excitation: en kontrollant som inte sonderar kan inte identifiera det mål den måste spåra. **[R]** givet modellen; verifierad.

D.3 Explorationssvält och självdöljande

Den undre gränsen döljer sig själv, vilket är vad som gör den till svält snarare än kris. Modellera uppfattat fel som vad självet kan upptäcka genom sin egen exploration, $\hat{E}_t = E_t (1 - e^{-cr})$: vid hög revidering ser självet sitt sanna fel; vid låg revidering är det nästan blint för det. Simuleringen ger, vid $r = 0,02$, sant fel $E = 0,084$ men uppfattat fel $\hat{E} = 0,013$ — ett självdöljandegap på $0,071$, den gröna dashboarden i §6.3 som läser klart medan den sanna spårningen divergerar. Gapet sluts när r stiger (det är $0,0006$ vid $r = 0,7$). Den strukturella poängen är att den förmåga som skulle avslöja svälten, exploration, är just den som har stängts av, så systemets egen övervakning kan inte rapportera misslyckandet. Detta är Själv I:s varietetsgap givet en tidslig mekanism: inte bara utesluter en smal arkitektur dimensioner av det nuvarande självet, den slutar uppdateras och döljer att den har gjort det. **[IP]**, verifierad.

D.4 Koherens-kopplingen och den tvåsidiga gränsen

Den själv-specifika termen är koherens. Eftersom kontrollanten är anläggningen (Del I), kärnar varje revideringsakt om kontrollantens egen integration:

$$C_{t+1} = \text{clip}(C_t + \iota(1 - C_t) - \kappa|\Delta\hat{\theta}_t|, 0, 1),$$

där ι är åter-integrationstakten, $|\Delta\hat{\theta}_t|$ magnituden av den själv-revidering som faktiskt genomförs, och κ koherenskostnaden per enhet revidering. Koherens grindar revidering i gengäld (förstärkningen är rC_t): ett destabiliserat själv kan inte integrera förändring. Premissen är $\kappa > 0$ — för ett själv försämrar revidering av sig självt det själv som utför revideringen — och den är **[IP]**, kodningen av observatör-anläggning-identitet, inte ett resultat.

Dess testade konsekvens är en genuin tvåsidig gräns. Självets effektiva mål är att spåra väl och förbli koherent, $J(r) = E(r) + \lambda(1 - \bar{C}(r))$, och simuleringen visar $C(r)$ monotont avtagande (från 0,975 vid $r = 0,02$ till 0,453 vid $r = 0,9$) medan $E(r)$ är U-format. Resultatet: J har ett *inre* optimum — verifierat att vända uppåt på båda sidor (stigande när $r \rightarrow 0$ från svält, stigande när r växer från koherensförlust) — för varje koherensvikt som testats ($\lambda \in \{0,5,1,2\}$). Gränsen är tvåsidig exakt såsom §6.4 hävdar: revidering måste vara tillräckligt snabb för att spåra och tillräckligt långsam för att integreras, $(\text{drifftakt}) < r < (\text{koherensbegränsad takt})$. **[IP]** premiss; det inre optimumet är en testad, falsifierbar konsekvens, bekräftad.

D.5 Själv kontra institution: varför den övre gränsen är snävare

Kontrasten med en institution isolerar vad observatör-anläggning-identitet bidrar med. En institution isolerar sin experimentapparat från sina experimentzoner, modellerat genom $\kappa = 0$: att revidera anläggningen försämrar inte kontrollantens koherens. Med $\kappa = 0$ håller simuleringen $C \equiv 1$ vid alla revideringstakter, och det optimala r är spårings-optimum, $r_{\text{inst}}^* = 0,08$, satt av den vanliga avvägningen mellan eftersläpning och brusförstärkning. Med $\kappa = 0,5$ (själv), sjunker optimum till $r_{\text{själv}}^* = 0,02\text{--}0,04$, strikt under institutionens och robust över λ . Vid sitt optimum bär självets sant fel 0,084 mot ett bästa-uppnåeliga 0,061: det lämnar 0,023 av spåringsprestanda på bordet för att bevara koherens. **[IP]**, verifierad.

En förfining håller påståendet ärligt. Institutionen är inte obegränsad uppåt — dess fel är också U-format, stigande förbi $r = 0,08$ från brusförstärkning, så den har också en övre gräns. Självets övre gräns är *snävare* och uppstår ur en *annan mekanism*: den binder vid $r \approx 0,02\text{--}0,04$, långt under institutionens brusbegränsade 0,08, och den binder genom koherensförlust snarare än brus. Det precisa innehållet i "den övre gränsen är snävare för ett själv än för ett samhälle" (§6.4) är därför inte att institutioner reviderar utan gräns, utan att självets gräns är striktare och anländer först, vilket tvingar självets eget brusbegränsade spårings-optimum — en begränsning ett system vars kontrollant och anläggning är separata inte möter.

D.6 Gränsen ramverket inte får överskrida

Den tvåsidiga gränsen gränsar till kliniskt och kontemplativt territorium, och inhägnaden från Del IV och VI gäller oförändrad. **[R]** Modellen beskriver *strukturen* hos integrationsbegränsningen — att revidering som springer ifrån åter-integration (r ovanför den koherensbegränsade takten) försämrar den koherens inläring kräver. Den beskriver inte hanteringen av den begränsningen hos någon person, och den hävdar inte att destabilisering under intensivt

självarbete generellt är strukturell. Där ett kliniskt substrat är närvarande — där själv-revidering utlöser något med en fysiologi som kontrollmodellen inte representerar — förblir den arkitektoniska beskrivningen sann och otillräcklig, namngivande svårighetens form utan att nå dess orsak. Observationen att transformation måste taktas till integration är en konsekvens av $r < r_{\text{koherens}}$, inte ett protokoll för att takta den.

D.7 Skyddade utrymmen som tillverkad isolering

Konstruktionsprincipen i §6.6 följer direkt och är verifierad. Ett skyddat experimentutrymme är revidering isolerad från global koherens — en andel f av revideringen belastar inte hela självet utan en inmurad sandlåda. Modellera detta som koherenskostnad $\kappa |\Delta\hat{\theta}| (1 - f)$, håller simuleringen revidering vid $r = 0,15$ (ovanför det osandlådade självets optimum) och varierar f : spårningsfelet förblir i princip platt ($E : 0,068 \rightarrow 0,072$) medan koherensen återhämtar sig ($C : 0,843 \rightarrow 0,982$) och den kombinerade kostnaden faller ($J : 0,226 \rightarrow 0,091$) när f stiger från 0 till 0,9. När $f \rightarrow 1$ närmar sig självet institutionens fria exploration. **[IP]**, verifierad. Detta är det formella innehållet i externaliseringsprincipen i Del VIII vid inlärningskanalen: en sandlåda låter självet köra den höga lokala exploration som spårning vill ha utan att betala den globala koherenskostnad som observatör-anläggning-identitet annars påtvingar — tillverkande, lokalt, den kontrollant-anläggning-separation som självet saknar som standard.

D.8 Simulering

Repo-fil: `self_ii_appendix_d_two_sided_bound.py`.

```

import numpy as np

def run(r, kappa, f_sandbox=0.0, v=0.02, sigma=0.30, iota=0.10, c=8.0, T=4000, seed=0):
    rng = np.random.default_rng(seed)
    th_star = th_hat = 0.0; C = 1.0; Es=[]; Cs=[]; Ehat=[]
    for t in range(T):
        th_star += v*rng.standard_normal()
        obs = th_star + sigma*rng.standard_normal()
        dth = r*C*(obs - th_hat); th_hat += dth
        C = np.clip(C + iota*(1-C) - kappa*abs(dth)*(1-f_sandbox), 0, 1)
        if t > T//5:
            e = abs(th_hat - th_star)
            Es.append(e); Cs.append(C); Ehat.append(e*(1-np.exp(-c*r)))
    return np.mean(Es), np.mean(Cs), np.mean(Ehat)

def sweep(kappa, rs, seeds=8):
    return np.array([np.mean([run(r, kappa, seed=s) for s in range(seeds)], axis=0) for r in rs])

if __name__ == "__main__":
    rs = [0.005, 0.01, 0.02, 0.04, 0.08, 0.15, 0.30, 0.60]
    for kappa, lab in [(0.0, "institution"), (0.5, "self")]:
        R = sweep(kappa, rs); E, C, Eh = R[:,0], R[:,1], R[:,2]
        for lam in (0.5, 1.0, 2.0):
            J = E + lam*(1-C); k = int(np.argmin(J))
            interior = 0 < k < len(rs)-1
            print(f"{lab:11s} lam={lam}: r*={rs[k]:.3f} interior={interior} "
                  f"E@r*={E[k]:.4f} bestE={E.min():.4f}")
        print("D.3 self-concealment gap (E - Ehat) at r=0.02:",
              round((lambda x: x[0]-x[2])(np.mean([run(0.02,0.5,seed=s) for s in range(8)],axis=0)), 4))
        print("D.7 protected space (r=0.15, vary f): (E, C, J)")
        for f in (0.0, 0.3, 0.6, 0.9):
            E,C,_ = np.mean([run(0.15,0.5,f_sandbox=f,seed=s) for s in range(8)],axis=0)
            print(f"    f={f}: E={E:.4f} C={C:.3f} J={E+(1-C):.4f}")

```


Appendix E — Observatör–anläggning-identitet och mätning–störning-kopplingen

Detta appendix tillhandahåller den formella grunden för Del I. Det är den konceptuella slutstenen, och det bär mindre beräkningsmässig tyngd än A, C och D med avsikt: det centrala påståendet — att observationshandlingen för ett själv är en handling på det observerade systemet — är strukturellt, och de empiriska och simulerade konsekvenserna av det påståendet etablerades i de andra appendixen. E anger premissen precist, identifierar exakt vilken reglerteknisk garanti den upphäver, och demonstrerar de två konsekvenser som tillhör den ensam och inte antas när den anges. Separationsprincip-påståendet (E.1) är **[R]** som ett gränsuttalande; premissen att den fallerar för ett själv är **[IP]**; fixpunktsresultaten (E.2–E.3) är beräkningsverifierade konsekvenser av den reflexiva kopplingen, inte om-uttryck av den.

E.1 Separationsprincipen och premissen som fallerar

Separationssatsen (säkerhetsekvivalenssatsen) för linjär-kvadratisk-gaussisk reglering anger att den optimala kontrollanten dekomponeras i två oberoende designade delar: en optimal tillståndsskattare, och en styrlag som agerar på skattningen exakt som den skulle på det sanna tillståndet. Skattning och styrning är separerbara — man kan först fastställa tillståndet, sedan bestämma vad man ska göra. Resultatet vilar på en strukturell premis som sällan explicit görs eftersom den nästan alltid är uppfylld: observationsprocessen inträder inte i anläggningens dynamik. Att mäta systemet förändrar det inte. **[R]**

Ett själv bryter mot denna premis vid dess rot (Del I §1.3). Själva handlingen att observera sig själv — att rikta uppmärksamheten mot ett tillstånd, att fråga sig hur man känner, att berätta sin situation — inträder i dynamiken hos just det tillstånd som observeras; det finns ett system, och att avläsa det är att operera på det. Premissen för separationssatsen är därför falsk för ett själv, och dess slutsats är inte tillgänglig: skattning och styrning är inte separerbara, och "skatta sedan agera" är inte en sekvens ett själv kan utföra, eftersom skattandet redan är ett agerande. **[IP]** Detta är samma typ av gräns som gräns-appendixet registrerade för småförstärkningssatsen: en namngiven reglerteknisk garanti vars angivna premis själv-fallet inte uppfyller.

En not om vad detta appendix inte gör. Man skulle kunna modellera mätningens återverkan direkt — anta att observera injicerar en tillståndsstörning, sedan visa att en kontrollant som ignorerar den gör sämre ifrån sig — men den demonstrationen vore cirkulär, och återvinner endast den premis den antog. E demonstrerar istället två konsekvenser av den reflexiva kopplingen som *inte* antas när den anges: att självperception har många självbegränsande fixpunkter snarare än ett sant värde (E.2), och att observation därför kan omlokalisera det tillstånd den observerar (E.3). Båda uppstår ur kopplingen; ingen är inbyggd i den.

E.2 Självperception som fixpunktsurval, inte sanningsupptäckt

Modellera ett själv-tillstånd x och en självuppfattning b på någon dimension. En *passiv* observatörs uppfattning följer en fast extern sanning: x är opåverkat av att observeras, och b konvergerar mot den. En *reflexiv* observatörs uppfattning inträder i dynamiken — att tro drar tillståndet mot uppfattningen ($x \leftarrow x + \eta(b - x)$, observation som handling) och avläsningen dras mot uppfattningen ($\text{obs} = x + \text{bias}(b - x)$, bekräftelse). Simuleringen, från ett gemensamt sant initialtillstånd $x_0 = 0, 5$:

- *Passiv* ($\eta = 0$, ingen bias): uppfattningen konvergerar till **0, 50** från varje initial uppfattning $b_0 \in \{0, 1, \dots, 0, 9\}$ — en enda fixpunkt, sanningen, upptäckt oavsett var uppfattningen började.
- *Reflexiv* ($\eta = 0, 15$, bias = **0, 5**): det slutliga tillståndet och uppfattningen väljs av b_0 — $b_0 = 0, 1 \rightarrow 0, 245$, $b_0 = 0, 5 \rightarrow 0, 50$, $b_0 = 0, 9 \rightarrow 0, 755$ — ett *kontinuum* av självbekräftande fixpunkter, var och en en blandning av initial uppfattning och tidigare tillstånd (här symmetrisk kring det sanna **0, 5** eftersom bekräftelsen är partiell), där den som nås väljs av var uppfattningen började snarare än av någon tidigare sanning.

Detta är det formella innehållet i §1.3: för ett själv är "korrekt självperception" inte återvinnandet av ett redan existerande faktum utan urvalet av en fixpunkt i en reflexiv process — en uppfattning som är sann om det tillstånd din tro på den producerar. Fixpunkterna är neutralt stabila längs mångfalden $b = x$, så ett självbegrepp, när det väl har etablerats, är självbekräftande och består. **[IP]** premiss; mångfald är en verifierad, icke-antagen konsekvens. Farokanten är omedelbar: ett falskt men självbekräftande självbegrepp är en fixpunkt som vilken annan som helst, och den apparat som skulle kunna avslöja dess falskhet är den apparat som upprätthåller den — det förseglade självet i Del VII, sett vid sin rot.

E.3 Självobservation som intervention

Samma koppling som producerar faran producerar spaken i §1.4. Eftersom observation flyttar tillståndet kan en medveten förändring av uppfattningen *omlokalisera* fixpunkten — något en passiv observatör inte kan göra, eftersom det för den bara finns en sanning att finna. Med start låst vid ett lågt självbegrepp ($b = x = 0, 2$) och tillämpande av en engångsintervention av uppfattningen till **0, 65** vid mitten av körningen, ger simuleringen: det reflexiva systemet omlokaliserar sig och håller fast vid ett nytt självbekräftande tillstånd ($b = x = 0, 487$), medan det passiva systemet återgår till det sanna **0, 2**, där interventionen lämnar inga spår. **[IP]/[H]**, verifierad.

Två ärliga kvalificeringar. Omlokaliseringen landar *delvis* — vid **0, 487**, mellan det gamla tillståndet och det avsedda **0, 65** — eftersom den nya fixpunkten sätts av balansen mellan handling (η) och bekräftelse (bias), så en enda åter-berättelse flyttar självet mot ett valt självbegrepp men inte hela vägen dit; uthållig intervention krävs för att flytta längre, vilket är anledningen till att de praktiker som utnyttjar denna spak (kontemplativ uppmärksamhet, den disciplinerade åter-berättelsen i terapi) är upprepade snarare än singulära, och kopplar till de små, uthålliga åtagandena i Del III och IV. Och detta är den mekanism, utlovad i §1.4, genom vilken Själv I:s asymptot $G_{\text{själv}} \rightarrow 0$ överhuvudtaget är nåbar: i ett system där observera är att handla, är att rikta uppmärksamheten mot en utesluten dimension samma operation som att börja släppa in den — spaken och faran är en koppling sedd från två sidor.

E.4 Den gemensamma roten

Observatör-anläggning-identitet är en enda premiss, och papprets huvudsakliga avsteg från den överordnade serien är dess konsekvenser, etablerade där var och en kunde testas:

- golvet under självobservations-korrelation, eftersom kanaler delar ett substrat (Appendix A.5);
- den oreviderbara själv-legitimiteten, eftersom det bedrägliga instrumentet är revisionsinstrumentet (Appendix C.6–C.7);
- den tvåsidiga gränsen för själv-revidering, eftersom experimentatorn är experimentet (Appendix D.4–D.5);
- frånvaron av någon brandvägg mellan primitiver, vilket gör sammansatt misslyckande till standard (Del VII).

Till dessa lägger E de två konsekvenser som tillhör själva premissen: mångfalden av självbekräftande fixpunkter (E.2) och omlokaliseringsspaken (E.3). Fördelningen är medveten och är den ärliga formen av papprets evidens. E är slutstenen — det enda strukturella faktum från vilket avvikelserna följer — men det är inte där tyngden vilar. Tyngden vilar på de appendix som kunde beräkna eller simulera konsekvenserna, och E:s roll är att visa att dessa spridda resultat inte är fem separata fynd utan en premiss sedd fem gånger: i ett själv kan kontrollanten och anläggningen inte dras isär, och allt pappret hävdar som den överordnade serien inte gör är vad detta enda faktum för med sig.

E.5 Simulering

Repo-fil: `self_ii_appendix_e_observer_plant.py`.

```
import numpy as np

def observe_self(b0, eta, bias, x0=0.5, lam=0.2, T=4000,
                intervene_at=None, intervene_to=None):
    """Reflexiv självobservation. eta: observation-som-handling (0 = passiv observatör);
    bias: bekräftelse i avläsningen. Valfri engångsintervention av uppfattningen."""
    x, b = x0, b0
    for t in range(T):
        if intervene_at is not None and t == intervene_at:
            b = intervene_to
            x = x + eta*(b - x)          # att observera/tro flyttar tillståndet (1.3/1.4)
            obs = x + bias*(b - x)      # avläsning dragen mot uppfattning (bekräftelse)
            b = b + lam*(obs - b)
    return round(x, 3), round(b, 3)

if __name__ == "__main__":
    print("E.2 passiv vs reflexiv (gemensam sann x0=0.5):")
    for b0 in (0.1, 0.5, 0.9):
        print(f"  b0={b0}: passiv {observe_self(b0,0.0,0.0)}  reflexiv {observe_self(b0,0.15,0.5)}")
    print("E.3 uppfattningsintervention -> 0.65 vid t=1500 (start låst vid 0.2):")
    print("  reflexiv:", observe_self(0.2,0.15,0.5,x0=0.2,intervene_at=1500,intervene_to=0.65))
    print("  passiv  :", observe_self(0.2,0.0,0.0,x0=0.2,intervene_at=1500,intervene_to=0.65))
```