




Under faktoriseringen

Begränsad prediktion och observationskanalens ursprung

Artikel 0 i serien Styrning som ingenjörskonst

Grundartikeln i serien Styrning som ingenjörskonst. Argumenterar för att faktorisering — observationskanalen varje senare artikel förlitar sig på — uppstår ur begränsad representationskapacitet plus ett tidsprediktionsmål, utan krav på handling eller överlevnadstryck. En minimal modell uppvisar emergens, strukturerad blindhet och icke-unikt, symmetribrutet urval över fyrtio förregistrerade frön.

Björn Kenneth Holmström

Juli 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/sv/working-papers/below-the-factorization>

*Denna artikel ligger under Cykel 1. Varje artikel från I och framåt börjar med en redan etablerad faktorisering — en observationskanal som väljer ut några av världens variabler och förkastar resten, en gräns mellan vad ett system modellerar och vad det inte gör. Ingen av dem frågar var denna kanal kommer ifrån; var och en behandlar den som den primitiv på vilken resten byggs. Denna artikel tillhandahåller den saknade grunden. Dess centrala påstående är att faktorisering inte är primitiv: den uppstår ur två ingredienser, begränsad representationskapacitet och ett tidsprediktionsmål, utan att handling, belöning eller överlevnadstryck krävs. Härledningen är ett argument, märkt **[IP]**; mekanismen visas i en minimal modell och dess påståenden är märkta **[R within the model]**, fastställda över två förhandsregistreringar vars tröskelvärden och nollhypoteser fastställdes i förväg. Avsnitt 7 anger vad en enda miljö och en enda arkitekturfamilj inte kan berättiga. Eftersom detta är Artikel 0, är den skriven för att läsas först trots att den skrevs sent: argumentet förutsätter ingen tidigare artikel i serien, och kopplingarna tillbaka till Cykel 1 samlas i §6 snarare än förutsätts genomgående.*

Sammanfattning

Governance as Engineering-serien behandlar en institution som en regulator som agerar på en modell av sin värld, och gapet mellan modellen och världen — varietetsgapet från artikel VI — som källan till dess karakteristiska misslyckanden. Under den bilden ligger ett objekt som varje artikel använder och ingen undersöker: faktoriseringen, valet av vilka variabler som överhuvudtaget existerar för systemet. Denna artikel frågar om faktorisering är fundamental eller härledd, och argumenterar för att den är härledd.

Två ingredienser räcker. Ett system med begränsad representationskapacitet, som endast tränas för att förutsäga sina egna framtida observationer, tvingas komprimera; och komprimering under ett prediktionsmål är inte fri grovkornighet utan urval av de variabler som bär prediktiv struktur. Vi argumenterar för detta **[IP]** mot standardlistan av kandidater — ändlig energi, lokalitet, kausalitet, symmetribrott — och visar att var och en tillhandahåller ett nödvändigt villkor men inte urvalet, och

att det minimala tillräckliga paret är begränsad kapacitet tillsammans med tidsprediktion. Påståendet är medvetet starkare än vad ramverket behöver: det kräver varken handling eller överlevnadstryck. En passiv prediktor räcker.

En minimal modell uppvisar mekanismen och, över fyrtio frön i två registrerade körningar, tre egenskaper hos den **[R within the model]**. För det första, *emergens*: en flaskhalsad prediktor tränad på renderad video av ett rörligt objekt återskapar objektets latenta kausala variabler — positioner och hastigheter — som linjärt adresserbara storheter, utan att någonsin få veta att de existerar. För det andra, *strukturerad blindhet*: under kapacitetsbrist försämras prediktorn inte jämnt; den offrar ett sammanhängande kausalt underrum helt och behåller resten, och blir en *statisk observatör* som representerar var saker är och inte vart de är på väg. Detta är varietetsgapet mekaniserat — en institution vid sin representationsgräns håller en sammanhängande partiell modell och är strukturellt blind för återstoden, inte jämnt suddig över den. För det tredje, *icke-unikt, symmetribrutet urval*: vid kapacitetsgränsen förbinder sig systemet diskret till en variabel i ett konkurrerande par, och där miljön är symmetrisk görs valet av träningsstillfälligheter snarare än av världen. Den första registrerade operationaliseringen av strukturerad blindhet misslyckades och korrigerades under en andra registrerad körning; korrigeringen rapporteras som en del av resultatet.

Två konsekvenser organiserar resten av seriens grundvalar. Faktorisering är icke-unik: beteendemässigt ekvivalenta faktoriseringar bildar stora ekvivalensklasser, så världen begränsar system endast vid beteendegränsen och fastställer inte ett internt språk — koordination är urval inom en klass, inte upptäckt av en unik sanning (§4). Men icke-unikhet är inte godtycklighet: inom rummet av ekvivalensklasser är de som bevarar miljöns kausala variabler objektivt bättre på robusthet, sampleffektivitet och överföring, så institutioner förhandlar koordinatsystem inom en klass som verkligheten faktiskt begränsar (§5). Artikeln avslutar med att återgrunda fyra resultat från serien i dessa grundvalar (§6) och ange dess begränsningar (§7): distinktionen passiv/aktiv är oprövad, påståendet om två ingredienser demonstreras snarare än bevisas generellt, och korrespondensen tränat nätverk–institution förblir genomgående tolkande.

1. Den oprövade primitiven

1.1 Vad serien bygger på och aldrig bygger

Governance as Engineering-serien har ett bärande objekt som den aldrig lägger direkt tyngd på. Från och med Artikel I är en institution en regulator: den har en modell av någon del av världen, den agerar på den modellen, och analysen handlar om vad som händer när modellen och världen divergerar. Artikel VI benämner divergensen varietetsgapet och gör det till motorn i seriens felmoder. Artikel XII drar en gräns mellan en regulators jurisdiktion och den miljö den utesluter, och studerar vad uteslutningen kostar. Artikel XVII frågar vad det innebär att certifiera att en modell är adekvat för sin värld. Var och en av dessa analyser börjar efter att ett tidigare steg redan har ägt rum: världens kontinuerliga, högdimensionella flöde har redan styckats upp i en ändlig uppsättning variabler — *dessa räknas, dessa gör det inte* — och regulators modell är en modell i *dessa* variabler. Denna uppstyckning är faktoriseringen. Den är observationskanalen, valet av tillståndsrymd, den ontologi som institutionen resonerar i. Och serien behandlar den som given.

Att behandla den som given är inte en brist i de tidigare artiklarna; det är en arbetsfördelning. Man kan studera hur en regulator misslyckas gentemot sin värld utan att fråga var dess variabler kom ifrån, precis som man kan studera en marknad utan att härleda begreppet pris. Men frågan ligger där, och det är den sorts fråga som seriens egen metod — komprimera teorin, finn den mindre uppsättningen primitiver ur vilken resten följer — är skyldig att så småningom ställa. Om faktorisering kan härledas, vilar ramverket på färre axiomer, och de egenskaper hos faktoriseringar som serien utnyttjar (att de kan vara felaktiga, att de kan delas, att de kan driva) blir egenskaper med en mekanism bakom sig snarare än stipulationer.

1.2 Frågan, preciserad

En faktorisering, i denna series användning, är en avbildning från ett systems råa sensoriska gränssnitt till en intern tillståndsrymd: en partition av världens flöde i de variabler som systemet förutsäger, beslutar och agerar i. Inom reglerteknik är det tillståndsrymdrepresentationen; inom maskininlärning den latenta variabelmodellen; inom kognition ontologin; i en institution den uppsättning storheter som den samlar in, rapporterar och styr efter. Frågan i denna artikel är huruvida den avbildningen är primitiv — en utgångspunkt som måste postuleras — eller om den är det oundvikliga resultatet av något enklare.

Frågan har en form som är värd att ange noggrant, eftersom de uppenbara svaren är fällor. Det räcker inte att nämna en fysisk begränsning som *tillåter* faktorisering, eftersom nästan varje begränsning tillåter nästan varje partition. Det räcker inte heller att nämna en begränsning som *tvingar fram komprimering*, eftersom komprimering ensamt inte väljer ut en faktorisering — det kräver bara att *några* variabler utesluts, inte vilka. En framgångsrik härledning måste producera urvalet: den måste förklara inte bara att systemet styckar upp världen, utan att det styckar upp den vid leder som följer världens egen struktur. Det är ribban §2 sätter för kandidaterna.

1.3 Plan

Avsnitt 2 argumenterar för påståendet om två ingredienser mot standardlistan av djupare primitiver, och isolerar det specifika par som producerar urval snarare än blott komprimering. Avsnitt 3 uppvisar mekanismen i en minimal modell och rapporterar de tre registrerade egenskaperna. Avsnitt 4 utvecklar icke-unikhet: ekvivalensklassen av beteendemässigt identiska faktoriseringar, och vad det innebär för koordination. Avsnitt 5 löser den skenbara spänningen mellan icke-unikhet och det uppenbara faktum att vissa faktoriseringar är bättre — distinktionen mellan ontologisk och pragmatisk preferens. Avsnitt 6 återgrundar fyra resultat från serien i dessa grundvalar. Avsnitt 7 anger vad artikeln inte visar.

2. De två ingredienserna

2.1 Kandidatlistan, och varför enskilda principer misslyckas

Fråga vad som kan ligga under faktorisering och en standardlista samlas av sig själv: ändlig energi, lokalitet, kausalitet, symmetribrott, begränsad representation. Var och en har föreslagits, i en eller annan tradition, som den grund ur vilken ett systems uppstyckning av världen härstammar. Tagga en i taget levererar var och en något verkligt, och var och en faller kort på samma lärorika sätt — den tillhandahåller ett nödvändigt villkor utan att tillhandahålla urvalet.

Ändlig energi tvingar fram en gräns för upplösningen. Varje system inbäddat i en termodynamisk omgivning har ändlig fri energi, informationsbehandling kostar energi, och därför kan inget system följa varje mikrotillstånd: det måste grovkornas. Men ändlig energi begränsar *hur mycket* som kan representeras, inte *vad*. En energibudget tillfredsställs av vilken partition som helst med rätt kardinalitet, inklusive partitioner som inte spårar något alls om världen. Energi begränsar precision; den väljer inte en ontologi.

Lokalitet tillhandahåller ett gränssnitt. I ett universum av lokala interaktioner har ett system direkt kausal kontakt endast med sin omedelbara omgivning, vilket delar världen i en sensorisk yta och allt bortom den. Detta är en genuin partition, påtvingad av rumtiden — men det är partitionen mellan insida och utsida, inte faktoriseringen av utsidan i variabler. Lokalitet ger gränsen; den ger inte abstraktionen tvärs över den.

Kausalitet tillhandahåller formen. Världens kausala struktur antyder en privilegierad uppstyckning — den som grupperar samman tillstånd som kräver samma intervention — och ett system som vill manipulera utfall måste representera de kausala variabler som har betydelse. Men kausalitet ensam påtvingar ingen grovhet: en laplacesk demon som följer hela den kausala grafen på atomär upplösning bryter mot ingen kausal princip. Kausalitet formar faktoriseringens leder utan att tvinga den att överhuvudtaget vara en komprimering.

Symmetribrott tillhandahåller en tillblivelseberättelse. Ett initialt odifferentierat system, som interagerar med sin miljö, förstärker de distinktioner som har differentiella konsekvenser för det och ignorerar resten; faktorisering är det frusna protokollet över vilka symmetrier som bröts. Detta är en vacker redogörelse för *hur* en faktorisering kan formas över tid, men det är en dynamisk berättelse snarare än en härledning från en princip: den förutsätter ett system med dynamik som redan förstärker vissa skillnader framför andra, vilket är det mesta av det som skulle förklaras.

Begränsad representation kommer närmast och är, av det skälet, den minst informativa. Att säga att ett system *representerar* något är redan att postulera en kodning från världstillstånd till interna tillstånd — och den kodningen är en faktorisering. Kandidaten är närmast tautologisk: den härleder inte faktorisering, den döper om den. Den användbara frågan är vad som gör representationen själv både begränsad och *selektiv* — begränsad så att komprimering tvingas fram, selektiv så att komprimeringen spårar världen.

2.2 Det tillräckliga paret

Mönstret i misslyckandena pekar mot reparationen. Varje enskild princip tillhandahåller antingen *trycket* att komprimera (energi, begränsad kapacitet) eller *formen* som en bra komprimering skulle anta (lokalitet, kausalitet) men inte båda, och symmetribrott tillhandahåller dynamiken utan målet. Det som producerar urval är sammanflätningen av ett komprimeringstryck med ett mål som gör vissa variabler mer värda att behålla än andra. Det minimala sådana paret är **begränsad representationskapacitet** och ett **tidsprediktionsmål**.

Argumentet är kort. Begränsad kapacitet tvingar systemet att utesluta variabler — det kan inte representera allt. Ett prediktionsmål över tid tilldelar varje variabel ett värde: de variabler som är värda att behålla är de som reducerar felet i att förutsäga framtida observationer, och dessa är exakt de variabler som bär miljöns kausala struktur framåt i tiden, eftersom det är den kausala strukturen som får framtiden att bero på nuet. Under en flaskhals komprimerar systemet då inte bara; det komprimerar *mot* de kausala variablerna, eftersom det är dem målet betalar för. Komprimering tillhandahåller nödvändigheten av att utesluta; prediktion tillhandahåller urvalet av vad som ska behållas. Ingenting räcker ensam — obegränsad prediktion behåller allt och faktorerar ingenting; begränsad representation utan ett mål komprimerar godtyckligt — och tillsammans producerar de en uppstyckning av världen vid leder som följer världens egen dynamik. Detta är påståendet som §3 uppvisar: lederna modellen finner är fysikerns variabler, och den finner dem eftersom det är billigast att förutsäga framtiden i dessa koordinater.

Statusen för detta argument är **[IP]**. Det är inte ett teorem; det är en rekonstruktion av varför två ingredienser som var för sig misslyckas tillsammans lyckas, disciplinerad av kravet att en härledning ska producera urval och inte bara komprimering. Det som bär bevisbördan är modellen i §3, där paret instansieras och det förutsagda urvalet mäts.

2.3 Det starkare påståendet: passivitet

Paret som just nämndes är mer asketiskt än de versioner det explorativa arbetet först nådde, och asketismen är poängen. En naturlig formulering grundar faktorisering i *begränsning plus viabilitet*: ett system styckar upp världen eftersom det måste överleva, och överlevnad väljer ut de variabler som har betydelse för att förbli viabel. En annan, mer minimal, grundar den i *handling under osäkerhet*: en agent som måste handla på ofullständig information tvingas bilda tillräckliga statistikor över sina tillstånd, och dessa statistikor är en faktorisering. Båda är sunda, och båda importerar något som denna artikels påstående klarar sig utan — en insats. Viabilitet kräver att systemet kan dö; handling kräver att det kan agera. Var och en smugglar in ett syfte i härledningen.

Påståendet här är starkare eftersom det tar bort båda. Systemet i §3 agerar inte, kan inte dö, och har inget mål bortom att förutsäga bildrutor det aldrig kommer att påverka. Det är en passiv observatör av en värld likgiltig inför det. Och det faktorerar ändå — rent, och mot de kausala variablerna. Detta är av betydelse för serien eftersom det lokaliserar observationskanalens ursprung *före* agentskap snarare än i det. Faktorisering är inte något ett system gör för att kunna agera eller överleva; det är vad som händer med varje begränsat system som försöker förutse sina observationer, oavsett om något står på spel. Agentskap, viabilitet och styrning är sedan senare berättelser berättade ovanpå en faktorisering som prediktion ensam redan producerat. Varietetsgapet väntar inte på att en institution ska ha intressen; det öppnas i samma stund som ett begränsat system börjar modellera en värld större än dess kapacitet, vilket alltid sker.

3. Den minimala modellen: faktorisering från begränsad prediktion

3.1 Design

Påståendet i §2 — att begränsad kapacitet och ett tidsprediktionsmål tillsammans räcker för att producera en faktorisering — är den sorts påstående som en minimal modell kan bekräfta jakande och aldrig kan vederlägga generellt. Det som följer demonstrerar mekanismen i en miljö över ett kapacitetssvep; §7 anger tydligt vad en enda miljö inte kan berättiga. Demonstrationen är värd att göra konkret eftersom det *sätt* på vilket kapacitet producerar faktorisering visar sig bära artikelns tyngd: det är inte så att ett svältfött system ser en suddig version av allt, utan att det ser en sammanhängande *del* av världen och är blind för resten, och vilken del det behåller är, vid marginalen, inte alls bestämd av världen.

Miljön är en prick som rör sig i en tvådimensionell låda med reflekterande väggar. Dess latent kausala tillstånd är fyra skalärer — två positioner (x, y) och två hastigheter (v_x, v_y) — och miljön är symmetrisk under utbyte av de två rumsaxlarna konstruktionsmässigt: ingenting i dynamiken, renderingen eller bruset skiljer x från y . Systemet observerar aldrig detta tillstånd. Det observerar en 16×16 pixelrendering med additivt brus, och dess enda mål är att förutsäga framtida bildrutornas prickpositioner vid offset $\{5, 10, 20\}$ från en kort historik av tidigare bildrutor. En GRU med dold bredd h är flaskhalsen; h sveps över $\{2, 4, 8, 16\}$, och ett 3-platsvillkor $h = 3$ läggs till för tie-break-testet i §3.4. Efter träning används linjära prober för att regressera varje sann latent skalär på det slutliga dolda tillståndet, på undanhållen data. Linjära prober är ett medvetet val, inte en bekvämlighet: de registrerade påståendena handlar om *linjärt avkodbar* struktur, minimistandarden för att säga att en variabel är representerad snarare än i princip återvinningsbar. En olinjär prob skulle återvinna mer och bevisa mindre.

Två registrerade körningar ligger bakom resultaten. Den första (frön 0–19, det fulla svepet) testade emergens, en axelbaserad operationalisering av strukturerad blindhet och ett förutsägelser om avtagande abstraktion. Den andra (frön 20–39, $h \in \{2, 3\}$) testade en reviderad, typbaserad operationalisering av strukturerad blindhet på nya frön efter att den första körningen falsifierade axelversionen. Båda förhandsregistreringarna, med fastställda tröskelvärden och nollhypoteser, finns i det kompletterande materialet; sekvensen redovisas ärligt i §3.5 eftersom korrigeringen är en del av resultatet, inte en pinsamhet att släta över.

3.2 Emergens [R inom modellen]

En faktorisering uppträder, oöverbakat. Vid $h = 8$ kodar det dolda tillståndet linjärt alla fyra latent variabler tillräckligt väl för att kallas en representation av dem — medianen över frön $R^2 = 0.94$ för varje position och $0.63\text{--}0.68$ för hastigheterna — och vid $h = 16$ är återvinningen ren för varje variabel (medianer $0.76\text{--}0.98$). Systemet instruerades endast att förutsäga pixlar; det byggde, inuti sitt dolda tillstånd, det positions–hastighetskoordinatsystem som en fysiker skulle ha valt. Detta är den jakande halvan av §2:s påstående: tidsprediktion under en flaskhals är tillräckligt för att få miljöns kausala variabler att *existera*, som linjärt adresserbara storheter, för ett system som aldrig fick dem.

Positioner uppstår först och överallt. Även vid $h = 2$ — en skalär kapacitet per rumsdimension, långt ifrån tillräckligt för hela tillståndet — återvinns positionerna vid median $R^2 \approx 0.86$ medan hastigheterna kollapsar till nära noll. Kapacitet köper inte en jämnt försämrade version av hela tillståndet; den köper helheten av vissa variabler och inget av andra. Den observationen är ämnet för §3.3.

3.3 Strukturerad blindhet [R inom modellen]

Det centrala resultatet handlar om *formen* på misslyckande under svält, och det är här den första registrerade förutsägelsen misslyckades och lärde oss något.

Den första körningen operationaliserade "strukturerad blindhet" som *rumsaxel*-asymmetri: ett svältfött system, förutsade vi, skulle behålla en rumsaxel och utesluta den andra, så att pilotkörningens uppenbara axelkollaps skulle återkomma i de flesta frön. Det gjorde den inte. Endast **3** av **20** frön visade axelasymmetri; den registrerade förutsägelsen misslyckades som formulerad, och enligt förhandsregistreringens egna regler omklassificerades piloten därmed som en körning som hade hamnat i ett minoritetsutfall. Men misslyckandet var inte jämn försämring — den fastställda nollhypotesen. Under en annan uppdelning var blindheten total och strukturerad i *varje* frö. Uppdelningen är inte rumsaxel utan *variabeltyp*: position kontra hastighet. I **17** av dessa **20** frön behåller det svältfödda systemet båda positionerna och förkastar båda hastigheterna.

Den andra körningen registrerade detta typbaserade påstående och testade det på frön 20–39. Det höll. Typstrukturerad blindhet i **17/20**; och — det bärande resultatet — *ingen jämn suddighet i något frö*, över båda körningarna sammantaget, **40** av **40**: i dessa körningar försämrade kapacitetssvält aldrig en enda gång de fyra variablerna jämnt. Den offrade ett sammanhängande kausalt underrum helt. Vad den svältfödda prediktorn blir är en **statisk observatör**: den representerar var pricken är och har nästan ingen representation av vart den är på väg, och dess

förutsägelse av framtiden är, i praktiken, nuet som hålls stilla. Hastigheter är de variabler med lägre värde per enhet dold kapacitet under en kortsiktig prediktionsförlust — positionen vid de närmaste offseten ges mestadels av positionen nu — och därför är det underrummet som försvinner. Detta är inte en perceptuell begränsning i vanlig mening. Systemet ser inte en svag version av hastighet; det har ingen hastighetskoordinat alls.

Vilket underrum som offras är en funktion av målet, och den korta horisonten utför här ett synligt arbete. Under ett långsiktigt mål, där framtiden har drivit långt från nuet, blir hastigheten den mer värdefulla variabeln och blindheten borde inverteras — systemet skulle behålla derivatan och förlora den momentana kartan. Vad resultatet påstår överlever över olika mål är *formen* på misslyckandet, hel-underrumsoffer snarare än jämn suddighet; vilket specifikt underrum som försvinner är målberoende, och §8 noterar detta som en begränsning av det specifika fyndets generalitet.

Varietetsgapet från Artikel VI är detta resultat på institutionell skala. En institution vid sin representationsgräns uppfattar inte en svag, jämnt dämpad kopia av sin miljö; den upprätthåller en sammanhängande partiell modell — de variabler som mest reducerar dess prediktionsfel — och är *strukturellt blind* för resten, inte suddig över den. Den institutionella motsvarigheten är ett departement, en myndighet eller en mätregim som behåller de variabler som dess rapporteringsmiljö mest belönar medan den förlorar de som skulle avslöja rörelse, instabilitet eller fördröjda konsekvenser. Den svältfödda prediktorn behåller kartan och förlorar derivatan: den känner till världens tillstånd men inte dess rörelse.

En minoritetsbassäng kvarstår och är värd att namnge snarare än att dölja. Utfallet i axelläge — behåll en rumsaxel med dess hastighet, uteslut den andra axeln helt — återkom i exakt $3/20$ frön i *båda* körningarna. En reproducerbar $\sim 15\%$ minoritet över oberoende fröbatcher är en andra attraktor, inte samplingsbrus. De två lösningarna är förlustrankade (den statiska observatörlösningen uppnår strikt lägre valideringsförlust än någon axellägeslösning i den första körningens data), vilket är anledningen till att de flesta initialiseringar når den och en stabil minoritet inte gör det. Att två kvalitativt olika faktoriseringar av samma miljö kan nås under identiska begränsningar, åtskilda av en liten förlustskillnad, är det första uppträdandet i denna artikel av den icke-unikhet som §4 behandlar generellt — här anländer den spontant, inuti enskilda träningskörningar.

3.4 Diskret, symmetribrutet urval [R inom modellen]

Om ett svältfött system behåller positioner och utesluter hastigheter är den naturliga nästa frågan vad som händer vid marginalen — när kapaciteten ökas med ungefär en skalär utöver den positionsdominerade regimen. Läger systemet till hälften av varje hastighet, eller en hel hastighet? $h = 3$ -villkoret testat detta, och svaret är skarpt. Det lägger till en hel hastighet. Över samtliga 20 frön återvinns positionerna (medianer $R^2 = 0.91$) och en hastighet återvinns vid $R^2 \approx 0.6-0.7$ medan den andra ligger i princip på noll — en bimodal uppdelning med ingenting däremellan. Kapacitet vid marginalen sprids inte; den binds.

Och *vilken* hastighet som binds till verkar avgöras av ingenting i miljön. Den gynnade hastigheten delar sig 11 mot 9 mellan v_x och v_y över frön — en myntsingling. Eftersom miljön är axelsymmetrisk konstruktionsmässigt, och ensemblesplitten inte visar någon riktningsbias, finns det inga belägg för att världen väljer v_x framför v_y ; valet görs av initialiseringen och träningsbanan, och det görs diskret. Detta är symmetribrott i precis mening: ett symmetriskt problem, en asymmetrisk lösning, och en ensemble som återställer symmetrin endast aggregerat. Icke-unikheten i §4 är inte bara att många faktoriseringar *skulle kunna* väljas; den ligger i att valet är påtvingat, skarpt, och — där världen är symmetrisk — godtyckligt.

Den minimala modellen ger därför tre resultat, och de är de tre ingredienser som resten av artikeln behöver. För det första producerar prediktion under en flaskhals miljöns latentia kausala variabler utan övervakning — *emergens*. För det andra, när kapaciteten är för liten, är misslyckandet strukturerat: systemet förlorar hela variabler snarare än lite av allt — *strukturerad blindhet*. För det tredje kan den behållna variabeln vid marginalen väljas godtyckligt bland symmetriska alternativ — *icke-unik faktorisering*. Emergens är föremålet för §2:s tillräcklighetspåstående; strukturerad blindhet grundar varietetsgapet; icke-unikhet är vad §4 och §5 utvecklar till påståendet att koordination är urval inom en privilegierad klass snarare än upptäckt av en unik sanning.

3.5 Vad sekvensen visar om metod

Den första registrerade förutsägelsen för §3.3 misslyckades, och artikeln är starkare för att rapportera det än för att ha gissat rätt. En enda pilotkörning hade visat axelkollaps; hade vi publicerat den som *resultatet* hade vi rapporterat en 15%-attraktor som fenomenet. Flerfröfördelningen korrigerade det, avslöjade den faktiska (typ)strukturen, och en andra registrerad körning bekräftade korrigeringen på nya frön. Detta är seriens disciplin om fördelningar-intrajektorier (Artikel IX) som gör precis vad den finns till för, och den speglar Artikel XVIII:s båge, där ett registrerat early-warning-index misslyckades och tvingade fram en revidering. De bekräftade

påståendena i detta avsnitt — emergens, hel-underrumsblindhet, diskret symmetribrutet urval — vilar på 40 frön över två förhandsregistreringar. Den enda förutsägelse som misslyckades (avtagande abstraktion: att kapacitet utöver uppgiftskvoten skulle köpa pixeldetaljer men inte renare latent struktur) förs inte in i artikelns påståenden; $h = 16$ förbättrade hastighetsåtervinningen jämfört med $h = 8$, så uppgiftskvoten var inte mättad vid $h = 8$ och platåpåståendet är helt enkelt ostyrkt på denna skala.

4. Icke-unikhet: ekvivalensklassen

4.1 Världen begränsar endast gränsen

Avsnitt 3 producerade en faktorisering och visade att kapaciteten avgör vilka variabler den innehåller. Det visade inte att faktoriseringen är unik, och det är den inte. Detta är det andra grundläggande faktumet, och det är det som förvandlar koordination från ett upptäcktsproblem till ett urvalsproblem.

Det formella uttalandet är ett bisimulationsresultat, standard inom förstärkningsinlärning och reglerteknik och värt att formulera i denna artikels termer. Kalla två faktoriseringar *beteendemässigt ekvivalenta* om de, för varje historik av systemets interaktioner, inducerar samma fördelning över framtida observationer — samma förutsägelser, och där handling förekommer, samma optimala policy. Två interna tillstånd som alltid leder till samma betingade framtid är bisimilära; en faktorisering är en aggregering av råa historiker till sådana tillstånd; och två aggregeringar som bevarar bisimulationsrelationen är omöjliga att särskilja utifrån. Världen testar ett system endast vid dess beteendegräns — vad det förutsäger, vad det gör — och lägger ingen begränsning på de interna koordinater i vilka systemet når dessa förutsägelser. Konsekvensen: **världen upprätthåller konsistens vid gränsen och lämnar det interna språket fritt.**

Den ekvivalensklass detta inducerar är inte liten. I varje icke-trivial miljö är den generiskt enorm, längs minst tre oberoende axlar.

4.2 Tre lager av icke-unikhet

De tre är värda att separeras, eftersom de bär mycket olika vikt för serien och alltför ofta blandas samman.

Det första är **måttfrihet**: koordinattransformationer. Om en faktorisering använder (x, y) och en annan använder $(x + y, x - y)$ kan de vara beteendemässigt identiska — en linjär ommixning av samma information, med avkodaren justerad för att kompensera. Varje inverterbar transformation av det interna tillståndet som bevarar input–output-avbildningen ger en annan giltig faktorisering. Detta är verkligt men ytligt; det säger att det interna språket inte är unikt, inget mer.

Det andra är **redundans**: överkompleta representationer. Ett system vars minimala tillräckliga tillstånd är fyrdimensionellt men vars kapacitet är sexton kan lagra överskottsinformation som ingen uppgift kräver, och många olika sexton-dimensionella koder projicerar till samma fyrdimensionella

tillräckliga mångfald. Även detta är verkligt och likaså ytligt — en byråkrati med fler kategorier än den behöver fungerar fortfarande; de extra kategorierna är helt enkelt inte bärande.

Det tredje är **djup icke-unikhet**, och det är den som har betydelse. Två faktoriseringar kan prestera identiskt *under rådande förhållanden* medan de skiljer sig skarpt under andra — i robusthet mot distributionsskiften, i kommunicerbarhet, i reparerbarhet, i vilka variabler de gör synliga, och i vem som bär kostnaden för vad de komprimerar bort. Det starka påståendet är därför inte att många faktoriseringar är lika bra, utan det skarpare:

Många faktoriseringar är observationellt ekvivalenta under en utvärderingsregim medan de blir skarpt icke-ekvivalenta under en annan.

Djup icke-unikhet är där styrning kommer in, eftersom det är där valet bland till synes ekvivalenta faktoriseringar visar sig få konsekvenser som den rådande regimen inte avslöjar.

4.3 $h=3$ -resultatet som måttfrihet, anläggande av sig själv

Avsnitt 3.4 uppvisade redan det första lagret utan att bli ombedd. Vid $h = 3$ förbinder sig systemet till en hastighet i ett symmetriskt par, och valet — v_x eller v_y — delade sig nästan jämnt över frön utan att något i miljön avgjorde det. Två nätverk tränade på samma värld når olika interna koordinater och identiskt beteende. Det är måttfrihet som uppträder spontant inuti enskilda träningskörningar: inte en familj av representationer vi konstruerade för att bevisa en poäng, utan en förgrening som optimeraren tog olika på olika frön eftersom världen lämnade den fri. Ekvivalensklassen i §4.1 är inte en abstraktion som lagts över modellen; modellen faller in i distinkta punkter av den på egen hand, och endast ensemblen avslöjar att punkten aldrig var fixerad.

4.4 Koordination som urval, och oenighetens form

Om det inte finns någon unik korrekt faktorisering kan koordination mellan system inte bestå i att alla konvergerar mot den enda sanna beskrivningen. Det är i stället ett **urvalsproblem**: att välja, från en stor ekvivalensklass, en delad representation som ska tjäna som konvention för gemensamt handlande. Språk är det renodlade fallet — det finns ingen unikt korrekt avbildning från erfarenhet till ord, engelska och franska är lika kraftfulla faktoriseringar av vad man skulle kunna säga, och en gemenskap koordinerar sig genom att bestämma sig för en inte för att den är sannare utan för att den är delad, låst av historien och kostnaden för att byta.

Denna omramning skärper vad oenighet *är*, och distinktionen är en som serien använder på andra ställen. Om två system är oeniga men deras faktoriseringar är beteendemässigt ekvivalenta — relaterade genom en koordinattransformation — är oenigheten en **måttoenighet**, i princip lösbar genom översättning. Om deras faktoriseringar ligger i olika ekvivalensklasser är oenigheten **substantiell**, lösbar endast genom nya data eller en omförhandling av vad som optimeras. Att förväxla de två är ett karakteristiskt institutionellt misslyckande: att behandla en översättningsbar koordinatskillnad som en värdekonflikt, eller en äkta värdekonflikt som ett blott översättningsmisslyckande. Icke-unikhet är vad som gör distinktionen väldefinierad, och §5 är vad som hindrar den från att kollapsa i relativism.

5. Pragmatisk preferens utan ontologisk preferens

5.1 Spänningen, och dess upplösning

Avsnitt 3 och 4 tycks tillsammans peka åt motsatta håll. Avsnitt 3 visade att vissa faktoriseringar är objektivt sämre: den statiska observatören vid $h = 2$, blind för hastighet, kommer att misslyckas i samma stund som prediktion kräver att man vet vart saker är på väg, och ingen perspektivförändring reparerar det. Avsnitt 4 visade att faktorisering är icke-unik, det interna språket fritt. Om båda håller, i vilken mening är då en faktorisering bättre än en annan?

Upplösningen är en distinktion som vetenskapsfilosofin i stort sett har avgjort, överförd till denna miljö. Separera två betydelser av en "föredragen" faktorisering:

- **Ontologisk preferens:** verkligheten besitter en sann uppdelning, oberoende av varje observatör — ett enda korrekt sätt att stycka världen i objekt och orsaker. Detta är det metafysiska påståendet, och det är det man ska förkasta. Världen kommer inte företiketterad; till och med fundamental fysik erbjuder ekvivalenta formuleringar (Newtonsk, Lagrangisk, Hamiltonsk) av samma dynamik.
- **Pragmatisk preferens:** givet en klass av system med särskilda sensorer, horisonter och mål, är vissa faktoriseringar objektivt bättre — mer robusta, mer sampleffektiva, mer överförbara under distributionsskiftet. Detta är ett ingenjörsmässigt påstående, och det är sant.

De två är förenliga eftersom pragmatisk preferens inte väljer ut en unik faktorisering. Den väljer ut en **privilegierad ekvivalensklass**. Verkligheten föredrar inte (x, y, v_x, v_y) framför $(x + y, x - y, v_x + v_y, v_x - v_y)$ — båda bevarar samma interventionsrelevanta information, och varje system med prediktionsmålet kommer att klara sig lika bra i endera. Vad verkligheten privilegierar är den *klass* av faktoriseringar som bevarar de kausala variablerna, framför den klass som inte gör det. Inom den privilegierade klassen förblir det interna språket fritt; mellan klasserna diskriminerar världen skarpt. Faktoriseringen vid $h = 2$ är sämre inte för att den valde fel koordinater utan för att den föll ut ur den privilegierade klassen helt och hållet — den tappade ett kausalt underrum, och ingen koordinattransform inuti dess utarmade representation kan återvinna vad kapaciteten aldrig kodade in.

5.2 Kausal invarians som substitut för objektivitet

Det som gör en klass privilegierad är att dess faktoriseringar följer miljöns *kausala* struktur — de relationer som håller över interventioner och distributionsskiften, inte bara över träningsdistributionen. Detta är det interventionistiska kausalitetsbegreppet som utför det arbete som metafysisk objektivitet inte kan. Den studsande prickens framtida position beror kausalt på dess nuvarande position och hastighet; en faktorisering som kodar in dessa variabler generaliserar till regimen den aldrig tränades på, medan en som förlitar sig på ytkorrelationer i de specifika träningspixlarna inte gör det. Vi kan inte ha observatörsoberoende objektivitet, men vi kan ha kausal invarians, och kausal invarians räcker för att göra "bättre" och "sämre" icke-godtyckliga utan att göra någon enskild faktorisering unikt korrekt.

Den linje artikeln förbinder sig till är alltså denna: **det må inte finnas något unikt korrekt koordinatsystem, men det finns bättre och sämre invarianter**. Icke-unikhet är verklig och är inte relativism, eftersom friheten är frihet *inom* en klass som verkligheten begränsar, inte frihet att stycka världen hur man vill.

5.3 Institutioner som förhandlare inom en begränsad klass

Det är här grundvalarna möter serien. Om verkligheten inte har någon unik faktorisering men har privilegierade ekvivalensklasser, då är en institution varken en spegel som upptäcker världens sanna struktur eller en fri konvention som inte är ansvarig inför något. Den är en **förhandlare av ett delat koordinatsystem från inom en privilegierad klass** — fri i sitt val av internt språk, bunden av kravet att den klass den arbetar i fortfarande spårar de kausala variabler dess handlingar beror på.

Tre läsningar som den senare serien gör faller direkt ur detta, och anges här endast tillräckligt långt för att visa grunden; §6 samlar den fullständiga uppsättningen. Certifiering (Artikel XVII) är lämplighetsprövning, inte sanningsprövning: den frågar om en faktorisering fortfarande spårar de relevanta kausala variablerna tillräckligt väl för att stödja livskraftig handling, en pragmatisk och falsifierbar fråga, inte om den är den sanna. Distinktionen mellan mått och substantiell (Artikel X) är precis distinktionen inom-klass kontra mellan-klass från §4.4, och observatörsoberoende är skyddet mot att missta den ena för den andra. Och signalerna om att en faktorisering har fallit ur sin privilegierade klass — att miljön har skiftat eller en ny kausal variabel har blivit relevant — är exakt vad serien på andra ställen kallar källtermer (Artikel XVI): de fel som tvingar fram en omfaktorisering, inte mot en sannare sanning utan mot ett verktyg som åter är adekvat för sin värld.

Det finns en försiktighetsåtgärd som det explorativa arbetet insisterade på och som denna artikel antar: *ekvivalent* måste alltid indexeras till ett kriterium. Två institutionella faktoriseringar som producerar jämförbar makrostabilitet kan fördela röst, risk, tolkningsauktoritet, anpassningsbörda och felsynlighet mycket olika, och att kalla dem ekvivalenta för att de är ekvivalenta *med avseende på stabilitet* döljer exakt dessa skillnader. Den starkaste versionen av icke-unikhet är inte "många kartor fungerar, så välj en"; den är att valet bland beteendemässigt ekvivalenta kartor avgör vilka förluster som görs osynliga av den valda kartan. Det är inte en relativistisk slutsats. Det är motsatsen — ett insisterande på att kriteriet namnges, eftersom världens begränsning vid gränsen underbestämmer det och något måste bära tyngden av resten.

6. Vad detta återgrundar

Syftet med en grundvalsartikel är inte att lägga till ett resultat utan att flytta befintliga resultat till en mindre bas. Fem av seriens bärande påståenden är, enligt redogörelsen i §§2–5, konsekvenser av begränsad prediktion snarare än oberoende stipulationer. Detta avsnitt anger varje återgrundning en gång och på dess rätta nivå; ingen av dem om-argumenteras här utöver kopplingen.

Varietetsgapet (Artikel VI) är strukturerad blindhet på institutionell skala. Artikel VI postulerar ett gap mellan en institutions modell och dess värld och gör det till motorn i seriens felmoder. Avsnitt 3 tillhandahåller mekanismen och, mer användbart, korrigerar en naturlig felläsning av den. Gapet är inte en jämn dämpning — en svag, jämnt nedtonad kopia av världen. Det är hel-underrums offret från §3.3: ett system vid sin kapacitetsgräns behåller en sammanhängande partiell modell, de variabler som mest reducerar dess prediktionsfel, och är strukturellt blind för resten. Det som Artikel VI behandlade som en kvantitet — hur stort är gapet — får en form: *vilket* underrum som utesluts, och fyndet att under ett kortsiktigt mål är det dynamiken som försvinner först, där institutionen behåller en karta över var saker är och förlorar vart de är på väg. Denna återgrundning är **[R inom modellen]** för mekanismen, **[IP]** för den institutionella läsningen.

Certifiering (Artikel XVII) är lämplighetsprövning inom en klass. Om det inte finns någon ontologiskt föredragen faktorisering men det finns privilegierade ekvivalensklasser (§5), då kan certifiering av en faktorisering inte vara att kontrollera den mot sanningen. Det är att kontrollera att den fortfarande ligger i den privilegierade klassen — fortfarande spårar de kausala variablerna tillräckligt väl för att stödja livskraftig handling. Artikel XVII:s certifieringsgolv är, i dessa termer, kravet att ett system behåller medlemskap i den klass verkligheten begränsar, och dess omöjlighet av slutgiltig självcertifiering är observationen att medlemskap endast kan testas mot konsekvenser som systemet inte fullt kontrollerar. **[IP]**, XVII:s egen nivå, som denna artikel inte höjer.

Källtermer (Artikel XVI) är utträdessignaler från den privilegierade klassen. En faktorisering faller ur sin klass när miljön skiftar eller en ny kausal variabel blir relevant, och de fel detta producerar är inte brus att undertrycka utan bevis för att den nuvarande uppstyckningen inte längre spårar världen. Artikel XVI:s källtermer är exakt dessa signaler; §5:s ramverk säger vad de är bevis *på* — inte på en sannare sanning som väntar på att bli funnen, utan på den pragmatiska otillräckligheten hos det nuvarande verktyget, vilket tvingar fram en omfaktorisering mot en klass som åter är adekvat. **[IP]**.

Distinktionen mellan mått och substantiell (Artikel X) är gränsen inom-klass/mellan-klass.

Avsnitt 4.4 drar den redan: en oenighet mellan faktoriseringar relaterade genom en koordinattransformation är en måttoenighet, lösbar genom översättning; en oenighet mellan faktoriseringar i olika ekvivalensklasser är substantiell, lösbar endast genom data eller omförhandlade kriterier. Artikel X:s krav på observatörsoberoende är skyddet mot att förväxla de två — mot att behandla en översättningsbar skillnad som en värdekonflikt, eller en värdekonflikt som ett blott översättningsmisslyckande. **[IP]**.

Och det sätter upp den pluralismfråga som nästa artikel tar sig an. Om faktoriseringar är icke-unika, miljöprivilegierade och individuellt benägna att falla ur sin klass när regimen skiftar, följer en naturlig designfråga omedelbart: snarare än att förbinda sig till en faktorisering, skulle ett system kunna upprätthålla flera och flytta sin vikt mot den som för tillfället håller? Det är en arkitekturfråga, inte en grundvalsfråga, och det är där Artikel XIX börjar. Avsnitt 3.3:s stabila minoritetsattraktor — två förlustrankade faktoriseringar av samma miljö, båda nåbara — är den minsta instansen av det fenomen som den artikeln skalar upp: värdet av att hålla mer än en uppstyckning av en värld som ingen enskild uppstyckning fullt ut passar.

7. Slutsats

Serien börjar med en institution som redan har en modell av sin värld. Denna artikel frågar var modellens *variabler* kommer ifrån — den föregående uppstyckning som avgör vad institutionen överhuvudtaget kan representera — och svarar att de kommer från inget mer än ett begränsat system som försöker förutsäga sina egna observationer. Inget agentskap krävs, ingen överlevnadsinsats, inget mål bortom förväntan. Begränsad kapacitet tvingar fram komprimering; ett prediktionsmål får komprimeringen att välja de variabler som bär världens kausala struktur framåt; och resultatet är en faktorisering vid leder som följer världen, producerad av en passiv observatör utan något på spel.

Tre egenskaper hos den faktoriseringen, fastställda över fyrtio frön i två förhandsregistrerade körningar, förs in i resten av serien. Den *uppstår* oövervakat. Den misslyckas genom *helunderrumsblindhet* snarare än jämn suddighet, så att ett system vid sin gräns är en statisk observatör — som håller kartan, förlorar derivatan — vilket är varietetsgapet givet en mekanism och en form. Och den är *icke-unik*: beteendemässigt ekvivalenta faktoriseringar bildar stora ekvivalensklasser, det interna språket är fritt, och vid marginalen görs systemets val bland symmetriska alternativ av träningstillfälligheter snarare än av världen. Icke-unikhet är inte relativism, eftersom friheten är frihet inom en klass som verkligheten begränsar: det finns inget unikt korrekt koordinatsystem, men det finns bättre och sämre invarianter, och en institution är en förhandlare av ett koordinatsystem inom en privilegierad klass snarare än en upptäckare av världens sanna struktur eller en konvention som inte är ansvarig inför något.

Observationskanalen som varje senare artikel förutsätter är därför inte en primitiv att postulera utan det tidigaste som en begränsad prediktor bygger. Varietetsgapet väntar inte på intressen; det öppnas i samma stund som kapacitet möter en värld större än sig själv, vilket alltid sker. Allt serien säger om regulatorer, gränser, certifiering och drift sägs ovanpå en faktorisering som prediktion ensam redan producerade — och, enligt §3.3, redan producerade med en inbyggd blind fläck för rörelse som ingen mängd av samma mål reparerar.

8. Vad denna artikel inte visar

Den visar inte att påståendet om två ingredienser håller generellt. Avsnitt 2 argumenterar för det och §3 demonstrerar det i en miljö med en arkitekturfamilj. Att begränsad prediktion producerar en kausal faktorisering *här* är fastställt inom modellen; att den måste göra det, för varje begränsad prediktor i varje miljö, är den förmodan som demonstrationen stöder, inte ett teorem den bevisar. En enda miljö kan bekräfta tillräcklighet i ett fall och kan inte fastställa den universellt.

Den visar inte att passivitet och handling producerar samma faktoriseringar. Det starkare påståendet i §2.3 — att ingen insats krävs — är just ett påstående om det passiva fallet, och det säger inget om huruvida tillägg av handling förändrar vilka faktoriseringar som uppstår. Intervention ger ett system tillgång till världens kausala struktur genom en kanal som prediktion saknar (förmågan att testa, inte bara observera, vad som beror på vad), och huruvida denna tillgång skärper, utvidgar eller endast om-koordinerar den passiva faktoriseringen är oprövat här. Det är det naturliga nästa experimentet och artikeln påstår ingenting om dess utfall.

Resultatet om strukturerad blindhet är specifikt för ett kortsiktigt mål. Den statiska observatören i §3.3 behåller positioner och utesluter hastigheter eftersom, vid prediktionsoffset på några få steg, ges den nära framtiden mestadels av nuet. Under ett långsiktigt mål, där framtiden har drivit långt från nuet, blir hastigheten den mer värdefulla variabeln, och blindheten borde inverteras. *Formen* på resultatet — hel-underrumsoffer, aldrig jämn suddighet — är vad artikeln påstår överlever över olika mål; *vilket* underrum som offras är målberoende, och artikeln visar endast det kortsiktiga fallet.

Proberna ser endast linjär struktur. Varje återvinningssiffra är en linjär prob, genom registrerat val: påståendet gäller linjärt avkodningsbara variabler, minimistandarden för att säga att en variabel är representerad. En olinjär prob skulle finna mer, och i synnerhet kan återvinningen av hastighet vid $h = 8$, som den linjära proben rapporterar som brusig över frön, återspegla en kod som finns men ännu inte är linjäriserad. Där artikeln säger att en variabel saknas, är det ärliga påståendet att den inte är linjärt tillgänglig; genuin frånvaro och olinjär närvaro särskiljs inte.

Korrespondensen tränat nätverk–institution är genomgående tolkande. Varje institutionell läsning i denna artikel är **[IP]**. En GRU under en flaskhals är en modell av en begränsad prediktor; att ett departement, en myndighet eller en marknad faktorerar sin värld genom samma mekanism

är ett argument genom strukturell analogi, inte ett uppmätt faktum om någon institution. Artikelns empiriska påståenden är påståenden om modellen; deras räckvidd till styrning är exakt så stark som analogin, och inte starkare.

Den avgör inte den ontologiska frågan. Avsnitt 5 förkastar ontologisk preferens och vilar allt på pragmatisk preferens och kausal invarians. Det bevisar inte att verkligheten saknar en föredragen faktorisering — det är ett metafysiskt påstående som artikeln medvetet avstår från — endast att ramverket inte behöver någon sådan preferens, och att kausal invarians räcker för att göra "bättre" och "sämre" icke-godtyckliga. Huruvida världen, ytterst, är styckad vid egna leder är en fråga som denna artikel är byggd för att inte behöva ett svar på.

Appendix A — Modell, träning och utdata

Konventioner. Nivåerna följer serien: **[R]** rigorös, **[IP]** i princip, **[H]** heuristisk; "**[R inom modellen]**" markerar resultat som är exakta för den angivna modellen utan anspråk bortom den. De två registrerade körningarna är `paper_0-01-4-multiseed_factorization.py` (frön 0–19, dolda storlekar {2, 4, 8, 16}) och `paper_0-01-7-confirmation_run.py` (frön 20–39, dolda storlekar {2, 3}); deras förhandsregistreringar, med fastställda tröskelvärden och nollhypoteser, är `paper_0-01-3-multiseed-preregistration.md` och `paper_0-01-6-confirmation-preregistration.md`. Varje siffra som citeras nedan skrivs ut av dessa skripts analysblock i `multiseed_summary.txt` och `confirmation_summary.txt`.

A.1 Miljö

En ensam prick rör sig i en enhetslåda med reflekterande väggar. Dess latent tillstånd är (x, y, v_x, v_y) , uppdaterat genom $x \leftarrow x + v_x \Delta t$ (och likaså y) med $\Delta t = 0.05$; en väggkontakt negerar motsvarande hastighet och klipper positionen till $[0, 1]$. Startpositionerna är likformigt fördelade i lådan, starthastigheterna likformigt fördelade i $[-1, 1]$. Tillståndet observeras aldrig. Vad systemet ser är en 16×16 bildruta där ett 3×3 -område kring prickens pixelposition sätts till ett, med additivt gaussbrus ($\sigma = 0.1$) och klippning till $[0, 1]$. Miljön är symmetrisk under utbyte av x - och y -axlarna: positioner avbildas på de två arrayaxlarna genom samma indexberäkning, hastighetsfördelningen är isotrop, och bruset är oavhängigt och identiskt fördelat per pixel. Denna symmetri är vad som gör $h = 3$ -tie-breaket i §3.4 till ett symmetribrottstest snarare än en mätning av en inbyggd bias; den närapå jämna 11/9-ensemblesplitten är beviset för att ingen bias överlever på den nivå som proben mäter.

A.2 Uppgift och modell

Från varje trajektoria om 200 steg är träningsexemplen fönster om 20 konsekutiva bildrutor; målet är prickens sanna position vid offset $\{5, 10, 20\}$ bortom fönstret. Modellen är en enkellagers GRU med dold bredd h som avbildar den 256-dimensionella bildsekvensen till ett slutligt dolt tillstånd, följt av en linjär avkodare till de 3×2 framtida positionerna. Målfunktionen är medelkvadratfelet för dessa positioner. Observera att *målet* är position vid alla offset; hastighet är aldrig ett mål och övervakas aldrig. Att det dolda tillståndet alls kommer att koda in hastighet (§3.2) är därför emergent — hastighet representeras instrumentellt eftersom den krävs för att förutsäga framtida position, inte för att något efterfrågade den.

Träning använder Adam med 10^{-3} , batchstorlek 128, upp till 25 epoker med tidigt stopp (tålmod 5) på en undanhållen 20% valideringsuppdelning. Körning 1 använde 600 trajektorier; pilotkörningen som föregick den (omklassificerad som en pilot av det registrerade protokollet, §3.1) använde 2000 över 50 epoker, vilket är anledningen till att pilotens enskilda trajektorier landade rent i den axellägesattraktor som flerfröfördelningen senare visade vara en $\sim 15\%$ minoritet.

A.3 Prober och mått

Efter träning extraheras det slutliga dolda tillståndet på en undanhållen probuppsättning (de sista 2000 valideringsexemplen). Varje latent skalär regresseras på det dolda tillståndet genom vanlig linjär regression, och återvinning rapporteras som R^2 på den uppsättningen. Linjära prober är registrerade, inte tillfälliga: påståendet gäller linjärt avkodningsbar struktur, och negativ R^2 (en prob sämre än medelvärdesprediktorn) klipps till noll innan något aggregat bildas.

Två asymmetrimått sammanfattar $h = 2$ (och lägesetiketten vid $h = 3$). Med per-axel-återvinning $A_x = \frac{1}{2}(R_x^2 + R_{v_x}^2)$, $A_y = \frac{1}{2}(R_y^2 + R_{v_y}^2)$ och per-typ-återvinning $A_{\text{pos}} = \frac{1}{2}(R_x^2 + R_y^2)$, $A_{\text{vel}} = \frac{1}{2}(R_{v_x}^2 + R_{v_y}^2)$ är axelasymmetrin $|A_x - A_y|$ och typasymmetrin $|A_{\text{pos}} - A_{\text{vel}}|$. Körning 1 registrerade axelmåttet som sin operationalisering av strukturerad blindhet; när den misslyckades registrerade körning 2 typmåttet och unionskriteriet $\max(\text{axis}, \text{type}) > 0.3$ (det allmänna "ingen jämn suddighet"-påståendet) på nya frön. Endast för beskrivande lägesetiketter är ett frö *likformigt* om ingen asymmetri överstiger 0.3 och får annars etiketten för den större asymmetrin; de registrerade besluten använder de råa måtten, aldrig etiketten.

A.4 Registrerade utfall

Körning 1 (frön 0–19): emergens stöds för positioner vid varje kapacitet och för hela tillståndet vid $h = 16$ (medianer: $x, y \geq 0.86$ för alla h ; hastigheter 0.76–0.79 vid $h = 16$); axeloperationaliseringen av strukturerad blindhet *misslyckades* (3/20); förutsägelsen om avtagande abstraktion *misslyckades* ($h = 16$ förbättrade hastighetsåtervinningen jämfört med $h = 8$ snarare än endast pixeldetaljer, så platåpåståendet dras tillbaka och förekommer inte i artikelns påståenden). Körning 2 (frön 20–39): typstrukturerad blindhet *stöds* (17/20); ingen jämn suddighet *stöds* (20/20, och 40/40 sammanslaget över körningarna); diskret hastighetsurval vid $h = 3$ *stöds* (20/20 över tröskeln inom frö, gynnad hastighet delad 11 v_x / 9 v_y). Axellägesminoriteten återkom vid exakt 3/20 i båda körningarna.

A.5 Figurer

`multiseed_r2_boxplots.png` (latent återvinning per variabel över de fyra kapaciteterna, frön 0–19);
`multiseed_h2_symmetry.png` (histogram över tappad axel och A_x mot A_y -spridningsdiagram vid $h = 2$, som visar axeloperationaliseringens misslyckande); `confirmation_h2_modes.png` (axelasym mot typasym vid $h = 2$, frön 20–39, typklustret och de tre axellägesutliggarna);
`confirmation_h3_tiebreak.png` ($R_{v_x}^2$ mot $R_{v_y}^2$ vid $h = 3$, de två ockuperade hörnen och den tomma diagonalen som gör urvalet diskret).