




Guvernörer, vaktposter och broar

Det institutionella värde som vinnaren-tar-allt-urval inte belönar

Rapport XIX i serien Styrning som ingenjörskonst

Visar att en faktorisering kan bära tre funktionellt åtskilda sorters värde — att styra väl, varna tidigt eller hålla samman ekologin — och att dessa dissocierar: den som styr bäst är i allmänhet inte den som varnar bäst eller förbinder bäst. Vinnaren-tar-allt-urval belönar endast den första. Demonstrerat över tjugo oberoende omskolade modellekologier.

Björn Kenneth Holmström

Juli 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/sv/working-papers/governors-sentinels-bridges>

*Rapport 0 fastställde att faktoriseringar inte är unika och att vilken som är bäst bestäms av omgivningen, inte fastställs av världen. Denna artikel tar upp den arkitekturfråga som icke-unikheten tvingar fram. Om ingen enskild faktorisering passar varje regim finns en stående frestelse att välja den för tillfället bästa och styra genom den — och en stående fråga om vad det urvalet förkastar. Svaret, demonstrerat över tjugo oberoende tränade modellekologier, är att en faktorisering kan bära åtminstone tre funktionellt åtskilda sorters värde — den kan styra väl, varna tidigt eller hålla samman ekologin — och att dessa dissocierar: den som styr bäst är i allmänhet inte den som varnar bäst eller förbinder bäst. Vinnaren-tar-allt-urval belönar endast den första. De empiriska påståendena märks **[R inom modellen]**; de institutionella tolkningarna är **[IP]**. Två av de tre rolldissociationerna replikeras rent, arkitekturpåståendet replikeras i sin bärande hälft, och en designkonsekvens bekräftas i riktning men når inte upp till sin förhandsregistrerade styrka — rapporteras som sådan snarare än slätas över.*

Sammanfattning

En adaptiv institution som möter en föränderlig omgivning kan inte permanent förbinda sig till en enda modell av sin värld, eftersom Rapport 0 visade att den bästa faktoriseringen är regimberoende. Den naturliga responsen är att bevara flera och styra genom den som för tillfället presterar bäst — ett vinnaren-tar-allt-urval över en bevarad portfölj. Denna artikel frågar vad det urvalet lämnar på bordet.

Med ett modellzoo bestående av sju prediktiva faktoriseringar tränade på en studsande-prick-miljö under fem stressregimer, utvärderade på en regimskiftande ström, urskiljer vi tre roller en faktorisering kan spela. En *guvernör* agerar med lågt fel under rådande förhållanden. En *vaktpost* upptäcker fel innan den aktiva guvernören gör det, oavsett om den själv skulle kunna styra väl. En *bro* intar en strukturellt central position i grafen av ömsesidigt översättningsbara faktoriseringar och håller ekologin sammankopplad oavsett hur den styr eller varnar. Det centrala påståendet är att dessa roller dissocierar — att styrningsförmåga varken förutsäger varningsvärde eller konnektivitetsvärde — och att vinnaren-tar-allt-urval, som enbart belönar styrningsförmåga, därför gör sig av med de andra två som en bieffekt.

Påståendena är registrerade på *fenomennivå*, inte *identitetsnivå*: vi förhandsregistrerar inte att någon specifik tränad modell behåller sin roll, endast att rollstrukturen återkommer över oberoende tränade ekologier. En förhandsregistrerad replikation tränar om modellzoo:t under tjugo frön. Resultaten [**R inom modellen**]: adaptiv revision (bevara alla för avkänning, förbind en för handling, återöppna vid evidens) följer ett ouppnåeligt orakel och slår en monokultur i alla tjugo zoo; den främsta guvernören skiljer sig från den främsta vaktposten i sjutton zoo, med svagt korrelerade poäng för guvernör och vaktpost ($\rho = 0.48$); den främsta guvernören skiljer sig från den främsta bron i samtliga tjugo, med en modell som inte är främsta guvernör som artikulationspunkt i ekologin i nitton fall. Två registrerade påståenden överlevde inte omträningen, och båda disciplinerar pilotens överpåståenden: pilotfyndet att blind stängning är den *sämsta* arkitekturen var en engångsartefakt från ett enda zoo — arkitekturerna som saknar adaptiv avkänning byter bottenposition beroende på frö — och pilotens rena portföljresultat (täckningsvalda vaktpostuppsättningar slår individuellt bästa) bekräftas i riktning men ligger under den registrerade tröskeln, så vaktpostdissociation visar sig endast vara svagt exploaterbar genom portföljkonstruktion vid de testade storlekarna.

Konsekvenserna för serien är tre. Dissociationen mellan guvernörs- och vaktpostvärde ger Rapport XVI:s källtermer en mekanism: optimering mot den bästa styrenheten gör sig av med tidig varningskapacitet, inte för att varning är kostsam utan för att den är okorrelerad med styrningsförmåga. Brorollen tillför ett felmod som saknas i de tidigare rapporterna — styrning kan misslyckas inte bara genom dålig handling eller missad varning utan genom förlust av konnektivitet i faktoriseringsrymden, en fragmentering som ingen förbättring av den aktiva guvernören reparerar. Och certifiering (Rapport XVII) visas kräva testning av alla tre roller, eftersom ett system som endast granskas för styrningsduglighet är blint för det vaktpost- och brovärde som dess optimering tyst kasserar.

1. Arkitekturfrågan

1.1 Vad icke-unikheten tvingar fram

Rapport 0 avslutades med ett uppskov. Efter att ha visat att faktoriseringar inte är unika, att beteendemässigt likvärdiga sådana bildar stora ekvivalensklasser och att omgivningen bland *icke-ekvivalenta* sådana gynnar den som följer dess aktuella kausala variabler, konstaterade den att en designfråga omedelbart följer och lade den åt sidan. Frågan är denna. Om ingen enskild faktorisering är tillräcklig under varje regim ett system kommer att möta, och om systemet kan hålla fler än en, hur många bör det då hålla, och på vilken grund bör det behålla dem som det för tillfället inte använder? Rapport 0:s egen minimala modell innehöll redan det minsta exemplet på trycket: två förlustrankade faktoriseringar av samma omgivning, båda nåbara, en styrande och en inte. Skalat uppåt är det en portfölj, och en portfölj väcker frågan om vad varje hållen faktorisering är *till för*.

Standardssvaret är vinnaren-tar-allt. Under varje fast regim finns en bästa styrenhet; ett system som kan identifiera den bör handla genom den, och bör växla när regimen skiftar och en annan styrenhet blir bäst. Detta är ingen halmgubbe – det är nära optimalt när omgivningen är stationär eller långsamt varierande, och Rapport 0:s resultat om den privilegierade klassen tycks stödja det, eftersom det säger att omgivningen verkligen diskriminerar mellan faktoriseringar på basis av tillräcklighet. Om verkligheten belönar den tillräckliga faktoriseringen, varför då bevara de otillräckliga?

Svaret som denna artikel utvecklar är att ”tillräcklig” gjorde mer arbete i den meningen än vad enbart styrningsprestanda kan bära. En faktorisering som styr dåligt under den rådande regimen kan ändå göra något som den aktuella styrenheten inte kan: se det fel som är på väg att inträffa, eller hålla öppen en översättningsväg mellan faktoriseringar som annars skulle driva utom ömsesidig räckvidd. Detta är former av tillräcklighet som styrningsprestandaredovisning inte mäter, och vinnaren-tar-allt-urval, just för att det optimerar styrningsprestanda, är blint för dem. Frågan om vad som ska bevaras besvaras därför inte genom att rangordna styrenheter. Den kräver kunskap om huruvida värdet av en bevarad faktorisering uttöms av hur väl den skulle styra – och denna artikels empiriska belastning är att så inte är fallet.

1.2 Arkitekturerna under luppen

Undersökningen är konkret. Sju prediktiva faktoriseringar av en studsande-prick-miljö, som skiljer sig i kapacitet och i den stressregim de tränades under, bildar ett fast zoo. De möter en ström som skiftar regim sex gånger – normal, vind, dämpad, oskärpa, normal, vind – och fem sätt att använda zoo:t jämförs mot den. En *monokultur* förbinder sig från början till den enskilda modell med bäst valideringsförlust och reviderar aldrig. *Full pluralism* medelvärdesbildar alla sju prediktioner vid varje steg. Ett *vinnaren-tar-allt-orakel* växlar, vid varje steg, till den modell som faktiskt har det lägsta aktuella felet – en ouppnåelig övre gräns, eftersom den läser just det framtida fel den är tänkt att förutsäga, inkluderad endast för att markera taket. En *sluten vinnaren-tar-allt* förbinder sig till en modell och omprövar sitt val endast med långa fasta intervall. Och en *adaptiv periodisk revision* upprätthåller en rullande uppskattning av varje modells senaste fel och byter aktiv styrenhet när en utmanare konsekvent slår den sittande med en marginal – den bevarar alla faktoriseringar för avkänning samtidigt som den förbinder sig till en för handling, och återöppnar förbindelsen när evidensen vänder.

Dessa fem är inte godtyckliga. De är punkter på en enda avvägning mellan hur mycket arkitekturen *avkänner* – hur många faktoriseringar den håller levande och utvärderade – och hur mycket den *förbinder sig* – hur skarpt den sluter sig kring en för handling. Monokultur och slutna WTA befinner sig vid den lågavkännande änden; full pluralism avkänner allt men förbinder sig aldrig, och späder ut skarpa specialister till ett medelvärde; oraklet är den ouppnåeliga gränsen för perfekt avkänning och perfekt förbindelse; och adaptiv revision är den uppnåeliga versionen av den gränsen, som avkänner brett och förbinder sig provisoriskt. Avsnitt 3 rapporterar vilka av dessa ordningar som överlever omträning. Men arkitekturjämförelsen är endast ramen. Substansen är vad avkänningen bevarar – och varför de bevarade faktoriseringarna är värda att behålla även när de aldrig styr.

2. Fenomen, inte identitet

2.1 Den metodologiska faran

Piloten till denna artikel producerade en levande uppsättning fynd om sju specifika tränade modeller. En modell varnade för fel som den aldrig styrde igenom; en annan var strukturellt central för ekologin trots att den sällan styrde; en tredje, tränad på oskärperegimen, visade sig vara nästan oanvändbar under oskärpa – dess träningsetikett ingen vägledning till dess institutionella roll. Lästa naivt är detta påståenden om `normal_h8`, `damped_h8` och `blur_h8` – tre särskilda artefakter producerade av tre särskilda träningskörningar. Som påståenden om de artefakterna är de sanna och nästan värdelösa, eftersom ingenting om styrning följer av sju neurala nätverks tillfälliga egenskaper. Faran är att missta en beskrivning av ett tränat zoo för en upptäckt om faktoriseringspluralism.

Artikelns centrala metodologiska åtagande är den distinktion som upplöser faran. Ett *modellidentitetspåstående* säger att en namngiven modell spelar en namngiven roll – att `normal_h8` är en vaktpost. Ett *fenomennivåpåstående* säger att rollstrukturen återkommer – att i en godtycklig tränad ekologi är den modell som styr bäst i allmänhet inte den som varnar bäst, vilka dessa modeller än råkar vara. Det första är en egenskap hos artefakter och är inte registrerat någonstans i denna artikel. Det andra är en egenskap hos faktoriseringspluralism som sådan, och det är den enda sortens påstående som artikeln gör anspråk på. Vilken modell som är vaktposten är en tillfällighet av ett frö; att vaktposten i allmänhet inte är guvernören är resultatet.

2.2 Vad detta förpliktar metoden till

Att hålla påståendena på fenomennivå dikterar experimentet. Det räcker inte att utvärdera det fasta zoo:t över många miljödragningar, eftersom det endast skulle fastställa att de *namngivna* rollerna är stabila under utvärderingsbrus – och lämna den djupare frågan, huruvida rollstrukturen är en strukturell konsekvens av pluralism eller en tillfällighet hos dessa sju modeller, orörd. Rollstrukturen kan endast testas genom att regenerera ekologin: träna om hela zoo:t under nya frön, så att modellerna själva skiljer sig från körning till körning, och fråga om *dissociationen* återkommer trots att identiteterna inte gör det. Varje frö producerar ett nytt zoo – nya initialiseringar, nya träningsdata, ny utvärderingsström – och de registrerade frågorna ställs till var och en. Tjugo sådana zoo utgör den registrerade evidensen.

Detta är anledningen till att poängen som definierar de tre rollerna specificeras som funktioner beräkningsbara på *vilket* zoo som helst, inte som etiketter knutna till särskilda modeller. Guvernörspoängen är det negativa genomsnittliga strömfelet för en modell använd som ensam styrenhet. Vaktpostpoängen är antalet distinkta feltoppar som en modell varnar för i förväg medan den är undertryckt. Brospoängen är modellens betweenness i grafen över beteendestånd, trösklad där grafen precis hänger samman. Var och en är ett tal som vilket zoo som helst ger, så dissociationspåståendena – att argmax för en poäng i allmänhet inte är argmax för en annan, att poängen är svagt korrelerade över den poolade populationen – är påståenden om populationen av zoo, inte om sju fasta punkter i den.

Förutsägelserna fastställdes i förväg med förbundna trösklar och förbundna nollhypoteser, och rapporteras i §§3–6 exakt som de utföll: två av de fyra passerade rent, en passerade i sin bärande hälft och misslyckades i den hälft som piloten hade lutat sig mot, och en misslyckades snävt i den förutsagda riktningen. Modellidentiteter, den regimspecifika geometrin hos avståndsgrafen och de namngivna broarna för särskilda regimer förblir explorativa genomgående – illustrativa för fenomenet, aldrig evidens för det. Linjen som artikeln håller är att ett påstående förtjänar registrerad status endast om det överlever att modellerna själva tränas bort under det.

3. Adaptiv pluralism approximerar oraklet [R inom modellen]

Den första frågan är om arkitekturpåståendet överlever omträning. Piloten jämförde fem sätt att använda ett fast zoo av sju faktoriseringar mot en regimskiftande ström: en *monokultur* som förbinder sig till den enskilda modellen med bäst valideringsförlust; *full pluralism* som medelvärdesbildar alla sju prediktionerna; ett *vinnaren-tar-allt-orakel* som växlar till den modell som för tillfället är bäst (en ouppnåelig övre gräns, eftersom den läser det framtida fel den försöker förutsäga); en *sluten vinnaren-tar-allt* som låser fast en modell och omprövar endast med långa intervall; och en *adaptiv periodisk revision* som följer en rullande uppskattning av varje modells fel och byter när en utmanare konsekvent slår den sittande med en marginal. Den registrerade replikationen tränar om hela zoo:t under tjugo oberoende frön och frågar vilka av pilotens ordningar som återkommer.

Två påståenden var registrerade under P1, och de separerar sig rent. Det första – att adaptiv revision följer oraklet och slår monokulturen – höll i vart och ett av de tjugo zoo:na. Adaptiv låg närmare oraklet än full pluralism i 20/20 frön och slog monokulturen i 20/20. Detta är det bärande resultatet: en arkitektur som bevarar alla faktoriseringar för avkänning men förbinder sig till en för handling, och återöppnar förbindelsen när evidensen vänder, närmar sig robust prestandan hos ett orakel som inte kan existera, och slår robust att förbinda sig till den enskilda globalt bästa modellen. Den styrningsläsning som serien har burit sedan triadslingeartiklarna överlever intakt – **handla genom tillfällig stängning, lär genom återöppning** – nu som en fröstabil regelbundenhet snarare än en enskild trajektoria.

Det andra registrerade påståendet under P1 överlevde inte, och misslyckandet är värt att ange rakt ut eftersom piloten lutade sig mot det. Piloten fann att sluten vinnaren-tar-allt var den *sämsta* arkitekturen – den rena bilden av ”stängning utan avkänning” som den kardinalsyndens. Över tjugo omtränade zoo håller detta inte: sluten WTA var den *sämsta* arkitekturen i endast 2/20 frön, och den fulla femvägsordningen som piloten rapporterade höll i endast 1/20. Det som rubbar den är monokulturen, vars prestanda har mycket hög varians över frön: när den bäst-enligt-validering-modellen råkar generalisera över regimer är monokulturen endast medelmåttig, men när den inte gör det är monokulturen fångad utan mekanism att fly, och är sämre än en sluten WTA som åtminstone omprövar ibland. De två arkitekturer som saknar adaptiv avkänning – monokultur och sluten WTA – byter bottenposition mellan sig beroende på frö. Det ärliga påståendet är därför inte att blind stängning är det unika *sämsta* fallet, utan det svagare och sannare: **arkitekturerna utan adaptiv avkänning befinner sig i botten av ordningen, och vilken av dem som är sämst är inte stabilt**. Ramen ”stängning utan avkänning” var en egenskap hos ett zoo, inte hos jämförelsen.

4. Guvernör och vaktpost är olika roller [R inom modellen]

Pilotens mest suggestiva fynd var att en modell som sällan styr ändå kan upptäcka fel tidigt – att vara en dålig styrenhet och vara en användbar tidigvarningssensor är separerbara egenskaper. Om den separationen är en artefakt av sju särskilda tränade modeller är den en anekdot; om den återkommer över oberoende tränade zoon är den ett strukturellt drag hos faktoriseringspluralism. Detta är triadens första ben, registrerat som P2.

För varje omtränat zoo, definiera en *guvernörspoäng* (negativt genomsnittligt strömfel vid användning som ensam styrenhet) och en *vaktpostpoäng* (antalet distinkta feltoppsepisoder som en modell varnar för, där en varning innebär att modellen konsekvent överträffar den aktiva styrenheten medan den är undertryckt, före en senare topp med en fastställd ledtid). Det registrerade testet frågar om den bästa guvernören och den bästa vaktposten är samma modell, och om de två poängen är korrelerade över den poolade populationen av modeller.

De dissocierar. Den främsta guvernören skilde sig från den främsta vaktposten i 17/20 zoon, och den poolade rangkorrelationen mellan guvernörs- och vaktpostpoängen var 0,481 – under den registrerade övre gränsen på 0,5, om än med liten marginal. Båda villkoren passerade, och den ärlighet som marginalen kräver är att korrelationen klarade sin tröskel med en hårsman; dissociationen är verklig och replikerbar men inte enorm. Det som replikeras är det kvalitativa påståendet: **den faktorisering som styr bäst är i allmänhet inte den som varnar bäst, och styrningsskicklighet förutsäger vaktpostvärde endast svagt**. De alternativ som ser problem tidigt är, oftare än inte, alternativ som skulle styra dåligt om de fick kontroll.

Styrningsläsningen är källtermsberättelsen från Rapport XVI gjord konkret. Ett system som renodlat optimerar för den bästa aktuella styrenheten optimerar guvernörsvärde, och guvernörsvärde är nära ortogonalt mot vaktpostvärde; så optimeringen gör sig av med tidigvarningskapacitet som en bieffekt, inte för att varning är kostsam utan för att den är okorrelerad med det som maximeras. Ett minoritetsramverk som är olämpligt att driva institutionen kan ändå vara det som upptäcker en klass av fel som den dominerande ramen är blind för – revisorn, oppositionen, den marginaliserade forskaren – och skälet att bevara det är just att dess värde ligger i en dimension som urval inte belönar. En reservation som piloten insisterade på och replikationen bekräftar: vaktpostprecisionen är genomgående låg (varningar är ofta falska), så påståendet är *svag men mätbar tidig varning till en betydande kostnad av falsklarm*, aldrig tillförlitlig förutsägelse. De institutionella motsvarigheterna genererar också många falsklarm; deras värde ligger inte i att de vanligtvis har rätt utan i att de ibland är tidiga nog för att spela roll.

5. Portföljkonstruktion: effekten är verklig men svag [R inom modellen]

Om vaktpostvärde dissocierar från styrningsvärde följer en designfråga: när man bevarar en begränsad portfölj av faktoriseringar för deras varningsvärde, bör man då behålla de individuellt bästa vaktposterna, eller en uppsättning vald för kompletterande täckning? Pilotens svar från ett enda zoo var avgörande – diversifierade, täckningsvalda portföljer slog portföljer av de individuellt starkaste modellerna. P3 registrerade detta på de omtränade zoon, och här levererar replikationen ett genuint, lärorikt delresultat snarare än en ren bekräftelse.

Vid portföljstorlek fyra slog en portfölj som valts girigt för marginell topptäckning en portfölj av de fyra bäst styrande modellerna i 11 av 20 zoon, med en genomsnittlig täckningsfördel på ytterligare två toppepisoder. Riktningen är den förutsagda – den registrerade nollhypotesen, att urval efter högsta nytta skulle vinna en majoritet och reducera vaktpostbevarande till ett rangordningsproblem, *inträffade inte*; urval efter högsta nytta vinner inte. Men det registrerade godkännandet krävde att den diversifierade portföljen skulle vinna i minst 12 av 20 zoon, och den vann i 11. **P3 misslyckas som registrerat.** Portföljeffekten är riktningsmässigt bekräftad och genomgående liten: diversifierat urval är i genomsnitt bättre, men vid denna portföljstorlek och denna zoostorlek är fördelen för liten för att klara en majoritetsgräns över frön.

Vi rapporterar detta som ett misslyckande och avstår från att rädda det. Den positiva genomsnittliga fördelen är verklig och pekar åt rätt håll, och det vore lätt att notera att elva av tjugo plus ett positivt medelvärde "egentligen" stöder påståendet – men tröskeln fastställdes i förväg just för att en nära-miss skulle läsas som en nära-miss. Den försvarbara slutsatsen är snävare än pilotens: dissociationen i §4 är verklig (guvernörer är inte vaktposter), men den är endast svagt *utnyttjbar* genom portföljkonstruktion vid $K=4$. Den skarpa designregel som piloten föreslog – välj vaktposter efter marginell täckning, inte individuell prestige – stöds i riktning men inte i styrka. Huruvida en bredare klyfta öppnar sig vid mindre portföljer, där komplementaritet har mer utrymme att spela roll, är en fråga för ett separat registrerat test och inget denna artikel besvarar.

6. Guvernör och bro är olika roller [R inom modellen]

Den tredje rollen kommer från topologi snarare än prestanda. Behandla varje faktorisering som en nod och de beteendemässiga avstånden mellan dem som kanter; grafen, trösklad vid den punkt där den precis blir sammanhängande, har artikulationspunkter — noder vars borttagning bryter sönder ekologin — och noder med hög betweenness som ligger på många kortaste vägar mellan andra. En faktorisering kan vara strukturellt central i denna mening oavsett om den styr eller varnar väl: dess värde ligger i att den håller de andra faktoriseringarna ömsesidigt nåbara. Detta är *bro*-rollen, registrerad som P4.

Det är det starkast replikerade resultatet i artikeln. Modellen med högst betweenness skilde sig från den främsta guvernören i 20/20 zoon, och i 19/20 zoon var minst en modell utanför de två bästa guvernörerna en artikulationspunkt i minst en regimgraf. Brovärde och styrningsvärde är i huvudsak orelaterade: den faktorisering som håller samman ekologin är, med nästan perfekt regelbundenhet över omtränade zoon, inte den faktorisering som styr den. Detta blottlägger ett felmod som är skilt från både dålig handling och missad varning. En institution kan styra väl och varna väl och ändå fragmenteras, om den faktorisering som höll dess delar ömsesidigt begripliga undertrycks — och eftersom en bros bidrag är osynligt i vanlig prestanda registrerar ingenting i vare sig guvernörs- eller vaktpostvärdesredovisningen dess förlust förrän grafen brister. **Styrningsmisslyckande är inte bara dålig prediktion eller långsam varning; det kan vara förlust av konnektivitet i faktoriseringsrymden** — en långsam divergens av världsmodeller som ingen mängd finjustering av den aktiva guvernören reparerar, eftersom reparationen som krävs är en återuppbyggd översättningsväg, inte en bättre styrenhet.

Triaden sluts nu. Tre funktionellt åtskilda sorters institutionellt värde har visats dissociera över oberoende tränade ekologier: *guvernören* som handlar väl, *vaktposten* som varnar tidigt, och *bron* som bevarar översättning. Två av de tre dissociationerna replikeras rent (guvernör≠vaktpost, guvernör≠bro; P2 och P4), arkitekturpåståendet replikeras i sin bärande hälft (P1a), och portföljkonsekvensen bekräftas i riktning men inte i registrerad styrka (P3). En enskild faktorisering kan inneha en roll och inte de andra; vinnaren-tar-allt-urval belönar endast den första; och skälet att bevara resten är att de bär värde längs dimensioner som urvalstrycket inte mäter.

Roll	Värde	Belönas av urval?
Guvernör	handlar med lågt fel under rådande förhållanden	direkt
Vaktpost	upptäcker fel före den aktiva guvernören	nej — ortogonal mot styrningsskicklighet (P2)
Bro	håller faktoriseringsekologin sammankopplad	nej — orelaterad till styrningsskicklighet (P4)

7. Vad detta återgrundar, och vad det öppnar

7.1 Källtermer får en mekanism

Rapport XVI introducerade källtermer: de fel ett system genererar genom att undertrycka de alternativ det optimerade bort, den ackumulerande kostnaden av att ha slutit sig kring en faktorisering. Den beskrev fenomenet men sade inte *varför* optimering gör sig av med de alternativ som skulle ha varnat för problem — om varningskapacitet är dyr, medvetet bortbytt, eller förlorad via någon annan väg. Avsnitt 4 tillhandahåller vägen. Vaktpostvärde är nära ortogonalt mot styrningsvärde ($\rho = 0,48$ över den poolade populationen, främsta guvernören $\neq$ främsta vaktposten i 17 av 20 zoon). Ett system som optimerar styrningsprestanda betalar därför inte ett pris för att kasta bort varningskapacitet; det kastar bort den som en bieffekt av att maximera en storhet som varningskapacitet inte korrelerar med. Källtermen är inte en kostnad systemet valde att ådra sig utan en dimension optimeringen inte kunde se. Detta är ett skarpare och mer nedslående påstående än det ursprungliga: man kan inte undvika källtermer genom att vara villig att betala för vaktposter, eftersom urvalstrycket inte representerar dem som något köpbart — de måste bevaras genom en mekanism utanför styrningsmålet, vilket är precis vad den periodiska revisionens avkänningskanal är.

7.2 Ett felmod som serien inte hade

Brorollen (§6) tillför något genuint nytt till seriens katalog över misslyckanden. De tidigare artiklarna analyserar att styrning bryter samman genom dålig handling (en guvernör otillräcklig för sin regim) eller genom missad varning (en källterm ignorerad tills den toppar). Broresultatet identifierar ett tredje mod som ingetdera av dessa beskriver: förlust av konnektivitet i faktoriseringsrymden. En ekologi kan vara full av tillräckliga guvernörer och användbara vaktposter och ändå fragmenteras, om den faktorisering som höll dess delar ömsesidigt översättningsbara tas bort — och eftersom en bro inte bidrar till styrnings- eller varningsprestanda registreras dess borttagning i inget prestandamått förrän grafen redan har brustit. Resultatet var det starkast replikerade i artikeln (främsta guvernören $\neq$ främsta bron i 20 av 20 zoon; en modell som inte tillhör de främsta guvernörerna en artikulationspunkt i 19 av 20), vilket gör felmodet inte till en kuriositet utan till en stående strukturell risk för varje system som utvärderar sina komponenter endast efter vad de gör snarare än efter vad de förbinder. I institutionella termer är detta forskningsinstitutet som inte sätter någon policy men låter två ministerier förstå varandra, eller det

regionala organet som inte styr någonting men håller en marginaliserad gemenskap läsbar för centrum: nedlagt efter en resultatgenomgång, och saknat först när den översättning det i tysthet upprätthöll är borta.

7.3 Certifiering måste testa tre roller

Rapport XVII ramade in certifiering som att testa om en faktorisering förblir tillräcklig för sin värld. Avsnitten 4 och 6 visar att tillräcklighet har åtminstone tre oberoende komponenter, och att en certifieringsregim som endast mäter styrningstillräcklighet är strukturellt blind för två av dem. Ett system kan klara varje test av hur väl det handlar och ändå göra sig av med de vaktposter som skulle varna för nästa regim och de broar som håller dess ekologi samman, eftersom dessa bidrag är osynliga för styrningsprestandarevision. Certifiering som är tillräcklig för bilden i denna artikel måste utvärdera varningstäckning och konnektiv centralitet som separata axlar — en portföljnivårevision av roller, inte en komponentnivårevision av prestanda. Detta är den konstruktiva motsvarigheten till §7.1:s nedslående resultat: källtermer kan inte köpas, men de kan *revideras för*, om certifieringsregimen är byggd för att se de dimensioner som styrningsmålet inte kan.

7.4 Vad detta öppnar: faktoreringsrymdens geometri och topologi

Två explorativa fynd från det underliggande arbetet är inte registrerade här men markerar riktningen som nästa artikel tar. Det första är att det beteendemässiga avståndet mellan faktoriseringar inte är fast: samma modeller ligger nära under en regim och långt ifrån under en annan, så metriken på faktoreringsrymden är miljöinducerad och tidsvarierande snarare än en fast bakgrund (regimavståndsmatriserna korrelerar så högt som 0,90 mellan vissa regimpar och så lågt som 0,09 mellan andra). Det andra är att konnektivitetströskeln — den minsta översättningstolerans vid vilken ekologin förblir sammankopplad — skiljer sig åt mellan regimer, så att vissa stressregimer pålägger en högre "översättningsbörda" än andra, och konnektivitet kan förloras antingen genom att höja den bördan eller genom att ta bort en bro. Båda anges här endast som motivation; behandlade ordentligt kräver de sin egen registrerade replikation, eftersom den nuvarande körningen håller dem som illustrativa. De är ämnet för en planerad syskonartikel om faktoreringsrymdens geometri och topologi, för vilken rollen som etableras här är grunden: guvernörer, vaktposter och broar är de objekt vars föränderliga avstånd och konnektivitet den artikeln skulle mäta.

8. Vad denna artikel inte visar

Två registrerade förutsägelser misslyckades, och artikelns påståenden är trimmade för att matcha. Pilotens fynd att slutet vinnaren-tar-allt är den *sämsta* arkitekturen replikerades inte (§3): arkitekturerna som saknar adaptiv avkänning befinner sig i botten av ordningen, men vilken som är sämst är fröberoende, så ”stängning utan avkänning är det kardinala misslyckandet” dras tillbaka. Pilotens rena portföljresultat replikerades inte med styrka (§5): täckningsvalda vaktportföljer slog individuellt bästa i riktning, men i endast 11 av 20 zoon mot en registrerad ribba på 12, så designregeln ”välj vaktposter efter marginell täckning” stöds riktningsmässigt men inte vid den förhandsregistrerade tröskeln. Inget av misslyckandena repareras genom omtolkning.

De bekräftade dissociationerna är kvalitativa, och en är snäv. P2 passerade, men guvernör-vaktpost-rangkorrelationen klarade sitt 0,5-tak endast vid 0,48; dissociationen är verklig och replikerbar men inte stor, och artikeln påstår inte att styrnings- och varningsvärde är orelaterade, endast svagt relaterade. P4 är däremot stark. Artikelns tilltro till trerollsbilden vilar huvudsakligen på de två rena resultaten (P1a, P4) och de två kvalificerade (P2, P3), och bör inte läsas som enhetlig.

En miljöfamilj, en zoosammansättning, en arkitekturfamilj. Den studsande pricken med fem stressregimer är en enda miljötyp; uppsättningen av sju modeller är fast över frön så att endast initialisering och data varierar, vilket testar dissociationens återkomst men inte dess robusthet mot en annan uppsättning faktoriseringar; och varje modell är en liten GRU-prediktor. Att rollerna dissocierar över omtränade zoon av *denna* sammansättning är fastställt; att de skulle dissociera i en materiellt annorlunda ekologi är den förmodan som resultatet stöder, inte ett påstående det bevisar.

Rollpoängen är metrikberoende. Vaktpostpoängen beror på detektorns fönster, marginal, horisont och topptröskel, alla fastställda i förväg men inte härledda från första principer; en annan rimlig detektor skulle producera andra antal och skulle kunna förskjuta de gränsfall som P2 och P3 utgör. Bropoängen beror på valet av beteendavstånd (RMS-differens av strömfelserier) och på att utvärdera betweenness vid konnektivitetströskeln. Dessa är försvarbara operationaliseringar, inte kanoniska sådana, och artikelns påståenden bör läsas som påståenden om dessa mått, robusta mot frö men inte visat robusta mot omdefinition.

Den institutionella läsningen är genomgående tolkande. Varje styrningsöversättning — källtermer, broar som översättningsbevarare, certifiering av roller — är [IP]. Experimentet handlar om sju GRU:er och en rörlig prick; att ett departement, en revisor eller ett regionalt organ instansierar samma rollstruktur är ett analogiargument vars räckvidd är exakt analogins styrka.

9. Metod och konfidens

Nivåerna följer serien: **[R]** rigorös, **[IP]** i princip, **[H]** heuristisk, där **[R inom modellen]** markerar resultat som är exakta för den angivna modellen och inte gör anspråk på mer. Det registrerade protokollet, med fastställda trösklar och nollhypoteser, är `paper_xix-0-preregistration.md`; den enzoo-pilot som det ersätter rapporteras i `03-results.md`, `04-results.md` och `05-results.md`, och betecknas genomgående som en pilot – den motiverar förutsägelseerna men räknas inte som evidens för någon av dem. Replikationsskriptet `paper_xix-1-role_triad_replication.py` tränar om tjugo zoon och beräknar varje registrerad storhet; dess analysblock skriver pass/fail-sammanställningen för §§3–6 till `role_triad_summary.txt`. Det centrala metodologiska åtagandet (§2) är att endast fenomennivåpåståenden – återkomst av rollstrukturen över omtränade ekologier – är registrerade; modellidentitetspåståenden är explorativa.

Appendix A — Modellzoo, ström och rollmått

Zoo (fast över frön). Sju prediktorer för den studsande-prick-miljön: `normal_h8`, `normal_h16`, `compressed_h2` (kapacitet 8, 16, 2, tränade på normalregimen), `wind_h8`, `damped_h8`, `blur_h8` (kapacitet 8, tränade på vind-, dämpad respektive oskärperegimen) samt `velocity_aux_h8` (kapacitet 8, normalregimen, med ett extra prediktionshuvud för aktuell hastighet). Var och en är en enkellagers GRU över den 256-dimensionella bildsekvensen med en linjär avkodare till framtida positioner vid offset $\{5, 10, 20\}$; `velocity_aux_h8` bär ett extra hastighetshuvud tränat med vikt 0,1. Sammansättningen hålls fast så att dissociation inte kan uppstå genom att uppsättningen ändras; endast fröet varierar.

Miljö och regimer. Basmiljön är Rapport 0:s studsande prick. Fyra stressregimer modifierar den: *vind* lägger till konstant acceleration, *dämpad* multiplicerar hastigheten med 0,6 vid väggkontakt, *oskärpa* faltar den renderade bilden med en 3×3 -boxkärna, och *normal* är basregimen. Per frö tränas varje modell på 500 sekvenser om 200 steg från sin regim (tolv fönster samplade per sekvens), 20 epoker med tidig stopp vid tålamod 4, Adam vid 10^{-3} . Detta är lättare än pilotens konfiguration, valt för att tjugo fulla zoon ska kunna tränas om över natten på en 8-kärnig CPU; vikter cachas per frö så att en avbruten körning kan återupptas utan att redan färdigtränade modeller tränas om.

Regimskiftesström. Sex segment om 500 steg — normal, vind, dämpad, oskärpa, normal, vind — sammanfogade, regenererade per frö. Alla modeller utvärderas på samma ström inom ett frö; det kvadratiske felet per tidssteg beräknas batchvis snarare än genom pilotens steg-för-steg-loop.

Guvernörspoäng. Negativt genomsnittligt strömfel för en modell använd som ensam styrenhet (lägre fel = bättre guvernör). De fem arkitekturerna i §3 beräknas från felvektorer per modell: monokultur använder modellen med bäst valideringsförlust rakt igenom; full pluralism medelvärdesbildar de sju prediktionerna (beräknat från prediktioner, inte från fel); oraklet tar det lägsta felet per steg; slutna WTA omprövar var 500:e steg över ett 30-stegs fönster; adaptiv revision byter när en utmanares rullande 50-stegsfel slår den sittandes med en 5% marginal under 5 på varandra följande steg.

Vaktpostpoäng. Från en detektor med rullande fönster (fönster 20, marginal 10% av det aktiva felet, horisont 50, minsta ledtid 10, topp = aktivt fel över två gånger regimens öppningsfönstermedian). En sann positiv är en distinkt toppepisod som en modell varnar för — den

slår konsekvent den aktiva styrenheten medan den är undertryckt, före toppen med minst den minsta ledtiden. Poängen är antalet distinkta episoder som varnats för (täckning); precision rapporteras vid sidan om men är inte poängen.

Propoäng. Beteendavståndet mellan två modeller är RMS-differensen av deras strömfelserier. Avståndsgrafen trösklas vid konnektivitetströskeln — den minsta kantvikt vid vilken den blir sammanhängande — och propoängen är betweennesscentralitet vid den tröskeln; artikulationspunktsstatus registreras per regimgraph. Kräver `networkx`.

Registrerade utfall. P1a (adaptiv följer oraklet, slår monokultur): godkänd, 20/20 på båda benen. P1b (sluten WTA är sämst): underkänd, 2/20. P2 (guvernör $\neq$ vaktpost): godkänd, främsta guvernör $\neq$ främsta vaktpost 17/20, poolad Spearman $0,48 < 0,5$. P3 (diversifierad $>$ högsta nytta-täckning vid $K = 4$): underkänd, diversifierad vann 11/20 mot en ribba på 12, genomsnittlig fördel $+2,0$ episoder. P4 (guvernör $\neq$ bro): godkänd, främsta bro $\neq$ främsta guvernör 20/20, icke-topp-2-guvernör en artikulationspunkt 19/20.

Explorativt (ej registrerat). Per-regim avståndsheatmaps och deras korsregimkorrelationer (fyndet om miljöberoende metrik, §7.4); namngivna modellroller; vaktpostens precision/recall-front; per-regim konnektivitetströsklar och broidentiteter; cykelrang och redundanstrender. Dessa illustrerar fenomenet och hålls för den planerade syskonartikeln om geometri/topologi.