




Variationsgapet

Vad vi inte optimerar för, förlorar vi förmågan att se

Rapport VI i serien Styrning som ingenjörskonst

Målfunktioner är observationsarkitekturer. Lågdimensionella värdefunktioner producerar samma strukturella kollaps som lågdimensionella styrkanaler. Variationsgapet — skillnaden mellan verklighetens dimensionalitet och värdearkitekturs — är ett enhetligt diagnostiskt verktyg för systemisk blindhet.

Björn Kenneth Holmström

Maj 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/sv/working-papers/the-variety-gap>

Sammanfattning

Varje styrsystem opererar under en explicit eller implicit målfunktion. Den funktionen väljer vilka dimensioner av verkligheten systemet uppmärksammar, vilka avvikelser det korrigerar, och – avgörande – vilka signaler som aldrig når beslutsnivån. Denna artikel behandlar målfunktioner som observationsarkitekturer. Med stöd i Ashbys lag om nödvändig variation (Ashby, 1956) och de styrteoretiska resultaten från serien *Governance as Engineering*, visar den att lågdimensionella värdefunktioner producerar samma strukturella kollaps som lågdimensionella styrkanaler: de exkluderade dimensionerna återinträder så småningom som olösliga kriser.

Introducerar *variationsgapet* (**G**) — avståndet mellan verklighetens effektiva dimensionalitet och värdearkitekturens dimensionalitet — som ett enhetligt diagnostiskt verktyg. Gapet definieras formellt (Bilagorna A–B) och operationaliseras genom mätprotokoll (Bilaga G), även om empirisk tillämpning av dessa protokoll återstår som framtida arbete. När **G** överstiger ett kritiskt tröskelvärde blir systemet konstitutionellt blint för de hot det mest behöver uppfatta (Conant & Ashby, 1970; Shannon, 1948). Argumentet utvecklas i tre explicita lager: en rigorös cybernetisk kärna, en tolkande tillämpning på nationella styrningsmisslyckanden och en avgränsad filosofisk extrapolation till metastyrningen av själva värdet.

Långsiktig civilisatorisk livskraft, hävdar artikeln, kräver inte bara högdimensionella värderingsarkitekturer utan en varaktig institutionell förmåga till öppen värdeevolution – en asymptotisk strävan mot fullständig verklighetsintegration som inget ändligt system kan slutföra (Beer, 1972; Kauffman, 2000).

Bidrag

- Etablerar **målfunktioner som observationsarkitekturer**, och förenar optimeringsteori, styrteori och epistemologi (Goodhart, 1975; Conant & Ashby, 1970).
 - Formulerar **Goodhart-Ashby-syntesen**: en målfunktion kommer att optimera bort sin egen förmåga att uppfatta systemets verkliga tillstånd närhelst den utelämnar en dimension som är kausalt kopplad till just den proxy den optimerar. (Manheim & Garrabrant, 2018).
 - Introducerar **variationsgapet** (**G**) som ett operationaliserbart mått på systemblindhet och kollapsrisk.
 - Demonstrerar ramverkets *potentiella förklaringsomfång* genom **landfallsstudier** tolkade som variationsgapsöverskridanden (Governance as Engineering Series; Gilens & Page, 2014; FAO, 2022). Dessa omtolkningar är konsistenta med ramverket men utgör inte oberoende validering.
 - Artikulerar **metastyrningsimperativet**: att utforma institutioner som medvetet kan utveckla sina egna värderingsarkitekturer innan **G** blir fatalt (Beer, 1979; von Foerster, 1984).
-

Del I — Styrningens grammatik och dess generalisering

Innan vi kan hävda att *vad ett system optimerar för avgör vad det kan se*, måste vi fastställa en mer fundamental princip: att observationsstrukturen — hur information samlas in, aggregeras och överförs — sätter hårda gränser för vad en styrenhet kan åstadkomma, oavsett dess intentioner, resurser eller kompetens. Den principen är ryggraden i serien *Governance as Engineering*, som tillämpar styrteori och kybernetik på institutionell design (Wiener, 1948), och den generaliseras naturligt från utformningen av institutioner till utformningen av de värden dessa institutioner tjänar.

1.1 Fyra felmoder, en mekanism

Serien *Governance as Engineering* modellerar styrsystem som återkopplingsslingor. Fem artiklar demonstrerar, över fyra skilda domäner, att en enda mekanism driver strukturella styrningsmisslyckanden: *aggregering förstör information*. När en central styrenhet endast observerar en sammanfattning — ett nationellt genomsnitt, en aggregerad preferensundersökning, en årlig beståndsuppskattning — förlorar den den rumsliga, tidsmässiga och fördelningsmässiga detaljrikedom som krävs för att reagera ändamålsenligt på det verkliga, distribuerade system den styr. Den förstörda informationen kan inte återskapas i efterhand. Ingen grad av institutionell kvalitet, deliberativ sofistikation eller verkställighetskapacitet kan agera på en signal som aldrig anlände (Shannon, 1948; Conant & Ashby, 1970).

Serien identifierar fyra karaktäristiska felmoder, var och en en manifestation av samma underliggande dynamik:

- **Rumslig blindhet** (Artikel I): En styrenhet som endast observerar det systemövergripande medelvärdet kan inte skilja en allvarlig lokal kris från en mild systemövergripande fluktuation. Dess fördröjda, enhetliga respons når fram för svag till den utsatta noden och stör de friska — "medelvärdessproblemet."
- **Frekvensgap** (Artikel II): En styrenhet med en enda responslatens kan inte stabilisera störningar över alla tidsskalor samtidigt. Snabba chocker passerar innan den hinner reagera; långsamma förskjutningar är osynliga för dess korta observationsfönster. Ingen ensklig arkitektur täcker hela störningsspektrumet.
- **Preferensosynlighet** (Artikel III): Representationskedjor djupare än två eller tre lager förstör variansen i medborgarnas preferenser. Brus överväldigar signal; policynivån styr en fantom — reagerar på brusstrukturen i sitt eget representationsmaskineri snarare än på vad medborgarna faktiskt vill.
- **Observationsmässig otillräcklighet** (Artikel IV): Styrsystem som övervakar en komplex förnybar resurs genom en enda aggregerad dimension (t.ex. total biomassa) kan inte upptäcka de snabba, medelsnabba och långsamma störningar som driver resursens dynamik. Den oobserverade variationen framträder som okontrollerad varians — ofta påskyld av en kollaps (Ostrom, 1990; Ashby, 1956).

Avgörande är att dessa felmoder inte bara adderas; de förstärker varandra. Artikel V demonstrerar *koordinationsmisslyckandets skatt*: när flera strukturella defekter samexisterar är den effektiva styrningskapaciteten inte summan av de individuella förlusterna utan deras produkt. Ett system som uppvisar alla fyra felmodellerna samtidigt är, i informell mening, kategoriskt oförmöget till de funktioner det påstår sig utföra.

1.2 Den enhetliga principen

Över varje undersökt domän gäller samma logik: en observationskanal reducerar dimensionaliteten hos den information den överför. Informationen som går förlorad är den information som var specifik — rumslig, tidsmässig, fördelningsmässig, dimensionell. När den väl har kasserats kan den inte rekonstrueras vid mottagaränden. Institutioner, hur väl designade de än är, opererar på den signal som överlever kanalen. Om den signalen har berövats just de dimensioner som krävs för att upptäcka och reagera på en given störning, är institutionell kvalitet maktlös att överbrygga gapet.

Detta är inte ett politiskt påstående. Det är en strukturell begränsning som följer av matematiken inom styrteori, informationsteori och Ashbys lag om nödvändig variation. Lagen sammanfattas ofta som *endast variation kan absorbera variation*, men dess precisa innebörd är störningsrelativ, och distinktionen är avgörande: en styrenhet behöver inte – och gör det aldrig – matcha hela variationen hos det system den styr. All reglering körs på en reducerad modell, och en styrenhet som är långt enklare än sin anläggning kan stabilisera den utmärkt, förutsatt att dess variation täcker de *störningar som dess mål måste avvisa*. Vad ingen styrenhet kan göra är att avvisa störningsvariation som den saknar intern variation att matcha. Den icke-täckta variationen – inte det harmlösa, ständigt närvarande gapet mellan ett systems fulla komplexitet och dess modell – blir okontrollerad varians i utfallen, som uppträder som kriser styrenheten inte såg komma och inte kan förklara (Ashby, 1956; det precisa villkoret, $\dim(V) \geq \dim(D) - \dim(\text{acceptabla utfall})$, anges i §2.3).

1.3 Från styrning till värde

Seriens formella resultat fokuserar på styrningsinstitutioner: var information aggregeras, hur snabbt den flödar, vem som fattar beslut. Men samma mekanism verkar en nivå upp. Ett styrsystems *målfunktion* — vad det explicit optimerar för, värderar eller betraktar som framgång — är i sig en observationsarkitektur. Den definierar vilka dimensioner av världen som är operationellt relevanta och överlämnar, genom utelämnande, resten åt bruset.

När ett samhälle optimerar för BNP prioriterar det inte bara ekonomisk produktion. Det konstruerar ett informationssystem som gör ekonomiska transaktioner mycket synliga samtidigt som obetalt omsorgsarbete, ekosystemhälsa, social tillit och existentiell mening görs strukturellt osynliga (Stiglitz, Sen & Fitoussi, 2009; Raworth, 2017). Målfunktionen är filtret. Den väljer ut vilka tillstånd som erkänns som avvikelser att korrigera, och vilka som inte gör det. De dimensioner som faller utanför optimeringsrymden blir, i styrteoretiska termer, oobserverbara — och så småningom ostyrbara. De ackumuleras som externaliteter tills de bryter igenom systemets stabilitetströsklar, vid vilken punkt de återuppträder som kriser för vilka systemet saknar både sensor och vokabulär.

Detta är artikelns grundläggande drag: att behandla optimeringsfunktioner inte enbart som uttryck för preferenser, utan som *arkitektoniska val som bestämmer systemets perceptuella gränser*. De felmoder som identifierats i styrningsserien — rumslig blindhet, frekvensgap, preferensosynlighet, observationsmässig otillräcklighet — är inte unika för byråkratiska strukturer. De är generella egenskaper hos varje system som komprimerar en komplex, högdimensionell verklighet till en lågdimensionell signal i kontrollsyfte. Vad ett system optimerar för är vad det komprimerar in i sin styrkanal. Kompressionsförlusten är vad det till slut blir oförmöget att se.

Återstoden av denna artikel formaliserar denna insikt. Del II utvecklar den strukturella identiteten mellan målfunktioner och observationsarkitekturer. Del III introducerar variationsgapet som en enande diagnostisk indikator och modellerar dess dynamik. Del IV och V tillämpar ramverket på de saknade dimensionerna av socialt och ekologiskt värde samt på de landfallsstudier som grundar argumentet. Del VI utforskar metastyrningsimperativet: nödvändigheten av institutioner som medvetet kan utveckla sina egna värderingsarkitekturer. Genomgående skiljer vi den rigorösa kärnan från tolkande utvidgningar och filosofisk extrapolation, så att argumentets grundvalar förblir synliga.

Del II — Optimeringens vändning: Värdefunktioner som observationsarkitekturer

Del I fastställde att aggregering förstör information och att institutionell kvalitet inte kan återställa vad observationskanalen kasserar. Det argumentet handlade om *styrssystem* — institutioner som samlar in data, fattar beslut och agerar. Men samma arkitektur verkar på värdenivån. Varje styrssystem förkroppsligar, explicit eller implicit, en uppsättning mål. Dessa mål avgör vad som räknas som signal, vad som räknas som brus och vilka dimensioner av verkligheten som systemet strukturellt är kapabelt att uppmärksamma. Denna del formaliserar den insikten: en målfunktion är inte enbart en preferensförklaring. Den är en observationsarkitektur.

2.1 Den strukturella identiteten

Betrakta en godtycklig styrenhet — en termostat, en centralbank, ett departement — som försöker stabilisera ett system i närvaro av störningar. För att kunna agera måste den ta emot information om systemets tillstånd. Observationskanalen $\mathbf{y} = \mathbf{C}\mathbf{x} + \boldsymbol{\epsilon}$ avbildar det sanna tillståndet $\mathbf{x}$ på den uppmätta signalen $\mathbf{y}$, där matrisen $\mathbf{C}$ väljer vilka dimensioner som observeras och bruset $\boldsymbol{\epsilon}$ stör överföringen (Shannon, 1948). Styrenheten agerar på $\mathbf{y}$, inte på $\mathbf{x}$. De dimensioner av $\mathbf{x}$ som inte projiceras genom $\mathbf{C}$ är osynliga för den, oavsett deras kausala betydelse.

Betrakta nu en målfunktion — BNP-maximering, aktieägarvärde, ideologisk renhet, valseger eller en flerdimensionell uppsättning välmåendendikatorer. Målfunktionen definierar ett värderum $\mathbf{V}$ på vilket systemets enorma tillståndsrum $\mathbf{R}$ projiceras. Endast de dimensioner av $\mathbf{R}$ som avbildas på $\mathbf{V}$ är operationellt relevanta: det är de tillstånd som framträder som avvikelser från målet, som kostnader att minimera eller som mål att närma sig. Avbildningen från $\mathbf{R}$ till $\mathbf{V}$ är, strukturellt sett, en observationskanal. Det är en matris som väljer vilka aspekter av verkligheten systemet *ser som betydelsefulla*.

Identiteten är inte metaforisk. I båda fallen komprimeras ett högdimensionellt tillståndsrum till en lågdimensionell signal. Information går förlorad. Styrenheten — vare sig det är en styrningsinstitution eller en hel civilisations optimeringslogik — agerar på den komprimerade signalen. Om en kausalt relevant dimension av $\mathbf{R}$ ligger i nollrummet för värdeprojektion, är den dimensionen funktionellt osynlig. Den blir en del av systemets oobserverbara underrum. Styrenheten reagerar inte på den, inte för att den väljer att ignorera den, utan för att dess egen arkitektur har gjort den oförnimbar.

Detta är det grundläggande påståendet: *en målfunktion är en observationsarkitektur*. Vad ett system optimerar för avgör vad det kan uppfatta. Valet av värdemetrik är samtidigt valet av blindhet. Conant och Ashby (1970) bevisade att varje god regulator av ett system måste besitta en modell av det systemet. Korollariet är att en regulator vars interna modell utelämnar kausalt relevanta dimensioner, i dessa dimensioner, inte alls är en regulator — den är en blind aktiveringsmekanism.

2.2 En målfunktions dimensionalitet

Om målfunktioner är observationsarkitekturer kan vi karaktärisera dem genom samma egenskaper vi använder för varje observationskanal: dimensionalitet, aggregeringsstruktur och temporal horisont.

Dimensionaliteten hos en målfunktion är antalet oberoende tillståndsdimensioner den följer. Ett BNP-mål är endimensionellt: den enorma mångfalden av mänskliga aktiviteter — omsorg, kreativitet, ekosystemunderhåll, social tillit, fritid, sjukdom — projiceras på en enda monetär axel (Stiglitz, Sen & Fitoussi, 2009). Ett aktieägarvärdesmål är endimensionellt: all företagsaktivitet komprimeras till aktiekursen. Ett auktoritärt stabilitetsmål är endimensionellt: alla sociala fenomen mäts mot deras närhet till eller avvikelse från regimens fortbestånd.

Operationell specifikation: Hur räknar vi dimensioner? Appendix G tillhandahåller tre protokoll av ökande stringens: (1) uppräknings av oberoende policymål från officiella dokument, (2) principalkomponentanalys på tidsseriedata av policyutfall, (3) informationsteoretiska kompressionskvoter. Det första är genomförbart men approximativt; det andra och tredje är "i princip"-protokoll som ännu inte implementerats. Genomgående i denna uppsats, om inget annat anges, använder dimensionalitetsuppskattningar Protokoll 1 (målräkning) tillämpat heuristiskt. Ett BNP-endast-mål har $\dim(\mathbf{V}) \approx 1$ inte för att vi har mätt det precis, utan för att endast en oberoende variationsaxel följs i policybeslut.

En **flermålsfunktion** — som FN:s mål för hållbar utveckling med sina 17 mål och 169 delmål — är högre dimensionell men introducerar en annan strukturell spänning. Dimensionaliteten är inte enkelt antalet indikatorer utan den *effektiva* dimensionaliteten: hur många oberoende frihetsgrader värderingsarkitekturen kan särskilja och avväga. Om alla indikatorer underordnas ett enda slutgiltigt mått (t.ex. tillväxt) kollapsar den effektiva dimensionaliteten (Raworth, 2017). Weaver (1948) särskilde tre slags problem: enkla (få variabler), oorganiserad komplexitet (många variabler mottagliga för statistisk behandling) och organiserad komplexitet (många variabler med strukturerade ömsesidiga beroenden). De flesta styrssystem möter organiserad komplexitet, men deras värderingsarkitekturer är ofta utformade för enkelhet.

Aggregeringsstrukturen beskriver hur målfunktionen komprimerar lokala, distribuerade tillstånd till en global sammanfattning. BNP är en extrem aggregator: den ekonomiska aktiviteten på en kontinent uttrycks som ett enda tal. Ingen av variansen däri är förnimbar för måttet. Den **temporal horisonten** — diskonteringsräntan — avgör vilka framtida tillstånd som är synliga och vilka som inte är det. En brant diskonteringsränta gör den

avlägsna framtiden effektivt oobserverbar: dess tillstånd registrerar ingen meningsfull signal i målfunktionen, precis som ett lågpasfilter avlägsnar höga frekvenser från en sensoravläsning.

En målfunktion med ett enda mått, hög aggregering och brant diskontering är, i signalbehandlingstermer, en smalbandig, lågdimensionell observationskanal. Den är strukturellt oförmögen att registrera den fulla variationen i det system den är avsedd att styra. Allt som är sant om världen men frånvarande i det måttet kunde lika gärna inte existera — tills det producerar en störning som inte kan ignoreras.

2.3 Nödvändig variation för värderingsarkitekturer

Ashbys lag om nödvändig variation (Ashby, 1956) slår fast att en styrenhet endast kan stabilisera ett system om dess interna variation — antalet distinkta tillstånd den kan särskilja och reagera på — matchar eller överskrider variationen hos de störningar systemet möter. Formellt, för ett störningsrum $\mathbf{D}$ och en målmängd $\mathbf{G}$, måste styrenhetens variation $\mathbf{V(R)}$ uppfylla $\mathbf{V(R)} \geq \mathbf{V(D)} - \mathbf{V(I)}$. Om styrenhetens variation är otillräcklig uppträder den oabsorberade variationen som okontrollerad varians i utfallen.

Denna lag formulerades för fysiska och biologiska styrenheter — termostater, nervsystem, organisatoriska regulatorer. Men samma logik gäller direkt för värderingsarkitekturer. "Styrenheten" är den uppsättning mål som väljer vilka störningar som uppmärksammas och vilka som inte gör det. Dess variation är målfunktionens dimensionalitet — antalet oberoende tillståndsdimensioner den kan särskilja och prioritera. "Störningsrummet" är den fulla vidden av miljömässig, social och intern variation som kan driva systemet bort från dess önskade tillstånd.

Utvidgningen följer: en värderingsarkitektur måste besitta minst lika mycket dimensionalitet som det störningsrum den måste styra, minus dimensionaliteten hos acceptabla utfall. $\mathbf{dim(V)} \geq \mathbf{dim(D)} - \mathbf{dim(I)}$. Om detta villkor överträds existerar störningsdimensioner som målfunktionen inte kan registrera. Dessa störningar är, i formell mening, oobserverbara för systemets optimeringslogik. De ackumuleras som externaliteter — oprissatta, omätta, oredovisade — tills de bryter igenom trösklar som tvingar dem till synlighet genom kris.

Detta är inte ett normativt påstående. Det är en strukturell prediktion. Ett system som optimerar för en endimensionell variabel i en flerdimensionell värld *kommer* att överrumplas av de exkluderade dimensionerna, inte för att dess institutioner är inkompetenta, utan för att dess värderingsarkitektur saknar den sensoriska apparatur som krävs för att upptäcka dem i förväg. Misslyckandena är inbyggda i optimeringsgeometrin.

Denna artikel insisterar inte på en bokstavlig, precis mätning av $\mathbf{dim(R)}$ och $\mathbf{dim(V)}$ — sådan mätning är ett öppet forskningsproblem och termerna används heuristiskt här. Formella operationaliseringsförsök hänskjuts till Appendix B. Den konceptuella poängen är att det finns ett glapp, att det växer under stelhet, och att dess konsekvenser följer Ashbys lags logik.

2.4 Goodhart–Ashby-syntesen

Goodharts lag säger i sin kanoniska formulering: "När ett mått blir ett mål upphör det att vara ett gott mått" (Goodhart, 1975). Den gängse tolkningen är beteendemässig: agenter spelar ut måttet, optimerar sin prestation mot proxyvariabeln snarare än den underliggande verkligheten. Detta är korrekt men ofullständigt.

Den djupare mekanismen är arkitektonisk. När ett enskilt mått upphöjs till målfunktionsstatus smalnar systemets observationskanal till enbart det måttet. All information som tidigare gjorde måttet till en användbar proxy låg i dess korrelation med det bredare tillståndsrummet — en korrelation som berodde på att systemet *inte* optimerade för det exklusivt. I samma ögonblick som måttet blir målet börjar systemet optimera bort just de betingelser som upprätthöll korrelationen. Proxyvariabeln divergerar från målvariabeln, inte främst på grund av spel, utan för att observationsarkitekturen har komprimerats till den punkt där själva divergensen är osynlig för det mått som skulle upptäcka den (Manheim & Garrabrant, 2018; Strathern, 1997).

Detta ger Goodhart–Ashby-syntesen: *en målfunktion kommer att optimera bort sin egen förmåga att uppfatta systemets verkliga tillstånd närhelst den utelämnar en dimension som är kausalt kopplad till just den proxy den optimerar*. Utlösaren är inte att målfunktionen är lägre-dimensionell än systemet — alla målfunktioner är det, utan skadeverkan — utan att optimeringen aktivt eroderar den korrelation som gjorde proxyn informativ, och gör det i en dimension målfunktionen inte kan se. Proxyvariabeln kollapsar inte för att agenter fuskar, utan för att målfunktionens låga dimensionalitet gör proxy-måldivergensen till en oobserverbar dimension. Styrenheten fortsätter optimera måttet, blind för det växande gapet, tills gapet manifesterar sig som en kris som måttet inte kan förklara.

De klassiska exemplen är ekonomiska: inflationsmål som negligerar finansiell stabilitet; standardiserade provresultat som urholkar utbildningskvalitet (Strathern, 1997); BNP-tillväxt som maskerar ekologisk degradering. Men logiken är domängenerell. En auktoritär regim som optimerar för kortsiktig kontroll förlorar förmågan att uppfatta den legitimitet som upprätthåller kontroll på lång sikt. En social medieplattform som optimerar för engagemang förlorar förmågan att uppfatta den epistemiska miljö den degraderar. I varje fall skapar målfunktionens låga dimensionalitet en observationsmässig blind fläck som till slut förstör just det utfall funktionen var avsedd att säkra. Müller (2018) tillhandahåller omfattande historisk dokumentation av hur måttfixering förvränger organisatoriskt beteende över domäner — från medicin till utbildning till polisväsende — och illustrerar mekanismen i praktiken.

2.5 Relaterad forskning

Argumentet som utvecklas här befinner sig i skärningspunkten mellan flera etablerade forskningstraditioner, där var och en närmar sig samma territorium från en annan vinkel. Den föreliggande syntesen är nydanande inte i sina individuella komponenter utan i att behandla målfunktioner explicit som observationsarkitekturer vars dimensionalitet är en designvariabel — och i att utvidga Ashbys lags logik till själva värderingsarkitekturen.

- **Kybernetik och styrteori:** Ashbys lag (1956) utgör den formella ryggraden; Stafford Beers livskraftiga systemmodell (1972, 1979) tillämpar kybernetiska principer på organisationsdesign, även om den stannar kort före att analysera de värdefunktioner dessa organisationer optimerar. Det föreliggande arbetet utvidgar den kybernetiska traditionen uppåt, från styrningsstrukturer till de mål som animerar dem.
- **Flermålsoptimering och Paretofronter:** Ingenjörslitteraturen om flermålsstyrning har länge erkänt att optimering för ett enda mått kan producera patologiska utfall. Artikeln generaliserar denna insikt: *dimensionaliteten* hos målfunktionen är en oberoende strukturell variabel med stabilitetskonsekvenser.
- **Ekologisk ekonomi och hållbarhetsvetenskap:** Kritiken av BNP och kravet på flerdimensionella välmåendemått — inklusive Stiglitz-Sen-Fitoussi-rapporten (2009), Doughnut Economics (Raworth, 2017) och Human Development Index — är försök att *öka värderingsarkitekturers dimensionalitet*. Denna artikel tillhandahåller det formella styrteoretiska resonemanget för varför sådana ökningar inte bara är etiskt önskvärda utan strukturellt nödvändiga för långsiktig stabilitet.
- **AI-alignment och felaktig belöningspecifikation:** Problemet med belöningshackning i förstärkningsinlärning — där en agent optimerar en proxybelöningsfunktion och producerar oavsiktliga, ofta katastrofala utfall (Amodei et al., 2016) — är en precis analog till den värdefunktionskollaps som beskrivs här. Argumentet generaliserar detta från AI-system till institutionella och civilisatoriska system.
- **Komplexitetsteori och evolutionära system:** Stuart Kauffmans "angränsande möjliga" (2000), Talebs antifragilitet (2012) och studiet av punkterad jämvikt i sociala system (Gould & Eldredge, 1977) pekar alla mot den obegränsade framväxten av nyhet i komplexa miljöer. Det föreliggande ramverket formaliserar styrningsimplikationen: i ett öppet störningsrum måste värderingsarkitekturer själva vara öppna.
- **Politisk teori och demokratisk legitimitet:** Den deliberativa vändningen inom demokratisk teori — medborgarpaneler, deltagande budgetering (Habermas, 1996; Dryzek, 2000; Ostrom, 1990) — kan omtolkas som institutionella mekanismer för att expandera målfunktionens dimensionalitet genom att introducera signaler den existerande arkitekturen inte kan upptäcka. Artikeln tillhandahåller ett strukturellt språk för varför sådana mekanismer inte är kosmetiska utan väsentliga för systemisk livskraft.

Del III — Variationsgapet: Dynamik och upplösningströskeln

Om målfunktioner är observationsarkitekturer är deras tillräcklighet inte ett binärt villkor utan en fråga om grad — och den graden kan förskjutas över tid i takt med att miljön genererar nya störningsdimensioner som den befintliga värderingsarkitekturen aldrig utformades för att följa. Denna del introducerar *variationsgapet* som en enande diagnostisk indikator, modellerar dess dynamik heuristiskt, identifierar den kritiska tröskel där observerbarheten kollapsar, och argumenterar för att upplösning — ett värdeparadigms död eller transformation — inte är en patologi utan en strukturell nödvändighet när den tröskeln väl har passerats.

3.1 Definiera gapet

Låt **R** beteckna verklighetens effektiva tillståndsrum så som det bär på ett givet systems livskraft. Detta är inte ett påstående om metafysisk oändlighet; det är mängden av oberoende dimensioner längs vilka systemet kan störas — ekologiska, ekonomiska, sociala, teknologiska, psykologiska och så vidare — på en upplösningssnivå som är relevant för dess överlevnad. Dimensionaliteten i detta rum, **dim(R)**, är stor och, avgörande, inte statisk. Nya dimensioner träder emergenta in i det relevanta störningsrummet över tid: klimatförändring inför en koldimension i ekonomisk planering; digitala medier inför en epistemisk integritetsdimension i demokratisk styrning; demografisk transition inför en generationsrättvisdimensions i finanspolitiken. Kauffman (2000) fångar denna generativa egenskap med begreppet "det angränsande möjliga": vid varje given tidpunkt blir nya tillstånd i systemet nåbara som inte var nåbara tidigare, vilket utvidgar den effektiva dimensionaliteten i det rum styrningen måste navigera. Från varje ändlig styrningsarkitekturs perspektiv är verklighetens effektiva dimensionalitet öppen.

Låt **V** beteckna systemets värderingsarkitektur — den explicita eller implicita målfunktion som väljer vilka tillstånd som är synliga som framgångar eller misslyckanden, vilka kostnader som räknas och vilka avvägningar som är tillåtna. Dess dimensionalitet, **dim(V)**, är antalet oberoende axlar som värdefunktionen kan särskilja och väga mot varandra. Ett system som enbart optimerar BNP har **dim(V) ≈ 1**; ett som balanserar flera välmåendedimensioner har en större, men fortfarande ändlig, **dim(V)**.

Variationsgapet är då:

$$G = \text{dim}(\mathbf{R}) - \text{dim}(\mathbf{V})$$

Mätstatus: Variationsgapet definieras formellt i Appendix A och mäts operationellt i Appendix G. I de empiriska tillämpningar som följer (landfall, historisk analys) uppskattas *G* heuristiskt med hjälp av kvalitativ mönstermatchning mot ramverkets förutsagda misslyckandesignaturer. Dessa uppskattningar är illustrativa — storleksordningsbedömningar snarare än precisa mätningar. Att flytta ramverket från diagnostisk lins till validerad teori kräver implementering av de mätprotokoll som specificeras i Appendix G.

G är alltid positivt — ingen ändlig värderingsarkitektur uttömmar den verklighet den styr — och det tenderar att växa över tid om inte systemet aktivt expanderar sin värdedimensionalitet. Gapet är ett mått på systemets strukturella okunskap: antalet kausalt relevanta dimensioner som helt enkelt är frånvarande från dess optimeringslandskap. Ju större gap, desto större volym av verklighet som kan påverka systemets öde utan att systemet någonsin uppfattar det som något som betyder något.

Två förbehåll hindrar detta mått från att bevisa för mycket. För det första är **R** här inte den råa verkligheten utan det ovan definierade livskraftsrelevanta störningsrummet; variationsgapet är därför inte den trivialt stora, alltid ofarliga diskrepansen mellan ett systems fulla komplexitet och varje ändlig modell — en diskrepans som varje fungerande styrenhet bär utan skada — utan underskottet gentemot de störningar som faktiskt har bäring på överlevnaden, den storhet som §2.3:s krav på nödvändig variation gör precis. För det andra är en dimension som saknas i **V** betydelsebärande endast i den mån den är *kausalt kopplad* till systemets livskraft: en okopplad exkluderad dimension vidgar **G** aritmetiskt men kostar ingenting, medan en kopplad sådan är vad som återinträder som kris. Den diagnostiska tyngden hos **G** vilar på dessa två kvalifikationer, inte på dimensionsräkning ensam — precis vad simuleringen i Appendix C uppvisar, där kollapsen följer av att den exkluderade dimensionen är kopplad till det optimerade målet, inte av dess blotta exkludering.

3.2 Gapets dynamik

Eftersom **dim(R)** expanderar över tid — i takt med att miljöer, teknologier och sociala konfigurationer producerar nya former av störningar — och **dim(V)** också kan expandera, om än typiskt långsammare och mot institutionellt motstånd, uppvisar gapet dynamik. En heuristiskt användbar första ordningens modell är:

$$dG/dt = \alpha - \beta \cdot A(V)$$

där α , β och $A(V)$ är konceptuella parametrar som införs för att synliggöra gapdynamiken. Dessa är *inte* för närvarande uppmätta kvantiteter — Appendix G tillhandahåller operationella protokoll för framtida empiriskt arbete. Modellen används illustrativt i texten för att organisera kvalitativa observationer om hur styrsystem halkar efter sina störningsmiljöer. Den bör inte tolkas som en kalibrerad prediktiv ekvation.

- α är *uppkomsthastigheten* för nya störningsdimensioner: hur snabbt verklighetens effektiva tillståndsrums expanderar.
- $A(V)$ är *anpassningshastigheten* hos värderingsarkitekturen: den hastighet med vilken systemet lägger till nya dimensioner till sin målfunktion.
- β är *anpassningseffektiviteten*: i vilken utsträckning ansträngningar att expandera $\dim(V)$ lyckas faktiskt spåra de nyuppkomna dimensionerna.

När $\beta \cdot A(V) \geq \alpha$ är gapet hanterat. Systemets värderingsarkitektur expanderar tillräckligt snabbt för att följa den föränderliga störningsmiljön, och systemisk blindhet ackumuleras inte. När $\beta \cdot A(V) < \alpha$ växer gapet. Systemet förlorar gradvis perceptuell kontakt med den verklighet det måste navigera. Underskotten är inledningsvis subtila — signaler i marginalen, märkliga kriser som tycks komma från ingenstans — och sedan, i takt med att gapet vidgas, katastrofala. Meadows (2008) beskriver denna dynamik i systemtermer: när ett systems informationsflöden är för långsamma eller för smala i förhållande till förändringshastigheten överskrider systemet systematiskt sina gränser och eroderar sina egna bärande betingelser.

Detta är inte ett påstående att α , β eller $A(V)$ för närvarande är mätbara med precision. De introduceras här som en konceptuell byggnadsställning, ett sätt att synliggöra de strukturella krafter som driver styrsystem mot blindhet. De formella härledningsförsöken och operationaliseringsutmaningarna utforskas i Appendix B. Kärnintuitionen är robust: i en föränderlig värld är en statisk värderingsarkitektur en gradvis självblindande sådan. Systemet måste springa bara för att hindra sitt perceptuella gap från att växa.

3.3 Den kritiska upplösningströskeln

I takt med att G växer ökar volymen av oobserverade kausala dimensioner. Dessa dimensioner upphör inte att verka; de genererar effekter som korsar in i systemets observerbara rum, men i förvrängd form — som oförklarad volatilitet, som "exogena chocker", som kriser vilka tycks sakna uppenbar orsak inom systemets ramverk. Systemets egen optimeringslogik kan inte attribuera dessa effekter korrekt, eftersom de dimensioner från vilka de härrör inte ingår i dess värdekarta. Det reagerar på symptom snarare än orsaker, och dess responser förstärker ofta de underliggande störningarna. Taleb (2012) beskriver denna dynamik som den skörhet som uppstår när system optimeras för ett smalt intervall av betingelser och förlorar förmågan att absorbera variabilitet.

Det existerar en kritisk tröskel, G_{crit} , vid vilken signalen från de observerade dimensionerna överväldigas av bruset från de icke-observerade. Formellt är detta den punkt där signal-brusförhållandet i värdekanalen faller under ett (Appendix B).

Provisorisk uppskattning: Baserat på Rapport III:s analys av representationskedjor uppskattar vi $G_{crit} \approx 2-3$ för de flesta styrkontexter (Appendix G.5), men detta är högst osäkert och kontextberoende. Empirisk kalibrering kräver variansdekomponeringsstudier som ännu inte har genomförts. Landfallen nedan bedöms som "närmar sig" eller "överskrider" G_{crit} baserat på kvalitativ mönstermatchning mot förväntade misslyckandesignaturer (reaktiv styrning, brusspårning, policy-utfallsdekorrelation), inte direkt SNR-mätning.

Samma konstitutionella oobserverbarhetsvillkor identifierades i Artikel III för demokratiska representationskedjor, nu generaliserat till själva värderingsarkitekturen. När $G > G_{crit}$ är informationen som målfunktionen bär om systemets verkliga tillstånd mindre än informationen som bidras av oöverbvakade störningar (Shannon, 1948). Systemet optimerar inte längre mot sina uttalade mål; det optimerar mot en fantom och följer bruskaraktäristiken hos sin egen okunskap.

Vid denna tröskel inträder systemet i ett tillstånd av *strukturell självblindhet*. Det kan inte uppfatta orsakerna till sin egen instabilitet, inte för att det saknar data, utan för att de kategorier i vilka det skulle kunna formulera dessa orsaker inte existerar i dess värderingsarkitektur. Det kommer att tolka ekologisk kollaps som en exogen utbudschock, demokratisk delegitimering som ett kommunikationsmisslyckande, institutionell drift som ett ledarskapsproblem. Intervenerna som följer — mer tillväxt, hårdare kontroll, bättre kommunikation — kommer att hämtas från den existerande dimensionsmängden och lämnar de faktiska exkluderade dimensionerna orörda, ofta förvärrar dem. Detta är den mekanistiska kärnan i vad senare avsnitt kommer att beskriva i landrapporterna: punkten där själva optimeringsarkitekturen har blivit den primära generatoren av systemisk sårbarhet.

3.4 Upplösning som strukturell nödvändighet, inte misslyckande

När ett system passerar G_{crit} är inkrementell anpassning inom dess befintliga värderingsarkitektur inte längre tillräcklig. Problemet är inte att arkitekturen är dåligt kalibrerad, utan att den saknar de dimensionella axlar på vilka de relevanta störningarna är definierade. Att lägga till mer av samma — förfina BNP-måttet, skärpa kontrollapparaten, förbättra förhandlingsprotokollet — kan inte återvinna information som aldrig fångades från första början. Den enda vägen till att återställa observerbarhet är att lösa upp den befintliga värderingsarkitekturen och ersätta den med en av högre dimensionalitet.

Upplösning här är inte nödvändigtvis civilisationens eller statens kollaps, även om den kan ta den formen. Det är ett specifikt optimeringsparadigms död. En ekonomi organiserad kring BNP-tillväxt kan behöva omorganiseras kring ett flerdimensionellt välmånderamverk. Ett politiskt system vars målfunktion är koalitionsöverlevnad kan behöva rekonstrueras kring genuin demokratisk preferensöverföring. Upplösningen kan vara katastrofal — revolution, kollaps, krig — eller så kan den hanteras: konstitutionell reform, skapandet av nya styrande institutioner, det medvetna antagandet av nya mått och mandat. Gould och Eldredge (1977) beskrev biologisk evolution i termer av punkterad jämvikt: långa perioder av stabilitet avbrutna av snabb

omorganisation. Samma mönster uppträder i styrningsarkitekturers historia. Vad variationsgapet tillför är en mekanistisk redogörelse för *varför* punkteringen blir nödvändig: systemets egen optimeringslogik förstör gradvis dess perceptuella kontakt med verkligheten, tills gapet är för stort för att upprätthållas och omorganisation tvingas fram.

Landrapporterna som följer i Del V tillhandahåller illustrativa fall. Japans kontinuitetsfälla är en upplösning i slow motion, där värderingsarkitekturen fixerad vid efterkrigsstabilitet har blivit så stel att systemet gradvis fryser snarare än utvecklas. Rysslands läsbarhetsunderskott är en akut överskridning av **G_crit**: kontrollens värderingsarkitektur förstörde sin egen observerbarhet och genererar nu strategisk blindhet som ett strukturellt utflöde. Storbritanniens centraliserings-leveransgap, Brasiliens koalitionsöverlevnadsoptimering, Europeiska unionens förhandlingsutspädningspiral — varje fall är ett där värderingsarkitekturens dimensionalitet blev otillräcklig för den störningsmiljö den mötte, och gapet växte tills upplösningstrycket blev obestridligt.

Att gestalta upplösning som strukturell nödvändighet snarare än misslyckande gör den inte smärtfri. Den förändrar dock styrningsfrågan. Frågan är inte längre "hur förhindrar vi vårt nuvarande systems kollaps?" utan "kan vi hantera upplösningen av vårt nuvarande värdeparadigm och framväxten av ett högre dimensionellt sådant innan gapet blir fatalt?" Detta är det högsta ordningens designproblem, och det är ämnet för Del VI.

Vad variationsgapet introducerar är ett enda konceptuellt mått som spårar denna båge. Innan vi går vidare till de empiriska illustrationerna vänder vi oss i Del IV till de specifika dimensioner som de flesta styrningsarkitekturer exkluderar — sanning, mening, samhörighet och välmående — och undersöker hur deras exkludering accelererar närmandet till **G_crit**, och hur deras inkludering strukturellt expanderar systemets observationsrum.

Del IV — De saknade dimensionerna: Sanning, mening, samhörighet och välmående som signalkanaler

Variationsgapet växer därför att verkligheten kontinuerligt genererar nya störningsdimensioner, och de flesta värderingsarkitekturer förblir statiska. Men alla dimensioner är inte likvärdiga. Vissa är *grundläggande*: de är de kanaler genom vilka systemet förvärvar förmågan att följa andra, mer specifika dimensioner över lång tid. När dessa grundläggande dimensioner exkluderas vidgas variationsgapet inte bara med ett — det vidgas därför att systemet förlorar den sensoriska apparatur som behövs för att upptäcka själva gaptillväxten. Denna del undersöker fyra sådana dimensioner — sanning, mening och samhörighet, välmående samt relationell integritet — och omformulerar var och en inte som ett moraliskt ideal utan som en observationskanal vars frånvaro strukturellt degraderar systemets perceptuella fält.

4.1 Omramning genom gapet

På Del II:s och III:s språk kan var och en av dessa dimensioner förstås som en uppsättning signalaxlar som följer långsamma, distribuerade, högdimensionella tillstånd i ett samhälle. De är styrningens motsvarighet till den "långsamma ekologiska signalen" i Artikel IV: indikatorer som verkar över årtionden, är synliga endast inifrån systemet och kräver en lång, kontinuerlig observationsbaslinje för att tolkas korrekt. Att exkludera dem från värderingsarkitekturen utelämnar inte bara några få mått; det avlägsnar själva de kanaler genom vilka systemet skulle kunna lägga märke till att dess egen sociala väv, epistemiska integritet eller långsiktiga anpassningsförmåga bryts ned.

Eftersom dessa dimensioner är långsamma att förändras och diffusa i sina effekter är deras försämring osynlig för värdefunktioner med kort horisont och hög aggregering. En kvartalsvis BNP-rapport avslöjar ingenting om erosionen av tillit; ett årligt val registrerar inte att mening frikopplas från arbete. Gapet mellan **dim(V)** och **dim(R)** växer tyst i dessa dimensioner, tills den ackumulerade degraderingen manifesterar sig som en kris — politisk omvälvning, existentiell förtvivlan, institutionell delegitimering — som systemets egen värderingsarkitektur inte kan spåra till sitt ursprung. Vid den punkten är systemet redan under signal-bruströskeln för dessa dimensioner. Det har förlorat förmågan att uppfatta vad som gick fel.

4.2 Signaldimensioner i detalj

Sanning som signaltrohet

Ett styrsystems relation till sanning är inte främst en fråga om ärlighet eller integritet bland dess tjänstemän, även om dessa spelar roll. Strukturellt är sanning *signalens trohet* när den når beslutsnivån. Varje systematiskt incitament att förvränga, filtrera eller försköna information — vare sig för politisk bekvämlighet, karriäravancemang eller ideologisk koherens — degraderar observationskanalen. Degraderingen förstärks: en förvrängd signal producerar felkalibrerade interventioner, vars utfall sedan rapporteras genom samma förvrängande kanal, vilket producerar ytterligare felkalibrering.

En värderingsarkitektur som belönar bekväma narrativ framför korrekt information väljer i själva verket för förstörelsen av sin egen observerbarhet. Detta är mekanismen bakom det läsbarhetsunderskott som diagnostiserades i Rysslandsrapporten (Governance as Engineering Series), men den verkar i mildare former överallt. När en byråkrati optimerar för uppåt tilltalande rapporter förlorar den förmågan att se problem tills de är för stora att dölja. När ett politiskt system optimerar för valnarrativ förlorar det förmågan att uppfatta den långsamma erosionen av de betingelser som gör vallegitimitet meningsfull. Den exkluderade dimensionen är sanning, och dess exkludering förstör till slut förmågan att korrekt uppfatta någon annan dimension. På andra ordningens kybernetiks språk förlorar systemet förmågan att observera sitt eget observerande (von Foerster, 1984).

Mening, samhörighet och tillhörighet som långsamma sociala sensorer

Mänskliga varelser är inte bara ekonomiska aktörer; de är meningsskapande, relationssökande varelser. Känslan av att ens liv har betydelse, att man tillhör en gemenskap, att framtiden är värd att investera i — detta är inte lyxvaror. De är det psykologiska och sociala substrat på vilket samarbete, tillit och långsiktig orientering vilar. När de eroderar uppträder effekterna inte i ekonomiska indikatorer förrän erosionen har fortskridit tillräckligt långt för att manifesteras som mätbara utfall: sjunkande arbetskraftsdeltagande, stigande dödlighet till följd av förtvivlan, politisk extremism, sammanbrott för civila institutioner. Wilkinson och Pickett (2009) demonstrerade att de sociala missförhållanden som förknippas med ojämlikhet — eroderad tillit, förhöjd statusångest, försvagade gemenskapsband — inte enbart är korrelerade med ekonomiska svårigheter; de följer den *relationella* kvaliteten i ett samhälle, en dimension som är osynlig för aggregerade inkomstmått.

Dessa dimensioner är långsamma variabler. De förändras över årtionden, inte månader. Deras dynamik är synlig endast för observationssystem som följer relationell kvalitet, gemenskapsammanhållning och existentiellt välmående över flera tidsperioder — den kulturella motsvarigheten till den intergenerationella ekologiska kunskap som diskuterades i Artikel IV (Ostrom, 1990). En värderingsarkitektur som exkluderar mening och samhörighet är blind för den gradvisa urholkningen av de sociala betingelser som upprätthåller systemet. Den kommer att behandla den slutliga krisen — polarisering, nihilism, institutionell kollaps — som en plötslig chock snarare än slutstadiet av en lång, oobserverad trend.

Välmående som flerdimensionell tillståndsuppföljning

Den mest välbekanta av de saknade dimensionerna, välmående, åberopas ofta som ett önskvärt supplement till BNP. Men dess strukturella roll är djupare. En värderingsarkitektur som endast följer ekonomisk produktion följer en dimension av mänsklig välfärd. De andra — fysisk hälsa, psykiskt lidande, social tillit, miljö kvalitet, upplevelsen av autonomi och värdighet — är inte enbart korrelerade med ekonomiska utfall; de är kausalt oberoende i betydande grad. De kan försämrans medan BNP stiger, och när de försämrans tillräckligt långt återverkar de på ekonomisk nedgång på sätt som enbart ett BNP-mått inte kan förutse (Stiglitz, Sen & Fitoussi, 2009).

Detta är Goodhart–Ashby-mekanismen inom välfärdsdomänen: att optimera en endimensionell proxy (inkomst) förstör informationen om de andra dimensioner som tidigare var korrelerade med den. De exkluderade dimensionerna blir osynliga, och systemet fortsätter att hävda framgång baserat på proxyn även när den underliggande välfärd den påstås representera kollapsar. Raworth (2017) konceptualiserar detta som behovet av ett ekonomiskt ramverk begränsat av både sociala fundament och planetära tak — en flerdimensionell värderingsarkitektur som synliggör vad BNP systematiskt döljer. Epidemin av psykisk ohälsa i rika samhällen, ökningen av kronisk sjukdom, omsorgskrisen — dessa är inte bieffekter av välstånd. De är de exkluderade dimensionerna som återinträder som störningar som värderingsarkitekturen inte kan förklara.

Kärlek som relationell integritet

Kanske den mest utmanande dimensionen att gestalta i ingenjörstermer, men likväl en som uppträder återkommande i redogörelser för institutionella misslyckanden. Med "kärlek" menar vi inte romantisk känsla, utan den bredare kapaciteten för icke-transaktionellt samarbete, ömsesidig omsorg och viljan att bära kostnader för andra utan omedelbar återbärning. Denna relationella integritet är tillitens substrat. Den får institutioner att fungera bortom räckvidden för kontrakt och sanktioner. När den är närvarande faller koordinationskostnader; när den eroderar måste varje interaktion medieras av formella regler, övervakning och incitament — en transaktionskostnadseskalering som till slut gör komplext kollektivt handlande omöjligt. Bateson (1972) närmade sig detta territorium genom begreppet "mönstret som förbinder", och argumenterade för att överlevnadens grundläggande enhet inte är organismen utan organismen-i-sin-miljö — en relationell enhet som lågdimensionella observationssystem inte kan fånga.

En värderingsarkitektur som inte kan uppfatta relationell integritet kommer att optimera för effektivitet, produktion och regelefterlevnad på sätt som konsumerar just den tillit som dess institutioner är beroende av. Den exkluderade dimensionen — relationernas kvalitet — degraderas osynligt tills systemet finner sig oförmöglet att koordinera precis när koordination är som mest nödvändig. Ostroms (1990) arbete om bestående allmänningssystem avslöjade att de mest framgångsrika resursstyrningssystemen var de som bevarade relationella goden — tillit, ömsesidighet, ansvarsskyldighet ansikte mot ansikte — vid sidan av materiella utfall. Kollapsen av ett hög tillitssamhälle till ett låg tillit-, hög övervakningssamhälle är en överskridning av variationsgapet: värdefunktionens dimensionalitet var otillräcklig för att registrera den tillgång den likviderade.

4.3 Det arkitektoniska påståendet omformulerat

Del II fastställde att en målfunktion är en observationsarkitektur. Del III introducerade variationsgapet och upplösningströskeln. Analysen i denna del ger ett specifikt, testbart påstående: *en värderingsarkitektur som exkluderar dimensionerna sanning, mening, välmående och relationell integritet accelererar strukturellt sitt närmande till **G_crit***. Dessa dimensioner är inte valfria etiska utsmyckningar; de är de observationskanaler genom vilka ett samhälle följer sin egen långsiktiga livskraft. När ett styrsystem behandlar dem som externaliteter — omätta, oprissatta, osynliga för optimeringslogiken — gör det inte ett värdeval som kan korrigeras senare. Det förstör systematiskt sin egen kapacitet att upptäcka försämringen av de betingelser som krävs för dess egen överlevnad.

Konsekvenserna är inte spekulativa. Landrapporterna som följer i Del V dokumenterar hur specifika styrningsarkitekturer, genom att optimera smala värdefunktioner, överskred upplösningströskeln i just dessa dimensioner. Sovjetsystemet optimerade för ideologisk kontroll och förlorade förmågan att uppfatta sanningen om sin egen ekonomiska och sociala verklighet. Den japanska efterkrigsmodellen optimerade för stabilitet och förlorade förmågan att uppfatta erosionen av anpassningsförmåga. Den angloamerikanska aktieägarmodellen optimerade för finansiell avkastning och förlorade förmågan att uppfatta förstörelsen av social tillit och folkhälsa. I varje fall försvann inte de exkluderade dimensionerna. De ackumulerades som latent störningar tills de framtvingade en räkenskap som systemet då inte längre kunde förstå.

Den arkitektoniska slutsatsen är otvetydig: dimensionaliteten i ett samhälles värderingsarkitektur är en designvariabel med överlevnadskonsekvenser. Frågan är inte om dessa dimensioner ska inkluderas, utan om systemet kommer att uppfatta behovet av deras inkludering innan gapet blir oöverbryggbart — eller först efteråt. Del VI kommer att ta upp den institutionella frågan om hur ett styrsystem kan utforma för medveten värdeevolution. Men först grundar Del V argumentet i landrapporternas konkreta historia och återberättar varje som en överskridning av variationsgapet.

Del V — Landrapporterna omtolkade genom variationsgapet

Serien *Governance as Engineering* producerade en uppsättning nationella styrningsdiagnoser: Tyskland, Frankrike, Sverige, Indien, Europeiska unionen, Storbritannien, Brasilien, USA, Finland, Japan och Ryssland. Varje rapport identifierade en särpräglad felmod — verkställighetsunderskott, integrationsbräcklighet, återkopplingsfördröjning, synkroniseringsmisslyckande, koherensunderskott, kontroll-leveransglapp, ackumuleringsunderskott, integrationsunderskott, kapacitetsbegränsning, kontinuitetsfälla, läsbarhetsunderskott. Under ytdiversiteten framträder ett gemensamt mönster: i varje fall optimerade styrsystemet för en smal värdefunktion, de exkluderade dimensionerna vidgade variationsgapet, och gapet överskred så småningom en tröskel där systemet inte längre kunde uppfatta källorna till sin egen instabilitet.

Denna del återberättar fem av dessa fall genom variationsgapets lins. Syftet är inte att återuppta de ursprungliga diagnoserna utan att demonstrera att variationsgapet tillhandahåller ett enande mått som gör felmoderna kommensurabla — och att de föreslagna åtgärderna i varje rapport implicit syftar till att expandera **dim(V)**.

Metodologisk not om landfallen: Variationsgapsuppskattningarna som presenteras i denna del är heuristiska, inte empiriska. De härleds genom mönstermatchning av observerade styrmisslyckanden mot ramverkets förutsagda signaturer, inte genom att mäta **dim(V)**, **dim(D)** eller **G** direkt. Landsrapporterna utvecklades oberoende inom serien Styrning som ingenjörskonst med hjälp av olika diagnostiska vokabulärer; denna del omtolkar dessa fynd genom variationsgap-linsen för att demonstrera ramverkets potentiella förklaringskraft.

Detta är tolkningsarbete, inte validering. Ramverket skulle valideras om det genererade nya förutsägelser om styrmisslyckanden i länder som ännu inte studerats — förutsägelser som sedan bekräftades av oberoende observation. Det valideringsarbetet återstår att göra. Vad denna del demonstrerar är *konsistens*: variationsgapmekanismen skulle, om den är korrekt, förklara de observerade misslyckandemönstren. Den bevisar inte att mekanismen är korrekt.

5.1 Japan: Optimering för stabilitet exkluderar anpassningsförmåga

Japans efterkrigstida styrningsarkitektur var en enastående prestation. Den optimerade för stabilitet — social ordning, institutionell kontinuitet, grundläggande funktionalitet — och levererade det under årtionden. Systemet med livstidsanställning, keiretsu-nätverken, *amakudari*-pensioneringspipelinen, LDP:s permanenta valdominans: allt var komponenter i en värderingsarkitektur med **dim(V) ≈ 1**. Måttet var kontinuitet (*Governance as Engineering Series*, Japanrapporten).

Variationsgapet växte tyst. I takt med att ekonomin mognade, befolkningen åldrades, Kina reste sig och digitala teknologier omstrukturerade den globala konkurrensen expanderade störningsrummet **dim(R)** till att inkludera anpassningsförmåga, entreprenöriell dynamik, demografisk förnyelse och kapaciteten för paradigmskifte. Dessa dimensioner var strukturellt osynliga för en värderingsarkitektur kalibrerad för stabilitet. Systemet kunde uppfatta en sjunkande födelsetal, en planande tillväxttakt, en krympande arbetskraft — det publicerade noggranna prognoser — men det kunde inte uppfatta erosionen av sin egen förmåga att reagera på dessa signaler, eftersom den erosionen inte var en avvikelse från stabilitetsmålet. Den var en *konsekvens* av att ha träffat målet för exakt under för lång tid.

Kontinuitetsfällan är en överskridning av variationsgapet. Den exkluderade dimensionen — anpassningsförmåga — återvände som demografisk nedgång, regional utarmning, zombieföretag och en kulturell atmosfär av värdig resignation. Systemets egen optimeringslogik hindrar det från att uppfatta krisens källa eftersom källan är själva optimeringslogiken. De föreslagna åtgärderna — institutionell *Kaizen*, solnedgångslagstiftning, kontrollerad kreativ förstörelse, kommunal rekonfiguration — är alla i praktiken försök att öka **dim(V)** genom att lägga till anpassningsförmåga och förnyelse som explicita värdedimensioner.

5.2 Ryssland: Optimering för kontroll förstör observerbarhet

Rysslands maktvertikal är det renaste fallet av en värderingsarkitektur som selekterar för sin egen observationsmässiga förstörelse. Målfunktionen är kontroll — specifikt regimens överlevnad, vilket kräver undertryckande av varje oberoende auktoritetscentrum som skulle kunna utmana den. **dim(V) ≈ 1** (*Governance as Engineering Series*, Rysslandsrapporten).

Den exkluderade dimensionen är sanning. Vertikalen förstör systematiskt den distribuerade intelligensen, de oberoende återkopplingskanalerna och det institutionella substrat som adaptiv styrning kräver, eftersom var och en av dessa, från vertikalens perspektiv, är ett potentiellt hot. Underrättelseapparaten berättar för presidenten vad han vill höra; militärledningen berättar för försvarsministern vad han vill höra; Potemkinkulisseeffekten fångar till slut själva ledarskapet i en fabricerad verklighet (Gel'man, 2015).

Variationsgapet vidgas snabbt. Systemet förlorar förmågan att uppfatta sin egen strategiska miljö. Kontroll–Blindhet–Chock-slingan — centralisera, undertryck återkoppling, bli blind, upplev katastrofal chock, överkorrigera reaktivt, återcentralisera — är den dynamiska signaturen för ett system som opererar långt bortom **G_crit**. Den exkluderade dimensionen återvänder som strategisk överraskning: Afghanistan, Sovjetkollapsen, Tjetjenien,

Georgien, Ukraina. Systemet kan inte lära eftersom lärande kräver att man uppfattar gapet mellan sin modell av verkligheten och verkligheten själv — och det gapet är just vad värderingsarkitekturen har gjort osynligt.

Ryssland är ramverkets gränsfall. Infrastrukturen för att expandera **dim(V)** — distribuerad auktoritet, säkra återkopplingskanaler, en befolkning som inte systematiskt tränats till passivitet — har medvetet förstörts. Ramverket kan diagnostisera tillståndet; det kan inte, inom den existerande arkitekturen, ordinera ett botemedel.

5.3 Storbritannien: Optimering för centraliserad leverans exkluderar lokal kontext

Storbritanniens styrningsarkitektur har under årtionden optimerat för centraliserad kontroll av leverans. Under regeringar från båda stora partier har beslutsfattande auktoritet koncentrerats till Westminster medan lokal institutionell kapacitet gradvis har urholkats (Bevir & Rhodes, 2003). Värdefunktionen är **dim(V) ≈ 1**: skenet av koherent, nationellt styrt handlande, mätt genom centralt specificerade mål och kapacitetsmätt (Governance as Engineering Series, Storbritannienrapporten).

De exkluderade dimensionerna inkluderar lokal kontextuell kunskap, relationell tillit, distribuerad institutionell kapacitet och den stressabsorptionsinfrastruktur — gemenskapsutrymmen, ungdomsverksamhet, bostadsstöd — som bearbetar social påfrestning innan den når det individuella nervsystemet. Centralisera–Misslyckas–Centralisera-slingan beskriver gapdynamiken: central ambition → standardiserad design → lokal glapp → leveransmisslyckande → politiskt tryck → ytterligare centralisering. Varje cykel vidgar gapet genom att ytterligare urholka den lokala kapacitet som skulle behövas för att sluta det.

Överskridningen av variationsgapet manifesteras som kontroll-leveransglappet. Centralmakten tillkännager 8 500 nya psykisk ohälsa-arbetare medan de lokala myndigheter som skulle kunna förhindra psykisk ohälsa-kriser genom social infrastruktur är bankrutta. De exkluderade dimensionerna — lokal kontext, relationell tillit, gemenskapsresiliens — återinträder som stigande psykisk ohälsa-fall, sjunkande institutionell tillit och post-Brexit-suveränitetsparadoxen där "att ta tillbaka kontrollen" producerade mindre kontroll, inte mer, för de gemenskaper som röstade för det. De föreslagna Banbrytarregionerna, översättningslagren och utfallsmåtten är strukturella försök att öka **dim(V)** genom att följa leveranstrohet och stressfördelningsindikatorer vid sidan av de centrala kapacitetsmåten.

5.4 Brasilien: Optimering för koalitionsöverlevnad exkluderar medborgarpreferenser

Brasiliens 1988 års konstitution skapade en styrningsarkitektur som i praktiken optimerar för koalitionsöverlevnad. Presidentskapet är hypermäktigt men kongressen är hyperfragmenterad; inget presidents parti har någonsin varit i närheten av en legislativ majoritet. För att regera måste den verkställande makten sammanställa en flerpartikoalition vars transaktionsvaluta är staten själv (Governance as Engineering Series, Brasilienrapporten; Scalia, 2020). Värdefunktionen är **dim(V) ≈ 1**: styrbarhet, köpt genom fördelning av ministerposter, budgetändringar och patronatskap.

Den exkluderade dimensionen är genuin demokratisk representation — medborgarpreferensers förmåga att färdas genom det politiska systemet och forma policyutfall. *Centrao's* transaktionsfilter förstör preferenssignalen. Representationskedjan — medborgare till kommunfullmäktigeledamot till delstatsdeputerad till federal deputerad till minister — är tillräckligt djup och brusig för att signal-brusförhållandet ska falla under ett, ett fenomen förenligt med det bredare fyndet att genomsnittliga medborgarpreferenser har nära noll inflytande på policy i system dominerade av organiserade intressen (Gilens & Page, 2014). Policynivån styr en fantom och reagerar på brusstrukturen i koalitionsförhandlingsprocessen snarare än på vad medborgarna faktiskt vill.

Variationsgapet vidgas i takt med att infångningsjämvikten stabiliseras. Den exkluderade dimensionen återvänder som Genombrott–Infångningsslingan: kris producerar ett anmärkningsvärt institutionellt genombrott — *Plano Real*, *Bolsa Família*, *PIX*, *Operation Car Wash* — som skapar genuint värde, men infångningsarkitekturen, som genombrottet inte monterade ned, omringar värdet och extraherar det. Vinsterna försvinner; systemet återgår till en lågkapacitetsbaslinje. Cykeln upprepas, varje gång från en startpunkt inte mycket högre än den föregående, eftersom den exkluderade dimensionen — demokratisk ansvarsskyldighet — inte kan ackumuleras.

Den föreslagna Algoritmiska förbifarten, kommunala laboratorier och anti-infångningsarkitekturen är mekanismer för att expandera **dim(V)** genom att skapa oberoende observationskanaler — budgetspårning i realtid, medborgardeliberativa råd, självupprätthållande leveranskontrakt — som inte är föremål för koalitionsfiltret.

5.5 Europeiska unionen: Optimering för förhandling exkluderar temporal och rumslig koherens

Europeiska unionen är ett metasystem sammansatt av 27 suveräna styrningsarkitekturer, av vilka flera lider av sina egna variationsgapunderskott. EU:s egen värdefunktion, formad av dess institutionella struktur, är **dim(V) ≈ 1**: medlemsstatskonsensus. Varje beslut måste passera genom en förhandlingsprocess kalibrerad till den mest motvilliga medlemmen. Måttet är överenskommelse (Governance as Engineering Series, EU-rapporten).

De exkluderade dimensionerna är hastighet och rumslig koherens. EU kan konvergera mot ett beslut — återhämtningsfonden på 750 miljarder euro, migrationspakten, klimatmålen — men det kan inte anlända tillsammans, i tid. Förhandlings-Utspädningsslingan beskriver gapdynamiken: kris → nödkoordination → partiell överenskommelse → utspädd implementering över 27 olika administrativa system → temporär stabilisering →

underliggande divergens kvarstår. Systemet optimerar för att undvika oenighet snarare än att maximera samstämmighet.

Variationsgapet vidgas i takt med att integrationen fördjupas. En delad valuta utan finansunion, öppna gränser utan enhetliga migrationssystem, sammankopplade energinät utan gemensam strategisk planering — varje expansion av ömsesidigt beroende skapar nya störningsdimensioner som den konsensusbaserade värderingsarkitekturen inte kan följa. De exkluderade dimensionerna återvänder som polykrisen: energichock, geopolitisk krigföring, inflation, klimatstörningar, som alla anländer simultant över ett system vars koordination opererar på en tidsskala av månader till år medan kriser opererar på dagar till månader.

De föreslagna Koherensregionerna, stående finanspolitisk kapacitet, differentierat beslutsfattande och subsidiaritet som ett routingprotokoll är försök att öka **dim(V)** genom att lägga till temporal responsivitet och rumslig differentiering som explicita värddimensioner — utan att, avgörande nog, förstöra den medlemsstatsdiversitet som gör unionen värd att bevara.

5.6 Sammanfattande tabell

Värdena för $\dim(V)$, $\dim(R)$ och G i denna tabell är kvalitativa bedömningar baserade på landsrapporternas diagnostiska fynd. De illustrerar hur variationsgap-ramverket skulle tolka dessa fynd, men de utgör inte oberoende mätningar. Att behandla dem som data vore ett kategorifel. De är konceptuell byggnadsställning — plattshållare för de faktiska mätningar som Appendix G:s protokoll skulle producera.

Tabellens värde ligger i att visa att olika styrmissslyckanden kan karakteriseras med en gemensam vokabulär (variationsgap, uteslutna dimensioner, kollapsmoder). Dess svaghet är att denna karakterisering inte har validerats mot oberoende empiriska data.

Land / System	Ungef. $\dim(V)$	Kärnvärde som optimeras	Viktigaste exkluderade $\dim(R)$	G-status	Kollapsmod
Japan	1	Stabilitet / Kontinuitet	Anpassningsförmåga, förnyelse	$> G_{crit}$	Gradvis systemisk frysning (demografisk stagnation)
Ryssland	1	Kontroll / Regimöverlevnad	Sanning, distribuerad intelligens	$\gg G_{crit}$	Strategisk blindhet → plötsliga chocker
Storbritannien	1	Centraliserad leverans / Kontrollskén	Lokal kontext, relationell tillit, stressfördelningsinfrastruktur	$> G_{crit}$	Implementeringsmisslyckande, demokratisk fränkoppling
Brasilien	1	Koalitionsöverlevnad / Styrbarhet	Medborgarpreferenser, demokratisk ansvarsskyldighet	$> G_{crit}$	Genombrott-Infångningscykler, ackumuleringsunderskott
Europeiska unionen	1	Medlemsstatskonsensus	Hastighet, rumslig koherens, temporal samstämmighet	$> G_{crit}$	Polykris, Förhandlings-Utspänningsspiral

Tabellen erbjuds inte som en precis empirisk mätning — värdena är ungefärliga, heuristiska och avsedda att illustrera ramverket snarare än att bevisa det. Vad de avslöjar är en strukturell monotonicitet: i varje fall har en värderingsarkitektur som approximerar en endimensionell optimeringsfunktion tillåtit variationsgapet att vidgas förbi den kritiska tröskeln där de exkluderade dimensionerna återinträder som existentiella kriser. De specifika kriserna skiljer sig åt — demografisk frysning, strategisk chock, implementeringsmisslyckande, ackumulationskollaps, polykris — men den underliggande mekanismen är densamma.

Implikationen är inte att dessa system borde ha "lite mer" av de exkluderade dimensionerna. Det är att deras värderingsarkitekturer är *dimensionalitsbegränsade* på ett sätt som garanterar slutgiltig upplösning om inte dimensionaliteten expanderar. Del VI tar upp frågan om hur ett styrsystem kan utforma för sådan expansion — medvetet, adaptivt och innan gapet blir oöverbryggbart.

Del VI — Metastyrning: Att utforma för öppen värdeevolution

Vi har diagnostiserat mönstret: lågdimensionella värderingsarkitekturer tillåter variationsgapet att vidgas tills exkluderade dimensioner återvänder som olösliga kriser. Landrapporterna illustrerar att detta inte är en hypotetisk bana utan det observerbara tillståndet hos flera av världens mest sofistikerade styrsystem. Frågan som kvarstår är om banan kan förändras — och i så fall vilka institutionella former den förändringen kräver.

Denna del skiftar från diagnos till design. Den föreskriver inte en specifik värderingsarkitektur; ramverket har ingen auktoritet att göra det. Den specificerar de strukturella egenskaper som varje värderingsarkitektur måste besitta om den ska undvika den självblindande dynamik som beskrivits i Del I till V. Och den argumenterar för att det högsta ordningens styrningsproblem inte är valet av rätt värden, utan konstruktionen av institutioner kapabla att medvetet utveckla sina egna värderingsarkitekturer i takt med att störningsmiljön förändras.

6.1 Det högsta ordningens styrningsproblem

Om målfunktioner är observationsarkitekturer, och om verklighetens effektiva dimensionalitet expanderar över tid, då har varje fix värderingsarkitektur en ändlig livslängd. Den kan vara tillräcklig för den störningsmiljö i vilken den utformades, men i takt med att nya dimensioner uppstår — klimatförändring inför en koldimension; digitala medier inför en epistemisk integritetsdimension; demografisk transition inför en generationsrättvisdimensionsdimension — hamnar arkitekturens dimensionalitet på efterkälken. Variationsgapet växer. Till slut överskrider systemet **G_crit** och inträder i det tillstånd av strukturell självblindhet som beskrivs i Del III.

Detta ger en skarp implikation: *den centrala styrningsutmaningen för en komplex civilisation är inte att välja den korrekta målfunktionen, utan att upprätthålla kapaciteten att revidera målfunktionen i takt med att miljöns dimensionalitet expanderar.* Kalla detta metastyrningsproblemet. Det är problemet att styra styraren — eller, mer precist, att styra den värderingsarkitektur som avgör vad styraren kan uppfatta.

Metastyrningsproblemet har ingen slutgiltig lösning. Eftersom **dim(R)** är öppen (Kauffman, 2000) finns det ingen slutlig, komplett uppsättning värden som permanent kommer att sluta gapet. Den enda livskraftiga hållningen är en pågående process av värdeedimensionell expansion — en permanent kapacitet för perceptuell evolution. Alternativet är att acceptera att systemet så småningom kommer att överrumplas av dimensioner det inte kan se, och att dess egen optimeringslogik kommer att förhindra det från att känna igen blindhetens källa.

6.2 Andra ordningens kybernetik och värderingsarkitektur

Andra ordningens kybernetik, med ursprung i Heinz von Foersters arbete och utvecklad av tänkare som Stafford Beer, gör en distinktion som är direkt tillämplig här. Ett första ordningens kybernetiskt system reglerar sin miljö. Ett andra ordningens kybernetiskt system reglerar sin egen reglering — det observerar sitt eget observerande och justerar sin perceptuella apparat i ljuset av vad det lär sig om sina egna blinda fläckar (von Foerster, 1984).

Ett styrsystem som behandlar sin värderingsarkitektur som given och fix opererar på första ordningen. Det optimerar för en specificerad uppsättning utfall och behandlar varje misslyckande att uppnå dessa utfall som ett implementeringsproblem, inte ett specifikationsproblem. Ett styrsystem som behandlar sin värderingsarkitektur som ett föremål för medveten design — som bygger kapaciteten att ifrågasätta, granska och utveckla de dimensioner längs vilka det uppfattar framgång och misslyckande — opererar på andra ordningen. Det erkänner att de farligaste misslyckandena inte är misslyckanden att uppnå de uttalade målen, utan misslyckanden att lägga märke till att målen själva har blivit felriktade i förhållande till den verklighet systemet måste navigera.

Ashby-begränsningen gäller även på denna metanivå. Regulatören av värderingsarkitekturen måste själv besitta tillräcklig variation för att upptäcka gaptillväxt, för att skilja signal från brus i framväxten av nya störningsdimensioner och för att utlösa anpassning innan **G_crit** överskrids. En metastyrningsinstitution med låg variation — säg, en kommitté av existerande maktbärare som granskar sina egna mål — kommer att tendera att bevara den existerande dimensionaliteten eftersom den inte kan uppfatta de dimensioner den saknar. Designutmaningen är att skapa metastyrningsinstitutioner med högre variation än den värderingsarkitektur de har till uppgift att utveckla. Beer (1979) erkände detta problem inom organisationsdesign och argumenterade för att de metasystemiska funktionerna hos en livskraftig organisation — de som styr styrandet — själva måste vara föremål för rekursiv variationsingenjörskonst.

6.3 Institutionella mekanismer för värdeevolution

Hur skulle sådana institutioner kunna se ut i praktiken? Landrapporterna och ingenjörskartiklarna innehåller fröet till ett svar. Över de olika diagnoserna återkommer en gemensam uppsättning institutionella former — inte som tillfälliga drag i specifika förslag, utan som de strukturella förutsättningarna för varje system som söker expandera sitt eget perceptuella fält. Fyra mekanismer är särskilt framträdande.

Värdegranskning. På samma sätt som en finansiell granskning bedömer integriteten i en organisations räkenskaper, skulle en värdegranskning bedöma dimensionaliteten i ett styrsystems målfunktion. Den skulle fråga: vilka dimensioner av verkligheten följer detta system för närvarande? Vilka dimensioner, kända för att vara kausalt relevanta för systemets långsiktiga livskraft, är frånvarande från dess optimeringslandskap? Vad är det

uppskattade variationsgapet, och vad är dess förändringstakt? Värdegranskningen behöver inte producera ett precist numeriskt svar — mätutmaningarna är betydande, såsom diskuteras i Appendix B — men det strukturerade, institutionaliserade ställandet av frågan skulle i sig vara en perceptuell expansion. Det skulle göra gapet diskuterbart på ett sätt som de flesta styrningsarkitekturer för närvarande inte tillåter.

Ständiga deliberativa organ med mandat att synliggöra nya dimensioner. Medborgarpaneler, intergenerationella råd och framtidskommissioner uppträder återkommande i landrapporternas rekommendationer — inte som kosmetisk demokratisk fönsterputsning, utan som sensoriska organ. En legislatur vald på korta valcykler och organiserad kring existerande partipolitiska dimensioner är strukturellt begränsad i sin förmåga att uppfatta långsamma, distribuerade, framväxande störningsdimensioner. Ett ständigt deliberativt organ sammansatt av medborgare utvalda genom sortition, med ett mandat att överväga långtidshorisontutmaningar och synliggöra värden som det existerande politiska systemet inte kan registrera, tillhandahåller en kompletterande observationskanal. Dess variation är högre än legistatuens eftersom den inte är begränsad av valkonkurrensens dimensionalitet. Den kan uppfatta vad den existerande värderingsarkitekturen gör osynligt. Habermas (1996) och Dryzek (2000) har, från demokratiteorins insida, argumenterat för att legitimt lagstiftande kräver deliberativa procedurer som tillåter nya anspråk och perspektiv att komma upp till ytan — en konvergens mellan det normativa argumentet för deliberativ demokrati och det strukturella argumentet för att expandera perceptuell variation.

Japans föreslagna Demokratikommission, Brasiliens föreslagna kommunala medborgarråd, EU:s föreslagna ständiga medborgarpaneler för långtidshorisontbeslut och Storbritanniens föreslagna deliberativa infrastruktur för psykisk hälsa och social omsorg är alla instanser av samma strukturella drag: att skapa ett institutionellt rum där nyblivna relevanta dimensioner kan synliggöras innan de blir kriser.

Konstitutionella protokoll för förebyggande reform. Upplösning, såsom hävdades i Del III, är en strukturell nödvändighet när **G** väl överskrider **G_{crit}**. Frågan är om upplösning tar formen av katastrofal kollaps eller hanterad arktekonisk transition. Ett styrsystem som önskar undvika kollaps måste skapa legala och institutionella vägar för att reformera sin egen värderingsarkitektur — procedurer för konstitutionella tillägg, solnedgångsklausuler för större institutionella arrangemang, mekanismer för att överföra auktoritet till högre dimensionella värderamverk — som är rigorösa nog att förhindra infångning men flexibla nog att tillåta evolution.

"Solnedgångslagstiftningen" som föreslås i Japanrapporten, "anti-infångningsarkitekturen" som specificeras i Brasilienrapporten och "finanspolitik-prestationsanpassningen" som utformats för Storbritannienrapporten är alla, i grunden, protokoll för *förebyggande upplösning*: mekanismer som tillåter en dimension av den existerande arkitekturen att avvecklas och ersättas innan dess otillräcklighet genererar en systemisk kris. De är styrningens motsvarighet till adaptiv gain scheduling i styrteori — kapaciteten att justera styrparametrarna i respons på förändringar i systemdynamiken.

Värdefraktalitet. Artikel I och II i ingenjörsserien fastställde att ingen enskild styrenhet kan stabilisera en flerskalig störningsmiljö. Samma logik gäller för värderingsarkitekturer. En enda, samhällsomfattande värdefunktion som tillämpas enhetligt över alla skalor — lokal, regional, nationell, planetär — kommer oundvikligen att vara för grov för att fånga dimensionaliteten i lokala kontexter samtidigt som den är för smal för att fånga dimensionaliteten i globala utmaningar. En fraktal värderingsarkitektur distribuerar funktionen för värdespecifikation över flera skalor, där varje följer de dimensioner som är relevanta för dess störningsband.

Lokala gemenskaper kan optimera för dimensioner av relationell integritet, platsbaserad ekologisk kunskap och omedelbart välmående som är osynliga för nationella indikatorer. Nationella system kan optimera för dimensioner av distributiv rättvisa, institutionell kapacitet och långsiktig finanspolitisk hållbarhet. Planetär styrning kan optimera för dimensioner av systemisk risk, global allmänningssintegritet och intergenerationell rättvisa. Den fraktala strukturen förhindrar att någon enskild värderingsarkitektur dominerar hela systemet — och förhindrar därför att hela systemet överrumplas av samma uppsättning exkluderade dimensioner simultant. Ostroms (1990) polycentriska styrningsteori tillhandahåller den empiriska grunden för detta påstående: bestående allmänningssinstitutioner nästlade lokal, regional och interkommunal styrning, där varje opererade med den observationsmässiga granularitet som var lämplig för dess skala. Den fraktala värderingsarkitekturen generaliserar denna princip från resurshantering till själva värderingsarkitekturen.

6.4 Helhetens asymptotiska natur

Denna artikels argument kan nu uttryckas i sin fullaste form, och termen "helhet" ges en precis innebörd som undviker den vaga spiritualism med vilken den ofta förknippas.

Ett styrsystem är *helhetligt* inte när det optimerar för allt — det är omöjligt — utan när det upprätthåller en aktiv, institutionaliserad kapacitet att expandera dimensionaliteten i vad det optimerar för, i respons på framväxten av nyblivna kausalt relevanta dimensioner. Helhet är inte ett sluttillstånd. Det är en asymptotisk egenskap: ett systems *närmande* mot fullare verklighetsintegration, styrt av den hastighet med vilken det kan expandera **dim(V)** i förhållande till den hastighet med vilken **dim(R)** expanderar.

Den "oändlighetsattraktor" som antydde i introduktionen är, i detta ramverk, inte ett metafysiskt påstående om verklighetens natur utan ett epistemiskt sådant om positionen för varje ändlig observatör. Eftersom verklighetens effektiva dimensionalitet är öppen — nya störningsdimensioner uppstår i takt med att teknologier, miljöer och sociala konfigurationer utvecklas — kan ingen ändlig värderingsarkitektur någonsin vara komplett. Gränsen är

ouppnåelig. Den enda livskraftiga hållningen är att upprätthålla en process av ständig uppstigning: en styrningsarkitektur som kan lära sig att värdera vad den tidigare inte kunde uppfatta. Denna idé ekar Peirces (1931–1958) uppfattning om undersökning som en obegränsad gemenskapsprocess som närmar sig sanningen asymptotiskt, aldrig anländer men alltid avancerar.

Denna omramning löser en långvarig spänning mellan teknokratisk optimering och holistisk intuition. Den teknokratiska impulsen är att förfinas de existerande måtten — att göra BNP mer exakt, att förbättra inflationsmålet, att optimera effektiviteten i existerande tjänsteleverans. Den holistiska impulsen är att insistera på att "allt hänger samman" och att smala mått förstör vad de misslyckas med att mäta (Bateson, 1972). Variationsgapsramverket visar att båda impulserna är delvis korrekta: teknokratisk förfining förbättrar signal-brusförhållandet inom en given dimensionalitet, men den kan inte adressera själva gapet, som växer ur dimensionalitetsunderskottet. Den holistiska impulsen identifierar korrekt att helhet är nödvändig — men den saknar ofta det analytiska språket för att specificera *vilka* ytterligare dimensioner som är strukturellt nödvändiga och *hur* de ska integreras. Ramverket tillhandahåller det språket.

6.5 Legitimitet och ramverkets gräns

En styrningsarkitektur som uppfyller alla de strukturella villkor som specificeras i denna artikel — tillräcklig värdedimensionalitet, fraktal distribution av värdespecifikation, ständiga deliberativa organ för dimensionssynliggörande, protokoll för förebyggande upplösning — skulle vara strukturellt kapabel till långsiktig adaptiv livskraft. Den skulle inte därmed vara legitim.

Legitimitet kan inte reduceras till informationsteoretisk effektivitet. Den kräver de styrdas samtycke, uttryckt genom processer som de styrda själva betraktar som auktoritativa. Den kräver narrativ, identitet och mening — känslan av att styrsystemet är *vårt*, att det förkroppsligar värden vi känner igen som våra egna, att deltagande i det är deltagande i ett kollektivt projekt med moralisk tyngd. Ingenjörssramverket har ingenting att säga om dessa dimensioner direkt. Det kan specificera de strukturella förutsättningarna för legitimitet — ett system som inte kan uppfatta medborgarpreferenser kan inte vara demokratiskt legitimt i någon meningsfull mening — men det kan inte leverera själva legitimitetsinnehållet. Detta parallelliserar den distinktion Habermas (1996) drar mellan lagens *fakticitet* (dess strukturella effektivitet) och dess *validitet* (dess normativa acceptabilitet), och insisterar på att båda är nödvändiga.

Detta är inte en svaghet i ramverket. Det är dess ärliga gräns. Ramverket identifierar vad som måste vara sant för att styrning ska vara strukturellt möjlig. Det identifierar inte vad som skulle göra ett särskilt styrningsarrangemang *rätt* eller *accepterat*. Ingenjörskonst kan utforma ett livskraftigt fartyg; den kan inte avgöra vart fartyget ska segla.

Vad ramverket däremot gör är att det snävar in utrymmet för legitim oenighet. Om denna artikels argument är korrekt, då är varje värderingsarkitektur som systematiskt exkluderar dimensionerna sanning, mening, välmående och relationell integritet inte bara etiskt tvivelaktig utan strukturellt självdestruktiv. Den konstruerar en bana mot upplösning, vare sig den avser det eller inte. Frågan om hur dessa dimensioner ska inkluderas — på vilken skala, genom vilka institutioner, med vilka avvägningar — förblir en fråga om kollektivt val. Frågan om *huruvida* de ska inkluderas, antyder ramverket, är det inte. Den besvaras av variationsmatematiken och de ackumulerande bevisen för civilisatoriska blinda fläckar.

6.6 Metastyrningsimperativet, omformulerat

Denna artikels argument har rört sig genom tre lager: en rigorös cybernetisk kärna som fastställer att målfunktioner är observationsarkitekturer och att låg dimensionalitet producerar självblindhet; en tolkande tillämpning på nationella styrningsmisslyckanden, som visar att variationsgapet förenar disparata kriser under en enda diagnostik; och en filosofisk extrapolation till helhetens natur och utformningen av värdeutvecklande institutioner.

Slutsatsen som framträder ur denna båge är denna: *en civilisation som vet hur man optimerar men inte hur man utvecklar vad den optimerar för är en civilisation som vet hur man springer men inte vart — och, så småningom, inte hur man ser stupet*. Metastyrningsimperativet är att inom styrningsarkitekturen bygga ett andra ordningens system vars funktion inte är att uppnå de nuvarande målen utan att ifrågasätta dem — att uppfatta, innan gapet blir fatalt, de dimensioner som den nuvarande värderingsarkitekturen exkluderar.

Detta är ett designproblem av utomordentlig svårighet. Det ber ett system att institutionalisera kapaciteten för sin egen självtranscendens — att bygga maskineriet för sin egen obsoletet. De institutionella former som skisserats i denna del — värdegranskningar, deliberativa dimensionssynliggörande organ, protokoll för förebyggande upplösning, fraktala värdedistributioner — är preliminära och ofullständiga. De är förslag på hur en metastyrningsarkitektur *skulle kunna* se ut, inte ritningar för hur den *måste* se ut.

Vad som inte är preliminärt är den diagnos som gör en sådan arkitektur nödvändig. Variationsgapet växer som standard, eftersom verkligheten genererar nyhet och värderingsarkitekturer tenderar mot stelhet. Ju närmare ett system kommer perfekt optimering av en fix uppsättning värden, desto mer fullständigt blindar det sig för allt utanför dessa värden. Goodharts lag är inte en kuriositet inom ekonomisk mätning. Den är det lokala uttrycket för en universell tendens: smal optimering förstör den perceptuella kapacitet på vilken optimering beror. Det enda sättet att bryta tendensen är att in i själva styrningsarkitekturen bygga en permanent öppenhet för de dimensioner det ännu inte har lärt sig att värdera.

Detta fullbordar artikelns substantiella båg. Del VII kommer att avsluta med att omformulera det centrala argumentet, sammanfatta bidragen och identifiera de öppna frågor som definierar forskningsfronten.

Del VII — Slutsats: Från diagnos till imperativ

Vi har rört oss från observationens formella arkitektur till variationsgapets dynamik, genom de saknade dimensionerna av social perception, till kollapsens empiriska illustrationer och slutligen till det metastyrningsmaskineri som skulle kunna möjliggöra medveten värdeevolution. Vad som återstår är att samla argumentet i en kompakt form, erkänna dess begränsningar och identifiera nästa steg för dem som vill testa eller utvidga det.

7.1 Argumentet i korthet

Varje styrsystem väljer, genom sin målfunktion, den delmängd av verkligheten det uppmärksammar. Det urvalet är inte en neutral representation av världen; det är en aktiv kompression som kasserar information. De kasserade dimensionerna — rumslig variation, temporal frekvens, preferensers fördelning, de långsamma signalerna om ekologisk och social integritet — är de dimensioner systemet blir strukturellt oförmöget att uppfatta. De upphör inte att verka. De ackumuleras som externaliteter, som oförklarad varians, som kriser vilka tycks komma från ingenstans, tills systemets egen optimeringslogik är oförmögen att känna igen källan till sin instabilitet.

Denna artikel har benämnt avståndet mellan verklighetens effektiva dimensionalitet och ett styrsystems värderingsarkitekturs dimensionalitet *variationsgapet* (**G**). Den har visat att **G** har dynamik: i en föränderlig värld tillåter en statisk värderingsarkitektur gapet att växa. När det överskrider en kritisk tröskel inträder systemet i konstitutionell oobserverbarhet — ett tillstånd där brus överväldigar signal och systemets interventioner, hur välmående de än är, blir frikopplade från den verklighet de måste påverka (Shannon, 1948). Vid den punkten är upplösning — värdeparadigmets död eller transformation — inte ett misslyckande utan en strukturell nödvändighet (Gould & Eldredge, 1977; Taleb, 2012).

Goodhart–Ashby-syntesen formaliserar kärnmekanismen: varje målfunktion med dimensionalitet lägre än variationen i det system den styr kommer så småningom att optimera bort sin egen förmåga att uppfatta systemets verkliga tillstånd (Ashby, 1956; Goodhart, 1975; Manheim & Garrabrant, 2018). Landrapporterna — Japan som optimerar stabilitet till stagnation, Ryssland som optimerar kontroll till blindhet, Storbritannien som optimerar centraliserad leverans till lokal oobserverbarhet, Brasilien som optimerar koalitionsöverlevnad till demokratisk oläsbarhet, Europeiska unionen som optimerar konsensus till temporal inkoherens — är inte anomalier. De är det förväntade utfallet av lågdimensionella värderingsarkitekturer som opererar i högdimensionella störningsmiljöer.

Helhet är, i detta ramverk, inte en sentimental anknytning till allt. Det är den asymptotiska egenskapen hos ett styrsystem som upprätthåller en aktiv kapacitet att expandera sin värdedimensionalitet i takt med att nya kausalt relevanta dimensioner framträder (Kauffman, 2000; Peirce, 1931–1958). Metastyrningsimperativet är att bygga institutioner — värdegranskningar, deliberativa dimensionssynliggörande organ, protokoll för förebyggande upplösning, fraktala värdedistributioner (Beer, 1979; Ostrom, 1990; Habermas, 1996; Dryzek, 2000) — som kan uppfatta gapet innan det blir fatalt, och som kan styra värderingsarkitekturens evolutionära expansion snarare än att vänta på att kollaps ska tvinga fram den.

7.2 Sammanfattning av bidrag

Artikeln gör fem distinkta bidrag till studiet av styrning, komplexa system och värdeteori.

För det första etablerar den den **strukturella identiteten mellan målfunktioner och observationsarkitekturer**. Detta enda drag förenar optimeringsteori, styrteori och epistemologi under en gemensam formalism. Det avslöjar att valet av vad man optimerar för samtidigt är valet av vad man blir blind för (Conant & Ashby, 1970).

För det andra formulerar den **Goodhart–Ashby-syntesen**. Goodharts lag visas vara ett specialfall av en djupare princip: lågdimensionell optimering förstör systematiskt den information som behövs för att upptäcka proxyvariabelns divergens från målvariabeln. Syntesen utvidgar Goodhart från den ekonomiska mätningens domän till arkitekturen för varje värdesystem.

För det tredje introducerar den **variationsgapet** (**G**) som ett enande diagnostiskt mått. Gapet definieras som glappet mellan verklighetens effektiva dimensionalitet och värdefunktionens dimensionalitet. Dess dynamik modelleras heuristiskt; dess kritiska tröskel identifieras; dess överskridande visas producera de signaturkollapsmönster som observerats över landrapporterna.

För det fjärde demonstrerar den ramverket genom **empirisk omtolkning av nationella styrningsmisslyckanden**. Landrapporterna, ursprungligen utvecklade oberoende inom serien *Governance as Engineering*, visas vara konsistenta med variationsgapsmekanismen. Varje rapport identifierar en lågdimensionell värderingsarkitektur, ett växande gap och en karakteristisk kollapsmod (Governance as Engineering Series; Gilens & Page, 2014; Bevir & Rhodes, 2003; Gel'man, 2015).

För det femte artikulerar den **metastyrningsimperativet**: erkännandet att det högsta ordningens styrningsproblem inte är valet av rätt mål, utan utformningen av institutioner kapabla att medvetet utveckla sina egna målfunktioner. Detta förskjuter diskursen från "vad bör vi optimera för?" till "hur kan vi förbli kapabla att ställa den frågan, med ökande sofistikation, över tid?" (von Foerster, 1984; Beer, 1979).

7.3 Öppna frågor och forskningsfronten

Argumentet som framförs här är en öppning, inte en slutsats. Flera betydande frågor förblir olösta.

Operationalisering av variationsgapet. Artikeln använder $\dim(R)$ och $\dim(V)$ heuristiskt. För att G ska bli en fullt operationell diagnostik skulle man behöva tillförlitliga metoder för att uppskatta den effektiva dimensionaliteten hos en störningsmiljö och den effektiva dimensionaliteten hos en värderingsarkitektur. Den förra skulle kunna dra nytta av tekniker från komplexitetsvetenskap — principalkomponentanalys av historiska störningsdata, attraktorrekonstruktion, effektiv dimensionsuppskattning i dynamiska system. Den senare skulle kunna involvera formell innehållsanalys av policymål, budgetallokeringar och institutionella mandat. Båda uppgifterna är icke-triviala, och denna artikel försöker dem inte. De utgör ett betydande empiriskt forskningsprogram.

Mätning av den kritiska tröskeln. Artikeln identifierar G_{crit} med signal-brusförhållandetröskeln från Artikel III, men den identifieringen är teoretisk. I verkliga styrsystem kan kollaps inträffa före eller efter den formella SNR-tröskeln, beroende på kopplingsstyrka, buffringskapacitet och de icke-linjära interaktioner som den nuvarande linjära modellen inte fångar. Att bestämma det empiriska värdet av G_{crit} över olika systemtyper är en prioritet för framtida arbete.

Ickelinjär dynamik. Modellen $dG/dt = \alpha - \beta \cdot A(V)$ är linjär och av första ordningen. Verkliga styrsystem uppvisar tröskeleffekter, hysteres och vägberoende som en linjär modell inte kan fånga (Meadows, 2008). Interaktionen mellan variationsgapstillväxt och den icke-linjära dynamiken i legitimitetskaskader, institutionella tippningspunkter och nätverkskollaps kräver mer sofistikerad behandling.

Transitions genomförbarhetsgradienten. Artikeln identifierar institutionella mekanismer för värdeevolution — granskningar, deliberativa organ, upplösningsskott — men adresserar inte fullt ut den politiska ekonomin för deras implementering. Samma lågdimensionella värderingsarkitekturer som gör sådana mekanismer nödvändiga genererar också motstånd mot deras antagande. Landrapporterna erbjuder transitionsvägar för specifika kontexter, men en generell teori om hur värderingsarkitekturer blir självmodifierande förblir ett öppet problem.

Legitimitetsgapet. Såsom erkändes i Del VI kan ingenjörsramverket specificera de strukturella villkoren för livskraft; det kan inte leverera demokratisk legitimitet. Hur man förenar behovet av värddimensionell expansion med kravet på folkligt samtycke, särskilt när de exkluderade dimensionerna ännu inte uppfattas av den befolkning vars samtycke söks, är ett djupt problem i skärningspunkten mellan politisk teori, kognitionsvetenskap och institutionell design. Artikeln löser det inte (Habermas, 1996; Dryzek, 2000).

7.3.1 Mätgapet

Ramverkets mest omedelbara begränsning är gapet mellan formell definition och empirisk mätning. Variablerna $\dim(V)$, $\dim(R)$, G och G_{crit} definieras precis i Bilagorna A–B med hjälp av linjär algebra, men verkliga styrsystem kommer inte med etiketterade observationsmatriser och störningsrymder. Appendix G tillhandahåller mätprotokoll, men dessa protokoll har inte implementerats. Detta innebär:

Alla kvantitativa påståenden i uppsatsen är provisoriska. Variationsgapsuppskattningarna för landfallen ($G \approx 2-3$), den kritiska tröskeluppskattningen ($G_{crit} \approx 2-3$), de dynamiska parametrarna (α , β) — alla är storleksordningsbedömningar, inte mätningar. De tjänar till att göra ramverket konkret och falsifierbart, men de har inte falsifierats (eller bekräftats) av data.

Ramverkets empiriska status är "testbart men ännu inte testat." Det genererar förutsägelser:

- System med större variationsgap bör uppvisa mer frekventa styrmisslyckanden
- Gaptillväxttakt bör korrelera med institutionell rigiditet
- Passage av G_{crit} bör producera karakteristiska misslyckandesignaturer (brusspårning, policy-utfallsdekorrelation)

Dessa förutsägelser är specifika nog att kunna vara felaktiga, vilket innebär att ramverket har empiriskt innehåll. Men att testa dem kräver implementering av Appendix G:s protokoll, vilket kräver resurser och tillgång som denna uppsats inte mobiliserar.

Forskningsprioriteten är operationalisering. Innan teoretiska utvidgningar eftersträvas behöver ramverket empirisk förankring. Detta innebär: att mäta $\dim(V)$ för 5–10 länder med hjälp av PCA på budget-/lagstiftningsstidsserier; att mäta $\dim(D)$ med hjälp av historisk chockfaktoranalys; att testa om uppskattad G förutsäger frekvensen av styrmisslyckanden i paneldata; och att empiriskt kalibrera G_{crit} genom att identifiera SNR-trösklar i dokumenterade kollapsar.

Tills detta arbete är gjort förblir ramverket en diagnostisk lins och konceptuell vokabulär — användbart för att organisera observationer, men inte validerat som förklarande eller prediktivt.

7.4 Det civilisatoriska vadet

Variationsgapsramverket implicerar ett vad. Vadet är att en civilisation som lär sig att medvetet expandera sin värderingsarkitektur — som bygger kapaciteten att uppfatta vad den för närvarande exkluderar — kommer att överleva en som inte gör det. Vadet kan inte bevisas i förväg; det kan endast testas av historien.

Men det historiska protokollet, sådant det är, lutar mot ramverkets prediktion. Civilisationer som optimerade för en smal uppsättning värden — militär expansion, elitextraktion, ideologisk renhet, kortsiktigt välstånd — kollapsade upprepade gånger på sätt som deras egna beslutsfattare inte kunde förutse, eftersom kollapsens källor låg i dimensioner deras värderingsarkitekturer inte kunde registrera. Mönstret är inte deterministiskt; det finns motexempel på adaptiva civilisatoriska transitioner. Men bevisbördan, antyder ramverket, ligger hos påståendet att en fix, lågdimensionell värderingsarkitektur kan hantera en öppen störningsmiljö i oändlighet (Taleb, 2012; Kauffman, 2000).

Vad ramverket erbjuder är inte ett slutgiltigt svar utan ett strukturerat sätt att ställa frågan. Det tillhandahåller ett språk i vilket de strukturella nödvändigheterna för värdeevolution kan göras precisa. Det identifierar variationsgapet som den enda variabel som spårar den ackumulerande risken för systemisk blindhet. Det föreslår, i preliminär form, det institutionella maskineri som skulle kunna hålla gapet inom gränser. Och det insisterar, med så mycket klarhet som den nuvarande formella apparaten tillåter, att frågan om vad en civilisation lär sig att värdera är det mest konsekvensrika designbeslut den någonsin kommer att fatta — och det för vilket den för närvarande är sämst utrustad.

7.5 Inbjudan

Vad som har etablerats: Uppsatsen etablerar ett konceptuellt ramverk och en formell struktur. Den visar att målfunktioner är observationsarkitekturer (Del II), att lågdimensionell observation skapar strukturell blindhet (Del I–III) och att specifika uteslutningar (sanning, mening, välbefinnande, relationell integritet) accelererar gaptillväxt (Del IV). Den demonstrerar att disparata styrmisslyckanden kan omtolkas med hjälp av en enhetlig vokabulär (Del V) och specificerar institutionella mekanismer som i princip skulle möjliggöra värdeevolution (Del VI).

Vad som inte har etablerats: Ramverket har inte validerats empiriskt. Landfallsomtolkningarna är konsistenta med ramverket men testar det inte. Mätprotokollen existerar men har inte implementerats. De kvantitativa påståendena ($G \approx 2-3$, $G_{crit} \approx 2-3$) är illustrativa, inte uppmätta. Den dynamiska modellen är konceptuell, inte kalibrerad.

Gränsen mellan bidrag och strävan: Bidraget är ett *sätt att se* styrmisslyckanden — en strukturerad vokabulär och formell apparat som gör vissa mönster synliga. Strävan är att detta sätt att se ska visa sig vara empiriskt grundat när mätarbetet väl är gjort. Uppsatsen kan inte påstå sig ha fullbordat det arbetet, endast ha specificerat vad det skulle kräva.

Simuleringarna, de formella härledningarna och landanalyserna som presenterats över serien *Governance as Engineering* och denna artikel utgör ett diagnostiskt instrument. De genererar testbara prediktioner: om relationen mellan värdedimensionalitet och kollapsrisk, om variationsgapets tillväxtdynamik under olika anpassningsregimer, om prestationseffekterna av specifika metastyrningsinstitutioner. Prediktionerna väntar på empirisk konfrontation.

Artikeln avslutar därför inte med en deklaration utan med en inbjudan. Inbjudan är att behandla variationsgapet inte som en metafor utan som en variabel — att mäta det, att modellera det, att testa dess konsekvenser och att utforma de institutioner som skulle kunna hindra det från att överskrida den tröskel vid vilken en civilisation inte längre kan se källorna till sin egen skörhet.

Arbetet som ligger framför är substantiellt. Det kommer att kräva samarbete över styrteori, komplexitetsvetenskap, politisk ekonomi, institutionell design och de många domäner av värdeteori som denna artikel endast har börjat integrera. Det kommer att kräva institutionella experiment — värdegranskningar i verkliga styrningssammanhang, deliberativa dimensionssynliggörande organ med genuina mandat, protokoll för förebyggande upplösning testade på hanterbara skalor — vars utfall inte kan garanteras men vars brådska kan demonstreras.

Vad ramverket tillhandahåller, i detta skede, är en startpunkt som är rigorös nog för att vara fel på specifika, identifierbara sätt och därmed kapabel att förbättras. Om variationsgapsmekanismen motstår empirisk testning kommer den att erbjuda styrsystem något de aldrig har haft: en formell redogörelse för varför vad de optimerar för avgör vad de kan uppfatta, varför den begränsningen till slut förstör dem, och vad de skulle kunna bygga för att transcendera den innan gapet blir en grav.

Appendix A: Formell härledning av villkoret för minsta värdeedimensionalitet (statisk)

Detta appendix formaliserar utvidgningen av Ashbys lag om nödvändig variation från fysiska styrenheter till värderingsarkitekturer, vilket ger villkoret $\dim(\mathbf{V}) \geq \dim(\mathbf{D}) - \dim(\mathbf{G})$ som används i huvudtexten. Härledningen är statisk: den behandlar störningsrummet och värderingsarkitekturen som fixa, utan att modellera deras temporala evolution (se Appendix B för den dynamiska utvidgningen).

A.1 System, störning och mål

Betrakta ett system $\mathbf{S}$ vars tillstånd vid varje tidpunkt är en vektor $\mathbf{x} \in \mathbf{X}$, där $\mathbf{X}$ är ett ändligdimensionellt vektorrum över de reella talen. Systemet är utsatt för en störningsvektor $\mathbf{d} \in \mathbf{D}$, där $\mathbf{D}$ är störningsrummet. Systemets dynamik modelleras inte direkt; vi abstraherar den till avbildningen från störningar till utfall.

En *styrningsregulator* (en värderingsarkitektur) försöker hålla systemet inom en utsedd målmängd $\mathbf{G} \subset \mathbf{X}$. Målmängden representerar de acceptabla tillstånden i världen såsom de definieras av värderingsarkitekturen. Om exempelvis värderingsarkitekturen följer BNP och arbetslöshet är $\mathbf{G}$ mängden av tillstånd där båda är inom acceptabla gränser.

Regulatorn observerar inte det fulla tillståndet $\mathbf{x}$. Den observerar en projektion:

$$\mathbf{y} = \mathbf{C} \mathbf{x} + \boldsymbol{\epsilon}$$

där $\mathbf{C}: \mathbf{X} \rightarrow \mathbf{Y}$ är en linjär observationsmatris och $\boldsymbol{\epsilon}$ är brus. Valet av $\mathbf{C}$ bestäms av värderingsarkitekturen: den väljer vilka dimensioner av tillståndsrummet som är operationellt synliga.

A.2 Variation som dimensionalitet

Ashby definierade variation som logaritmen av antalet särskiljbara tillstånd. I ett kontinuerligt tillståndsrum anpassar vi detta som den *effektiva dimensionaliteten* — rangen av det relevanta vektorrummet. Specifikt:

- $\dim(\mathbf{D})$ = störningsrummets rang: antalet oberoende sätt på vilka systemet kan knuffas bort från sitt mål.
- $\dim(\mathbf{G})$ = målmängdens rang: antalet oberoende riktningar i vilka systemet tillåts variera och fortfarande betraktas som "acceptabelt." Om målet är en enda punkt är $\dim(\mathbf{G}) = 0$.
- $\dim(\mathbf{V})$ = observationsrummets $\mathbf{Y}$ rang, dvs. antalet oberoende signaldimensioner som värderingsarkitekturen kan särskilja.

Detta är en förenkling: verkliga störningar kan vara icke-linjära, icke-Gaussiska och dynamiskt kopplade. Rangvillkoret fångar det linjära fallet; utvidgningar är möjliga men bortom det aktuella omfånget.

A.3 Ashbys lag i dimensionell form

Ashbys lag i sin ursprungliga formulering: $\mathbf{V}(\mathbf{R}) \geq \mathbf{V}(\mathbf{D}) - \mathbf{V}(\mathbf{G})$, där $\mathbf{V}(\cdot)$ är variation. Genom att avbilda variation på dimensionalitet (för tillräckligt reguljära rum, med variation som logaritmen av antalet särskiljbara tillstånd, skalar variation med rang) erhåller vi:

$$\dim(\mathbf{V}) \geq \dim(\mathbf{D}) - \dim(\mathbf{G}) \quad (1)$$

Detta är det statiska villkoret för nödvändig variation för en regulator vars observationskanal har rang $\dim(\mathbf{V})$. Det fastställer: antalet oberoende signaldimensioner som regulatorn kan observera måste vara minst antalet oberoende störningsdimensioner minus antalet oberoende dimensioner som systemet tillåts ockupera inom målmängden.

Om $\dim(\mathbf{V}) < \dim(\mathbf{D}) - \dim(\mathbf{G})$ existerar störningsdimensioner som ligger i nollrummet för observationsmatrisen $\mathbf{C}$. Dessa störningar kan knuffa systemet ut ur målmängden utan att regulatorn någonsin registrerar en avvikelse, eftersom regulatorns observationsrum är ortogonalt mot dem.

A.4 Tillämpning på värderingsarkitekturer

En *värderingsarkitektur* fungerar som regulatorn i detta schema. Den definieras av en målfunktion $\mathbf{J}(\mathbf{x})$ som minimeras eller maximeras, men för stabilitetsändamål är den relevanta egenskapen *vilka avvikelser från det önskade tillståndet som är synliga som kostnader*. Värderingsarkitekturens effektiva observationsmatris $\mathbf{C}$ väljer de dimensioner av tillståndet som ingår i målfunktionen.

En värderingsarkitektur med $\dim(\mathbf{V}) = \mathbf{k}$ följer $\mathbf{k}$ oberoende dimensioner av systemets tillstånd och är blind för resten. Det minimala dimensionalitetsvillkoret (1) blir:

$$\dim(\text{Värderingsarkitektur}) \geq \dim(\text{Störningsrum}) - \dim(\text{Målmängd})$$

I huvudtexten förenklas detta till $\dim(\mathbf{V}) \geq \dim(\mathbf{D}) - \dim(\mathbf{G})$, med förståelsen att $\dim(\mathbf{D})$ — störningsmiljöns effektiva dimensionalitet — är stor och öppen i praktiken.

A.5 Tolkning och brasklappar

Denna härledning tillhandahåller en konceptuell brygga från Ashbys lag till variationsgapet. Det är inte ett operationellt mätprotokoll. De viktigaste begränsningarna är:

1. **Linjäritet:** Verkliga observationskanaler är icke linjära. Rangvillkoret fångar första ordningens informationsförlust; högre ordningens interaktioner mellan dimensioner modelleras inte.
2. **Dimensionalitetssuppskattning:** $\dim(\mathbf{D})$ och $\dim(\mathbf{G})$ är inte direkt observerbara i de flesta styrningssammanhang. Att uppskatta den effektiva dimensionaliteten hos en störningsmiljö kräver tidsserieanalys av historiska chocker, vilket är genomförbart i princip men icke-trivialt.
3. **Statiskt antagande:** Villkoret säger ingenting om hur $\dim(\mathbf{D})$ eller $\dim(\mathbf{V})$ förändras över tid. Det gäller för en fix ögonblicksbild. Det dynamiska fallet, där $\dim(\mathbf{D})$ expanderar och $\dim(\mathbf{V})$ måste anpassas, behandlas i Appendix B.
4. **Målmängdsdimensionalitet:** Termen $\dim(\mathbf{G})$ kan misstolkas. Om målmängden är en enda punkt (t.ex. exakt 2% inflation) är $\dim(\mathbf{G}) = 0$ och villkoret är $\dim(\mathbf{V}) \geq \dim(\mathbf{D})$. Om målet tillåter ett brett spektrum av acceptabel variation är $\dim(\mathbf{G})$ större och kravet på $\dim(\mathbf{V})$ är avslappnat. Detta fångar intuitionen att ett system med lösa mål behöver mindre precis observation.

Med förbehåll för dessa begränsningar uttrycker ekvation (1) artikelns arkitektoniska insikt i en kompakt, falsifierbar form: en värderingsarkitektur som följer för få dimensioner i förhållande till den störningsmiljö den möter är strukturellt oförmögen att stabilisera det system den styr. Variationsgapet $\mathbf{G} = \dim(\mathbf{D}) - \dim(\mathbf{G}) - \dim(\mathbf{V})$ kvantifierar underskottet; när $\mathbf{G} > \mathbf{G}_{\text{crit}}$ överskrider systemet den upplösningströskel som beskrivs i Del III.

Appendix B: Utvidgning till tidsvarierande dimensionalitet — Variationsgapets dynamik och upplösningströskeln

Appendix A behandlade störningsrummet $\mathbf{D}$ och värderingsarkitekturen $\mathbf{V}$ som statiska, vilket gav ett ögonblicksvillkor: $\dim(\mathbf{V}) \geq \dim(\mathbf{D}) - \dim(\mathbf{G})$. Men störningsmiljöns effektiva dimensionalitet är inte fix. Nya teknologier, miljöförändringar, sociala omstruktureringar och geopolitiska skiften introducerar kontinuerligt nya variationsdimensioner som styrsystem måste navigera. Detta appendix utvidgar det statiska villkoret till fallet där både $\dim(\mathbf{D})$ och $\dim(\mathbf{V})$ kan variera över tid, formaliserar den heuristiska modellen $d\mathbf{G}/dt = \alpha - \beta \cdot \mathbf{A}(\mathbf{V})$ som används i Del III och härleder upplösningströskelvillkoret.

B.1 Tidsvarierande dimensionalitet

Låt $\dim(\mathbf{D})(t)$ beteckna störningsrummets effektiva dimensionalitet vid tidpunkten t , och $\dim(\mathbf{V})(t)$ värderingsarkitekturens effektiva dimensionalitet vid tidpunkten t . Målmängdens dimensionalitet $\dim(\mathbf{G})$ antas vara fix för enkelhets skull — mängden acceptabla utfall behandlas som en konstitutionell konstant, även om den i praktiken också kan utvecklas.

Variationsgapet vid tidpunkten t är:

$$\mathbf{G}(t) = \dim(\mathbf{D})(t) - \dim(\mathbf{G}) - \dim(\mathbf{V})(t)$$

Det statiska villkoret $\mathbf{G} \leq 0$ (eller $\mathbf{G} < \mathbf{G}_{\text{crit}}$) är nu ett rörligt mål. Ett system som uppfyller villkoret vid t_0 kan överträda det vid t_1 om $\dim(\mathbf{D})$ växer snabbare än $\dim(\mathbf{V})$. Det evolutionära trycket på styrningsarkitekturer uppstår just ur denna dynamik: marken förskjuts under dem.

B.2 Störningsrummets dynamik

Expansionen av $\dim(\mathbf{D})$ drivs av framväxten av vad Kauffman (2000) kallar "det angränsande möjliga" — nya tillstånd och interaktioner som tidigare inte var nåbara. I styrningstermer uppstår nya störningsdimensioner genom mekanismer som inkluderar:

- **Teknologisk förändring:** digitalisering introducerar cybersäkerhet, epistemisk integritet och algoritmisk rättvisa som styrningsdimensioner vilka inte existerade i den fördigitala eran.
- **Miljöförändring:** klimatförändring introducerar koldioxidbudgetar, anpassningsfinansiering och hanterad reträtt som dimensioner av offentlig politik.
- **Social förändring:** demografisk transition, urbanisering och kulturell pluralisering introducerar generationsrättvisa, rumslig rättvisa och identitetserkännande som styrningsdimensioner.
- **Förstärkning av ömsesidigt beroende:** globalisering och nätverksinfrastruktur kopplar samman tidigare oberoende system, så att störningar i en domän (energimarknader, leveranskedjor, informationsekosystem) propagerar till andra, vilket ökar den effektiva dimensionaliteten i det kombinerade störningsrummet (Taleb, 2012).

Vi modellerar denna expansion som:

$$\dim(\mathbf{D})(t) = \dim(\mathbf{D})(0) + \int_0^t \alpha(s) ds$$

där $\alpha(s)$ är den momentana uppkomsthastigheten för nya störningsdimensioner vid tidpunkten s . Generellt är $\alpha(s)$ icke-negativ och sannolikt icke-stationär — perioder av snabb teknologisk eller geopolitisk förändring producerar högre α . Det enklaste hanterbara fallet, som används i huvudtexten, antar att α är approximativt konstant över den relevanta tidshorisonten, vilket ger:

$$\dim(\mathbf{D})(t) = \dim(\mathbf{D})(0) + \alpha t$$

B.3 Värderingsarkitekturens dynamik

Värderingsarkitekturen kan också expandera sin dimensionalitet över tid — genom tillägg av nya mått, skapandet av nya styrningsinstitutioner eller synliggörandet av tidigare exkluderade värden genom politisk mobilisering eller deliberativa processer (Dryzek, 2000). Vi modellerar denna expansion som:

$$\dim(\mathbf{V})(t) = \dim(\mathbf{V})(0) + \int_0^t \beta(s) \cdot \mathbf{A}(\mathbf{V})(s) ds$$

där:

- $\mathbf{A}(\mathbf{V})(s)$ är *anpassningsansträngningen* vid tidpunkten s — resurserna och den politiska vilja som ägnas åt att expandera värderingsarkitekturen.

- $\beta(s)$ är *anpassningseffektiviteten* — den andel av anpassningsansträngningen som framgångsrikt översätts till en ökning i effektiv dimensionalitet. β kan vara mindre än 1 på grund av institutionell friktion, infångning av reformprocesser eller den inneboende svårigheten att uppfatta dimensioner som den existerande arkitekturen exkluderar.

Genom att kombinera dessa ges variationsgapets dynamik av:

$$dG/dt = \alpha(t) - \beta(t) \cdot A(V)(t) \quad (2)$$

Detta är den formella motsvarigheten till den heuristiska ekvationen i Del III. Gapet växer när uppkomsthastigheten för nya störningar överstiger den hastighet med vilken värderingsarkitekturen expanderar sin dimensionalitet. Gapet krymper när anpassning löper snabbare än uppkomst.

B.4 Den kritiska upplösningströskeln

Alla positiva värden på G är inte katastrofala. Ett system kan fungera med ett måttligt variationsgap och absorbera den observerade variansen som oförklarad brus, förutsatt att signalen från de observerade dimensionerna förblir dominant. Katastrof inträffar när gapet överskrider en kritisk tröskel G_{crit} vid vilken signal-brusförhållandet i värdekanalen faller under ett.

För att formalisera G_{crit} måste vi relatera variationsgap till informationsförlust. Observationskanalen $y = Cx + \epsilon$ överför information om det sanna tillståndet x med en hastighet begränsad av kanalkapaciteten (Shannon, 1948). När G ökar — när fler störningsdimensioner faller in i nollrummet för C — minskar den ömsesidiga informationen mellan x och y . SNR i värdekanalen är en avtagande funktion av G .

Efter ramverket från Artikel III definierar vi G_{crit} som det värde på gapet vid vilket:

$$I(x; y) \leq I(\epsilon; y)$$

där $I(x; y)$ är den ömsesidiga informationen mellan det sanna tillståndet och observationen, och $I(\epsilon; y)$ är den ömsesidiga informationen mellan bruset och observationen. Informellt: den information observationen bär om verkligheten är inte större än den information den bär om kanalens brusstruktur. Bortom denna punkt är systemets observationer mer informativa om egenskaperna hos dess egen mätapparatur än om den värld det måste styra.

För linjära Gaussiska kanaler reduceras detta villkor till den SNR-tröskel som är välbekant från signalbehandling: signalvariansen faller under brusvariansen. Det precisa värdet av G_{crit} beror på kanalstrukturen C och bruskovariansen, men den kvalitativa poängen är robust: det existerar en tröskel bortom vilken observationskanalen är konstitutionellt oinformativ.

B.5 Villkor för hanterad vs. ohanterad gaptillväxt

Ekvation (2) ger ett direkt villkor för livskraft:

- **Hanterad regim:** $\beta(t) \cdot A(V)(t) \geq \alpha(t)$. Variationsgapet är stabilt eller krympande. Systemet upprätthåller perceptuell kontakt med sin miljö.
- **Ohanterad regim:** $\beta(t) \cdot A(V)(t) < \alpha(t)$. Variationsgapet växer. Systemet förlorar progressivt observerbarhet av de störningsdimensioner som så småningom kommer att avgöra dess öde.

I den ohanterade regimen ökar $G(t)$ monotont. Om inte regimen skiftar — antingen faller α (störningsmiljön förenklas) eller $\beta \cdot A(V)$ stiger (anpassningen accelererar) — kommer $G(t)$ så småningom att korsa G_{crit} . Tiden till upplösning är:

$$T_{uppl} = (G_{crit} - G(0)) / (\alpha - \beta \cdot A(V))$$

Detta är den återstående tiden innan värderingsarkitekturen blir strukturellt oförmögen att uppfatta existentiella hot. Styrningsimplikationen är direkt: om T_{uppl} är kortare än den tidsskala som krävs för institutionell reform står systemet inför en påtvingad upplösning — kollaps — snarare än en hanterad transition.

B.6 Relation till empiriska fenomen

Denna dynamiska formalism fångar den bana som beskrivs i landrapporterna:

- I **Japan** var α låg i förhållande till efterkrigsdecennierna, men $\beta \cdot A(V)$ var ännu lägre — värderingsarkitekturen motstod aktivt dimensionell expansion eftersom stabilitet var det enda måttet. G växte långsamt men stadigt, och systemet närmar sig nu upplösning genom gradvis fryssning snarare än akut kollaps.
- I **Ryssland** var α måttlig men $\beta \cdot A(V)$ var kraftigt negativ — värderingsarkitekturen förstörde aktivt sin egen observationskapacitet. G sköt i höjden snabbt och korsade G_{crit} i ett komprimerat tidsfönster.

- I **Storbritannien** ökade α genom postindustriell omstrukturering och digital transformation, medan $\beta \cdot A(V)$ dämpades av centraliseringsdynamiken i Westminster-modellen och finansdepartementets ortodoxi. G växte genom ackumuleringen av leveransmisslyckanden och demokratisk fränkoppling.
- I **EU** ökade α kraftigt med polykrisen, medan $\beta \cdot A(V)$ förblev låg på grund av förhandlings-utspädningsarkitekturen. G vidgades tills koherens blev strukturellt ouppnåelig.

B.7 Brasklappar och öppna problem

Denna dynamiska utvidgning är en konceptuell byggnadsställning, inte en kalibrerad modell. Betydande begränsningar inkluderar:

1. **Mätning av α och β :** Uppkomsthastigheten för nya störningsdimensioner och anpassningseffektiviteten hos värderingsarkitekturer är för närvarande inte mätbara med precision. Att uppskatta dem kräver longitudinell analys av policydomäner, vilket är metodologiskt utmanande men möjligt i princip.
2. **Dynamikens linjäritet:** Ekvation (2) är av första ordningen och linjär. Verkliga system uppvisar tröskleffekter i både α (störningar kan uppstå i kaskader) och β (anpassning kan bli lättare eller svårare när G förändras). Ickelinjära utvidgningar krävs för realistisk modellering.
3. **Endogenitet hos α :** Störningarnas uppkomsthastighet är inte rent exogen. Ett styrsystem som aktivt utforskar sin miljö — genom experimenterande, övervakning och deliberativt synliggörande — kan upptäcka nya dimensioner tidigare, vilket effektivt ökar α på kort sikt men möjliggör tidigare anpassning. Relationen mellan utforskande och störningsuppkomst är komplex.
4. **Målmängdsutveckling:** Modellen behandlar $\dim(G)$ som fix. I praktiken omförhandlar samhällen periodiskt vad som räknas som acceptabelt — i konstitutionella ögonblick, genom sociala rörelser eller genom kris. Att inkorporera målmängdsdynamik skulle lägga till en tredje differentialekvation till systemet.
5. **Fraktal struktur:** Modellen aggregerar alla styrningsskalor till ett enda G . En mer fullständig behandling skulle dekomponera G efter skala och erkänna att lokala system kan upprätthålla observerbarhet av dimensioner som är osynliga för nationella system, och vice versa — den fraktala värderingsarkitektur som beskrevs i Del VI.

Med förbehåll för dessa begränsningar tillhandahåller Appendix B det formella stödet för artikelns centrala dynamiska påstående: i en föränderlig värld tillåter en statisk värderingsarkitektur variationsgapet att växa, och när det gapet korsar en kritisk tröskel blir upplösning — hanterad eller påtvingad — strukturellt oundviklig. Det enda sättet att undvika denna bana är att upprätthålla en adaptiv kapacitet som matchar den hastighet med vilken miljön genererar nyhet. De metastyrningsinstitutioner som föreslås i Del VI är utformade för att operationalisera just denna kapacitet.

Appendix C: Simuleringsarkitektur för värdefunktionskollaps

Detta appendix definierar en minimal dynamisk modell som gör Goodhart–Ashby-syntesen och variationsgapet konkret synliga. Simuleringen är medvetet enkel så att den strukturella mekanismen förblir transparent.

C.1 Systembeskrivning

Betrakta ett samhälle med två kopplade tillståndsvariabler:

- **W(t)** : ekonomisk produktion (välstånd), den *observerade dimensionen*.
- **E(t)** : miljömässig integritet (ekosystemhälsa), den *exkluderade dimensionen*.

Systemet utvecklas i diskreta tidssteg enligt:

$$W(t+1) = W(t) + \alpha \cdot E(t) \cdot I(t) - \delta_W \cdot W(t) \quad E(t+1) = E(t) - \beta \cdot I(t) + \gamma \cdot (E_0 - E(t)) + \eta \cdot W(t)$$

där:

- **I(t)** är styrinsatsen (ekonomisk investering) vald av policysystemet.
- **α** översätter aktuell miljö kvalitet till investeringens produktivitet. När E degraderas ger samma I mindre W i framtiden.
- **δ_W** är välståndets naturliga depreciering.
- **β** är miljö kostnaden per investeringseenhet.
- **γ** är miljöns naturliga regenereringshastighet mot dess baslinje E_0 .
- **η** fångar en fördröjd negativ återkoppling: högt tidigare välstånd (vilket implicerar tidigare investeringar) eroderar så småningom miljön ytterligare (t.ex. genom ackumulerad förorening, resursutarmning).

Avgörande är att kopplingen verkar i båda riktningarna: **E** stödjer **W**, men jakten på **W** degraderar **E**, och en degraderad **E** reducerar så småningom framtida **W**.

C.2 Värderingsarkitekturer (Styrenheter)

Vi jämför två styrningsarkitekturer som endast skiljer sig åt i sin *värdefunktionsdimensionalitet*, inte i sin kompetens.

Arkitektur 1D (Endast BNP)

- Målfunktion: **J₁ = W(t)**.
- Styrenheten observerar **W(t)** (med visst brus) och observerar inte **E(t)**. Den tror att maximering av W alltid är bra.
- Styrlag: $I(t) = I_0 + K \cdot (W_{\text{mål}} - W_{\text{obs}}(t))$, där I_0 är en baslinje och K är en förstärkning. Styrenheten investerar mer när W ligger under det önskade målet och försöker driva W uppåt.

Arkitektur 2D (Välmåendemedveten)

- Målfunktion: **J₂ = W(t) + λ · E(t)** (med $\lambda > 0$).
- Styrenheten observerar både **W(t)** och **E(t)**. Den erkänner att E har värde och att degradering av E skadar framtida W.
- Styrlag: $I(t)$ väljs för att hålla båda variablerna inom en önskad region. Konkret dämpas investeringen när E faller under ett tröskelvärde: $I(t) = I_0 + K \cdot (W_{\text{mål}} - W_{\text{obs}}(t)) \cdot f(E)$, där $f(E)$ är en sigmoid som reducerar investeringen när E sjunker, vilket förhindrar att den skadliga återkopplingslingen utlöses.

Båda styrenheterna har tillgång till samma finansiella resurser; den enda skillnaden är dimensionaliteten i deras värderingsarkitektur.

C.3 Parameterisering

Parameter	Värde	Betydelse
α	0,3	Investeringsproduktivitet per enhet av E
δ_W	0,05	Välståndsdepreciering
β	0,25	Miljökostnad per enhet av I
γ	0,1	Miljöns regenereringshastighet
η	0,02	Fördröjd skada från tidigare välstånd
E_0	100	Miljömässig baslinjeintegritet
$W_{\text{mål}}$	120	Önskad välståndsnivå
I_0	5	Baslinjeinvestering
K	2,0	Förstärkning (identisk för båda arkitekturerna)
λ	1,5	Vikt för miljö i 2D-målfunktionen
Brus σ_W, σ_E	1,0, 0,5	Observationsbrus (1D observerar endast W)

Initialtillstånd: **W(0)=60, E(0)=90.**

C.4 Förväntat beteende

Arkitektur 1D lyckas initialt: investering höjer W, och eftersom E fortfarande är frisk är produktiviteten hög. Styrenheten "lär sig" att investering är effektiv och fortsätter att driva W mot målet. Under tiden degraderas E tyst eftersom den inte observeras. När E faller sjunker investeringsproduktiviteten ($\alpha \cdot E$ minskar), så mer I behövs för att upprätthålla W, vilket accelererar E:s nedgång. Så småningom utlöser den ackumulerade miljöskulden ett kraftigt fall i W som styrenheten inte kan förstå — dess egna handlingar orsakade kollapsen, men dess värderingsarkitektur gav den ingen kategori i vilken den kunde uppfatta E som en relevant variabel. Banan visar ett klassiskt överskridnings-och-kollapsmönster.

Arkitektur 2D, som observerar E, börjar moderera investeringen när E närmar sig farliga nivåer. W växer långsammare men kollapsar aldrig. Systemet når ett stabilt, lägre jämviktstillstånd där båda dimensionerna är balanserade.

C.5 Relevans för variationsgapet

Denna simulering är en direkt instansiering av Goodhart–Ashby-syntesen:

- Den 1D målfunktionen är en observationskanal med dimensionaliteten **$\dim(\mathbf{V})=1$** . Den projicerar det fulla tillståndsrummet (W, E) på en enda axel.
- Den exkluderade dimensionen E är kausalt kopplad till målvariabeln W. Att optimera proxyvariabeln W utan att övervaka E förstör så småningom den korrelation som gjorde W till en bra proxy.
- Kollapsen följer variationsgapets logik: **$\mathbf{G} = \dim(\mathbf{R}) - \dim(\mathbf{V}) = 2 - 1 = 1 > 0$** . Gapet växer när E försämras, och när kopplingen slår tillbaka skapade systemets egen optimeringslogik den kris det inte kunde förutse.


Samma mekanism ligger till grund för de misslyckanden på landsnivå som beskrivs i Del V: varje fall är en högre dimensionell version av denna grundläggande loop.

C.6 Reproducerbarhet

Python-skriptet som genererar simuleringen och visualiseringen finns tillgängligt i det medföljande repositoriet (se "Simulation Code" i det kompletterande materialet). Skriptet använder standard NumPy och Matplotlib; inga proprietära paket krävs.

Figur C.1: Värdefunktionskollaps i ett minimalt tvållståndssystem

Appendix C: Value-Function Collapse — The Goodhart-Ashby Synthesis in a Minimal Model
 $W(t+1)=W+\alpha \cdot E \cdot I - \delta \cdot W \cdot W \mid E(t+1)=E-\beta \cdot I + \gamma \cdot (E_0-E) + \eta \cdot W \mid$ 1D controller observes only W; 2D observes W and E



1D-styrenheten (som endast observerar W) lyckas initialt och driver välståndet till ~ 1000 genom aggressiv investering. Detta utarmar miljöintegriteten E till nära noll. När E väl kollapsar försvinner produktiviteten ($\alpha \cdot E \cdot I$) och systemet går in i en terminal nedgång — W faller till noll trots fortsatt styrinsats. Styrenheten kan inte uppfatta den miljöförstöring som orsakade dess eget misslyckande; den exkluderade dimensionen återvänder som oförklarlig kollaps.

2D-styrenheten (som observerar både W och E) modererar investeringen när E sjunker och upprätthåller båda variablerna på degraderade men stabila nivåer ($W \approx 37$, $E \approx 11$). Systemet når aldrig 1D-målet på $W=120$, men det överlever.

Fasporträttet (nederst till vänster) visar banorna i tillståndsrummet: 1D spiralerar mot systemdöd i origo, medan 2D hittar en låg-jämviktsattraktor. Det kritiska fyndet (överst till höger): även mätt med 1D-målfunktionen (endast W) presterar 2D-arkitekturen bättre efter $t \approx 100$. BNP-systemet optimerar bort sin egen förmåga att generera BNP.

Detta är Goodhart-Ashby-syntesen i sin enklaste form: en värderingsarkitektur med $\dim(V)=1$ kan inte upprätthålla stabilitet i ett system med $\dim(R)=2$ när dimensionerna är kausalt kopplade. Hysteresmekanismen (degraderade ekosystem regenererar med 20% av normal hastighet) återspeglar den ekologiska verkligheten och säkerställer att differentieringen är permanent, inte övergående.

Appendix D: Tabell för uppskattning av variationsgapet i landrapporterna

Följande tabell tillhandahåller illustrativa uppskattningar av variationsgapet för de styrningsarkitekturer som analyserats i Landrapportserien. Värdena för **dim(V)**, **dim(R)** och **G** är heuristiska och avsedda att göra ramverket gripbart, inte att tjäna som precisa empiriska mätningar. Kolumnen **G_crit-status** anger om det uppskattade gapet överskrider den kritiska tröskel vid vilken observerbarheten kollapsar, såsom diskuterats i Del III och Appendix B. **Kollapsmoden** beskriver det karaktäristiska sätt på vilket de exkluderade dimensionerna återinträder som systemiska kriser.

Land / System	Kärnvärde som optimeras	Ungef. dim(V)	Viktigaste exkluderade dim(R)	Uppskattad dim(R) – dim(G)	G	G_crit-status	Kollapsmod
Japan	Stabilitet / Kontinuitet	1	Anpassningsförmåga, förnyelse, demografisk dynamik	≥ 3	≥ 2	> G_crit	Gradvis systemisk frysning (demografisk stagnation, zombieföretag, värdig nedgång)
Ryssland	Kontroll / Regimöverlevnad	1	Sanning, distribuerad intelligens, legitimitet	≥ 4	≥ 3	» G_crit	Strategisk blindhet → plötsliga chocker (Kontroll–Blindhet–Chock-slinga)
Storbritannien	Centraliserad leverans / Kontrollskén	1	Lokal kontext, relationell tillit, stressfördelningsinfrastruktur	≥ 4	≥ 3	> G_crit	Implementeringsmisslyckande, demokratisk fränkoppling (Centralisera–Misslyckas–Centralisera)
Brasilien	Koalitionsöverlevnad / Styrbarhet	1	Medborgarpreferenser, demokratisk ansvarsskyldighet, rumslig rättvisa	≥ 4	≥ 3	> G_crit	Genombrott–Infångningscykler, ackumuleringsunderskott
Europeiska unionen	Medlemsstatskonsensus	1	Hastighet, rumslig koherens, temporal samstämmighet	≥ 3	≥ 2	> G_crit	Polykris, Förhandlings–Utpädningspiral
USA	Integration / Federal koordination	~2 (federalism distribuerar viss variation, men integration saknas)	Systemövergripande koherens, lärande över delstatsgränser, distributiv rättvisa	≥ 3	≥ 1	> G_crit	Eskalera–Blockera–Kringgå–Delegitimera-spiral
Tyskland	Verkställighet / Policyimplementering	~1 (ingenjörsmässig rigor fokuserar på implementeringskvalitet)	Strategisk agilitet, riskkapital, digital transformation	≥ 3	≥ 2	> G_crit	Förlamade utgifter, implementeringsgap
Frankrike	Integration / Social sammanhållning	~1 (Jakobinsk enhetlighet)	Reformhållbarhet, perifer integration, återkoppling från implementering	≥ 3	≥ 2	> G_crit	Reform–explosion–reträtt-cykel
Sverige	Återkoppling / Meningsskapande	~1 (konsensus, saklighet)	Snabb avkänning, läglig respons, integration över silogränser	≥ 2	≥ 1	Närmar sig G_crit	Driftslinga (signalundertryckning, fördröjd anpassning)
Finland	Framsynthet / Anticipatorisk kapacitet	~2 (stark framsynthet, men kapacitetsbegränsad)	Transformationshastighet, paradigmsättningskapacitet	≥ 3	≥ 1	Närmar sig G_crit	Kapacitetsbegränsning (kan se framtiden, kan inte nå den i tid)
Indien	Synkronisering / Flerskalig koordination	~1 (centralism och informell anpassning)	Formell institutionell kapacitet, rumslig och temporal synkronisering	≥ 4	≥ 3	> G_crit	Språng–eftersläpningscykler, informell kompensation

Not om uppskattning: Värdena i denna tabell är inte härledda från empirisk mätning. De representerar plausibla storleksordningsbedömningar som är förenliga med de detaljerade landrapporterna. Syftet är att illustrera variationsgapets logik över olika styrningsarkitekturer och att motivera den empiriska forskning som skulle ersätta dessa heuristiker med uppmätta kvantiteter. Artikelns centrala påstående — att lågdimensionella

värderingsarkitekturer tillåter variationsgapet att vidgas förbi den kritiska tröskeln — är inte beroende av precisionen i dessa specifika siffror. Det är beroende av den strukturella relation de illustrerar.

Appendix F: Annoterad referenslista

Detta appendix tillhandahåller en strukturerad guide till de nyckelverk som informerar *The Variety Gap*. Referenserna är organiserade efter tematiska kluster som motsvarar artikelns huvudsakliga argumentativa rörelser. För varje post förklarar en kort annotering dess relevans och det/de avsnitt där den mest naturligt citeras. Indikatorerna [R], [I] och [S] anger om referensen primärt stödjer den rigorösa kärnan, den tolkande bryggan eller det spekulativa/filosofiska lagret i artikeln. Denna kategorisering är avsedd att hjälpa författaren att infoga citat med en lämplig nivå av epistemisk bundenhet.

F.1 Grundläggande kybernetik, styrteori och informationsteori

Dessa verk underbygger den ingenjörsgammatik som etablerats i Artikel I–V och det formella maskineriet i Del I–III av föreliggande artikel.

- **Ashby, W. R. (1956). *An Introduction to Cybernetics*. Chapman & Hall.**
Den kanoniska formuleringen av lagen om nödvändig variation. Grundläggande för argumentet att varje regulator måste matcha variationen i det system den styr (Del I, II, III). [R]
- **Beer, S. (1972). *Brain of the Firm*. Allen Lane.**
Tillämpar Ashbys variationsingenjörskonst på organisationsdesign via den livskraftiga systemmodellen (VSM). Stödjer argumentet om fraktal arkitektur i Artikel II och metastyrningsdiskussionen i Del VI. [R/I]
- **Conant, R. C. & Ashby, W. R. (1970). "Every Good Regulator of a System Must Be a Model of That System." *International Journal of Systems Science*, 1(2), 89–97.**
Formellt bevis för att effektiv reglering kräver intern modelleringskapacitet. Stödjer direkt påståendet att målfunktioner måste följa det styrda systemets dimensionalitet (Del II). [R]
- **Shannon, C. E. (1948). "A Mathematical Theory of Communication." *Bell System Technical Journal*, 27, 379–423, 623–656.**
Etablerar kanalkapacitet och gränserna för informationsöverföring. Underbygger argumentet om signal-brusförhållandetröskeln i Artikel III och upplösningströskeln i Del III. [R]
- **Wiener, N. (1948). *Cybernetics: Or Control and Communication in the Animal and the Machine*. MIT Press.**
Kybernetikens grundande text, som etablerar återkoppling som en universell princip över biologiska, mekaniska och sociala system. Tillhandahåller den intellektuella härstamningen för att behandla styrning som reglering (Del I). [R]

F.2 Målfunktioner som observationsarkitekturer och Goodhart–Ashby-syntesen

Detta kluster stödjer artikelns centrala drag: att behandla värde metriker som observationskanaler vars dimensionalitet bestämmer perceptuell kapacitet.

- **Goodhart, C. A. E. (1975). "Problems of Monetary Management: The U.K. Experience." I *Papers in Monetary Economics*, Reserve Bank of Australia.**
Den ursprungliga formuleringen av Goodharts lag. Används som utgångspunkt för Goodhart–Ashby-syntesen i Del II. [R/I]
- **Strathern, M. (1997). "'Improving Ratings': Audit in the British University System." *European Review*, 5(3), 305–321.**
Klassisk antropologisk redogörelse för hur metriker omformar de verkligheter de är avsedda att mäta. Illustrerar Goodhart-mekanismen i icke-ekonomiska domäner (Del II). [I]
- **Manheim, D. & Garrabrant, S. (2018). "Categorizing Variants of Goodhart's Law." *arXiv preprint arXiv:1803.04585*.**
Formell taxonomi över Goodhart-effekter, inklusive regimdrift. Stödjer generaliseringen från spel till strukturell blindhet (Del II). [R]
- **Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). "Concrete Problems in AI Safety." *arXiv preprint arXiv:1606.06565*.**
Identifierar belöningshackning och målmisspecifikation som centrala AI-alignmentproblem. Den strukturella analogin till värderingsarkitekturkollaps i styrsystem (Del II). [R/I]

- **Müller, J. Z. (2018). *The Tyranny of Metrics*. Princeton University Press.**

Historisk och institutionell analys av hur måttfixering förvränger organisatoriskt beteende. Tillhandahåller empirisk grund för påståendet att lågdimensionella mål blindar institutioner (Del II, IV). [I]

F.3 Variationsgapets dynamik, upplösning och evolutionära system

Dessa källor informerar modelleringen av G, upplösningströskeln och störningsmiljöers öppna natur.

- **Taleb, N. N. (2012). *Antifragile: Things That Gain from Disorder*. Random House.**

Argumenterar för att system utsatta för volatilitet måste expandera sin responskapacitet eller kollapsa. Underbygger variationsgapets dynamik och upplösningargumentet (Del III). [I/S]

- **Kauffman, S. A. (2000). *Investigations*. Oxford University Press.**

Introducerar "det angränsande möjliga" — idén att nya möjlighetsdimensioner uppstår kontinuerligt i komplexa system. Stödjer påståendet att $\dim(R)$ är öppen (Del III). [I/S]

- **Gould, S. J. & Eldredge, N. (1977). "Punctuated Equilibria: The Tempo and Mode of Evolution Reconsidered." *Paleobiology*, 3(2), 115–151.**

Den klassiska formuleringen av punkterad jämvikt: långa perioder av stabilitet avbrutna av snabb förändring. Analog till värderingsarkitekturers upplösning-och-reformdynamik (Del III). [I]

- **Meadows, D. H. (2008). *Thinking in Systems: A Primer*. Chelsea Green.**

Tillgänglig introduktion till bestånd, flöden, återkoppling och hävstångspunkter. Användbar för att grunda den systemdynamiska intuitionen i gapmodellen (Del I, III). [I]

F.4 De saknade dimensionerna: Välmående, mening, social sammanhållning och ekologisk integritet

Detta kluster grundar argumentet att vissa exkluderade dimensioner inte är valfria utan strukturellt nödvändiga.

- **Stiglitz, J. E., Sen, A., & Fitoussi, J.-P. (2009). *Report by the Commission on the Measurement of Economic Performance and Social Progress*. Franska regeringen.**

Formell kritik av BNP som välfärdsåtgärd. Stödjer argumentet att enmåttsvärderingsarkitekturer systematiskt exkluderar välmåendedimensioner (Del IV). [R/I]

- **Wilkinson, R. & Pickett, K. (2009). *The Spirit Level: Why More Equal Societies Almost Always Do Better*. Allen Lane.**

Empirisk demonstration av att sociala missförhållanden följer ojämlikhet, inte genomsnittsinkomst. Visar att exkluderade sociala dimensioner återinträder som hälso- och sammanhållningskriser (Del IV). [I]

- **Raworth, K. (2017). *Doughnut Economics: Seven Ways to Think Like a 21st-Century Economist*. Random House.**

Föreslår ett flerdimensionellt ekonomiskt ramverk begränsat av sociala och planetära trösklar. En tillämpad instans av att expandera värdedimensionalitet (Del IV). [I]

- **Ostrom, E. (1990). *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge University Press.**

Dokumenterar hur gemenskaper hanterar gemensamma resurser genom polycentrisk, flerdimensionell styrning. Grundar argumentet om nödvändig variation för allmäningsförvaltning i Artikel IV och Del IV. [R/I]

- **Weaver, W. (1948). "Science and Complexity." *American Scientist*, 36, 536–544.**

Klassisk distinktion mellan problem präglade av enkelhet, oorganiserad komplexitet och organiserad komplexitet. Tillhandahåller historisk inramning för dimensionalitetsutmaningen (Del II). [I]

F.5 Metastyrning, värdeevolution och andra ordningens kybernetik

Källor som informerar utformningen av institutioner kapabla att utveckla sina egna värderingsarkitekturer.

- **von Foerster, H. (1984). *Observing Systems*. Intersystems Publications.**
Grundläggande text för andra ordningens kybernetik: att observera observatören. Underbygger direkt metastyrningsargumentet i Del VI. [R/I]
- **Beer, S. (1979). *The Heart of Enterprise*. John Wiley.**
Utvidgar den livskraftiga systemmodellen till metanivåstyrningen av organisationen. Stödjer designprinciperna för värdeutvecklande institutioner (Del VI). [R/I]
- **Luhmann, N. (1995). *Social Systems*. Stanford University Press.**
Teori om autopoietiska sociala system som producerar sina egna element. Tillhandahåller ett sociologiskt ramverk för att förstå hur värderingsarkitekturer reproducerar sig själva och motstår förändring (Del VI). [I/S]
- **Habermas, J. (1996). *Between Facts and Norms: Contributions to a Discourse Theory of Law and Democracy*. MIT Press.**
Argumenterar för att legitim lag kräver deliberativa procedurer som tillåter nya anspråk och perspektiv att komma upp till ytan. Stödjer rollen för medborgarpaneler och deliberativa organ i värdeevolution (Del VI). [I]
- **Dryzek, J. S. (2000). *Deliberative Democracy and Beyond: Liberals, Critics, Contestations*. Oxford University Press.**
Systematiskt försvar av deliberativa institutioner som mekanismer för att synliggöra exkluderade perspektiv. Tillämpas direkt på metastyrningsdesignen i Del VI. [I]
- **Bateson, G. (1972). *Steps to an Ecology of Mind*. University of Chicago Press.**
Utforskar den systemiska naturen hos lärande, perception och "skillnaden som gör en skillnad." Påverkar omramningen av mening och samhörighet som informella dimensioner (Del IV, VI). [I/S]
- **Peirce, C. S. (1931–1958). *Collected Papers of Charles Sanders Peirce*, vol. 1–8. Harvard University Press.**
Introducerar begreppet om den "obegränsade gemenskapen" av undersökning och sanningens asymptotiska natur. Omrammar helhet som en öppen undersökningsprocess; underbygger inramningen av "oändlig uppstigning" i Del VI. [S]

F.6 Landfallsillustrationer

Dessa verk tillhandahåller empirisk grund för landrapporterna som omtolkas i Del V.

- **Serien Governance as Engineering (Artikel I–V) och de medföljande landrapporterna (Tyskland, Frankrike, Sverige, Indien, EU, Storbritannien, Brasilien, USA, Finland, Japan, Ryssland).**
Den primära empiriska basen. Varje rapport tillhandahåller den specifika diagnosen av en värderingsarkitekturs felmod. Citeras utförligt i Del V. [R/I]
- **Gilens, M. & Page, B. I. (2014). "Testing Theories of American Politics: Elites, Interest Groups, and Average Citizens." *Perspectives on Politics*, 12(3), 564–581.**
Empirisk demonstration av att genomsnittliga medborgarpreferenser har nära noll inflytande på policy i USA. Stödjer påståendet om preferensosynlighet i det generella argumentet och fallen Brasilien/Storbritannien (Del V). [I]
- **Food and Agriculture Organization (FAO). (2022). *The State of World Fisheries and Aquaculture 2022*. Rom: FAO.**
Dokumenterar det globala fiskeriläget och det återkommande misslyckandet hos centraliserad förvaltning. Grundar argumentet om observationsmässig otillräcklighet i Artikel IV och allmänningssdimensionen i Del IV. [R/I]
- **Bevir, M. & Rhodes, R. A. W. (2003). *Interpreting British Governance*. Routledge.**
Analyserar urholkningen av den brittiska staten och framväxten av styrning genom nätverk. Stödjer Storbritannien-diagnosen i Del V. [I]
- **Scalia, L. (2020). *The Brazilian Coalitional Presidentialism: The Political Economy of Governance*. Routledge** (eller jämförbar källa om presidencialismo de coalizão).
Analys av Brasiliens koalitionella presidentsystem och dess infångningsdynamik. Grundar Brasilien-fallet i Del V. [I]
- **Gel'man, V. (2015). *Authoritarian Russia: Analyzing Post-Soviet Regime Changes*. University of Pittsburgh Press.**
Undersöker centraliseringen av makt och undertryckandet av återkoppling i det samtida Ryssland. Stödjer Ryssland-diagnosen i Del V. [I]

Appendix G: Operationella definitioner och mätprotokoll

Detta appendix tillhandahåller konkreta mätprotokoll för ramverkets centrala variabler, specificerar när termer används rigoröst respektive heuristiskt samt upprättar en mätstege från mest till minst operationaliserad.

G.1 Operationaliseringsutmaningen

Ramverkets kärnvariabler – $\dim(V)$, $\dim(R)$, G , G_{crit} – definieras formellt i bilagorna A och B med hjälp av linjär algebra (rang av observationsmatriser, störningsrymder). Dessa definitioner är matematiskt precisa men inte direkt mätbara i verkliga styrsystem. Detta appendix överbryggar gapet mellan formell definition och empirisk mätning.

Den epistemiska strukturen i tre nivåer:

1. **Rigoröst operationaliserad:** Mätbar från administrativa data med definierade protokoll
2. **Operationaliserbar i princip:** Tydligt mätförfarande existerar men kräver resurser/åtkomst som för närvarande inte är tillgänglig
3. **Heuristisk:** Används för att organisera kvalitativ evidens; endast storleksordningsuppskattningar

I hela huvudtexten markerar vi nu vilken nivå varje användning tillhör.

G.2 Dimension av värdearkitektur – $\dim(V)$

Formell definition (Appendix A): Rang av observationsmatrisen C i $y = Cx + \epsilon$, där y är signalen som når beslutsfattare.

Operationellt protokoll 1 — Räkning av policymål (Nivå 1: Rigorös)

För ett styrsystem med explicita policymål:

```
dim(V) ≥ antal oberoende mål som följs upp i:
- Budgetkategorier som tilldelas >1 % av total budget
- Prestationsindikatorer som övervakas i årsrapporter
- Lagstadgade uppdrag i möjliggörande lagstiftning
- Explicita mål i koalitionsavtal / partiprogram
```

Oberoendetest: Två mål är oberoende om en förändring av det ena inte mekaniskt bestämmer det andra. BNP-tillväxt och arbetslöshet är korrelerade men oberoende (båda kan förändras). "Minska fattigdom" och "öka medianinkomsten" är inte helt oberoende – det första bestämmer delvis det andra.

Genomarbetat exempel — UK Treasury:

- Finansiell hållbarhet (skuldkvot i förhållande till BNP) — 1 dimension
- Ekonomisk tillväxt (BNP-tillväxttakt) — 1 dimension
- Sysselsättning (arbetslöshet) — 1 dimension
- Inflationsmål (KPI) — 1 dimension

Uppskattad $\dim(V) = 4$ för den ekonomiska politiken.

Men detta överskattar sannolikt den effektiva dimensionaliteten eftersom:

- Alla fyra är underordnade "bevara City of Londons förtroende"
- Avvägningar löses av ett enda meta-mål (finansiell stabilitet)
- Effektiv $\dim(V)$ snarare kring 2

Operationellt protokoll 2 — Principalkomponentanalys på tidsserier (Nivå 2: I princip)

För ett styrsystem med observerbara policyutfall över tid:

1. Konstruera tidsserier för n policyvariabler (budgetallokeringar, index för regleringssträngighet, verkställighetsåtgärder) över T tidsperioder
2. Beräkna korrelationsmatris
3. Utför PCA, behåll komponenter som förklarar $>5\%$ av variansen
4. $\dim(V)$ = antal behållna principalkomponenter

Detta avslöjar de effektiva frihetsgraderna i hur systemet faktiskt varierar sina utfall, inte bara vad det påstår sig optimera.

Operationellt protokoll 3 — Informationsteoretiskt (Nivå 2: I princip)

För ett styrsystem med diskreta beslutstillstånd:

$$\dim(V) \approx \log_2(\text{antal urskiljbara beslutstillstånd}) / \log_2(\text{antal inflödestillstånd})$$

Detta fångar hur mycket systemets utflöden komprimerar dess inflöden – den informationsflaskhals som värdearkitekturen skapar.

Nuvarande användning i uppsatsen: De flesta landfall använder Protokoll 1 (målräkning) heuristiskt, vilket ger $\dim(V) = 1$ eller 2. Dessa bör markeras som "storleksordningsuppskattningar" snarare än precisa mätningar.

G.3 Dimension av störningsrymd – $\dim(D)$ eller $\dim(R)$

Formell definition (Appendix A): Rang av störningsrymden D – antalet oberoende sätt systemet kan knuffas bort från sitt mål.

Operationellt protokoll 1 — Historisk chockdekomponering (Nivå 2: I princip)

För ett styrsystem med tidsseriedata om kriser:

1. Katalogisera n styrmisslyckanden / kriser över T tidsperioder
2. För varje kris, koda störningstyp över kandidatdimensioner:
 - Ekonomisk (recession, inflation, skuldkris)
 - Social (protester, strejker, demografisk förskjutning)
 - Ekologisk (torka, översvämning, resursutarmning)
 - Geopolitisk (krig, sanktioner, migration)
 - Teknologisk (automatisering, cyber, epistemisk)
 - Institutionell (korruption, legitimitet, kapacitet)
3. Utför faktoranalys för att identifiera latent störningsdimensioner
4. $\dim(D)$ = antal faktorer med egenvärde > 1

Genomarbetat exempel — Eurozonen 2008-2023:

- Finansiell smitta (statsskuld) — Faktor 1
- Institutionell fragmentering (Nord-Syd-klyfta) — Faktor 2
- Demokratisk legitimitet (populism, röstnedgång) — Faktor 3
- Geopolitisk (energiberoende, migration) — Faktor 4
- Uppskattad $\dim(D) \approx 4$

Operationellt protokoll 2 — Policydomänuppräknig (Nivå 3: Heuristisk)

För system utan tillräckliga tidsseriedata:

$\dim(D) \geq$ antal oberoende policydomäner som kräver aktiv styrning:

- Ekonomisk förvaltning
- Social sammanhållning
- Ekologisk integritet
- Demokratisk legitimitet
- Geopolitisk säkerhet
- Teknologisk anpassning

Varje domän poängsätts med 1 om den genererar störningar som inte är förutsägbara från de andra

Operationellt protokoll 3 — Scenarioplaneringsexpertelicitering (Nivå 2: I princip)

Strukturerad expertelicitering:

1. Samla panel av domänexperter
2. Generera 50+ "plausibla framtider" över 20-årshorisont
3. Klustra scenarier efter underliggande störningsfaktorer
4. $\dim(D) \approx$ antal oberoende kluster

Detta fångar den effektiva dimensionaliteten i det osäkerhetsutrymme systemet måste navigera.

Nuvarande användning i uppsatsen: Landfallen använder Protokoll 2 (domänuppräknig) heuristiskt. Appendix D tabell uppskattar $\dim(R) - \dim(G)$ i intervallet 2-4 för de flesta fall. Dessa är grova uppskattningar, inte mätningar.

G.4 Variationsgapet — G

Formell definition (Del III): $G = \dim(R) - \dim(G) - \dim(V)$

Operationellt protokoll (Nivå 2: I princip):

Givet mätningar av $\dim(R)$ och $\dim(V)$:

```
G = dim(R) - dim(V)    (förutsatt att dim(G) är liten / försumbar)
```

Tolkning:

- G = 0: Värdearkitekturen täcker störningsrymden
- G = 1-2: Måttligt gap, systemet är blint för 1-2 större störningsklasser
- G = 3+: Stort gap, systemet är strukturellt sårbart
- G > G_crit: Konstitutionell icke-observerbarhet (se nedan)

Valideringskontroll:

Ett styrsystem med variationsgap G bör uppvisa:

- Återkommande kriser i de uteslutna dimensionerna
- Policyresponser som konsekvent missar den faktiska störningskällan
- Mönster av "oförklarade" misslyckanden i retrospektiv analys

Nuvarande användning i uppsatsen: G uppskattas heuristiskt i landfallen. För de flesta fall är uppskattat G = 2-3, markerat som "närmar sig eller överskrider G_crit." Dessa bör uttryckligen etiketteras som "indikativa, inte uppmätta."

G.5 Kritisk upplösningströskel — G_crit

Formell definition (Appendix B): Värde av G vid vilket signal-brusförhållandet faller under ett: $I(x;y) \leq I(\epsilon;y)$

Operationellt protokoll (Nivå 2: I princip):

För Gaussiska kanaler:

```
G_crit nås när:
  Var(signal från observerade dimensioner) ≤ Var(brus från icke-observerade dimensioner)
```

Mätning:

1. Uppskatta varians i observerade policyindikatorer (Var_obs)
2. Uppskatta varians i residualutfall som inte förklaras av policy (Var_oförklarad)
3. Om $\text{Var_oförklarad} / \text{Var_obs} > 1$ har systemet passerat G_crit

Empirisk signatur för passerande av G_crit:

System bortom tröskeln uppvisar:

- Policyinterventioner producerar utfall okorrelerade med avsikt
- "Oförklarad" varians dominerar förklarad varians i utfallsmodeller

- Styrning blir reaktiv mot fantomsignaler (brusspårning)
- Mönstret matchar Rapport III:s SNR < 1 -villkor för representationskedjor

Uppskattat värde:

Från Rapport III:s analys av representationskedjor: tröskeln passeras vid 2-3 lager för realistiska brusparametrar. I analogi, för värdearkitekturer:

Provisorisk uppskattning: $G_{crit} \approx 2-3$ för de flesta styrkontexter

Detta är högst osäkert och bör endast behandlas som storleksordning.

Nuvarande användning i uppsatsen: G_{crit} används som en kvalitativ tröskel. Landfall markerade som "närmar sig" eller "överskrider" G_{crit} baserat på mönstermatchning mot förväntade misslyckandesignaturer, inte direkt SNR-mätning.

G.6 Störningsemergenshastighet — α

Formell definition (Appendix B): $\alpha(t)$ är den momentana hastigheten för emergens av nya störningsdimensioner: $\dim(D)(t) = \dim(D)(0) + \int \alpha(s) ds$

Operationellt protokoll (Nivå 3: Heuristisk):

$\alpha \approx (\text{antal nya större policydomäner under period } T) / T$

Där "ny större policydomän" innebär:

- Kräver dedicerad institutionell kapacitet (nytt departement/ny myndighet)
- Genererar störningar som inte är förutsägbara från befintliga domäner
- Förbrukar $>0,5$ % av policybandbredd (lagstiftningstid, budget)

Exempel:

- Klimatanpassning (uppstod ~1990-talet)
- Cybersäkerhet (uppstod ~2000-talet)
- Epistemisk integritet / desinformation (uppstod ~2010-talet)
- AI-styrning (växer fram ~2020-talet)

Uppskattade värden:

Baserat på OECD:s policymässiga domäntillväxt 1980-2020:

Långsam förändringstakt: $\alpha \approx 0,1-0,2$ nya dimensioner per decennium
Snabb förändringstakt: $\alpha \approx 0,5-1,0$ nya dimensioner per decennium

Nuvarande användning i uppsatsen: α används i den dynamiska modellen $dG/dt = \alpha - \beta \cdot A(V)$ som en konceptuell parameter, inte en uppmätt kvantitet. Texten bör klargöra att den är illustrativ.

G.7 Anpassningseffektivitet — β

Formell definition (Appendix B): $\beta(t)$ är den andel av anpassningsansträngning som framgångsrikt översätts till ökad $\dim(V)$

Operationellt protokoll (Nivå 3: Heuristisk):

$\beta = (\text{faktisk ökning av } \dim(V) \text{ över period } T) / (\text{avsedd ökning av } \dim(V))$

Mätutmaningar:

- "Avsedd ökning" kräver tydliga policyuttalanden
- Institutionella reformer påstår sig ofta lägga till dimensioner utan att göra det
- Infångning/utspädning kan reducera effektiv β till nära noll

Uppskattade intervall:

Högfungerande adaptivt system: $\beta \approx 0,5-0,8$
(Sveriges konsensusmodell, Finlands framsynskapacitet)

Måttlig institutionell friktion: $\beta \approx 0,2-0,4$
(Tysklands koalitionsconsensus, Frankrikes reformcykler)

Hög infångning / hög rigiditet: $\beta \approx 0,0-0,1$
(Rysslands vertikal, Japans kontinuitetsfälla, Brasiliens koalitionsfilter)

Nuvarande användning i uppsatsen: β används konceptuellt i den dynamiska modellen, inte uppmätt empiriskt.

G.8 Användningsriktlinjer för huvudtexten

För att upprätthålla epistemisk stringens bör uppsatsen markera variabelanvändning med nivåanoteringar:

Nivå 1 (Rigorös): "UK Treasurys värdearkitektur följer fyra primära mål [Protokoll G.2.1], vilket ger $\dim(V) = 4$ (rigorös)."

Nivå 2 (I princip): "Uppskattad $\dim(D)$ för eurozonen 2008-2023 är ungefär 4 större störningsdimensioner [Protokoll G.3.1], men detta kräver validering genom formell faktoranalys (i princip)."

Nivå 3 (Heuristisk): "Vi uppskattar $\dim(V) \approx 1$ för Rysslands kontrollarkitektur (heuristisk). Detta är en storleksordningsbedömning baserad på kvalitativ analys, inte en mätning."

För landfallen i Del V:

Alla variationsgapsuppskattningar är för närvarande Nivå 3 (heuristiska). Texten bör uttryckligen ange detta:

"Variationsgapsuppskattningarna i detta avsnitt är illustrativa, baserade på kvalitativ mönstermatchning mot ramverkets förutsagda misslyckandesignaturer. Empirisk validering skulle kräva de mätprotokoll som specificeras i Appendix G."

G.9 Valideringskriterier

Ett påstående om att $\dim(V)$, $\dim(D)$ eller G har "uppmätts" snarare än "uppskattats" kräver:

För $\dim(V)$:

- Uppräkning av explicita policymål från primärkällor
- Oberoendetest som visar att målen inte mekaniskt bestäms av varandra
- Eller: PCA på tidsseriedata av policyutfall som visar behållna komponenter

För $\dim(D)$:

- Historisk katalog över styrmisslyckanden/kriser
- Faktoranalys eller expertelicitering som visar oberoende störningsdimensioner
- Eller: Scenarioklustring som visar osäkerhetsrymdens dimensionalitet

För G :

- Både $\dim(V)$ och $\dim(D)$ uppmätta (inte uppskattade)
- Explicit beräkning $G = \dim(D) - \dim(V)$

För passage av G_{crit} :

- Variansdekomponering som visar $\text{Var}(\text{oförklarad}) > \text{Var}(\text{förklarad})$
- Eller: Mönstermatchning mot förväntade signaturer (reaktiv styrning, fantomsignalspåring, okorrelerade policy-utfalls-relationer) med explicit reservation att detta är indikativt, inte bevis

G.10 Forskningsprioriteringar

För att flytta ramverket från heuristiskt till empiriskt:

Prioritet 1: Implementera Protokoll G.2.2 (PCA på policy-tidsserier) för 3-5 länder med tillräcklig data

Prioritet 2: Implementera Protokoll G.3.1 (historisk chockfaktoranalys) för EU, Storbritannien, Japan

Prioritet 3: Utveckla automatiserad mätning av $\dim(V)$ från budgetdokument och lagstiftningstext med hjälp av NLP

Prioritet 4: Testa om uppskattad G korrelerar med frekvensen av styrmisslyckanden i paneldata över länder

Prioritet 5: Empiriskt kalibrera G_{crit} genom att identifiera SNR-trösklar i historiska styrellapskollapser

Tills dessa är fullbordade förblir ramverket en diagnostisk lins snarare än en validerad prediktiv modell.

Appendix H: Testbara förutsägelser och falsifieringsprotokoll

Detta appendix operationaliserar ramverkets centrala förutsägelser för empirisk testning. Varje post specificerar förutsägelsen, de inblandade variablerna, mätansats, datakällor, statistiskt test och falsifieringsvillkor.

H.1 Förutsägelse 1: Variationsgap och krisfrekvens

Förutsägelse: System med större uppskattade variationsgap (G) kommer att uppleva fler styrningskriser under en given tidsperiod än system med mindre G , kontrollerat för BNP per capita och regimtyp. Kriser i de uteslutna dimensionerna kommer att vara oproportionerligt förhöjda.

Variabler:

- Oberoende: $G = \dim(D) - \dim(V)$, uppskattat heuristiskt via protokollen i Appendix G.
- Beroende: Antal styrningskriser över ett 20-årsfönster (2000-2020).
- Samvariabel: Krisantal i "uteslutna" respektive "uppföljda" dimensioner (kodade per lands värdearkitektur).
- Kontroller: BNP per capita, Polity IV / V-Dem regimpoäng, befolkningsstorlek.

Datakällor: Cross-National Time-Series Data Archive, V-Dem krisindikatorer, landsspecifik värdearkitekturkodning (Appendix G-protokoll).

Test: Negativ binomial regression med krisantal som utfall, G som prediktor och kontroller. En andra modell testas om G -krisrelationen är starkare för uteslutna dimensionskriser än för uppföljda dimensionskriser (interaktionsterm $G \times$ uteslutningsdummy).

Falsifiering: Ingen signifikant positiv koefficient på G , eller koefficienten negativ. Alternativt ingen signifikant interaktion med uteslutningsdummyn.

H.2 Förutsägelse 2: Gaptillväxt och institutionell rigiditet

Förutsägelse: Länder med högre institutionell rigiditet kommer att uppvisa snabbare variationsgaptillväxt (dG/dt) över ett 20–30-årsfönster än mer adaptiva system.

Variabler:

- Oberoende: Institutionell rigiditetsindex (sammansatt av vetospelare, svårighetsgrad för grundlagsändring, genomsnittlig regeringslängd).
- Beroende: $dG/dt \approx$ (förändring i antal framträdande policydomäner) – (förändring i antal oberoende uppföljda mål) över perioden.
- Kontroller: BNP-tillväxt, civilsamhällestäthet, medie-frihet.

Datakällor: V-Dem, Comparative Political Data Set, OECD Government at a Glance, egen kodning av policydomäner (Appendix G.6).

Test: Linjär regression av dG/dt på rigiditetsindex med kontroller. Alternativt tvågruppsjämförelse: hög- vs. låg-rigiditetsländer, skillnad i genomsnittlig dG/dt .

Falsifiering: Ingen signifikant skillnad i dG/dt mellan hög- och låg-rigiditetsgrupper, eller adaptiva system visar snabbare gaptillväxt.

H.3 Förutsägelse 3: Signaturmönster vid G_{crit}

Förutsägelse: I fall där ett styrsystem plausibelt passerade G_{crit} kommer tidsserieanalys att avslöja (a) sammanbrott av Granger-kausalitet från policyinsatser till utfall, (b) ökad policyvarians i förhållande till utfallsvarians, (c) spektrala belägg för att policy svarar på högfrekvent brus snarare än lågfrekvent signal.

Variabler:

- Policyinsatstidsserie (t.ex. budgetallokeringar, regleringsförändringar).
- Utfallstidsserie (t.ex. relevanta välbefinnandeindikatorer).
- SNR-proxy: kvot mellan förklarad och oförklarad varians i policy-utfallsmodeller före jämfört med efter det uppskattade överskridandet.

Datakällor: Landsspecifika administrativa data, rekonstruerade för historiska fall (t.ex. Sovjetunionen 1985-1991, brittiska finanstjänster 2005-2010, Venezuela 2005-2015).

Test: Inom-fallsdesign med avbruten tidsserie. Jämför perioder före och efter uppskattad G_{crit} avseende: Granger-kauslighetstester, varianskvoter, spektral koherens.

Falsifiering: Ingen signifikant förändring i dessa indikatorer över den uppskattade G_{crit} -gränsen, eller förändringar i motsatt riktning (förbättrad policy-utfallsskoppling efter överskridande).

H.4 Förutsägelse 4: Flerdimensionella värdearkitekturer och krisreduktion

Förutsägelse: Regeringar eller regioner som institutionellt har antagit flerdimensionella välbefinnanderamverk i minst fem år kommer att uppleva färre kriser i dimensioner som traditionellt utesluts av BNP-centrerade arkitekturer (hälsa, social sammanhållning, ekologisk integritet) jämfört med matchade kontroller.

Variabler:

- Behandling: Antagande av ett flerdimensionellt välbefinnanderamverk (binär, med implementerings-eftersläpnings-tröskel på 5 år).
- Beroende: Antal krishändelser i uteslutna dimensioner.
- Matchningsvariabler: BNP per capita, befolkningsstorlek, regimtyp, baslinjekrisfrekvens.

Datakällor: Wellbeing Economy Alliance (WEAll) fallstudier, nationella statistikbyråer, EM-DAT katastrofdatabas, V-Dem.

Test: Matchad fall-kontrolldesign. För varje behandlingsenhet väljs 2–3 kontrollenheter matchade på förperiodskaraktistika. Krisantal i uteslutna dimensioner under efterimplementeringsfönstret jämförs med betingad Poisson-regression.

Falsifiering: Ingen signifikant skillnad i krisfrekvens, eller behandlingsenheter presterar sämre.

H.5 Förutsägelse 5: Värdegranskningar och gapminskning

Förutsägelse: Organisationer (t.ex. kommuner) som slumpmässigt tilldelas att genomföra årliga strukturerade värdegranskningar kommer under en 3–5-årsperiod att (a) lägga till fler dimensioner till sina uttryckligen uppföljda mål och (b) uppleva färre "oväntade" negativa händelser (budgetöverskridanden, tjänsteleveransmisslyckanden som inte förutsågs av befintliga indikatorer) än kontrollorganisationer.

Variabler:

- Behandling: Slumpmässig tilldelning till värdegranskningsprotokoll (strukturerad granskning av måldimensionalitet, framväxande störningsdimensioner).
- Beroende 1: Förändring i antal oberoende uppföljda prestationsindikatorer.
- Beroende 2: Antal oförutsedda negativa händelser (operationaliserade som händelser som inte förutsågs av befintliga indikatorer inom planeringscykeln).

Datakällor: Kommunal administrativa data, egen datainsamling via intervention.

Test: Randomiserad kontrollerad studie med difference-in-differences-specifikation för kontinuerliga utfall och Poisson-regression för antalsutfall.

Falsifiering: Ingen signifikant behandlingseffekt på något av utfallen.

H.6 Förutsägelse 6: Goodhart–Ashby-simulatorkalibrering

Förutsägelse: I 3–5 väldokumenterade historiska fall av måttfixeringskollaps kommer en kalibrerad version av Appendix C:s värdefunktionskollapssimulator att producera out-of-sample-förutsägelser av kollapsbanan som överträffar en naiv extrapoleringsmodell (t.ex. linjär trend, ARIMA).

Variabler:

- Simulatorparametrar: α (produktivitet hos den uppföljda dimensionen från den uteslutna dimensionen), β (kostnad för att optimera måttet för den uteslutna dimensionen), γ (regenereringstakt), η (fördröjd skada), skattade från data före kollaps.

- Beroende: Out-of-sample rotmedelkvadratfel (RMSE) för kollapsbanan.
- Baslinj jämförelse: ARIMA eller linjär trend anpassad till data före kollaps, framskriven.

Datakällor: Historiska tidsserier för mått och utesluten dimension (t.ex. väntetidsmål och kliniska utfall i NHS-sjukhus; provresultat och läranderesultat i utbildningssystem; fiskekvoter och beståndsbio massa).

Test: För varje fall, anpassa båda modellerna till data före kollaps, projicera kollapsperioden, beräkna RMSE. Jämför med ett enkelt teckentest över fallen (i hur många fall överträffar simulatören baslinjen?).

Falsifiering: Simulatören överträffar inte den naiva modellen i en majoritet av fallen.

H.7 Förutsägelse 7: Representationskedjedjup och demokratisk tillfredsställelse

Förutsägelse: Demokratier med effektiva representationskedjor som överstiger 2–3 lager kommer att uppvisa signifikant lägre medborgerlig tillfredsställelse med demokratin och svagare preferens-politiköverensstämmelse än de med kortare kedjor, kontrollerat för ekonomisk prestation.

Variabler:

- Oberoende: Effektiv representationskedjedjup (federal/enhetlig $\times$ tvåkammar/enkammar $\times$ antal valda nivåer).
- Beroende 1: Genomsnittlig demokratisk tillfredsställelse (ESS, CSES).
- Beroende 2: Preferens-politiköverensstämmelse (skattad från CSES eller replikation av Gilens & Page-metodik för icke-amerikanska fall).

Datakällor: European Social Survey, Comparative Study of Electoral Systems, World Values Survey, kodning av institutionell struktur från V-Dem eller Comparative Political Data Set.

Test: Tvågruppsjämförelse: grund-kedje- (≤ 2 effektiva lager) vs. djup-kedje- (≥ 3 lager) demokratier. t-test på genomsnittlig tillfredsställelse och överensstämmelse. Regression med demokratisk tillfredsställelse som utfall, lagerantal som prediktor (kategorisk: 1-2 vs. 3+), och BNP per capita och valsystemstyp som kontroller. Testa för en tröskeleffekt vid 2-3-lagergränsen snarare än ett linjärt samband.

Falsifiering: Ingen signifikant skillnad i tillfredsställelse eller överensstämmelse mellan grund- och djup-kedjegrupperna, eller djup-kedjesystem visar högre tillfredsställelse.

H.8 Prioriteringsordning för forskning

Förutsägelserna är ordnade efter genomförbarhet för testning på nära sikt:

- **Genomförbart nu (sekundärdataanalys):** Förutsägelser 1, 4 och 7 (tvärsnitt, med befintliga datamängder och heuristisk G-uppskattning).
- **Genomförbart med måttlig investering:** Förutsägelser 2 och 3 (longitudinell datainsamling och inom-falls-tidsserieanalys).
- **Kräver ny datainsamling:** Förutsägelser 5 och 6 (RCT för värdegranskningar; simulatorkalibrering som kräver detaljerade fallspecifika parametrar).

Ramverkets empiriska trovärdighet kommer att byggas stegvis, med början i tvärsnittstester som kan genomföras med befintliga data och heuristiska operationaliseringar, och fortskrida mot mer krävande designer i takt med att initiala resultat motiverar det.