




Tre lagar från en gräns

Ashby, Goodhart och certifieringskostnad som konsekvenser av begränsad representation

Rapport XX i serien Styrning som ingenjörskonst

Härleder Ashbys lag, Goodharts lag och den monotona certifieringskostnaden från en enda premiss: en ändlig kontrollant som partitionerar sin värld. Ashby är ett duvslagsfacksteorem, Goodhart skärps till ett interventionsmängdsresultat med en registrerad demonstration, och certifieringskostnaden är en icke-avtagande redovisningsstorhet. Sökandet efter en starkare konserveringslag misslyckades, och misslyckandet rapporteras som en del av resultatet.

Björn Kenneth Holmström

Juli 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorknennethholmstrom.org/sv/working-papers/three-laws-from-one-bound>

*Rapport 0 härledde existensen av faktorisering från begränsad prediktion. Denna artikel utgår från samma premiss — en ändlig kontrollant som partitionerar sin värld i en begränsad mängd urskiljbara tillstånd — och härleder tre av de lagar som serien har lutat sig mot: Ashbys lag om nödvändig variation, Goodharts lag och den monotona kostnaden för att hålla en faktorisering kopplad till en föränderlig värld. Påståendet är inte att någon av de tre är ny. Det är att de inte är tre oberoende postulat utan en begränsning sedd under tre operationer — att hålla, att optimera, att underhålla. Härledningarna är ärligt nivågraderade. Ashby är närmast definitionsmässig när begränsad representation väl är given, och artikeln säger det. Goodhartresultatet skärps till ett interventionsmängdsteorem och ges en liten registrerad demonstration, märkt **[R inom modellen]**. Påståendet om kumulativ kostnad är en redovisningsolikhet, **[IP]** — och sökandet efter en starkare konserveringslag rapporteras ha misslyckats, eftersom rapporteringen av misslyckandet är poängen.*

Sammanfattning

Serien Styrning som ingenjörskonst importerar två lagar den inte härleder — Ashbys lag om nödvändig variation och Goodharts lag — och konstruerar en tredje, certifieringskostnaden från Rapport XVII. Denna artikel visar att alla tre följer av den enda premiss som Artikel 0 fastställde: begränsad representation, en ändlig kontrollant som partitionerar den uppgiftsrelevanta världen i ett begränsat antal interna tillstånd och tilldelar en handling per tillstånd.

Från den premissen följer tre konsekvenser. Ashby är ett fackteorem: om kontrollanten har färre interna tillstånd än uppgiften kräver distinkta responser, måste något tillstånd slå samman förhållanden som behöver olika handlingar, och kontroll är under gränsen för tillräcklighet — så nödvändig variation är nödvändig, inte bara tillrådlig. Härledningen är nästan definitionsmässig, och dess icke-ytliga innehåll är den precisering den tvingar fram: en kontrollant måste särskilja tillräckligt, särskilja rätt saker och återsärskilja när uppgiftens krav skiftar. Goodhart är ett strukturellt teorem: en begränsad kontrollant måste optimera genom en förlustbringande projektion av sitt mål, och vi bevisar — och demonstrerar över trettio registrerade världar — att sådan optimering försämrar målet precis när projektionen förkastar en målrelevant dimension som

optimeraren kan nå. Enbart förlustbringande projektion är otillräcklig; nåbarheten av den förkastade dimensionen är diskriminatoren. *Certifieringskostnad* är en monoton redovisningsstorhet: den kumulativa kostnaden för avkänning, revision, omfaktorisering och att bära obetald diskrepans är icke-avtagande över en kontrollants livstid — betala i små steg eller senare i kris.

Artikeln disciplineras mot sin egen frestelse till inflation. Ashbys teoremstatus är verklig men ytlig och flaggas som sådan. Certifieringsresultatet är en olikhet, inte en konserveringslag: vi sökte efter en bevarad storhet — en fast budget av representationskomplexitet som bara kunde flyttas mellan institution och individ — och fann ingen. Representationskomplexitet kan stiga eller falla; endast *kostnaden för att förbli i linje* är monoton. Det negativa resultatet rapporteras i §5 snarare än slätas över. Vad som återstår, och vad artikeln hävdar, är enandet: tre lagar serien behandlade som separata är tre ansikten av ändlig representation, och det enda genuint nya formella resultatet — att Goodhart styrs av den nåbara interventionsmängden — är det skarpaste av de tre eftersom det säger vilka proxyvariabler som är säkra och vilka som inte är det.

1. Tre lagar, en misstanke

Serien har tre bärande lagar med tre olika härstamningar. Ashbys lag om nödvändig variation anländer från cybernetiken som mottagen visdom: en kontrollant behöver minst lika mycket variation som det system den reglerar. Goodharts lag anländer från ekonomin som folkteorem: när ett mått blir ett mål upphör det att vara ett gott mått. Certifieringskostnaden är seriens egen, introducerad i Rapport XVII som det pris ett system betalar för att kontrollera att dess modell av världen fortfarande passar. Tre ursprung, tre register — en designt tumregel, en cynisk aforism, en intern konstruktion — och serien använder alla tre som om de vore oberoende fakta om styrning.

De har något gemensamt som deras olika ursprung skymmer. Var och en är ett påstående om vad ett *begränsat* system kan och inte kan göra. Ashby handlar om en kontrollant med ändlig variation. Goodhart handlar om ett mål som komprimerats till en ändlig proxyvariabel. Certifiering handlar om en ändlig modell som kontrolleras mot en obegränsad värld. Misstanken denna artikel driver är att gemensamheten inte är tillfällig — att de tre inte är tre lagar utan *en* begränsning sedd tre gånger, under tre olika operationer. Ashby är vad begränsadhet innebär när en kontrollant blott *håller* en faktorisering och måste handla genom den. Goodhart är vad begränsadhet innebär när kontrollanten *optimerar* genom faktoriseringens projektion. Certifieringskostnad är vad begränsadhet innebär när kontrollanten måste *underhålla* faktoriseringens passform över tid. Om det stämmer importerar serien ingenting den inte kunde härleda, och de tre lagarna upphör att vara separata axiom och blir teorem om ändlig representation — med den vinst i ekonomi, och förlust av mystik, som det för med sig.

Vinsten är värd att ange rakt ut eftersom den disciplinerar artikeln. Ett ramverk som postulerar Ashby, Goodhart och certifieringskostnad som tre oberoende lagar är ett ramverk med tre ställen där det skulle kunna ha fel. Ett ramverk som härleder dem från en premiss har ett ställe — premisen — och tre härledningarna som antingen går igenom eller inte gör det. Denna artikels bidrag är härledningarna och deras enande, inte någon av de tre lagarna individuellt; och eftersom två av de tre härledningarna ligger nära omformuleringar av sin premiss, är den ärliga artikeln noga med att säga vilka av dess resultat som är substantiella och vilka som är nära tautologier klädda i ny notation. Det enda genuint nya formella objektet här är den skärpta Goodhart i §4. Resten är konsolidering — värdefull som konsolidering, och inte mer.

2. Den enda premissen

Premissen är Rapport 0:s resultat, omformulerat i den form härledningarna behöver. En begränsad kontrollant kan inte representera sin värld i full detalj; den partitionerar den uppgiftsrelevanta världen i en ändlig mängd urskiljbara interna tillstånd — en faktorisering — och dess kontrollpolicy avbildar varje internt tillstånd på en handling. Låt N beteckna antalet urskiljbara interna tillstånd. Två egenskaper hos denna uppställning bär hela artikeln, och ingen av dem är ett extra antagande: de är vad "begränsad representation" och "en kontrollpolicy" redan betyder.

Den första är att N är ändligt. Detta är den begränsade representationen själv, och Rapport 0 argumenterade för att det inte är en stipulation utan villkoret för varje fysiskt realiserad kontrollant: ändlig kapacitet tvingar fram en partition, och partitionen har ett ändligt antal celler. Den andra är att policyn tilldelar *en handling per internt tillstånd*. Detta är vad det innebär att ha en policy: en avbildning från representerade situationer till responser. Om två situationer i världen hamnar i samma interna tillstånd har kontrollanten, till följd av konstruktionen, inget sätt att handla olika i dem — inte för att den väljer att låta bli, utan för att den distinktion den skulle behöva är en som dess representation inte innehåller. Dessa två egenskaper — ändligt N , en handling per cell — är allt som de följande avsnitten använder. Allt som följer nedströms är en konsekvens av ändligt många celler som var och en är förbunden med en enda respons.

Den empiriska grunden för att ta denna premiss som mer än ett antagande är Rapport 0:s, importerad här på sin nivå: **[R inom modellen]** för demonstrationen att begränsad prediktion producerar just en sådan faktorisering, **[IP]** för läsningen av institutioner som kontrollanter av detta slag. Inom Rapport XX tas premissen som given, och frågan är endast vad som följer av den.

3. Ashby som teorem — den första lagen [R]

Definiera den uppgiftsrelevanta miljövariationen V_A som antalet distinkta miljöbetingelser som kräver distinkta handlingar för att kontrollanten ska förbli tillräcklig. Detta är inte världens råa variation — en obegränsad storhet — utan variationen filtrerad genom kontrollantens uppgift: två världstillstånd som kräver samma respons räknas inte som distinkta, och endast skillnader som kräver olika handlingar bidrar till V_A . Det är en egenskap hos trippeln kontrollant–miljö–uppgift, inte hos kontrollantens interna modell.

Härledningen är en enda tillämpning av fackprincipen (pigeonhole principle). Kontrollantens representation har N interna tillstånd, och avbildningen från miljöbetingelser till interna tillstånd partitionerar de V_A uppgiftsrelevanta betingelserna i högst N celler. Om $N < V_A$ måste minst ett internt tillstånd innehålla två eller flera betingelser som kräver olika handlingar. Policyn tilldelar det tillståndet en enda handling; så för de betingelserna vidtar kontrollanten samma handling där olika handlingar behövdes, och minst en av dem ger ett otillräckligt utfall. Kontrollanten kan inte vara tillräcklig. Således kräver tillräcklighet $N \geq V_A$: kontrollantens variation måste vara minst lika stor som den uppgiftsrelevanta variationen i dess omgivning. Det är Ashbys lag, och den är nu ett teorem snarare än en tumregel — en strikt konsekvens av ändlig representation under en policy, inte en designprincip man kan välja att hedra eller ignorera.

Den ärliga bedömningen är att detta teorem ligger nära en definition, och artikeln vinner inget på att låtsas något annat. När "uppgiftsrelevant variation" väl definieras som "antalet betingelser som kräver distinkta responser" är Ashbys lag ett kort steg av räkning: du kan inte ge distinkta responser till fler betingelser än du har tillstånd att särskilja dem med. Härledningens värde är inte djup — det är placering. Den visar att Ashby sitter *under* serien snarare än bredvid den, att nödvändig variation inte är en ytterligare lag som ramverket måste anta utan en konsekvens av den begränsade representation som ramverket redan vilar på. Det är värt att fastställa en gång, rent och utan att översälja.

Det icke-ytliga innehållet är vad teoremets struktur tvingar fram när det väl är i handen: tre distinkta krav som den enda olikheten buntar samman. **Särskilj tillräckligt** — det råa kapacitetskravet, $N \geq V_A$, och inte mer än detta är vad fackargumentet levererar direkt. **Särskilj rätt saker** — partitionen av V_A betingelser i N celler måste gruppera samman betingelser som genuint delar en tillräcklig handling, eftersom en kontrollant med rikligt N som skär världen längs fel sömmar fortfarande slår samman betingelser som kräver olika responser; kapacitet är nödvändigt, inte tillräckligt. **Åter-särskilj när kvoten skiftar** — V_A är inte fast. En ny stress kan splittra vad som

tidigare var en betingelse i två som nu kräver olika handlingar: en faktorisering som förfinade den gamla uppgiftskvoten förfinar inte längre den nya, och det effektiva V_A stiger utan någon förändring hos kontrollanten. Detta är en chock i nödvändig variation, och teoremet är oförsonligt kring det: när V_A stiger måste kontrollanten höja sin egen variation — lägga till celler, engagera nya distinktioner — eller acceptera degradering, utan något tredje alternativ. Mekanismen genom vilken en institution åstadkommer den åter-särskiljningen är precis den avkännings- och justeringsapparat som Rapport XIX beskrev: vaktposter som upptäcker att kvoten har skiftat, broar som låter faktoriseringen expandera utan att fragmenteras. Ashbys lag, härledd, är vad som gör den apparaten nödvändig snarare än valfri — den statiska sidan av en gräns som de följande två avsnitten betraktar under optimering och över tid.

4. Goodhart som strukturellt teorem — optimeringssidan [R för teoremet]

Ashby handlar om en kontrollant som blott håller en faktorisering och handlar genom den. Goodhart handlar om vad som händer när kontrollanten *optimerar* — driver hårt för att förbättra en mätbar storhet — och det är här artikelns enda genuint nya formella resultat sitter. Goodharts lag uttrycks vanligen som en aforism, "när ett mått blir ett mål upphör det att vara ett gott mått", och behandlas som en cynisk empirisk regelbundenhet. Från begränsad representation är den varken cynisk eller empirisk: den är en strukturell konsekvens, och härledningen säger exakt vilka mått som är säkra att optimera och vilka som inte är det.

4.1 Trestegsuppdelningen

Härledningen har tre steg, motsvarande en uppdelning som det explorativa arbetet föreslog: Goodhart = projektion + optimering + icke-faktoriserbarhet.

Projektion. En begränsad kontrollant kan inte optimera det mål den ytterst bryr sig om, eftersom målet — patienthälsa, social välfärd, vetenskaplig förtjänst — är en högdimensionell latent storhet som dess representation inte kan hålla i full utsträckning. Den optimerar i stället en proxyvariabel: en mätbar storhet $M = g(f(E))$ som erhålls genom att projicera världen E genom kontrollantens faktorisering f och avläsa en skalär g . Projektionen är förlustbringande genom själva faktumet av begränsning — detta är återigen Ashbys ändliga N , nu tillämpad på målet snarare än på omgivningen. Varje institution optimerar en proxyvariabel eftersom den inte kan göra annorlunda.

Optimering. Optimeringstryck för systemet till tillstånd som maximerar M . Om dessa tillstånd sammanfaller med tillstånd som maximerar målet T uppstår ingen skada. Frågan är om de kan divergera, och begränsning ensamt besvarar den inte — en förlustbringande projektion kan fortfarande vara en fullständigt trogen *vägvisare* till målet om informationen den förkastade är information som optimeraren inte kan agera på.

Icke-faktoriserbarhet. Skada följer när optimeraren kan förflytta systemet längs en dimension som proxyvariabeln förkastade men målet behåller. Då existerar tillstånd där M förbättras medan T inte gör det, och optimering — som endast ser M — kommer att finna dem, eftersom de är just de

billiga riktningarna i M -rummet. Proxyvariabeln och målet glider isär inte överallt, utan längs de förkastade men ändå nåbara dimensionerna, och optimeringstryck är just den kraft som söker upp dessa dimensioner.

4.2 Interventionsmängdsteoremet

De tre stegen skärps till ett påstående som är mer användbart än "mått misslyckas", eftersom det drar gränsen mellan de mått som misslyckas och de som inte gör det.

Goodhart-från-faktorisering-teoremet. *En proxyvariabel M är säker under optimering om och endast om dess inducerade ordning av tillstånd över den nåbara interventionsmängden förfinar målordningen. Om M är en förlustbringande projektion som slår samman eller felordnar målrelevanta distinktioner, och optimering kan förflytta systemet längs de förkastade dimensionerna, så kommer proxyoptimering att nå tillstånd där M förbättras medan T stagnerar eller försämras.*

Det bärande ordet är *nåbar*. Förlustbringande projektion är nödvändig för Goodhart men inte tillräcklig: en proxyvariabel kan förkasta en målrelevant dimension och förbli säker, förutsatt att optimeraren inte kan röra sig längs den dimensionen. Det som omvandlar en oskadlig komprimering till en Goodhart-fälla är konjunktionen av förlust och räckvidd — den förkastade dimensionen måste vara en som optimerarens interventioner faktiskt kan förändra. Detta är anledningen till att vissa kraftigt komprimerade mått är robusta medan andra kollapsar i samma stund de optimeras: skillnaden är inte hur mycket de förkastar utan om det de förkastar ligger inom den nåbara interventionsmängden. Den slogan teoremet förtjänar är att **Goodhart är optimeringstryck applicerat på en projektion som glömde något exploaterbart** — där "exploaterbart" betyder just "nåbart och målrelevant".

Teoremet ansluter direkt till Rapport XVIII:s icke-faktoriserbarhetsteorem, som fastställde att värden i allmänhet inte faktoriserar genom en enda skalär under intervention. Goodhart är optimeringstidens korollarium: när icke-faktoriserbarheten är verklig och den förargliga dimensionen är nåbar, kommer den skalära proxyvariabel som ignorerade den att drivas isär från det värde den stod för.

4.3 En minimal demonstration [R inom modellen]

Teoremets icke-triviala påstående — att nåbarhet, inte förlustbenägenhet, är diskriminatoren — medger en ren demonstration, och den registrerades i förväg och kördes över trettio världar. En fast budget fördelas mellan en uppmätt dimension a och en dold dimension b ; målet belönar båda genom en konkav nyttofunktion $T = \alpha a^p + \beta b^p$; proxyvariabeln är den projektion som släpper den dolda dimensionen, $M = a^p$. Eftersom nyttan är konkav delar målets sanna optimum budgeten mellan de två dimensionerna; proxyvariabeln, som bara ser a , driver hela budgeten mot a . Huruvida det orsakar skada beror på en manipulerad variabel: den dolda dimensionens nåbarhet r , definierad som hur långt optimeraren får svälta b under dess måloptimala värde b^* .

Förutsägelsen var att degraderingen av målet skalar med r — noll när den dolda dimensionen är frusen vid sitt optimum ($r = 0$), maximal när den är fullt svältbar ($r = 1$). Över trettio slumpmässigt dragna världar löpte mediandegraderingen av målet 0,000, 0,007, 0,029, 0,079, 0,268 över $r \in \{0, 0,25, 0,5, 0,75, 1,0\}$: monoton i var och en av de trettio världarna, med en poolad rangkorrelation på 0,98 mellan nåbarhet och degradering. Vid $r = 1$ visade varje värld degradering över den registrerade tröskeln; vid $r = 0$ visade varje värld exakt ingen, eftersom frysning av den dolda dimensionen vid b^* tvingar budgetrestriktionen att placera proxyvariabelns optimum på målets. Samma förlustbringande proxyvariabel — $M = a^p$ genomgående — är oskadlig när dess förkastade dimension är utom räckhåll och skadlig i proportion till att den dimensionen kommer inom räckhåll.

Två ärlighetsnoter följer med in i artikeln. Resultatet för $r = 0$ är analytiskt snarare än en empirisk nollhypotes: att frysa b vid b^* gör nolldegradering sann till följd av konstruktionen, så det verifierar att implementationen reproducerar teoremets fryst-vid-optimum-fall, och den empiriska vikten faller på *skalnings*resultatet, att degradering styrs av nåbarhet över hela intervallet. Och det demonstrerade påståendet gäller specifikt degradering *från ett initialt måloptimalt tillstånd*: demon visar att nåbarhet är nödvändig för att optimering ska förflytta ett gott tillstånd till ett dåligt, inte det bredare och falska påståendet att en förlustbringande proxyvariabel är säker från vilken startpunkt som helst — en dimension som redan är frusen vid ett dåligt värde förblir dålig, och optimering av den uppmätta dimensionen kan inte reparera den.

5. Certifieringskostnad som monoton redovisning — underhållssidan [IP]

Ashby är begränsningen sedd i ett ögonblick, Goodhart begränsningen sedd under optimering. Det tredje ansiktet är begränsningen sedd över tid: vad det kostar att hålla en faktorisering matchad mot en värld som inte står stilla. Detta är seriens egen certifiering (Rapport XVII), och att härleda dess centrala egenskap från begränsad representation är artikelns tredje konsekvens — även om det ärliga resultatet här är svagare än vad den explorativa inramningen först antydde, och att säga det är en del av avsnittets uppgift.

5.1 Vad certifiering är, och varför den kostar

En faktorisering som är tillräcklig idag behöver inte vara tillräcklig imorgon, eftersom V_A skiftar (§3): ny stress splittrar betingelser som en gång delade en handling, och den faktorisering som förfinade den gamla uppgiftskvoten förfinar inte längre den nya. Certifiering är processen att kontrollera om den fortfarande gör det — samla in nya data, jämföra faktoriseringens prediktioner mot dem, upptäcka de diskrepanser som Rapport XVI kallar källtermer, och avgöra om faktoriseringen ska behållas eller omfaktoriseras. Varje steg konsumerar resurser, och — poängen som gör certifiering till en *kostnad* snarare än en observation — varje steg är irreversibelt i sin effekt på kontrollantens informationstillstånd. Även en certifiering som konstaterar "fortfarande tillräcklig" lämnar kontrollanten i ett nytt tillstånd: den vet nu att faktoriseringen är tillräcklig, och den kunskapen var inte gratis. En certifiering som konstaterar "omfaktorisera" medför den större kostnaden av att utöka den interna variationen för att täcka de nyuppdelade betingelserna.

5.2 Den monotona storheten

Definiera den kumulativa certifieringskostnaden som den löpande summan av fyra termer över kontrollantens livstid: avkänning (kostnaden för att samla in data), revision (kostnaden för att jämföra prediktion med data), omfaktorisering (kostnaden för att utöka eller revidera faktoriseringen när en mismatchning hittas), och *stängningsskuld* — den ackumulerade, ännu obetalda kostnaden för diskrepanser som har upptäckts eller uppstått men ännu inte lösts. Påståendet, seriens andra lag:

Den kumulativa kostnaden för att förbli i linje — avkänning plus revision plus omfaktorisering plus ackumulerad stängningsskuld — är icke-avtagande över kontrollantens livstid.

Resonemanget är att varje term är individuellt icke-negativ och ingen återbetalas någonsin. Avkänning och revision är betalda och borta. Omfaktorisering betalas när den uppstår. Stängningsskuld växer bara eller omvandlas till betald omfaktoriseringskostnad; en diskrepans blir inte ogjord. Så den löpande summan kan inte minska. Styrningsläsningen är den välbekanta given ett golv: en institution betalar antingen för certifiering i små regelbundna steg, eller skjuter upp den och betalar senare i kris, när den ackumulerade stängningsskulden förfaller på en gång. Uppskjutande ändrar när kostnaden betalas och kan höja dess totalbelopp genom ränta — en okorrigerad mismatchning genererar ytterligare mismatchning — men det kan inte göra kostnaden negativ eller återföra institutionen till dess informationsmässiga tillstånd före certifiering.

5.3 Konserveringslagen som inte finns där

Det explorativa arbetet sträckte sig efter något starkare än en monoton kostnad, och den ärliga rapporten är att det inte finns där. Den starkare förmodan var en *konserveringslag*: en fast budget av representationskomplexitet, konserverad under reform, som bara kunde *flyttas* — från institution till individ, från regel till omdöme — men aldrig minskas. Intuitionen är förförisk och har verkliga exempel. Förenkla en skattelagstiftning och komplexiteten återuppstår i skattebetalarens angelägenheter; förenkla skattebetalarens liv med en omfattande byråkrati och komplexiteten återuppstår i institutionen. Det läser sig som en konserveringslag: total komplexitet konstant, endast dess plats fri.

Det är inte en konserveringslag, och skillnaden är tillräckligt viktig för att anges som avsnittets resultat. Vad redovisningen faktiskt stöder är en *olikhet*, inte en likhet. I variationstermerna från §3 måste kontrollantens totala variation — institutionell plus kognitiv plus avkänning plus en felterm för den variation den misslyckas med att fånga — vara minst miljövariationen: $V_I + V_H + V_S + V_\epsilon \geq V_A$, eller i faktoriseringsentropinotation $H_B + H_R + H_O + H_\epsilon \geq H_W$. Detta är en nedre gräns för total variation, en omformulering av Ashby tillämpad på hela systemet av kontrollant plus operatörer. Den säger att budgeten måste vara *tillräckligt stor*; den säger inte att budgeten är *fast*. Representationskomplexitet kan genuint falla: en bättre faktorisering — en som skär världen närmare dess kausala fogar — kan täcka samma V_A med färre, bättre valda

distinktioner, och därmed minska total komplexitet samtidigt som kontrollen förbättras. Omvänt kan en dålig reform höja total komplexitet och försämma kontrollen. Komplexitet är inte konserverad; den är begränsad underifrån och i övrigt fri att röra sig upp eller ner.

Så den monotona storheten är *kostnaden för att förbli i linje*, inte *mängden komplexitet*. Detta är den korrigering avsnittet förbinder sig till: den andra lagen är en redovisningsolikhet om icke-återbetalningsbar kostnad, inte en konserveringsprincip om en fast komplexitetsbudget. Distinktionen är precis den sort som seriens anti-inflationsdisciplin finns till för att upprätthålla — en konserverad storhet vore ett starkare och mer elegant påstående, och det skulle vara falskt, och att rapportera att det är falskt är värt mer för ramverket än ett elegant resultat som inte håller. Det som överlever är verkligt och användbart: anpassning har en löpande kostnad som bara ackumuleras, vilket är anledningen till att uppskjutet underhåll inte är undviket underhåll. Det som inte överlever är den lockande bilden av komplexitet som en vätska som kan skuffas runt men aldrig tömmas. Den kan tömmas, genom att faktorisera bättre; vad som inte kan undflys är att betala, om och om igen, för att kontrollera att faktoriseringen fortfarande passar.

6. Varför en gräns ger tre lagar

De tre härledningarna kan nu ses som en. Var och en utgår från samma premiss — en kontrollant med ändligt många interna tillstånd, en handling per tillstånd — och betraktar den under en olik operation på faktoriseringen.

Ashby är den *statiska* sidan: gränsen sedd när kontrollanten bara håller en faktorisering och måste handla genom den i ett ögonblick. Begränsningen gäller kapacitet — tillräckligt många celler, skurna vid rätt sömmar, för att ge distinkta responser till betingelser som kräver dem. Goodhart är *optimeringssidan*: gränsen sedd när kontrollanten driver på för att förbättra en uppmätt projektion av sitt mål. Begränsningen gäller vilka projektioner som överlever att bli föremål för pådrivning — en proxyvariabel är säker endast där dess ordning förfinar målets över den nåbara mängden. Certifieringskostnad är den *dynamiska* sidan: gränsen sedd när kontrollanten måste hålla en faktorisering matchad mot en värld vars uppgiftskvot driver. Begränsningen är att matchning har en löpande kostnad som bara ackumuleras.

Variationsredovisningen i §5.3 är det som binder samman de tre, eftersom var och en är ett påstående om samma budget under en olik fråga. Ashby frågar om budgeten är tillräckligt stor för uppgiften nu: $V_I + V_H + V_S + V_\epsilon \geq V_A$. Goodhart frågar vad som händer när den täckta delen av budgeten optimeras medan en otäckt, nåbar del finns kvar: optimeringen finner gapet mellan vad proxyvariabeln mäter och vad målet behöver, och driver isär dem. Certifieringskostnad frågar vad som krävs för att hålla budgeten matchad mot V_A när V_A rör sig: priset för att upptäcka driften och åter täcka den, betalat i steg som aldrig återbetalas. Den statiska sidan säger att budgeten måste räcka till; optimeringssidan säger att den täckta budgeten inte kan pressas förbi vad den troget representerar; den dynamiska sidan säger att hålla budgeten matchad är en kostnad som bara växer.

Uttryckt på detta vis är de tre lagarna inte bara förenliga — de är samma teorem ställt inför tre frågor. Vad en kontrollant kan representera begränsar vad den kan göra (Ashby), vad den säkert kan optimera (Goodhart) och vad den kontinuerligt måste spendera för att förbli tillräcklig (certifiering). Den ekonomi artikeln gav sig ut för att köpa är köpt: serien behöver inte anta tre oberoende lagar, bara den enda gräns Rapport 0 redan fastställde, och härleda resten.

7. Vad detta återgrunder, och vad det inte visar

7.1 Återgrundning

Tre av seriens konstruktioner får en fastare grund. Rapport XVII:s certifieringsgolv är den per-händelse-term i §5:s monotona totalsumma — den lilla regelbundna betalning vars uppskjutande blir stängningsskuld; certifiering är inte en praktik serien rekommenderar utan en kostnad som den andra lagen säger inte kan undflys, bara tidsbestämmas. Rapport XVI:s källtermer är de diskrepanser som §5.1:s revision upptäcker: signalen att V_A har skiftat och att den nuvarande faktoriseringen inte längre förfinar den, vilket §3 identifierar som en chock i nödvändig variation. Och Rapport XIX:s rollen är den apparat som §3 visar vara nödvändig snarare än valfri: vaktposter upptäcker det skifte i V_A som Ashby säger måste mötas, broar möjliggör den åter-särskiljning Ashby kräver utan att fragmentera ekologin. Lagarna i denna artikel säger *vad som måste ske*; de artiklarna beskriver *de mekanismer som får det att ske*.

7.2 Vad denna artikel inte visar

Två av de tre härledningarna är nära omformuleringar, och artikelns värde är konsolidering. Ashby (§3) ligger nära en definition när uppgiftsrelevant variation väl definieras som betingelser som kräver distinkta handlingar; certifieringsmonotonicitet (§5) är en redovisningskonsekvens av icke-återbetalningsbara kostnader. Ingetdera är djupt. Endast interventionsmängdsteoremet (§4) är ett genuint nytt formellt resultat, och artikelns bidrag är enandet i §6, inte tre oberoende upptäckter. En läsare som vill ha ett nytt teorem bör endast se till §4.

Konserveringslagen är frånvarande, inte bara obevisad. Avsnitt 5.3 rapporterar ett negativt resultat: det finns ingen konserverad komplexitetsbudget, endast en nedre gräns. Representationskomplexitet kan stiga eller falla; den lockande bilden av komplexitet som en vätska som skuffas mellan institution och individ men aldrig töms är falsk. Detta anges som ett resultat eftersom alternativet — att presentera olikheten som om den vore den konserveringslag det explorativa arbetet sökte — skulle vara just den teoriinflation serien vaktar mot.

Goodhart-demonstrationen är minimal och delvis analytisk. Säkerheten vid $r = 0$ är sann till följd av konstruktionen, inte en empirisk nollhypotes (§4.3); den empiriska vikten vilar på skalningsresultatet för nåbarhet över trettio världar. Demon visar att degradering *från ett måloptimalt tillstånd* styrs av nåbarhet; den visar inte att en förlustbringande proxyvariabel är säker

från godtyckliga startpunkter. Och det är en medvetet enkel miljö — en budgetallokeringsvärld med konkav nytta — vald för att isolera teoremet, inte för att fastställa dess räckvidd över rikare sammanhang.

Premissen är importerad på Rapport 0:s nivå. Allt vilar på att begränsad representation producerar en uppgiftsförfinande faktorisering, vilket är **[R inom modellen]** för demonstrationen och **[IP]** för den institutionella läsningen. Härledningarna är endast så starka som den premissen; en kontrollant som bröt mot den — oändlig kapacitet, eller en policy som inte kan reduceras till en handling per representerat tillstånd — skulle undslippa alla tre lagarna, vilket är att säga att lagarna är konsekvenser av ändlighet, och inte gör anspråk på något om system som inte är ändliga i den relevanta meningen.

Den institutionella läsningen är [IP] genomgående. Att ett departement, en myndighet eller en måttregim instansierar V_A , en proxyprojektion och en certifieringskostnad är argument genom analogi. De formella resultaten handlar om kontrollanter med ändligt tillstånd; deras räckvidd till styrning är styrkan i den analogin och inget mer.

8. Metod och konfidens

Nivåerna följer serien: **[R]** rigorös, **[IP]** i princip, **[H]** heuristisk, där **[R inom modellen]** markerar ett resultat som är exakt för den angivna modellen och inte gör anspråk på mer. Denna artikel är i huvudsak härledningsbaserad; dess enda simulation är Goodhart-demonstrationen i §4.3, registrerad i `paper_xx-goodhart_demo_preregistration.md` och körd av `paper_xx-goodhart_demo.py`, med fastställda trösklar och nollhypoteser fixerade före körningen. De utforskningar som ligger bakom härledningarna (`06-conservation-law.md`, `07-ashby_s-law.md`, `08-goodhart.md`, `09-certification-entropy.md` och syntesen `08-reflection.md`) är argument, inte evidens, och citeras endast som källan till inramningen.

Konfidensnivåerna per resultat:

Resultat	Nivå	Not
Ashby som fackteorem (§3)	[R]	Verkligt men nära definitionsmässigt; värdet är placering, inte djup
Preciseringen i tre krav / chock i nödvändig variation (§3)	[R] för räkningen, [IP] för styrningsläsningen	Det icke-ytliga innehållet i Ashby-avsnittet
Interventionsmängdsteoremet (§4.2)	[R]	Det enda nya formella resultatet
Nåbarhet styr Goodharts allvarlighetsgrad (§4.3)	[R inom modellen]	30 registrerade världar; ändpunkten $r = 0$ är analytisk
Goodhart är <i>oundviklig</i>	görs inte anspråk på	Villkorat av att den förkastade dimensionen är målrelevant och nåbar
Certifieringskostnaden är monoton (§5.2)	[IP]	Redovisningskonsekvens av icke-återbetalningsbar kostnad
Komplexitetskonservering (§5.3)	misslyckad	Ingen konserverad budget; endast olikheten $\sum V \geq V_A$
En gräns ger tre lagar (§6)	[IP]	Enandet; artikelns bidrag
Alla institutionella läsningar	[IP]	Argument genom analogi från kontrollanter med ändligt tillstånd

Appendix A — Notation och Goodhart-demonstrationen

Notation. N : antalet urskiljbara interna tillstånd hos kontrollanten. V_A : uppgiftsrelevant miljövariation — antalet miljöbetingelser som kräver distinkta handlingar för tillräcklighet. $V_I, V_H, V_S, V_\epsilon$: institutionell, kognitiv (mänsklig), avkännings- och icke-fångad felkomponent av kontrollantens variation, med $V_I + V_H + V_S + V_\epsilon \geq V_A$ (ekvivalent $H_B + H_R + H_O + H_\epsilon \geq H_W$ i faktoriseringsentropitermer). $M = g(f(E))$: en skalär proxyvariabel som erhålls genom att projicera världen E genom kontrollantens faktorisering f . T : det latent mål som proxyvariabeln står som ställföreträdare för.

Demonstrationsmodell (§4.3). Var och en av 30 frön drar en värld: budget $C \sim U(5, 20)$, nyttoexponent $p \sim U(0, 3, 0, 7)$, målvikter $\alpha, \beta \sim U(0, 8, 1, 2)$. Budgeten fördelas mellan en uppmätt dimension a och en dold dimension b med $a + b \leq C$; målet är $T = \alpha a^p + \beta b^p$ (konkav, så det sanna optimumt delar budgeten), och proxyvariabeln är den projektion $M = a^p$ som släpper b . Det sanna optimumt har $a^*/b^* = (\alpha/\beta)^{1/(1-p)}$ skalat till $a^* + b^* = C$. Optimiseraren maximerar M över en nåbar mängd parametriserad av $r \in [0, 1]$: den dolda dimensionen får reduceras från b^* till $(1 - r)b^*$, där frigjord budget går till a . Degraderingen är $D(r) = (T^* - T(r))/T^*$. Allt är slutna form; den enda slumpmässigheten är världsdragningen. Ren numpy och matplotlib, sekunder på en CPU.

Registrerade utfall. P1 (Goodhart vid $r = 1$, $D > 0,10$): 30/30, median $D(1) = 0,268$. P2 (analytisk kontroll, $D(0) < 0,01$): 30/30, max $D(0) = 0$. P3 (allvarlighetsgrad skalar med nåbarhet, poolad Spearman $> 0,9$ och monoton per frö): poolad $\rho = 0,982$, monoton 30/30. Median D över $r \in \{0, 0,25, 0,5, 0,75, 1,0\}$: 0,000, 0,007, 0,029, 0,079, 0,268. Figuren `goodhart_scissors.png` visar stigande medelproxy och fallande medelmål när r ökar.