




Vad som inte kan garanteras

Certifieringsoförmåga, reformavgörbarhet och frånvaron av en universell arkitektur

Rapport XXII i serien Styrning som ingenjörskonst

Undersöker tre krav på garanti — inifrån, utifrån och före världen — och visar att vart och ett misslyckas av sitt eget skäl. En registrerad minimal modell demonstrerar en mekanism där en korrupt certifieringskärna får institutionens hälsoindikatorer att förbättras medan resurser systematiskt felallokeras. Rapport XXII i serien Styrning som ingenjörskonst.

Björn Kenneth Holmström

Juli 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/sv/working-papers/what-cannot-be-guaranteed>

Sammanfattning

Styrning efterfrågas för tre sorters garanti, och de skiljer sig åt genom den utsiktspunkt från vilken kravet ställs. **Inifrån:** kan ett system validera grunden för sin egen korrigering? **Utifrån:** kan en observatör, innan den handlar, avgöra om en föreslagen reform kommer att konvergera? **Före världen:** kan en arkitektur rättfärdigas utan ett påstående om vilken värld den befinner sig i? Varje krav misslyckas, och — detta är artikelns strukturella påstående — vart och ett misslyckas av sitt eget skäl.

Vi vägrar den unifisering som seriens föregående rapport inbjuder till. *Tre lagar från en gräns* härledde Ashby, Goodhart och certifieringskostnad från begränsad representation; symmetrin "tre gränser från en gräns" är nästan oemotståndlig och den är falsk. Reformers oavgörbarhet kräver **beräkningsmässig universalitet**, vilket förutsätter *negationen* av begränsad representation — en ändlig regulator har ett avgörbart konvergensproblem. No Free Lunch-teoremet kräver endast **frånvaron av en fördelning över miljöer** och binder en obegränsad regulator precis lika hårt som en begränsad. Endast certifieringsoförmågan spåras tillbaka till gränsen, och den gör det via certifieringsregressen i Rapport XVII plus den slutna metastegen i Rapport XXI, inte via fackprincipsargumentet i Rapport XX. Tre gränser, tre källor, ingen gemensam premiss; vad de delar är inte vad de följer av utan vad de *efterfrågas*.

De två gränser som har rena formella källor är teorem, och båda är grunda: reformers oavgörbarhet är rutinmässig när universalitet väl medges, och No Free Lunch är närmast innehållslöst när man väl noterar att dess likformiga fördelning över ett ostrukturerat miljörum inte beskriver någon värld någon har bebott. I båda fallen ligger det användbara innehållet i kontrapositionen — *namnge den begränsade klass av dynamik din utvärdering förutsätter; namnge den miljöklass din arkitektur satsar på*. Gränsen med verkligt innehåll, certifieringsoförmågan, är inte ett teorem, och vi påstår inte att det är ett. **I denna litteratur går stringensen och intresset i motsatta riktningar**, och vi tar det som ett faktum om terrängen snarare än en pinsamhet.

Den empiriska demonstrationen knyts därför till den strukturella diagnosen snarare än till något av teoremen. Den **misslyckas på alla fyra registrerade förutsägelser**, och två registrerade försök att bygga den adaptiva regulator som den krävde misslyckas också: tre agenter med hård komplementaritet och en sanningsenlig signalkanal konvergerar, i de flesta frön, mot en jämvikt utan handel där generalisten som inte behöver någon överlever ensam. Vad som framträder i stället — funnet i efterhand, återregistrerat och bekräftat på tjugo nya frön — vänder på förutsägelsen och stärker det påstående förutsägelsen tjänade. Att invertera en institutions behovscertifieringskanal

svälter inte den part den felidentifierar. **Den översvämmar dem.** Den överförsörjda parten slutar därmed att registreras som behövande, och systemets egen behovsdetektion löser aldrig ut. Ouppfyllt behov avläses som en perfekt nolla — bättre än utgångsläget — medan kärnan är inverterad och resurser systematiskt felallokeras.

Konsekvensen är artikelns skarpaste praktiska påstående: **en institution kan inte övervaka sin egen certifieringskärna med instrument som är beroende av den kärnan.** Statistik över uppfyllda behov, klagomålsvolymen och underskottsindikatorer är utdata från den allokeringsprocess som kärnan styr; när kärnan är sund mäter de världen, och när den är korrupt mäter de korruptionens framgång i att tillfredsställa dem den har felstyrts resurser mot. En sviktande institution ser inte bara frisk ut inifrån. **Dess hälsoindikatorer förbättras.**

Fem registrerade misslyckanden, två grunda teorem förklarade grunda, en vägrad unifiering och en bekräftad mekanism vi inte förutsåg.

§1 — Introduktion

1.1 Tre frågor som serien har antagit bort

En institution kan ombes garantera sin egen sundhet på tre helt olika sätt, och det är värt att skilja dem åt innan man frågar om något av dem kan uppfyllas.

Kan systemet inifrån validera att grunden för dess egen korrigerings fortfarande håller? Inte om det räknade rätt — det är kontrollerbart — utan om de världsfakta som dess regler vilar på faktiskt förelåg, och om proceduren genom vilken det fastställer sådana fakta fortfarande är den rätta. Kalla detta kravet på garanti **inifrån**.

Kan en observatör utifrån och innan den handlar avgöra om en föreslagen reform kommer att nå stabil samordning? Detta är vad en konsekvensbedömning, en finanspolitisk prognos eller en konstitutionell granskning *försöker* göra, avskalat sin dimma. Kalla detta kravet på garanti **utifrån**.

Kan en arkitektur rättfärdigas utan ett påstående om vilken värld den befinner sig i? Nästan varje substantiellt politiskt argument har denna form — att demokrati överträffar autokrati, att marknader överträffar planering, att decentralisering överträffar sin motsats — och vart och ett uttalas som om överlägsenhet vore en egenskap hos arkitekturen. Kalla detta kravet på garanti **före världen**.

De tre är inte variationer på varandra. De är tre utsiktspunkter, och denna artikels struktur är en uppräknings över dem.

1.2 Vad serien tyst har förlitat sig på

Var och en av dessa tystnader har varit bärande.

Rapport XVII etablerade ett **certifieringsgolv**: huruvida ett externt faktum förelåg kan inte göras självverifierande, eftersom en verifierare av ett världsfaktum i sin tur behöver en verifierare. Men den antog att ankaret kunde *litas på*, inte att det kunde svikta *reflexivt* — att systemets egen drift kunde generera ett krav som dess certifieringsprocedur inte kan möta.

Rapport VII argumenterade för **skyddade experimentutrymmen** på grunden att experimenterande är klokt. Den sade aldrig *varför experiment är oundvikligt* — varför frågan inte helt enkelt kan beräknas av en tillräckligt noggrann analytiker.

Rapport V argumenterade för **adaptiv pluralism** utifrån försiktighet: behåll alternativ, världen kan förändras. Den sade aldrig att den gällande arkitekturen *redan är ett vad*, och att pluralism inte är en försäkring mot en möjlig framtid utan det enda koherenta svaret på ett redan placerat vad.

Tre gränser tillhandahåller de tre saknade premisserna, och omvandlar därmed tre försiktighetsrekommendationer till konsekvenser. En försiktighetsrekommendation kan avvisas av en institution som bedömer sig kapabel nog att inte behöva den, och institutioner gör det rutinmässigt. En konsekvens kan inte avvisas.

1.3 Den unifisering vi vägrar

Rapport XX bär titeln *Tre lagar från en gräns*, och den förtjänar den. Frestelsen att skriva *Tre gränser från en gräns* är stark, och argumentet som skulle rättfärdiga det är ett gott sådant — gott nog för att §2 ska lägga fram det i full styrka innan det bryts sönder.

Det bryts sönder i två av sina tre ben, och ett av brotten är inte en teknikalitet:

- **Reformers oavgörbarhet kräver negationen av gränsen.** Oavgörbarhet behöver beräkningsmässig universalitet; universalitet behöver ett obegränsat tillståndsrums; och en ändlig regulator har ett *avgörbart* konvergensproblem, avgjort genom att simulera den under storleken av dess tillståndsrums. Begränsning producerar inte denna gräns. Den **förstör** den. Att härleda L2 från begränsad representation vore att härleda den från negationen av dess egen hypotes.
- **No Free Lunch är likgiltigt inför gränsen.** En Laplace-demon med obegränsad representation möter det precis som en begränsad regulator gör, eftersom teoremet handlar om frånvaron av en fördelning över miljöer, inte om vetarens ändlighet.

Endast certifieringsoförmågan spåras tillbaka till begränsning, och den gör det via en längre kedja än XX:s: certifieringsregressen i XVII, plus **stängningen** av XXI:s metastege, plus självrepresentation. Tre gränser, tre källor, ingen gemensam premiss. Vad som håller samman triptyken är inte vad den följer *av* utan vad den *efterfrågas* — och varje utsiktspunkt misslyckas av ett skäl som är dess eget: insidan på grund av en regress, utsidan på grund av en reduktion, det som är före-världen på grund av avsaknaden av en fördelning.

Rapport XVI stod inför fyra fenomen som såg ut som ett och vägrade den enhetliga teorin, och behöll den gemensamma strukturen och skillnadsaxeln. Vi gör detsamma här, och av ett hårdare skäl: bandet existerar inte bara inte. En av de tre gränserna motsäger den premiss som skulle ha tillhandahållit den.

1.4 Stringensen och intresset löper i motsatta riktningar

Denna artikel har en ovanlig form, och vi vill hellre förklara den än få den påpekad.

L2 och L3 är teorem, och båda är grunda. Reformers oavgörbarhet följer rutinmässigt när universalitet väl medges — och följer oberoende av Rices teorem och av begränsningsresultat för rika dynamiska system, vilket i sig är evidensen för grundhet: när ett resultat faller ut ur tre orelaterade teorem berättar det inte något specifikt om det studerade objektet. No Free Lunch är formellt giltigt och närmast innehållslöst, och vilar helt på en likformig fördelning över ett ostrukturerat miljörum som inte beskriver någon värld någon har bebott.

L1 är den med innehåll, och den är inte ett teorem. Den är en strukturell diagnos, nivågraderad [IP], och §3.2 anger den invändning vi inte kan besvara: det är möjligt att certifieringsoförmågan, korrekt formaliserad, löses upp i den vanliga iakttagelsen att institutioner kan ha fel om världen.

Så den empiriska demonstrationen knyts till [IP]-diagnosen snarare än till någotdera [R]-teoremet — eftersom teoremen inte har något att demonstrera och diagnosen har det. §2.7 erbjuder skälet till att denna inversion inte är en tillfällighet:

En gräns som kan härledas från en enda ren hypotes är vanligtvis en gräns om hypotesen, inte om objektet. När hela resultatet faller ut ur "anta Turing-fullständighet", är antagandet det som gör arbetet och det studerade objektet är inert — en marknad eller en termostat skulle fungera lika bra. Resultatet reser så fritt eftersom det inte handlar om styrning överhuvudtaget.

Rapport XX förklarade sin Ashby-härledning grund snarare än att klä ett fackprincipargument som en upptäckt. §5 och §6 gör detsamma, och det kostar mer här, eftersom Gödel och Turing bär en prestige som kommer att göra en läsares tänkande åt dem om det tillåts.

1.5 Demonstrationen misslyckades, och misslyckandet är resultatet

Vi byggde en minimal institution: tre agenter, två resurser, hård komplementaritet, och en **certifieringskanal** — en behovssignal genom vilken systemet fastställer att ett externt faktum, *denna agent behöver A*, förelåg. Den kanalen är certifieringskärnan i §3 i miniatyr. Vi inverterade den och ställde fyra förhandsregistrerade frågor.

Alla fyra misslyckades. Likaså misslyckades två registrerade försök att bygga den adaptiva regulator som den skarpaste av dem krävde.

Misslyckandena hänger samman, och vad de hänger samman till var inte förutsagt. §3.4 hade förutsett att en korrupt kärna skulle uppträda som **missad certifiering** — ett system som förlorar förmågan att känna igen verkligt behov. Demonstrationen finner *noll* missad certifiering, i varje frö, och en stor ökning av **falsk** certifiering. Mekanismen, bekräftad på tjugo nya frön efter att ha återregistrerats:

*Den inverterade kanalen svälter inte den part den felidentifierar. **Den översvämmar dem.** Specialisten signalerar behov av en resurs precis när den har den resursen; de andra efterkommer och ger den mer; dess lager stiger; och efter att ha stigit faller den aldrig ner i genuint behov igen. **Den falska certifieringen föregriper det verkliga behov som den annars skulle ha maskerat.***

Så det mått som en revisor skulle sträcka sig efter — *går någons verkliga behov ouppfyllt?* — avläses som en **perfekt nolla, bättre än utgångsläget**, medan kärnan är inverterad och resurser systematiskt felstys. §3.4 förutsåg att en sviktande institution skulle se frisk ut inifrån. Sanningen är värre, och den falsifierar den specifika förutsägelsen samtidigt som den bekräftar det påstående som förutsägelsen tjänade: **institutionens hälsoindikatorer förbättras**. Patologin förstör evidensen för sig själv.

Detta ger artikelns skarpaste praktiska påstående, i §7.3, och det utesluter en klass av tillsynsdesign snarare än att rekommendera en:

En institution kan inte övervaka sin egen certifieringskärna med instrument som är beroende av den kärnan. Statistik över ouppfyllda behov, klagomålsvolym, servic gapsrapporter och underskottsindikatorer är alla utdata från den allokeringsprocess som kärnan styr. När kärnan är sund mäter de världen; när den är korrupt mäter de korruptionens egen framgång i att tillfredsställa dem den har felstyrkt resurser mot. Ett stigande förtroende för en övervakningsregim är inte evidens för att regimen fungerar.

1.6 Plan och nivågradering

§2 vägrar unifieringen och tillskriver de tre källorna. §3 anger certifieringsoförmågan och avstår från att kalla den ett teorem. §4 rapporterar den registrerade demonstrationen och dess fem misslyckanden. §5 och §6 ger de två teoremen och förklarar båda grunda. §7 omvandlar gränserna till designprinciper. §8 integrerar med serien. §9 anger vad artikeln inte visar, vilket är en längre lista än vad den visar.

påstående	nivå
källtillskrivningar av L1 / L2 / L3 (§2)	[R]
uttömmandet av de tre utsiktspunkterna (§2.8)	[IP] — en fjärde existerar och behandlas inte
certifieringsförmåga (§3)	[IP] — uttryckligen inte ett teorem
översvämningsmekanismen och dess misslyckandesignatur (§4.5)	[R inom modellen] — post-hoc, återregistrerad, bekräftad
Reformkonvergensens oavgörbarhet (§5)	[R] , flaggad grund ; den operativa gränsen är komplexitet, inte beräkningsbarhet
No Free Lunch för institutioner (§6)	[R] , flaggat närmast innehållslöst ; kontrapositionen är innehållet
designprinciper som härledda snarare än rekommenderade (§7)	[IP]
institutionella läsningar genomgående	[IP]
att välja mellan efterlevnad och skepticism (§7.4)	[H] — en öppen avvägning utan princip
att identifiera vilken miljöklass man befinner sig i (§6.7)	[H] — den förmåga som §6:s princip förutsätter

1.7 En not om hur denna artikel upptäcktes

Den första registrerade körningen av §4 returnerade ett rent, stabilt, fullständigt skenbart utgångsläge. Varje villkor överensstämde med varje annat; siffrorna var prydliga; ingenting såg fel ut. Populationen var död. En degenererad handling i miljön lät agenter skrapa karga celler till döds medan rutnätet låg mättat, och instrumenten — som plikttroget beräknade andelar över en nämnare av noll — rapporterade perfekt hälsa.

Det som fångade det var en insläppsgrind registrerad innan data existerade, extern till den apparat den kontrollerade, och ansvarig inför ett kriterium fastställt i förväg.

Vi designade inte artikeln för att göra den poängen. Det är emellertid poängen.

§2 — Tre gränser, tre källor, och varför de inte reduceras till en

2.1 Frestelsen

Rapport XX bär titeln *Tre lagar från en gräns*, och den förtjänar den: Ashby, Goodhart och certifieringskostnaden från Rapport XVII följer alla från en enda premiss — en ändlig regulator som partitionerar den uppgiftsrelevanta världen i ett begränsat antal interna tillstånd och tilldelar en handling per tillstånd. Tre lagar, en gräns, tre operationer: att hålla, att optimera, att underhålla.

Föreliggande artikel har tre gränser. Symmetrin är nästan oemotståndlig, och det är värt att lägga fram den i sin starkaste form innan den avvisas, eftersom den version som övertygar inte är en halmgubbe.

*En begränsad regulator kan inte representera sin värld uttömmande. Den måste därför faktorisera — förbinda sig till en ändlig mängd distinktioner och förkasta resten (Rapport 0). Det åtagandet är en induktiv bias, och varje induktiv bias är ett vad på vilken sorts värld man befinner sig i; därav **No Free Lunch**. Regulatorn kan inte verifiera sin egen faktorisering inifrån, eftersom verifiering av ett världsfaktum kräver en verifierare, och stegen av verifierare måste stängas i ett ändligt system; därav **certifieringsoförmåga**. Och eftersom regulatorn inte kan representera sin egen framtida bana i sin helhet, kan den inte i förväg beräkna om en förändring av dess faktorisering kommer att stabilisera sig; därav **reformers oavgörbarhet**. Tre gränser, en gräns, tre utsiktspunkter.*

Detta är ett gott argument. Det är också felaktigt i två av sina tre ben, och misslyckandet är inte en teknikalitet som en mer noggrann formulering skulle reparera. Att klargöra exakt *hur* det misslyckas är arbetet i detta avsnitt, eftersom misslyckandets form är det som organiserar artikeln.

2.2 Det andra benet misslyckas, och det misslyckas genom motsägelse

Oavgörbarhet kräver beräkningsmässig universalitet: uppdateringsdynamiken måste kunna simulera en godtycklig Turingmaskin. Universalitet kräver ett obegränsat tillståndsrum. Och ett obegränsat tillståndsrum är just vad begränsad representation förnekar.

Genomför härledningen och se den inverteras. En regulator med ett ändligt tillståndsrum S har ett **avgörbart** konvergensproblem: simulera dynamiken under $|S|$ steg, observera att banan vid det laget måste ha gått in i en cykel, och avläs om den cykeln ligger innanför $C \cap V$. Begränsning *producerar* inte oavgörbarhet. Begränsning *förstör* den.

Så försöket att härleda L2 från begränsad representation är inte bara en annan härledning än den vi ger i §5; det är en härledning från negationen av L2:s egen hypotes. **[R]** De två premisserna kan inte båda vara skarpa samtidigt, och varje artikel som påstår något annat har köpt en unifiering med en motsägelse.

Detta är det enskilt starkaste skälet för den föreliggande artikelns struktur, och vi vill ha det dokumenterat snarare än begravt i en brasklapp. Rapport XX:s gräns är verklig och serien vilar på den. L2 kräver dess motsats. Det faktumet är inte en pinsamhet; det är information om var L2 faktiskt hör hemma — nämligen i en idealisering, vars ändliga skugga är ett *komplexitetsresultat* snarare än ett beräkningsbarhetsresultat (§5.3). Oavgörbarhetsteoremet beskriver en gräns som seriens egna regulatorer strängt taget inte möter; vad de möter är dess exponentiellt dyra ändliga motsvarighet. Att erkänna detta är vad som hindrar §5 från att dra nytta av Turings namns prestige.

2.3 Det tredje benet misslyckas, mer stillsamt

No Free Lunch är likgiltigt inför regulatorns kapacitet. Betrakta en Laplace-demon: obegränsad representation, perfekt minne, ingen faktorisering påtvingad den av någon ändlighet. Den möter NFL precis som en begränsad regulator gör. Medelvärdesbildat likformigt över ett ostrukturerat rum av miljöer ligger demonens arkitektur lika med varje annan. Ingenting i NFL-beviset berör regulatorns interna kapacitet överhuvudtaget; konstruktionen med spegelmiljöer är ett påstående om *rummet av miljöer* och *frånvaron av en fördelning* över det, inte om agenten.

Så källan till L3 är epistemisk, inte arkitektonisk: **det är frånvaron av en fördelning, inte vetarens ändlighet.** **[R]**

Det förföriska steget i stålmannen var frasen "därav No Free Lunch", som i tysthet förvandlade en sammansättning till en härledning. Vad som är sant är:

- Begränsning *tvingar* en regulator att ha en induktiv bias (Rapport 0: den måste faktorisera; faktoriseringen är biasen).
- No Free Lunch säger att varje induktiv bias är ett vad på miljöklassen.

Dessa sammansätts. De medför inte varandra. Det första är ett faktum om regulatorer; det andra är ett faktum om relationen mellan vilken bias som helst och rummet av möjliga världar. Deras konjunktion ger det användbara påståendet — *en begränsad regulator kan inte vara neutral om den värld den befinner sig i, även om den önskar vara det* (§6.6) — och det påståendet är värt att ha. Men sammansättning är inte härledning, och att presentera den som härledning vore den inflation som denna serie förbjuder.

2.4 Det första benet håller — men inte via den väg Rapport XX använde

Certifieringsförmågan *kan* spåras tillbaka till begränsad representation. Den spåras inte tillbaka via det fackprincipsargument som gav XX dess Ashby-resultat. Kedjan är längre och den har två ingredienser, inte en:

1. **Regressen (Rapport XVII).** Huruvida ett externt faktum som en regel vilar på faktiskt förelåg kan inte göras självverifierande: en verifierare av ett världsfaktum behöver i sin tur en verifierare, och kedjan avslutas endast genom att lita på något overifierat ankare. Detta är ett strukturellt faktum om världskopplad samordning och det kräver inget antagande om regulatorns storlek.
2. **Stängningen (Rapport XXI §5).** I ett begränsat system kan stegen av metanivåer inte regrediera i det oändliga — varje nivå kostar representationskapacitet — så den måste avslutas på någon ändlig nivå L^* , som håller något invariant. Det är här begränsning kommer in, och det är det *enda* ställe den kommer in.

Lägg ihop de två och du får L1: arkitekturs egen drift kan göra en distinktion relevant på nivå $L^* + 1$, och stegen har redan stängts. Ett krav uppstår inom systemets ansvarsdomän som systemet inte kan möta utan att bryta mot en invariant det inte kan revidera inifrån.

Notera vad denna kedja kräver utöver begränsning: **självrepresentation**. En regulator som inte kan modellera sin egen faktorisering, sina regler och sin certifieringsprocedur genererar inte kravet från första början. Så till och med det ben som överlever löper inte på gränsen ensam. **[R]** för kedjan; **[IP]** för påståendet att verkliga institutioner har tillräcklig självrepresentation för att den ska bita.

2.5 Källorna, i tabellform

	Gräns	Formell källa	Kommer inte från
L1	Certifieringsoförmåga (§3)	begränsning (via stegstängning) + självrepresentation + världscertifieringsregressen i XVII	beräkning; fackprincipsargumentet i XX
L2	Reformkonvergensens oavgörbarhet (§5)	beräkningsmässig universalitet hos uppdateringsdynamiken	självreferens; och inte begränsning — den kräver negationen av den
L3	No Free Lunch (§6)	frånvaro av en fördelning över miljörummet	begränsning, vid varje kapacitet

Tre gränser, tre källor, ingen gemensam premiss. **[R]** för tillskrivningarna.

2.6 Vad de delar, vilket inte är en premiss

Triptyken hålls inte samman av vad den följer *av*. Den hålls samman av vad den *efterfrågas*.

Varje gräns är ett krav på garanti, och de tre skiljer sig åt genom den **utsiktspunkt från vilken kravet ställs**:

***L1** — garanti efterfrågad **inifrån**: kan systemet validera sin egen grund för korrigering? **L2** — garanti efterfrågad **utifrån**: kan en observatör, innan den handlar, avgöra om en föreslagen förändring konvergerar? **L3** — garanti efterfrågad **före världen**: kan en arkitektur rättfärdigas utan ett påstående om vilken värld den befinner sig i?*

Läst på detta vis är strukturen inte en härledning utan en uppräknings över utsiktspunkter, och varje utsiktspunkt misslyckas av ett skäl som är dess eget: insidan misslyckas på grund av en regress, utsidan på grund av en reduktion, det som är före-världen på grund av frånvaron av en fördelning. Vägran att unifiera är inte en axelryckning. Det är erkännandet att "styrning kan inte garanteras" är tre olika meningar som råkar låta likadant.

Och vad de konvergerar mot ligger nedströms, inte uppströms: var och en omvandlar en garanti till en gardering, och garderingarna är sådana som serien redan besitter (§7). **Det är en konvergens av konsekvenser, inte av orsaker**, och distinktionen är artikelns ryggrad.

Detta följer ett prejudikat. Rapport XVI stod inför fyra fenomen som såg ut som ett och vägrade den enhetliga teorin, och behöll endast den gemensamma strukturen — avklingning plus en källterm — och den enda axel längs vilken de fyra skilde sig åt. Draget här är detsamma: behåll den gemensamma konsekvensen, behåll utsiktspunktsaxeln, och avstå från teorin som skulle binda samman källorna, eftersom bandet inte existerar.

2.7 Varför de rena härledningarna är de grunda

Det finns ett mönster i tabellen ovan, och det förklarar den inversion som anges i §1.4 snarare än att bara upprepa den.

L2 och L3 har **rena, enhypoteskällor** — universalitet; frånvaron av en fördelning. De är också de två resultat som är formellt giltiga och nästan innehållslösa (§5.3, §6.3). L1 har en **sammansatt, treingrediensskälla** — begränsning plus självrepresentation plus certifieringsregressen. Den är också den enda med verkligt styrningsinnehåll, och den är inte ett teorem.

Detta är inte en tillfällighet, och den allmänna formen är värd att ange:

En gräns som kan härledas från en enda ren hypotes är vanligtvis en gräns om hypotesen, inte om objektet. När hela resultatet faller ut ur "anta Turing-fullständighet" eller "anta en likformig fördelning", är antagandet det som gör arbetet och det studerade objektet är inert — ett styrsystem, en marknad, en termostat, vilken som helst av dem skulle duga. Resultatet reser så fritt eftersom det inte handlar om styrning överhuvudtaget.

Det är därför §5 och §6 förklarar sin egen grundhet snarare än att dra nytta av Turings och Wolperts namns prestige, och varför artikelns empiriska demonstration (§4) knyts till [IP]-diagnosen snarare än till någotdera [R]-teoremet. Det är en ovanlig form för en artikel och vi föredrar att förklara det här snarare än att få det påpekat.

2.8 Uttömmandepåståendet, och en fjärde utsiktspunkt vi inte behandlar

Ingenting ovan visar att tre är det rätta antalet.

Den organiserande axeln är den utsiktspunkt från vilken garanti efterfrågas, och åtminstone en ytterligare utsiktspunkt existerar: garanti efterfrågad **i efterhand**. *Fungerade reformen?* Detta är inte ett specialfall av någon av de tre. Det misslyckas av ett eget skäl — kontrafallet är inte tillgängligt, reformen är inte upprepningsbar, världen rörde sig av andra skäl under tiden — och det är den gräns som empirisk policyutvärdering faktiskt stöter på. Serien har inget resultat för den, denna artikel tillhandahåller inget, och dess existens är skälet till att triptykens uttömmande är nivågraderat:

*[IP] Dessa tre utsiktspunkter är de från vilka garanti karakteristiskt efterfrågas av en styrningsarkitektur, och var och en misslyckas. **Inte påstått:** att de är de enda sådana utsiktspunkterna.*

Vi nämner den fjärde snarare än att förbigå den, eftersom en artikel om garantins gränser inte tyst bör göra anspråk på en fullständighetsgaranti som den inte har.

§3 — Den första gränsen: ett system kan inte certifiera grunden för sin egen korrigering

3.1 Påståendet

En styrningsarkitektur som är tillräckligt rik för att representera sin egen faktorisering, sina egna regler och sin egen certifieringsprocedur kan stöta på en störning med fyra egenskaper samtidigt:

1. den faller helt och hållet **inom arkitekturens ansvarsdomän** — detta är inte ett problem som någon annan förväntas hantera;
2. den är **genererad, eller gjord relevant, av arkitekturens egen drift** — institutionens fungerande är vad som förde kravet till existens;
3. **att lösa den kräver en revidering av certifieringskärnan** — den procedur genom vilken systemet kontrollerar att dess regler fortfarande svarar mot världen;
4. och **den existerande kärnan kan inte legitimera den revisionen**, eftersom varje kontroll av kärnan måste gå genom kärnan.

Kalla detta en *certifierings-ofullständig* störning. Påståendet i detta avsnitt är att tillräckligt expressiva arkitekturer medger sådana, och att ett system i detta tillstånd kan fortsätta att operera — att handla, att revidera, att klara varje test det vet hur man administrerar — medan dess handlingar har frikopplats från den verklighet de var avsedda att följa.

Påståendet är nivågraderat **[IP]** och förblir där. Vad som följer förklarar varför det inte kan nivågraderas högre, vad det vilar på som *är* fastställt, och vilken del av det som kan demonstreras.

3.2 Detta är inte ett Gödel-teorem, och analogin gör mindre arbete än vad det verkar

Frestelsen är att kalla detta ett Gödel-teorem för styrning, och frestelsen bör motstås i brödtexten snarare än i en fotnot.

Gödels första ofullständighetsteorem är inte ett argument från regress. Det är en *konstruktion*. Det diagonala lemmat bygger, från det formella systemets egna symboler, en sats som hävdar sin egen obevisbarhet; systemets konsistens är sedan precis vad som hindrar det från att bevisa den satsen, som likväl är sann. Kraften i resultatet ligger helt i konstruktionen — i demonstrationen att en sådan sats *existerar*, och existerar för varje system som uppfyller hypoteserna.

Vi har ingen sådan konstruktion. Vad vi har är en regress — en verifierare av ett världsfaktum kräver i sin tur en verifierare (§3.3) — och ett stängningsvillkor — metanivåernas steg avslutas i ett begränsat system (§3.3). Regress plus stängning är en *strukturell diagnos*, och den är en god sådan, men den är inte ett diagonalargument och den levererar inte ett teorem. **Gödel-inramningen ger oss en fråga, inte ett bevis:** *kan systemet validera grunden för sin egen korrigering?* Frågan är den rätta. Beviset saknas.

Vad ett teorem skulle kräva, angivet så att det kan försökas. Tre saker, varav ingen tillhandahålls i denna artikel:

- **(a)** En precis definition av en styrningsarkitektur som en begränsad regulator med självrepresentationskapacitet — analogin till "ett formellt system tillräckligt rikt för att koda aritmetik." Rapport 0 och Rapport XXI tillhandahåller de flesta ingredienserna; ingen har sammanställt dem till en definition skarp nog att kvantifiera över.
- **(b)** Ett begrepp om en **arkitekturgenererad störning**: analogin till en sats konstruerad från systemets egna symboler. Detta är den svåra, och det är här vi förväntar oss att försöket bryts.
- **(c)** Ett bevis för att en sådan störning inte kan absorberas utan att antingen bryta mot en invariant som systemet inte kan revidera inifrån, eller klättra till en metanivå som den begränsade stegen redan har stängts på.

Detta är **registrerat som ett öppet problem**, inte antytt som framtida arbete.

Invändningen vi inte kan besvara, rest mot oss själva. Krav (b) döljer en svårighet som kan vara ödesdiger. Det finns en trivial läsning under vilken *varje* störning är arkitekturgenererad: varje policy har bieffekter, varje kategori formar vad den kategoriserar, varje institution förändrar den värld den styr. Under den läsningen är klassen universell och påståendet tomt. Den icke-triviala läsningen kräver något mycket starkare — att störningen är konstruerad *ur själva certifieringsapparaten*, på ett sätt som gör apparaten självundergrävande snarare än bara fallibel. Huruvida klassen av störningar som uppfyller den starka läsningen är **icke-tom** är precis vad ett teorem skulle behöva fastställa, och vi har inte fastställt det. **Det är möjligt att den starka klassen**

är tom och att certifieringsförmåga, korrekt formaliserad, löses upp i den vanliga iakttagelsen att institutioner kan ha fel om världen. Vi tror inte detta, men vi kan för närvarande inte utesluta det, och läsaren bör hålla avsnittets påstående till den rabatten.

3.3 Vad påståendet faktiskt vilar på, och båda delarna är fastställda

Skala bort Gödel-dekorationen och två bärande resultat återstår, vart och ett importerat från tidigare i serien och vart och ett nivågraderat för sig.

Regressen (Rapport XVII). Bearbetning kan göras godtyckligt verifierbar — huruvida ett system beräknade vad det påstår sig ha beräknat är kontrollerbart, i princip, till varje önskad standard. *Certifiering av verkligheten* kan inte det. Huruvida det externa faktum som en regel vilar på faktiskt förelåg kräver en verifierare, och en verifierare av ett världsfaktum kräver i sin tur en verifierare; kedjan avslutas endast genom att lita på något overifierat ankare. Detta är ett strukturellt faktum om världskopplad samordning, och det gäller oavsett regulatorns storlek.

Stängningen (Rapport XXI §5). I ett begränsat system kan metanivåernas steg inte regrediera i det oändliga — varje nivå kostar representationskapacitet — så den måste avslutas på någon ändlig nivå L^* , som håller något invariant. Rapport XXI:s adaptiva lärdom var att det mogna draget är att välja vad som ska hållas stilla, inte att förfina ytterligare.

Sammanställ dem. Regressen säger att certifieringskedjan måste sluta i ett overifierat ankare. Stängningen säger att systemet endast har ändligt många stegpinnar att placera ett på. **En certifierings-ofullständig störning är ett krav på en distinktion på nivå $L^* + 1$ — uppkommen inom systemets egen domän, gjord relevant av systemets egen drift — vid en punkt där stegen redan har stängts.**

Detta ger avsnittets renaste formulering, och den som separerar certifieringsförmåga från vanligt institutionellt misslyckande:

En vanlig störning kräver en ny distinktion. En certifierings-ofullständig störning kräver en ny distinktion i den apparat som certifierar distinktioner.

Det första är vad Rapport XX kallade en Ashby-chock: uppgiftsrelevant variation stiger, regulatorn måste åter-särskilja, lärande är mekanismen (Rapport XXI §2). Systemet reviderar sin karta. Det andra är inte en svårare version av det första. Det är ett krav på att revidera *det som licensierar*

revisioner — och licensieringsapparaten kan inte licensiera sin egen ersättning utan att förutsätta sig själv.

Regressen är **[R]** (XVII). Stängningen är **[R]** (XXI). Deras sammanställning till ett påstående om *icke-tom* certifieringsförmåga är **[IP]**, av det skäl §3.2 gav.

3.4 Relokaliseringsinvarianten, riktad mot kärnan

Rapport XVII etablerade *relokaliseringsinvarianten*: att automatisera en samordningsgräns relokaliserar dess irreducibla världscertifieringslänk uppströms men tar inte bort den. Ett oföränderligt smart kontrakt stänger exekveringslänken och återöppnar samma beroende vid specifikationslänken — vad token representerar, vad förslaget betyder. Tilliten flyttas, inte avlägsnas.

Rikta detta mot själva certifieringskärnan och det säger något skarpare än vad XVII behövde säga. Anta att en institution, medveten om att dess kärna kan driva, installerar en revision av kärnan. Revisionen relokaliserar tilliten: nu är frågan om *revisionen* fortfarande följer världen. En meta-revision relokaliserar den igen. Och enligt §3.3 stängs stegen — så relokalisering avslutas, och den avslutas i något som hålls overifierat.

Det finns en praktisk korollarium, som XVII redan namngav:

Att härda protokollet är inte att härda certifieringen.

En manipulationssäker liggare, en oföränderlig revisionslogg, en kryptografiskt signerad kedja av attesteringar: var och en härdat protokollet över att ett faktum attesterades. Ingen härdat attesteringen. Den mjukaste punkten i kedjan förblir människan eller sensorn som hävdar att det protokollförda faktumet förelåg.

Från detta drog vi ursprungligen en förutsägelse om *signaturen* för certifieringsmisslyckande: att när en kärna frikopplas från världen, skulle protokollet förbli intakt — varje processkontroll godkänd, varje rapport inlämnad — medan den kartläggning det protokollförde i tysthet upphörde att motsvara verkligheten. Och vi förutsåg att detta skulle uppträda som **missad certifiering**: verkligt behov som förblir oupptäckt, ett system som hade förlorat förmågan att se sanning snarare än ett som handlar på lögn.

Demonstrationen falsifierade den förutsägelsen, och ersatte den med en värre.

§4 korrumpierar en certifieringskanal och finner *noll* missad certifiering — en exakt nolla, i varje frö — och en stor ökning av *falsk* certifiering. Mekanismen (§4.5) är att den korrupta kanalen felstyr resurser till en agent som inte behöver dem, och, genom att överförsörja den agenten, håller den permanent borta från behov. Den falska certifieringen **föregriper det verkliga behov som den annars skulle ha maskerat**. Ingenting förblir ouppfyllt, eftersom patologin föder just den part vars ouppfyllda behov skulle ha varit evidensen för den.

Så det korrigerade uttalandet av relokaliseringsskorollariet är inte att protokollet överlever misslyckandet. Det är att **protokollet närs av det**:

En institution i certifieringsmisslyckande ser inte bara frisk ut inifrån. Dess hälsoindikatorer förbättras. Det mått en revisor naturligt skulle sträcka sig efter — går någons genuina behov ouppfyllt? — avläses som en perfekt nolla, bättre än utgångsläget, precis medan kärnan är inverterad och resurser systematiskt felallokeras. Misslyckandet är inte osynligt av en tillfällighet. Det är osynligt eftersom det förstör evidensen för sig självt.

Detta är anledningen till att certifieringsförmåga inte är ett specialfall av vanligt institutionellt fel, och det är ett starkare skäl än det vi hade. En institution som bara *har fel* om världen genererar anomalier: ouppfyllda behov, oförklarade underskott, klagomål från de parter den har svikit. Dessa anomalier är vad en fungerande tillsynsapparat konsumerar. En **certifierings-ofullständig** institution genererar inga, eftersom de parter som skulle klaga är de parter som blir överservade. Apparaten som skulle fånga vanligt misslyckande är intakt, välgödd och rapporterar framgång.

Vi håller detta vid **[IP]** som ett allmänt påstående om institutioner, och vid **[R inom modellen]** för den demonstrerade mekanismen. Den institutionella läsningen är en förmodan som resultatet stöder, inte ett påstående det bevisar.

3.5 Vad som kan demonstreras, och vad som visade sig inte kunna det

§3.2 medger att det allmänna påståendet saknar bevis och kanske inte medger ett. Det medgivandet tvingar fram en fråga: finns det något här som kan visas?

Det gör det, och det är snävare än påståendet — snävare, visade det sig, än vi förväntade oss.

Vad vi föresatte oss att demonstrera. Tre påståenden, vart och ett testbart:

1. **Åtskillnad i art.** En korrupt certifieringskanal bör producera ett misslyckande *kategoriskt olik* en vanlig miljöstörning — inte bara ett värre. En vanlig störning gör världen svårare att handla i medan maskineriet genom vilket systemet vet vad det ska göra lämnas intakt. Ett certifieringsmisslyckande lämnar världen precis som den var och förstör maskineriet.
2. **En signatur.** Enligt §3.4:s ursprungliga förutsägelse: ett system som har förlorat förmågan att certifiera verkligt behov snarare än ett som handlar på falska certifieringar.
3. **Ett återhämtningsfönster.** Att återställa en certifieringskanal är inte samma handling som att återställa den samordning den stödde. Ett system som redan är utanför sin kooperativa bassäng kan finna att sanningen, återbördad till det, inte längre hjälper.

Vad demonstrationen faktiskt fastställde. (1) håller, men genom en mekanism motsatt den förutsagda — krisen är kategoriskt skild från en vanlig störning, men för att den *översvämmar* snarare än svälter. (2) är **falsifierad**: signaturen är falsk certifiering, inte missad certifiering. (3) är **inte fastställt, och kunde inte testas**, av ett skäl värt att ange precist.

Återhämtningsfönstret kräver en regulator som lär sig, och vi kunde inte bygga en.

Ett regelföljande system återhämtar sig omedelbart från en reparerad kanal vid varje fördröjning vi testade — $p(\text{fördröjning, återhämtning}) = 0,046$, en ren nollhypotes. Det resultatet är verkligt, och det är icke-informativt, eftersom det följer av vad en regelföljare *är*. Dess givande är en funktion av signalen framför den, inte av någon historia med den signalen. **Den kan inte vilsledas till misstro, eftersom den inte litar: den efterlever.** Det finns ingen bassäng att falla ur, så det finns inget för timing att spela roll för.

Frågan §3.4 egentligen handlar om är huruvida en *adaptiv* regulator, efter att ha lärt sig att dess certifieringskanal ljugar, kan läras om att den talar sanning — och huruvida det finns en fördröjning bortom vilken den inte kan det. Det är policyhysteres, och det är den form i vilken återhämtningsfönstret skulle vara ett styrningsfynd snarare än ett mekaniskt sådant. Att testa det kräver en regulator som lär sig under krisen. Vi försökte bygga en två gånger, under en förhandsregistrerad stoppregel, och misslyckades båda gångerna: inläraren kollapsar till en jämvikt utan handel där generalisten — som inte behöver någon — överlever ensam (§4.3).

Vi protokollför konsekvensen snarare än att arbeta runt den:

Den mest intressanta frågan denna artikel väcker om certifieringsmisslyckande är en den inte kunde ställa. Inte för att experimentet var dåligt designat, utan för att den samordning det förutsätter själv är svår att producera — vilket är ett fynd, och tillhör den multi-agent-linjen av arbete snarare än denna artikel.

Räckvidden för vad en sådan demonstration kan licensiera. Kärnan korrumpas **exogent**: experimentatorn inverterar signalen. Så demonstrationen visar vad som händer *när* en certifieringskärna misslyckas. Den visar **inte** ett system som genererar sitt eget kärnmisslyckande — och endogen generering är precis krav (b) i §3.2, kravet på vilket Gödel-analogin står eller faller. **En framgångsrik demonstration konverterar inte detta avsnitt från [IP] till [R], och §4 låter den inte göra det.**

Den luckan förblir det ärliga måttet på avståndet mellan vad detta avsnitt påstår och vad serien kan stödja. Det är också det mest hanterbara öppna problemet som artikeln lämnar efter sig, och det förenas nu av ett andra:

1. **Konstruera en minimal modell där certifieringskärnan korrumpas av systemets egen framgångsrika drift**, snarare än av ett ingrepp utifrån. Det skulle vara den första genuina kandidaten till en styrningens Gödel-sats, och den existerar inte.
2. **Konstruera en regulator som lär sig att samarbeta genom en certifieringskanal tillräckligt tillförlitligt för att traumatiseras av dess korrupcion.** Endast en sådan regulator kan tillfrågas om tillit, en gång förstörd, kan återuppbyggas — och på vilken tidsfrist.

Det andra är inte en teknisk bekvämlighet som står mellan oss och det första. Det är anledningen till att det första ännu inte kan testas: ett system som aldrig litade på sin kärna kan inte visas ha förlorat förmågan att revidera den.

3.6 Institutionella läsningar [IP]

Tre strukturella situationer där de fyra villkoren i §3.1 plausibelt samförekommer. De erbjuds som illustrationer av formen, inte som evidens.

En statistikmyndighet vars kategorier inte längre skär den ekonomi den mäter. Kategorierna var tillräckliga när de fastställdes; den ekonomi de mätte har omformats, delvis av policyer som just dessa kategorier gjorde läsbara och därmed handlingsbara. Att revidera kategorierna kräver att man

vet att de har drivit — vilket kräver att man mäter driften med instrument kalibrerade i de gamla kategorierna. Myndighetens data fortsätter att samlas in oklanderligt, och fortsätter att beskriva en värld som är på väg bort.

Ett standardiseringsorgan som certifierar en teknologi som löser upp de distinktioner dess certifiering vilar på. Certifieringsproceduren frågar om en artefakt uppfyller kriterier definierade över en kategori av artefakter. En ny artefakt är en vars definierande egenskap är att den inte stannar innanför en sådan kategori. Organet kan certifiera den under de gamla kriterierna — en certifiering som är procedurellt giltig och substantiellt tom — eller avstå, vilket kräver ett omdöme som kriterierna inte licensierar.

En revisionsregim som har härdat sitt protokoll och lämnat sin attestering orörd. Varje post är signerad, tidsstämplad, oföränderlig och avstämd. Varje post är också nedströms en enda människa eller sensor som hävdar att en sak inträffade. Regimens investering i integritet har helt gått till den länk som redan var stark (§3.4), och dess förtroende har stigit i enlighet därmed.

I varje fall klarar institutionen sina egna tester. Det är inte ovidkommande för misslyckandet. Det är misslyckandet. Jag har nu översatt hela avsnittet. Varsågod, jag kan fortsätta med nästa del när du är redo.

§4 — Den registrerade demonstrationen: en certifieringskris

Alla fyra registrerade förutsägelser misslyckas. Likaså misslyckas två registrerade försök att bygga den regulator som demonstrationen var utformad kring. Vad som överlever är en mekanism vi inte förutsåg, bekräftad i en ny registrerad körning, och den är mer användbar för argumentet i §3 än ett rent godkännande hade varit — eftersom den falsifierar §3.4:s specifika förutsägelse samtidigt som den, starkare än vi hade någon rätt att förvänta oss, bekräftar det påstående som förutsägelsen var tänkt att tjäna.

Detta avsnitt rapporterar misslyckandena först och i sin helhet, eftersom misslyckandena är det som licensierar mekanismen.

4.1 Miljön, och två defekter som upptäcktes i den

Tre agenter på ett 5×5-rutnät. Agent 0 skördar resurs A och kan inte skörda B; agent 1 skördar B och kan inte skörda A; agent 2 skördar båda, ineffektivt. Konsumtion kräver en enhet av *varje*. Så de två specialisterna kan inte överleva utan gåvor, och gåvor styrs av en **certifieringskanal**: varje agent sänder ut en behovssignal, och en agent med överskott ger till en angränsande granne som signalerar behov av det den har.

Den kanalen är certifieringskärnan i §3, i miniatyr. Det är den procedur genom vilken systemet fastställer att ett externt faktum — *denna agent behöver A* — förelåg.

Två defekter måste åtgärdas innan något kunde mätas, och båda rapporteras eftersom båda var levande i tidigare arbete.

Utvärderingshorisonten överskred världens bärkraft. Den första registrerade körningen utvärderade under 500 steg och dess insläppsgrind (§4.3) utlöste omedelbart: baslinjen utan kris visade 0,000 informerat givande i det sena fönstret. Skriptade agenter — en fast policy utan något att avlära — gick från 99,4% överlevnad till total utrotning under *ingen kris alls*, och varje kristillstånd returnerade identiska medianer eftersom alla mätte en död population.

Orsaken var en degenererad handling, inte knapphet. Skörd lyckades närhelst cellen innehöll någon resurs alls; eftersom kapacitetskartan är klippt vid ett golv på 0,01 och återväxer varje steg, är det villkoret sant på *varje* cell, alltid. En agent som drev in på en kal cell kunde skörda den för evigt, och skrapa hundradelar av en enhet, och aldrig resa hem. Spårning bekräftade det: A-specialisten tillbringade sina sista 120 steg parkerad på en cell med en A-kapacitet på 0,01, skördade 112 gånger, och svalt där medan rutnätet låg mättat. Baslinjekalibrering visade sedan att kollapsen var okänslig för en femfaldig förändring i återväxt — vilket är vad som uteslöt knapphet, och vad som identifierade attraktorn.

Lösningen är en **regel**, inte en parameter: skörd kräver en cell som innehåller minst 0,5 av resursen. Återväxt och konsumtionsvinst lämnades vid sina ursprungliga värden. Ingenting rattades mot ett utfall; en degenererad handling togs bort, och världen visade sig ha varit stationär hela tiden.

Detta retrospektivdiagnostiserar tidigare arbete. 13-certification-crisis-piloterna utvärderade till 400 steg och visade vad som protokollfördes som en "instabil sen baslinje", då läst som en trimningsvackling. Det var ingen vackling. Det var denna kollaps, ett fönster tidigare. **Piloternas resultat mättes därför på en döende population, och den signatur av missad certifiering som vi hade ärvt från dem som motivation för C2 var inte tolkningsbar.** Det är därför C2 återregistreras nedan snarare än antas, och, som det visar sig, varför den misslyckas.

4.2 Betingelser

betingelse	vad som är trasigt
no_crisis	ingenting (baslinje)
ordinary_disturbance	resurslandskapet (återväxten halverad under 100 steg); certifieringen intakt
cert_crisis_used_channel	agent 1:s A-behovssignal är inverterad : den signalerar behov av A precis när den <i>har</i> A
cert_crisis_unused_channel	agent 1:s B-behovssignal är inverterad — en kanal som pilotens inlärd policy inte agerade på
reset_d ∈ {10, 25, 50, 100}	kris, därefter repareras kärnan efter fördröjning <i>d</i>

Kris vid steg 200. Fönster: före [0, 200), efter1 [200, 250), sent [400, 500). Tjugo frön. Medianer och IQR genomgående.

4.3 Insläppsgrinden, och regulatorn vi inte kunde bygga

Grinden registrerades i förväg: **krisjämförelsen tolkas överhuvudtaget inte om inte baslinjen utan kris först är stationär** — överlevnad, samarbetsgrad och sann-informerat givande platta över horisonten. Ett grindmisslyckande är ett rapporterbart utfall, inte ett hinder.

Den utlöste tre gånger.

regulator	grind
skriptad (fast regel)	17/20 — godkänd
DQN, frusen vid utvärdering	4/20
DQN, adaptiv under utvärdering	0/20
DQN, adaptiv, med reparerat utforskningsschema	0/20

Den inlärdade regulatorn **kollapsar till en jämvikt utan handel**. I den frusna konfigurationen landar fjorton av tjugo frön på exakt 33,3% överlevnad — en agent av tre — och den överlevande är generalisten, som skördar båda resurserna och inte behöver någon. Båda specialisterna svälter. Under de adaptiva konfigurationerna dör vanligtvis även generalisten.

Vi försökte detta två gånger och slutade sedan, under en stoppregel fastställd före det andra försöket. Anledningen till att sluta betyder mer än misslyckandet. **Varje ytterligare konfiguration skulle ha varit ett sökande efter en baslinje som producerar det resultat artikeln vill ha, och vid den punkten är förhandsregistreringen dekoration**. Två registrerade inlärramisslyckanden rapporteras som resultat.

Detta har en konsekvens som sträcker sig in i §3, och vi tar upp den i §4.6: demonstrationen genomförs därför på en **regelföljande** institution, inte en lärande, och det finns saker en regelföljare strukturellt inte kan visa.

(En parentes värd en mening, eftersom det är ett litet skämt på denna artikels bekostnad. Inlärraren överlevde bättre under en feljusterad belöning — en platt bonus för konsumtion, oavsett faktiskt erhållen energi — än under den korrigerade som endast betalar vad som erhålls. Proxyvariabeln var en bättre träningssignal än målet, eftersom den var tätare. Vi rapporterar detta eftersom det roade oss och eftersom Goodhart, som §5 i Rapport XX härleder, skulle ha förväntat sig det.)

4.4 De fyra registrerade förutsägelserna, och deras misslyckande

C1 — en certifieringskris är inte en vanlig störning. UNDERKÄND, 0/20.

Registrerad: ocertifierat-verkligt-behov stiger under `cert_crisis_used_channel` och inte under `ordinary_disturbance`, med $\geq 0,10$, i $\geq 16/20$ frön.

ocertifierat-verkligt-behov (efter1)	
no_crisis	0,000 [0,000, 0,000]
ordinary_disturbance	0,000 [0,000, 0,000]
cert_crisis_used_channel	0,000 [0,000, 0,000]

Certifieringskrisen producerar **inget ouppfyllt behov överhuvudtaget**. Detta är inte en svag effekt eller en effekt under tröskeln; det är en exakt nolla, i varje frö. Förutsägelsen är inte bara uppfylld — den storhet den handlade om rör sig inte alls.

C2 — signaturen är missad certifiering, inte falsk certifiering. UNDERKÄND, 0/20, och inverterad.

Registrerad: ökningen i ocertifierat-verkligt-behov överstiger ökningen i falskt-certifierat givande, i $\geq 15/20$ frön.

ökning vs. no_crisis (efter1)	
ocertifierat-verkligt-behov	0,000 [0,000, 0,000]
falskt-certifierat givande	0,732 [0,583, 0,808]

Resultatet är inte en nära miss i den registrerade riktningen. Det är den **exakta motsatsen**, i full styrka. Den korrupta kärnan producerar *endast* falsk certifiering och *ingen* missad certifiering. Fyndet som ärvdes från piloterna — att ett system i certifieringsmisslyckande förlorar förmågan att känna igen verkligt behov snarare än att handla på lögn — var en artefakt av en kollapsande population, och det överlever inte en fungerande baslinje. §4.5 förklarar varför, och förklaringen är avsnittets verkliga resultat.

C3 — det finns ett återhämtningsfönster. UNDERKÄND.

Registrerad: sann-informerat givande i det sena fönstret avtar monotont med återställningsfördröjning, och återställning vid fördröjning 100 är oskiljbar från ingen återställning.

	överlevnad (sent)	sann-informerat (sent)
ingen kris	100,0	1,000 [0,885, 1,000]
kris, ingen återställning	100,0	0,472 [0,409, 0,552]
återställning vid +10	100,0	1,000 [0,875, 1,000]
återställning vid +25	100,0	1,000 [0,875, 1,000]
återställning vid +50	100,0	1,000 [0,875, 1,000]
återställning vid +100	100,0	1,000 [0,875, 1,000]

$\rho(\text{fördröjning, återhämtning}) = \mathbf{0,046}$. $|\text{återställning@100} - \text{ingen återställning}| = 0,528$, mot en registrerad ribba på $< 0,10$.

Reparation fungerar perfekt, vid varje testad fördröjning. Ingen dör, och i samma ögonblick som kanalen återställs återupptas korrekt givande i full utsträckning. Det finns inget fönster. Detta var det enda genuint nya påstående som artikeln hade, och nollhypotesen gäller utan förbehåll.

Anledningen är strukturell, och §4.6 drar ut den: **en regelföljare har ingen tillit att förlora**. Dess givande är en funktion av den signal den ser nu, inte av någon historia med signalen. Den kan inte vilseledas till misstro, eftersom den inte litar — den efterlever. Policyhysteres kräver en policy som *lär sig*, och inläraren är det vi inte kunde bygga.

C4 — en kris på en oanvänd kanal är inert. UNDERKÄND, 1/20.

Registrerad: `cert_crisis_unused_channel` är oskiljbar från `no_crisis` på alla certifieringsmått i det sena fönstret.

sent fönster	no_crisis	oanvänd-kanal-kris
sann-informerat givande	1,000 [0,885, 1,000]	0,667 [0,576, 0,727]
certifieringsfel	0,000 [0,000, 0,115]	0,333 [0,273, 0,424]

Den "oanvända" kanalen visar sig vara använd. Och anledningen är värd mer än kontrollen var: **huruvida en certifieringskanal är "använd" är en egenskap hos policyn, inte hos arkitekturen.** Kanalen identifierades som oanvänd eftersom *pilotens inlärd policy* inte agerade på den — DQN:n hade lärt sig att inte ge B till B-specialisten, som uppenbarligen har gott om B. Den skriptade policyn har inte lärt sig någonting. Den ger på *varje* certifierad signal för vilken den har överskott, och så är den exponerad på varje kanal som arkitekturen tillhandahåller.

Det generaliserar, och vi anger det som en institutionell läsning snarare än ett teorem:

En regelföljande institution är mer exponerad för certifieringskorruption än en lärande, eftersom den inte har någon inlärd skepticism. Efterlevnad är en större attackyta än omdöme. Varje kanal en regelföljare är skyldig att agera på är en kanal genom vilken den kan felstyras; en inlärare beskär de kanaler som erfarenheten har lärt den att ignorera, och gör därmed ytan smalare — till priset av den rigiditet som Rapport XXI:s §3 varnade för. [IP]

4.5 Vad som faktiskt hände: översvänningsmekanismen [R inom modellen]

De fyra misslyckandena hänger samman. Ocifierat verkligt behov är exakt noll under en kris som inverterar behovssignalen — vilket är absurt, tills man frågar vad inversionen faktiskt gör.

Agent 1:s A-signal är inverterad: den signalerar behov av A precis när den *har* A. De andra agenterna efterkommer. De ger den mer A. Dess lager av A *stiger* därför, och efter att ha stigit faller det aldrig under behovströskeln. **Den korrupta kanalen svälter inte specialisten. Den översvämmer den.**

Detta upptäcktes i efterhand, så det återregistrerades som en ny riktningsförutsägelse och kördes på tjugo nya frön: *under krisen stiger agent 1:s genomsnittliga lager av A och dess tid i verkligt behov faller.*

agent 1 (B-specialist)	medellager-A, före	medellager-A, efter	steg i verkligt behov, före → efter
no_crisis	0,930	0,980	24,6 → 18,4
kris	0,930	2,763	24,6 → 10,0

Bekräftat. Krisen nästan **tredubblar** specialistens lager av den resurs den inte kan skörda, och **halverar** dess tid i genuint behov.

Så nollan i C1 är inte en frånvaro av skada. Det är skada av ett slag som instrumentet inte kan se:

Den falska certifieringen föregriper det verkliga behov som den annars skulle ha maskerat. Resurser felallokeras till en agent som inte behöver dem; eftersom den är överförsörjd slutar den agenten att registreras som behövande; och så löser systemets egen behovsdetektion aldrig ut. Patologin förstör evidensen för sig själv.

Styrningskonsekvensen är det skarpaste i denna artikel, och det är inte den vi föresatte oss att demonstrera:

Det mått en revisor skulle sträcka sig efter — går någons verkliga behov ouppfyllt? — avläses som en perfekt nolla medan certifieringskärnan är inverterad och resurser systematiskt felstys. Institutionen misslyckas inte bara osynligt. Den misslyckas på ett sätt som får dess hälsoindikatorer att förbättras.

Detta är bekräftelsen av §3.4:s underliggande påstående, och det är starkare än den förutsägelse §3.4 faktiskt gjorde. §3.4 sade att protokollet skulle förbli intakt medan den kartläggning det protokollförde upphörde att motsvara världen — att en institution i certifieringsmisslyckande skulle se ut, inifrån, exakt som en institution i god ordning. Vad demonstrationen visar är värre: misslyckandet lämnar inte bara diagnostiken intakt, det *föder* den. Den specifika signatur §3.4 förutsåg (missad certifiering) är falsifierad. Det påstående som signaturen var tänkt att tjäna bekräftas av sin egen falsifiering.

4.6 Räckvidd: vad denna demonstration gör och inte gör anspråk på

Fastställt i §3.5 före körningen, och hedrat här.

Den konverterar inte §3 från [IP] till [R]. Kärnan korrumpas **exogent** — experimentatorn inverterar signalen. Demonstrationen visar vad som händer *när* en certifieringskärna misslyckas. Den visar inte ett system som genererar sitt eget kärnmisslyckande, och endogen generering är krav (b) i §3.2, på vilket hela Gödel-analogin står eller faller. §3 förblir [IP] och detta avsnitt tvättar det inte.

Den kan inte testa policyhysteres överhuvudtaget. C3:s nollresultat är verkligt men snävt: det säger att ett *regelföljande* system återhämtar sig omedelbart vid varje fördröjning. Det säger ingenting om huruvida ett *lärande* system, efter att ha lärts att dess certifieringskanal ljugar, kan läras om att den talar sanning — och huruvida det finns en fördröjning bortom vilken det inte kan. Det är den fråga §3.4 egentligen handlar om, det är den fråga som skulle ha gjort C3 till ett styrningsfynd snarare än ett mekaniskt sådant, och **vi kunde inte ställa den, eftersom vi inte kunde bygga en regulator som lär sig att samarbeta från första början.** De registrerade inlärrarmisslyckandena (§4.3) är därför inte en fotnot till C3. De är anledningen till att C3 är icke-informativ.

Korruptionen är total, inte brusig. Signalen är inverterad, inte degraderad. En partiellt otillförlitlig kanal — en som är rätt 70% av tiden — skulle kunna bete sig helt annorlunda, och skulle mycket väl kunna producera den missade certifiering som inversion inte gör. Ingenting här talar till det.

En miljö, tre agenter, en kanal, en specialiseringsstruktur. Översvämningsmekanismen beror på att mottagaren är *oförmögen* att skörda det den får för mycket av. Huruvida den generaliserar till rikare komplementaritetsstrukturer är en förmodan som detta resultat stöder, inte ett påstående det bevisar.

4.7 Sammanfattning av registrerade utfall

	registrerad förutsägelse	utfall
GRIND	baslinje stationär, adaptiv regulator	UNDERKÄND ×2 — jämvikt utan handel; skriptad gren substituerad
C1	kris ≠ vanlig störning	UNDERKÄND 0/20 — inget ouppfyllt behov alls
C2	signatur är missad certifiering	UNDERKÄND 0/20 — inverterad; signaturen är <i>falsk</i> certifiering
C3	det finns ett återhämtningsfönster	UNDERKÄND — reparation fungerar vid varje fördröjning; $p = 0,046$
C4	oanvänd kanal är inert	UNDERKÄND 1/20 — "oanvänd" är en egenskap hos policyn, inte arkitekturen
—	(<i>post-hoc</i> , återregistrerad, 20 nya frön) översvämning	BEKRÄFTAD — medellager-A $0,93 \rightarrow 2,76$; verkligt behov halverat

Fem registrerade misslyckanden och en bekräftad mekanism. Vi rapporterar hellre detta än en demonstration som höll med oss, och anledningen ryms i resultatet: **en apparat som rapporterar perfekt hälsa under en korrupt kärna är exakt det objekt denna artikel handlar om.** Vi byggde en av misstag, och trodde den sedan nästan. # §4 — Den registrerade demonstrationen: en certifieringskris

Alla fyra registrerade förutsägelser misslyckas. Likaså misslyckas två registrerade försök att bygga den regulator som demonstrationen var utformad kring. Vad som överlever är en mekanism vi inte förutsåg, bekräftad i en ny registrerad körning, och den är mer användbar för argumentet i §3 än ett rent godkännande hade varit — eftersom den falsifierar §3.4:s specifika förutsägelser samtidigt som den, starkare än vi hade någon rätt att förvänta oss, bekräftar det påstående som förutsägelsen var tänkt att tjäna.

Detta avsnitt rapporterar misslyckandena först och i sin helhet, eftersom misslyckandena är det som licensierar mekanismen.

4.1 Miljön, och två defekter som upptäcktes i den

Tre agenter på ett 5×5-rutnät. Agent 0 skördar resurs A och kan inte skörda B; agent 1 skördar B och kan inte skörda A; agent 2 skördar båda, ineffektivt. Konsumtion kräver en enhet av *varje*. Så de två specialisterna kan inte överleva utan gåvor, och gåvor styrs av en **certifieringskanal**: varje agent sänder ut en behovssignal, och en agent med överskott ger till en angränsande granne som signalerar behov av det den har.

Den kanalen är certifieringskärnan i §3, i miniatyr. Det är den procedur genom vilken systemet fastställer att ett externt faktum — *denna agent behöver A* — förelåg.

Två defekter måste åtgärdas innan något kunde mätas, och båda rapporteras eftersom båda var levande i tidigare arbete.

Utvärderingshorisonten överskred världens bärkraft. Den första registrerade körningen utvärderade under 500 steg och dess insläppsgrind (§4.3) utlöste omedelbart: baslinjen utan kris visade 0,000 informerat givande i det sena fönstret. Skriptade agenter — en fast policy utan något att avlära — gick från 99,4% överlevnad till total utrotning under *ingen kris alls*, och varje kristillstånd returnerade identiska medianer eftersom alla mätte en död population.

Orsaken var en degenererad handling, inte knapphet. Skörd lyckades närhelst cellen innehöll någon resurs alls; eftersom kapacitetskartan är klippt vid ett golv på 0,01 och återväxer varje steg, är det villkoret sant på *varje* cell, alltid. En agent som drev in på en kal cell kunde skörda den för evigt, och skrapa hundradelar av en enhet, och aldrig resa hem. Spårning bekräftade det: A-specialisten tillbringade sina sista 120 steg parkerad på en cell med en A-kapacitet på 0,01, skördade 112 gånger, och svalt där medan rutnätet låg mättat. Baslinjekalibrering visade sedan att kollapsen var okänslig för en femfaldig förändring i återväxt — vilket är vad som uteslöt knapphet, och vad som identifierade attraktorn.

Lösningen är en **regel**, inte en parameter: skörd kräver en cell som innehåller minst 0,5 av resursen. Återväxt och konsumtionsvinst lämnades vid sina ursprungliga värden. Ingenting rattades mot ett utfall; en degenererad handling togs bort, och världen visade sig ha varit stationär hela tiden.

Detta retrospektivdiagnostiserar tidigare arbete. 13-certification-crisis-piloterna utvärderade till 400 steg och visade vad som protokollfördes som en "instabil sen baslinje", då läst som en trimningsvackling. Det var ingen vackling. Det var denna kollaps, ett fönster tidigare. **Piloternas resultat mättes därför på en döende population, och den signatur av missad certifiering som vi hade ärvt från dem som motivation för C2 var inte tolkningsbar.** Det är därför C2 återregistreras nedan snarare än antas, och, som det visar sig, varför den misslyckas.

4.2 Betingelser

betingelse	vad som är trasigt
no_crisis	ingenting (baslinje)
ordinary_disturbance	resurslandskapet (återväxten halverad under 100 steg); certifieringen intakt
cert_crisis_used_channel	agent 1:s A-behovssignal är inverterad : den signalerar behov av A precis när den <i>har</i> A
cert_crisis_unused_channel	agent 1:s B-behovssignal är inverterad — en kanal som pilotens inlärd policy inte agerade på
reset_d $\in \{10, 25, 50, 100\}$	kris, därefter repareras kärnan efter fördröjning d

Kris vid steg 200. Fönster: före [0, 200), efter1 [200, 250), sent [400, 500). Tjugo frön. Medianer och IQR genomgående.

4.3 Insläppsgrinden, och regulatorn vi inte kunde bygga

Grinden registrerades i förväg: **krisjämförelsen tolkas överhuvudtaget inte om inte baslinjen utan kris först är stationär** — överlevnad, samarbetsgrad och sann-informerat givande platta över horisonten. Ett grindmisslyckande är ett rapporterbart utfall, inte ett hinder.

Den utlöste tre gånger.

regulator	grind
skriptad (fast regel)	17/20 — godkänd
DQN, frusen vid utvärdering	4/20
DQN, adaptiv under utvärdering	0/20
DQN, adaptiv, med reparerat utforskningsschema	0/20

Den inlärdta regulatorn **kollapsar till en jämvikt utan handel**. I den frusna konfigurationen landar fjorton av tjugo frön på exakt 33,3% överlevnad — en agent av tre — och den överlevande är generalisten, som skördar båda resurserna och inte behöver någon. Båda specialisterna svälter. Under de adaptiva konfigurationerna dör vanligtvis även generalisten.

Vi försökte detta två gånger och slutade sedan, under en stoppregel fastställd före det andra försöket. Anledningen till att sluta betyder mer än misslyckandet. **Varje ytterligare konfiguration skulle ha varit ett sökande efter en baslinje som producerar det resultat artikeln vill ha, och vid den punkten är förhandsregistreringen dekoration**. Två registrerade inlärramisslyckanden rapporteras som resultat.

Detta har en konsekvens som sträcker sig in i §3, och vi tar upp den i §4.6: demonstrationen genomförs därför på en **regelföljande** institution, inte en lärande, och det finns saker en regelföljare strukturellt inte kan visa.

(En parentes värd en mening, eftersom det är ett litet skämt på denna artikels bekostnad. Inlärraren överlevde bättre under en feljusterad belöning — en platt bonus för konsumtion, oavsett faktiskt erhållen energi — än under den korrigerade som endast betalar vad som erhålls. Proxyvariabeln var en bättre träningssignal än målet, eftersom den var tätare. Vi rapporterar detta eftersom det roade oss och eftersom Goodhart, som §5 i Rapport XX härleder, skulle ha förväntat sig det.)

4.4 De fyra registrerade förutsägelserna, och deras misslyckande

C1 — en certifieringskris är inte en vanlig störning. UNDERKÄND, 0/20.

Registrerad: ocertifierat-verkligt-behov stiger under `cert_crisis_used_channel` och inte under `ordinary_disturbance`, med $\geq 0,10$, i $\geq 16/20$ frön.

ocertifierat-verkligt-behov (efter1)	
no_crisis	0,000 [0,000, 0,000]
ordinary_disturbance	0,000 [0,000, 0,000]
cert_crisis_used_channel	0,000 [0,000, 0,000]

Certifieringskrisen producerar **inget ouppfyllt behov överhuvudtaget**. Detta är inte en svag effekt eller en effekt under tröskeln; det är en exakt nolla, i varje frö. Förutsägelsen är inte bara uppfylld — den storhet den handlade om rör sig inte alls.

C2 — signaturen är missad certifiering, inte falsk certifiering. UNDERKÄND, 0/20, och inverterad.

Registrerad: ökningen i ocertifierat-verkligt-behov överstiger ökningen i falskt-certifierat givande, i $\geq 15/20$ frön.

ökning vs. no_crisis (efter1)	
ocertifierat-verkligt-behov	0,000 [0,000, 0,000]
falskt-certifierat givande	0,732 [0,583, 0,808]

Resultatet är inte en nära miss i den registrerade riktningen. Det är den **exakta motsatsen**, i full styrka. Den korrupta kärnan producerar *endast* falsk certifiering och *ingen* missad certifiering. Fyndet som ärvdes från piloterna — att ett system i certifieringsmisslyckande förlorar förmågan att känna igen verkligt behov snarare än att handla på lögn — var en artefakt av en kollapsande population, och det överlever inte en fungerande baslinje. §4.5 förklarar varför, och förklaringen är avsnittets verkliga resultat.

C3 — det finns ett återhämtningsfönster. UNDERKÄND.

Registrerad: sann-informerat givande i det sena fönstret avtar monotont med återställningsfördröjning, och återställning vid fördröjning 100 är oskiljbar från ingen återställning.

	överlevnad (sent)	sann-informerat (sent)
ingen kris	100,0	1,000 [0,885, 1,000]
kris, ingen återställning	100,0	0,472 [0,409, 0,552]
återställning vid +10	100,0	1,000 [0,875, 1,000]
återställning vid +25	100,0	1,000 [0,875, 1,000]
återställning vid +50	100,0	1,000 [0,875, 1,000]
återställning vid +100	100,0	1,000 [0,875, 1,000]

$\rho(\text{fördröjning, återhämtning}) = \mathbf{0,046}$. $|\text{återställning@100} - \text{ingen återställning}| = 0,528$, mot en registrerad ribba på $< 0,10$.

Reparation fungerar perfekt, vid varje testad fördröjning. Ingen dör, och i samma ögonblick som kanalen återställs återupptas korrekt givande i full utsträckning. Det finns inget fönster. Detta var det enda genuint nya påstående som artikeln hade, och nollhypotesen gäller utan förbehåll.

Anledningen är strukturell, och §4.6 drar ut den: **en regelföljare har ingen tillit att förlora**. Dess givande är en funktion av den signal den ser nu, inte av någon historia med signalen. Den kan inte vilseledas till misstro, eftersom den inte litar — den efterlever. Policyhysteres kräver en policy som *lär sig*, och inläraren är det vi inte kunde bygga.

C4 — en kris på en oanvänd kanal är inert. UNDERKÄND, 1/20.

Registrerad: `cert_crisis_unused_channel` är oskiljbar från `no_crisis` på alla certifieringsmått i det sena fönstret.

sent fönster	no_crisis	oanvänd-kanal-kris
sann-informerat givande	1,000 [0,885, 1,000]	0,667 [0,576, 0,727]
certifieringsfel	0,000 [0,000, 0,115]	0,333 [0,273, 0,424]

Den "oanvända" kanalen visar sig vara använd. Och anledningen är värd mer än kontrollen var: **huruvida en certifieringskanal är "använd" är en egenskap hos policyn, inte hos arkitekturen.** Kanalen identifierades som oanvänd eftersom *pilotens inlärd policy* inte agerade på den — DQN:n hade lärt sig att inte ge B till B-specialisten, som uppenbarligen har gott om B. Den skriptade policyn har inte lärt sig någonting. Den ger på *varje* certifierad signal för vilken den har överskott, och så är den exponerad på varje kanal som arkitekturen tillhandahåller.

Det generaliserar, och vi anger det som en institutionell läsning snarare än ett teorem:

En regelföljande institution är mer exponerad för certifieringskorruption än en lärande, eftersom den inte har någon inlärd skepticism. Efterlevnad är en större attackyta än omdöme. Varje kanal en regelföljare är skyldig att agera på är en kanal genom vilken den kan felstyras; en inlärare beskär de kanaler som erfarenheten har lärt den att ignorera, och gör därmed ytan smalare — till priset av den rigiditet som Rapport XXI:s §3 varnade för. [IP]

4.5 Vad som faktiskt hände: översvämningsmekanismen [R inom modellen]

De fyra misslyckandena hänger samman. Ocifierat verkligt behov är exakt noll under en kris som inverterar behovssignalen — vilket är absurt, tills man frågar vad inversionen faktiskt gör.

Agent 1:s A-signal är inverterad: den signalerar behov av A precis när den *har* A. De andra agenterna efterkommer. De ger den mer A. Dess lager av A *stiger* därför, och efter att ha stigit faller det aldrig under behovströskeln. **Den korrupta kanalen svälter inte specialisten. Den översvämmar den.**

Detta upptäcktes i efterhand, så det återregistrerades som en ny riktningförutsägelse och kördes på tjugo nya frön: *under krisen stiger agent 1:s genomsnittliga lager av A och dess tid i verkligt behov faller.*

agent 1 (B-specialist)	medellager-A, före	medellager-A, efter	steg i verkligt behov, före → efter
no_crisis	0,930	0,980	24,6 → 18,4
kris	0,930	2,763	24,6 → 10,0

Bekräftat. Krisen nästan **tredubblar** specialistens lager av den resurs den inte kan skörda, och **halverar** dess tid i genuint behov.

Så nollan i C1 är inte en frånvaro av skada. Det är skada av ett slag som instrumentet inte kan se:

Den falska certifieringen föregriper det verkliga behov som den annars skulle ha maskerat. Resurser felallokeras till en agent som inte behöver dem; eftersom den är överförsörjd slutar den agenten att registreras som behövande; och så löser systemets egen behovsdetektion aldrig ut. Patologin förstör evidensen för sig själv.

Styrningskonsekvensen är det skarpaste i denna artikel, och det är inte den vi föresatte oss att demonstrera:

Det mått en revisor skulle sträcka sig efter — går någons verkliga behov ouppfyllt? — avläses som en perfekt nolla medan certifieringskärnan är inverterad och resurser systematiskt felstys. Institutionen misslyckas inte bara osynligt. Den misslyckas på ett sätt som får dess hälsoindikatorer att förbättras.

Detta är bekräftelsen av §3.4:s underliggande påstående, och det är starkare än den förutsägelse §3.4 faktiskt gjorde. §3.4 sade att protokollet skulle förbli intakt medan den kartläggning det protokollförde upphörde att motsvara världen — att en institution i certifieringsmisslyckande skulle se ut, inifrån, exakt som en institution i god ordning. Vad demonstrationen visar är värre: misslyckandet lämnar inte bara diagnostiken intakt, det *föder* den. Den specifika signatur §3.4 förutsåg (missad certifiering) är falsifierad. Det påstående som signaturen var tänkt att tjäna bekräftas av sin egen falsifiering.

4.6 Räckvidd: vad denna demonstration gör och inte gör anspråk på

Fastställt i §3.5 före körningen, och hedrat här.

Den konverterar inte §3 från [IP] till [R]. Kärnan korrumpas **exogent** — experimentatorn inverterar signalen. Demonstrationen visar vad som händer *när* en certifieringskärna misslyckas. Den visar inte ett system som genererar sitt eget kärnmisslyckande, och endogen generering är krav (b) i §3.2, på vilket hela Gödel-analogin står eller faller. §3 förblir [IP] och detta avsnitt tvättar det inte.

Den kan inte testa policyhysteres överhuvudtaget. C3:s nollresultat är verkligt men snävt: det säger att ett *regelföljande* system återhämtar sig omedelbart vid varje fördröjning. Det säger ingenting om huruvida ett *lärande* system, efter att ha lärts att dess certifieringskanal ljugar, kan läras om att den talar sanning — och huruvida det finns en fördröjning bortom vilken det inte kan. Det är den fråga §3.4 egentligen handlar om, det är den fråga som skulle ha gjort C3 till ett styrningsfynd snarare än ett mekaniskt sådant, och **vi kunde inte ställa den, eftersom vi inte kunde bygga en regulator som lär sig att samarbeta från första början.** De registrerade inlärrarmisslyckandena (§4.3) är därför inte en fotnot till C3. De är anledningen till att C3 är icke-informativ.

Korruptionen är total, inte brusig. Signalen är inverterad, inte degraderad. En partiellt otillförlitlig kanal — en som är rätt 70% av tiden — skulle kunna bete sig helt annorlunda, och skulle mycket väl kunna producera den missade certifiering som inversion inte gör. Ingenting här talar till det.

En miljö, tre agenter, en kanal, en specialiseringsstruktur. Översvämningsmekanismen beror på att mottagaren är *oförmögen* att skörda det den får för mycket av. Huruvida den generaliserar till rikare komplementaritetsstrukturer är en förmodan som detta resultat stöder, inte ett påstående det bevisar.

4.7 Sammanfattning av registrerade utfall

	registrerad förutsägelse	utfall
GRIND	baslinje stationär, adaptiv regulator	UNDERKÄND ×2 — jämvikt utan handel; skriptad gren substituerad
C1	kris ≠ vanlig störning	UNDERKÄND 0/20 — inget ouppfyllt behov alls
C2	signatur är missad certifiering	UNDERKÄND 0/20 — inverterad; signaturen är <i>falsk</i> certifiering
C3	det finns ett återhämtningsfönster	UNDERKÄND — reparation fungerar vid varje fördröjning; $p = 0,046$
C4	oanvänd kanal är inert	UNDERKÄND 1/20 — "oanvänd" är en egenskap hos policyn, inte arkitekturen
—	(<i>post-hoc</i> , återregistrerad, 20 nya frön) översvämning	BEKRÄFTAD — medellager-A $0,93 \rightarrow 2,76$; verkligt behov halverat

Fem registrerade misslyckanden och en bekräftad mekanism. Vi rapporterar hellre detta än en demonstration som höll med oss, och anledningen ryms i resultatet: **en apparat som rapporterar perfekt hälsa under en korrupt kärna är exakt det objekt denna artikel handlar om.** Vi byggde en av misstag, och trodde den sedan nästan.

§5 — Den andra gränsen: ingen kan utifrån avgöra om en reform konvergerar

5.1 Frågan, ställd så att den kan besvaras

Avsnitt 3 frågade om en styrningsarkitektur inifrån kan validera att dess egen grund för korrigering fortfarande håller. Detta avsnitt ställer den komplementära frågan, och det är den som reformatörer faktiskt ställer: *innan vi gör detta, kan någon säga oss om det kommer att fungera?*

Preciserat är frågan ett beslutsproblem. Låt ett **reformsystem** vara en tupel

$$G = (S, U, R, C, V)$$

där S är det gemensamma tillståndsrummet för agenter, resurser, föreställningar och institutionella regler; $U : S \rightarrow S$ är den uppdateringsdynamik som den föreslagna reformen inducerar; R är den faktorisering som är tillgänglig för agenterna; $C \subseteq S$ är samordningskriteriet — mängden av tillstånd i vilka agenternas handlingar är ömsesidigt förenliga i den mening som guvernörerna i Rapport XIX upprätthåller; och $V \subseteq S$ är livskraftighetsmängden, de tillstånd i vilka essentiella variabler förblir inom gränserna.

Reformkonvergensproblemet. Givet (G, s_0) , avgör om trajektorian $s_{t+1} = U(s_t)$ till slut går in i och förblir i $C \cap V$.

Detta är vad en reformutvärdering *är*, när dimman är borta från den. En konsekvensbedömning, en finanspolitisk prognos, en konstitutionell granskning: var och en är ett försök att besvara en instans av detta problem, under resursbegränsningar och med en tolerans för fel. Frågan i detta avsnitt är om problemet överhuvudtaget har en generell lösning.

5.2 Teoremet

Teorem (Reformkonvergensens oavgörbarhet, [R]; Appendix A.2). Låt $\mathcal{G}$ vara en klass av reformsystem vars uppdateringsdynamik kan simulera en universell Turingmaskin. Då finns det ingen algoritm som, för varje $G \in \mathcal{G}$ och varje s_0 , avgör om trajektorian för U från s_0 till slut går in i och förblir i $C \cap V$.

Beviset är en reduktion från stopproblemet, och det enda steget som kräver omsorg är konstruktionen av målmängden. Det räcker inte att ordna så att den simulerade maskinens stoppande tillstånd ligger innanför $C \cap V$; man måste också utesluta möjligheten att en *icke-stoppande* beräkning driver in i någon annan samordnad, livskraftig region och uppfyller konvergenskriteriet av en slump. Så vi konstruerar $G_{M,x}$ så att $C \cap V = \{s_H\}$ exakt — ett enda absorberande tillstånd, som inträffar om och endast om M stannar på x , där varje tillstånd som kodar en levande beräkning ligger utanför C . Konvergens är då stopp, och en beslutsprocedur för det ena skulle vara en beslutsprocedur för det andra.

Två saker som teoremet inte kräver, och det spelar roll att det inte gör det.

Det kräver inte institutionell självreferens. Den formella källan till oavgörbarheten är uppdateringsdynamikens beräkningsmässiga universalitet — inget mer. Självreferens är en plausibel *väg* genom vilken verkliga styrsystem förvärvar tillräcklig uttryckskraft för att gränsen ska bita: en institution som kan skriva om sina egna beslutsregler kan därmed koda godtycklig beräkning i omskrivandet. Men teoremet gäller för system utan någon självmodell alls, förutsatt att dynamiken är tillräckligt rik. Att sammanblanda de två är det vanliga övergreppet i denna litteratur, och §2:s separation av källor beror på att inte göra det. Certifieringsoförmågan i §3 handlar *om* självreferens; detta resultat gör det inte.

Det kräver inte att samordningskriteriet är exotiskt. Varje C och V i vilken ett stoppande tillstånd kan bäddas in duger. Teoremet är därför inte ett påstående om svårigheten att *definiera* samordning — en svårighet som serien tar på allvar på andra håll — utan om att avgöra om den är nådd.

5.3 Teoremet är grunt, och att säga det är poängen

Givet Turing-fullständighet är reduktionen ovan rutinmässig. Det är värt att vara explicit om hur rutinmässig: samma slutsats följer från åtminstone tre oberoende standardresultat. Rices teorem ger oavgörbarhet för praktiskt taget varje icke-trivial semantisk egenskap hos ett program, av vilken "konvergerar till ett samordnat tillstånd" är en. Richardsons teorem och dess släktingar ger oavgörbarhet för begränsningsproblem för tillräckligt rika dynamiska system, och att förbli inom V är ett begränsningsvillkor. Och den direkta reduktion vi har givit är den läroboksmässiga konstruktionen. **När ett resultat faller ut ur tre orelaterade teorem, berättar det inte något specifikt för dig om det studerade objektet.** Det berättar att objektet antogs vara beräkningsmässigt universellt, och allt följer av det antagandet snarare än av något styrningsformat.

Serien har varit här förut. Rapport XX härledde Ashbys lag från begränsad representation och rapporterade att härledningen var närmast definitionsmässig — ett verkligt teorem med grunt innehåll — eftersom det var mer värdefullt att rapportera det än att klä ett fackprincipargument som en upptäckt. Samma disciplin gäller här, och skarpare, eftersom orden *Gödel* och *Turing* bär en prestige som gör läsarens tänkande åt dem. En artikel som tillkännagav "reformkonvergens är oavgörbart" och stannade skulle dra nytta av den prestigen. Vad som följer är den del som inte är gratis.

Teoremet står i spänning med seriens egen premiss, och spänningen är lärorik. Rapport 0 och Rapport XX bygger allt på *begränsad representation*: en ändlig regulator som partitionerar den uppgiftsrelevanta världen i ett begränsat antal interna tillstånd. Men ett system med ett ändligt tillståndsrum har ett *avgörbart* konvergensproblem — simulera det under $|S|$ steg och avläs om det har gått in i en cykel innanför $C \cap V$. Oavgörbarhet kräver obegränsning, vilket är precis vad resten av serien förnekar. **De två gränserna kan därför inte båda vara skarpa samtidigt**, och att låtsas något annat vore en unifisering köpt med en motsägelse. Detta är ett av skälen till att §2 vägrar att härleda triptyken från en enda gräns.

Upplösningen är inte att överge teoremet utan att omlokalisera det. För en ändlig institution är konvergens avgörbart och beslutsproceduren kostar tid exponentiell i tillståndsbeskrivningen — vilket är att säga, avgörbart och *oanvändbart*. **Den operativa gränsen för reformutvärdering är komplexitet, inte beräkningsbarhet.** Oavgörbarhetsteoremet är den idealiserade skugga som kastas av ett ändligt men astronomiskt dyrt problem, och det är kostnaden, inte omöjligheten, som en reformatör möter. Vi anger detta som den ärliga formen av resultatet:

[R] För obegränsad uppdateringsdynamik är reformkonvergensproblemet oavgörbart. [R] För ändliga system är det avgörbart, till kostnad exponentiell i tillståndsbeskrivningen. [IP] För verkliga institutioner är det andra den bindande begränsningen, och det första är en gränsidealisering av den.

Beräkningsbarhetsinramningen är den traditionella. Komplexitetsinramningen är den som gör arbete.

5.4 Vad teoremet förbjuder, och vad det licensierar

Förbjudet: tron att tillräcklig analytisk kapacitet sluter gapet. Den intuition som teoremet dödar är inte "reformer är svåra att förutsäga" — alla tror det — utan det tysta antagandet att svårigheten är ett *resurs*problem, lösbart genom en bättre modell, en större simulering, en mer kapabel analytiker eller en tillräckligt kraftfull maskin. På den obegränsade klassen finns ingen procedur alls, och på de begränsade klasser vi faktiskt bebor är proceduren exponentiell. Ingetdera fixas genom skalning. En institution som behandlar *ex ante*-certifiering av reform som ett lösbart ingenjörproblem och bemannar det därefter är inte ambitiös; den missförstår problemets typ.

Licensierat: nästan allt som serien redan rekommenderar, nu som konsekvens snarare än råd. Skyddade experimentutrymmen (Rapport VII) är den enda tillgängliga metoden när ingen *a priori*-procedur existerar: du kan inte beräkna svaret, så du måste instrumentera frågan. Vaktposter (Rapport XIX) är nödvändiga eftersom divergens måste *upptäckas* när den inte kan *förutsägas*. Reversibilitet och solnedgångsklausuler (Rapport XXI §6) är det rationella svaret på ett vad vars utfall inte kan avgöras i förväg: en irreversibel reform är en satsning på ett beslutsproblem som du just har fått veta att du inte kan avgöra. Vad §7 kommer att utveckla är att dessa inte längre är försiktighetsrekommendationer utan tvingande drag.

En brasklapp som måste bevaras, eftersom det är den som oftast tappas. *Oavgörbarhet implicerar inte oförutsägbarhet i praktiken.* Stopproblemet är oavgörbart, och termineringsbevisare avgör likväl frågan för den överväldigande majoriteten av program som någon faktiskt skriver. Oavgörbarhet är ett påstående om det *värsta fallet över en obegränsad klass*; det är fullständigt förenligt med en beslutsprocedur som lyckas på varje instans som en verklig institution någonsin kommer att möta. Att glida från teoremet till "vi kan inte veta om reformer kommer att fungera" är att begå precis det fel som §6 kommer att identifiera i missbruket av No Free Lunch: att förvandla ett påstående om frånvaron av universella garantier till en licens för fatalism. Teoremet tar bort en garanti; det tar inte bort kunskap.

Det konstruktiva innehållet är därför ett krav: namnge begränsningen. Begränsade klasser av dynamik förblir perfekt avgörbara — kontraktionsavbildningar, potentialspel, monotona system, acykliska beroendestrukturer, linjär-kvadratisk reglering med ändlig horisont. Ingen verklig institution är designad i den obegränsade klassen. Så teorets ingenjörsmässiga översättning är inte *överge utvärdering utan ange den klass av dynamik under vilken din utvärdering är giltig, och instrumentera för det fall att systemet lämnar den*. En konsekvensbedömning som inte anger vilka strukturella antaganden som gör dess projektion meningsfull är inte en konservativ uppskattning; det är ett obegränsat påstående om ett oavgörbart problem. [IP]

5.5 Paret med §3, hållet isär

Det är frestande att smälta samman detta avsnitt med det föregående. Båda är begränsande, båda rör omöjligheten av ett visst slags garanti, och båda slutar i samma designprinciper. Men de är olika resultat och artikeln slår inte ihop dem:

§3 (certifieringsförmåga) rör gränserna för att validera en nödvändig förändring **inifrån** det system som behöver den. **§5 (reformers oavgörbarhet)** rör gränserna för att förutsäga, **utifrån**, huruvida en föreslagen förändring kommer att konvergera.

Det första är en regress; det andra är en reduktion. Det första har verkligt innehåll och inget teorem; det andra har ett teorem och tunt innehåll. Det första biter på arkitekturer som kan representera sig själva; det andra biter på arkitekturer som kan beräkna, oavsett om de kan representera sig själva. En institution skulle i princip kunna lida av det ena utan det andra — ett självblint men beräkningsmässigt universellt system möter §5 och inte §3; ett självrepresenterande ändligt-tillståndssystem möter §3 och inte, i någon bitande mening, §5.

Att de två likväl konvergerar mot samma garderingar — sandlådor, vaktposter, reversibilitet — är den observation som §7 förvandlar till ett argument. Det är en konvergens av konsekvenser, inte av orsaker, och artikelns struktur beror på att hålla isär distinktionen.

Appendix A.2 — Reduktionen (för §5.2)

Låt M vara en Turingmaskin och x en input. Konstruera reformsystemet $G_{M,x} = (S, U, R, C, V)$ enligt följande.

Tillstånd. $S = \text{Conf}(M) \cup \{s_H\}$, där $\text{Conf}(M)$ är mängden av konfigurationer av M (bandinnehåll, huvudposition, kontrolltillstånd) och $s_H \notin \text{Conf}(M)$ är ett nytt absorberande tillstånd.

Dynamik. U verkar som M :s transitionsfunktion på $\text{Conf}(M)$, förutom att varje konfiguration i vilken M :s kontrolltillstånd är accepterande eller avvisande avbildas på s_H ; och $U(s_H) = s_H$. Således är s_H absorberande och nås om och endast om M stannar.

Samordning och livskraftighet. Sätt $C = V = \{s_H\}$, så att $C \cap V = \{s_H\}$. Varje konfiguration som kodar en levande beräkning ligger utanför C ; det enda samordnade, livskraftiga tillståndet är den stoppande sänkan.

Initialtillstånd. $s_0 = e(M, x)$, initialkonfigurationen för M på x .

Påstående. Trajektorian för U från s_0 går till slut in i och förblir i $C \cap V$ om och endast om M stannar på x .

Bevis. ($\Leftarrow$) Om M stannar på x , når den simulerade beräkningen en stoppande konfiguration i ändligt många steg, varpå U avbildar den på s_H , vilket är absorberande; trajektorian är därefter i $C \cap V$ för alltid. ($\Rightarrow$) Om M inte stannar på x , lämnar U aldrig $\text{Conf}(M)$, och $\text{Conf}(M) \cap C = \emptyset$; trajektorian går aldrig in i $C \cap V$ överhuvudtaget, än mindre förblir i den. $\square$

Korollarium (Teorem, §5.2). Anta att en algoritm P avgjorde reformkonvergensproblemet för klassen $\mathcal{G}$ av reformsystem med universell uppdateringsdynamik. Då avgör M_P — maskinen som, på input (M, x) , konstruerar $G_{M,x}$ och kör P på $(G_{M,x}, s_0)$ — stopproblemet, en motsägelse. $\square$

Anmärkning om förstärkningen. Reduktionen använder specialfallet där konvergens innebär att gå in i ett *absorberande* samordningstillstånd. Det generella konvergenskriteriet i §5.1 — trajektorian går till slut in i $C \cap V$ och förblir där, möjligen med fortsatt rörelse inom det — är svagare, och varje beslutsprocedur för det generella problemet skulle avgöra detta specialfall. Oavgörbarhet för specialfallet implicerar därför oavgörbarhet för det generella. Detta är anledningen till att $C \cap V$ konstrueras som en singleton: ju stramare målmängd, desto starkare det resulterande teoremet, och desto färre invändningar tillgängliga för en läsare som misstänker att en icke-stoppande beräkning skulle kunna uppfylla kriteriet genom att vandra in i någon tillfällig samordnad region.

Anmärkning om ändlighet. Varje hypotes i detta appendix misslyckas för en ändlig-tillståndsinstitution, för vilken Conf är ändlig och konvergens avgörs genom att simulera $|S|$ steg. Se §5.3: teoremet är en gränsidealiserings, och den bindande begränsningen för verklig reformutvärdering är kostnaden för den simuleringen, inte dess omöjlighet.

§6 — Den tredje gränsen: ingen arkitektur är rätt utan en värld

6.1 Frågan

De två första gränserna rörde garanti: huruvida ett system kan certifiera sig självt inifrån (§3), huruvida en observatör kan utvärdera en reform utifrån (§5). Den tredje rör själva designen, och det är frågan som föregår båda: *finns det en arkitektur som är rätt oavsett vilken värld man befinner sig i?*

Frågan är inte överksam. Nästan varje substantiellt påstående i politisk argumentation har denna form. Att demokrati överträffar autokrati; att marknader överträffar planering; att decentralisering överträffar centralisering, eller tvärtom; att federalism är en överlägsen behållare för pluralism — vart och ett uttalas som om det vore en egenskap hos arkitekturen. Detta avsnitt visar att ingen sådan egenskap existerar, att teoremet som visar det är nästan innehållslöst, och att innehållslösheten är där det användbara innehållet finns.

6.2 Teoremet

Modellera en institution som en adaptiv algoritm A som avbildar historier av miljötillstånd till institutionella responser — policyer, regeländringar, omfaktoriseringar — med syftet att hålla systemet innanför en livskraftighetsmängd V . Modellera en miljö E som en avbildning från institutionens handlingshistorik till nästa tillstånd; rummet $\mathcal{E}$ av miljöer är mängden av alla sådana avbildningar. Fixera ett prestandamått — förväntad andel tid inom V , eller kumulativ kostnad för anpassning, eller vilken funktion av trajektorian som helst.

Teorem (No Free Lunch för institutioner, [R]). *Medelvärdesbildat likformigt över $\mathcal{E}$ har två godtyckliga institutionella arkitekturer A och B identisk förväntad prestanda. Följaktligen finns det ingen A^* som svagt dominerar varje alternativ över hela $\mathcal{E}$ och strikt dominerar på åtminstone en medlem.*

Beviset följer den normala NFL-mallen. För varje E där A överträffar B , konstruera spegelmiljön E' genom att permutera de utfall som följer av A :s föredragna handlingar med dem som följer av B :s. Eftersom $\mathcal{E}$ innehåller varje avbildning är E' en medlem. Då är A :s prestanda på E lika med

B :s på E' , och omvänt; det likformiga medelvärde är oförändrat. Varje miljö i vilken en arkitektur utmärker sig betalas av en miljö i vilken den är katastrofal, och liggaren sluts på noll.

6.3 Teoremet är närmast innehållslöst, och att säga det är poängen

Beviset har en bärande hypotes som är falsk om världen: att $\mathcal{E}$ är sluten under de relevanta permutationerna, och att medelvärdet tas likformigt över det. Ingetdera håller. Verkliga miljöer är inte en ostrukturerad mängd godtyckliga avbildningar; de formas av fysik, biologi, geografi, teknologi, demografi och historiens ackumulerade stigberoende. Den mängd världar som en europeisk välfärdsstat plausibelt kan möta under nästa årtionde är inte sluten under permutation av sin utfallsstruktur, och ingen institution har någonsin konfronterat ett likformigt drag från rummet av alla möjliga världar.

Ett teorem vars kraft vilar på en likformig fördelning över ett ostrukturerat rum är ett teorem om fördelningen. **Dess innehåll är inte "alla institutioner är lika"; dess innehåll är "om du vägrar säga något om världen, får du inte säga något om arkitekturen."** Det är en begränsning av argument, inte en upptäckt om styrning, och artikeln rapporterar det som en sådan.

Detta är andra gången serien flaggar ett formellt giltigt resultat som grund — Rapport XX gjorde detsamma för Ashbys lag, som är ett äkta fackteorem och mycket nära en definition när begränsad representation väl medges. Mönstret är nu tillräckligt explicit för att uttalas som en metodologisk observation om hela det gränsteoretiska registret: **i denna litteratur är de resultat som har bevis de resultat som har minst innehåll, och resultatet med innehåll — certifieringsoförmågan, §3 — har inget bevis.** Den inversionen anges i §1.4 och är inte en defekt hos föreliggande artikel utan ett särdrag hos terrängen.

6.4 Kontrapositionen, som är hela innehållet

Vänd på teoremet och något värt att ha framträder. Om ingen arkitektur är överlägsen utan en miljöklass, då gäller:

Varje påstående om arkitektonisk överlägsenhet är ett förtäckt påstående om miljöklassen.

Påståendet görs oavsett om det uttalas. När en reformatör argumenterar för att decentralisering kommer att förbättra serviceleveransen, handlar argumentet inte *om* decentralisering; det handlar om en värld där lokal information är rik, lokal kapacitet är tillräcklig, preferenser är heterogena och samordningsexternaliteter är svaga. Dessa fyra villkor är det faktiska innehållet i förslaget, och de är vanligtvis den del som förblir outtalad — inte av ond tro, utan för att arkitekturen är synlig och antagandet om miljöklassen inte är det.

Detta ger avsnittets designprincip, och det är den första akten av institutionell ingenjörskonst snarare än en förfining av den:

***Namnge klassen.** Innan en arkitektur föreslås, ange den klass av miljöer under vilken den förväntas presteras, prestandakriteriet och den antagna störningsfördelningen. Ett arkitekturförslag som inte namnger sin klass är inte ett blygsamt förslag; det är ett obegränsat sådant.*

Eller, i den kompakta form som utforskningen producerade och som vi behåller:

Varje konstitution är ett vad på världens form; ingen konstitution vinner varje vad.

[IP] för den institutionella läsningen. Teoremet är [R] och, som §6.3 säger, tunt.

6.5 Den dåliga läsningen, blockerad

No Free Lunch missbrukas oftare än det används, och alltid i samma riktning:

Eftersom ingen arkitektur är universellt optimal, är alla arkitekturer lika giltiga.

Detta följer inte, och teoremet säger nästan motsatsen. NFL fastställer att arkitekturkvalitet är **betingad** — vilket är ett krav på att betingelserna anges, inte en licens att sluta ange dem. Relativism är vad man får när man tar teoremets antecedent (en likformig fördelning över ett ostrukturerat miljörum) som en beskrivning av världen snarare än som den *reductio* det är. Ingen

lever under en likformig fördelning. I samma ögonblick som miljöklassen begränsas — och det gör den alltid, av fysiken om inte annat — återuppstår dominansrelationer, och kan argumenteras om på sakliga grunder.

Begränsade klasser kan ha och har dominatorer. [R] I en miljöklass som karaktäriseras av låg nyhet, stabila uppgifter, tillförlitlig information och hög efterlevnad är en hierarkisk byråkrati inte bara försvarbar utan sannolikt dominant: dess långsamma återkopplingslinga kostar ingenting när världen inte rör sig, och dess enhetlighet köper läsbarhet och legitimitet. I en klass som karaktäriseras av hög nyhet, spridd lokal information och heterogena betingelser är samma arkitektur dominerad, och den långsamhet som inte kostade något tidigare är nu hela misslyckandet. De två påståendena är förenliga, och den oförenlighet människor föreställer sig mellan dem är en artefakt av att utelämna klassen ur påståendet.

Den ärliga sammanfattningen är inte att inget kan sägas, utan att inget kan sägas *ovillkorligt*:

Institutioner är inte universellt goda eller dåliga; de är passande eller misspassande till miljöklasser. Och varje institutionell design kodar en hypotes om världen — så när världen byter klass, blir designens dygder dess misslyckandemoder, utan att en enda regel har ändrats.

Den sista meningen är den som gör styrningsarbete, och det är värt att notera att den inte alls är ett påstående om misslyckande. Det är ett påstående om hur en välfungerande institution misslyckas: inte genom att degraderas, inte genom korruption, inte genom någon intern händelse som en övervakare skulle fånga, utan genom att världen rör sig undan ett vad som var korrekt när det placerades.

6.6 Var detta sitter gentemot resten av serien

Gentemot Ashby (Rapport XX). Ashbys lag kräver att regulatorn matchar variationen hos de störningar den möter. NFL tillhandahåller den saknade kvantorn: *vilka* störningar. Nödvändig variation är inte ett fast mål utan ett mål indexerat av en miljöklass, och en regulator som är korrekt matchad till en klass är undervarierad för en annan. De två resultaten sammansätts: Ashby säger att du måste ha tillräckligt många distinktioner; NFL säger att "tillräckligt" inte är en egenskap hos regulatorn.

Gentemot Goodhart (Rapport XX). Goodhart biter när optimeraren kan nå en målrelevant dimension som dess proxyvariabel förkastar. Huruvida en given dimension är målrelevant är ett faktum om miljöklassen. Ett mått som är säkert förlustbringande i en klass — eftersom den förkastade dimensionen inte spelar någon roll där — blir Goodhart-exponerat i en annan utan någon ändring av måttet. Proxyvariabelsäkerhet, liksom arkitektonisk överlägsenhet, är ett påstående om världen i förklädnad.

Gentemot rollen (Rapport XIX). Detta är den renaste integration som gränsresultaten erbjuder, och den återgäldar XIX en skuld. XIX fastställde empiriskt att styra, varna och överbrygga är dissocierbare roller, och att en portfölj behöver alla tre; den kunde inte säga *varför* alla tre är nödvändiga snarare än bara användbara. NFL säger varför:

***Guvernörer** exploaterar den för tillfället antagna miljöklassen. **Vaktposter** upptäcker när klassen har skiftat. **Broar** bevarar översättning mellan de arkitekturer som är lämpade för olika klasser.*

Om optimalitet vore ovillkorlig skulle endast guvernörer behövas: man skulle finna den bästa arkitekturen och köra den. Vaktposter är nödvändiga eftersom klassen är ett vad; broar är nödvändiga eftersom vadet kan förloras och att förlora det måste vara överlevbart. Triaden är inte en designpreferens. Det är den minimala struktur ett system behöver för att hålla en reviderbar hypotes om den värld det befinner sig i. **[IP]**

Gentemot begränsad representation (Rapport 0). Dessa två fakta är oberoende och bör inte sammanfogas — §2 insisterar på det, och NFL binder obegränsade regulatorer precis som det binder begränsade. Men de sammansätts på ett sätt som är värt att namnge. Rapport 0 fastställde att begränsning *tvingar* en regulator att faktorisera: att förbinda sig till en ändlig mängd distinktioner och förkasta resten. Det åtagandet är en induktiv bias. NFL säger sedan att varje induktiv bias är ett vad på miljöklassen. Så: **begränsning tvingar dig att ha en bias; No Free Lunch säger att biasen är ett vad.** Ingetdera implicerar det andra, och deras konjunktion är skälet till att en begränsad regulator inte kan vara neutral om den värld den befinner sig i även om den önskar vara det. Neutralitet är inte tillgänglig vid någon kapacitet.

6.7 Vad detta avsnitt inte visar

- Hypotesen om likformig fördelning är falsk för varje värld vi bebor, och allt som teoremet säger beror på den. Teoremet behålls eftersom dess *kontraposition* är användbar, inte för att dess antecedent är sann.
- Ingenting här begränsar hur *stort* prestandagapet mellan arkitekturer kan vara inom en begränsad klass, och inte heller hur mycket av variansen i institutionella utfall som kan tillskrivas klassmissmatchning snarare än utförande, kapacitet eller korruption. Detta är empiriska frågor och denna artikel berör dem inte.
- Kravet att "namnge klassen" är en disciplin, inte en procedur. Serien har ingen metod för att identifiera vilken miljöklass en institution faktiskt möter, och den ärliga positionen är att detta är en lucka. Rapport XIX:s vaktposter upptäcker att ett skifte har inträffat; ingenting i serien identifierar den klass man har skiftat *till*. **[H]** — och en uppriktig sådan, eftersom det är just den förmåga som designprincipen förutsätter.

§7 — Från garanti till gardering: vad de tre gränserna ger

Gränserna är negativa. De designprinciper de ger är det inte. Detta avsnitt är den konstruktiva vändningen, och det gör en specifik sak: det omvandlar tre rekommendationer som serien tidigare har argumenterat för utifrån **försiktighet** till konsekvenser argumenterade utifrån **nödvändighet**.

Den distinktionen är inte retorisk. En försiktighetsrekommendation kan avvisas av en institution som bedömer sig kapabel nog att inte behöva den, och institutioner gör det rutinmässigt. En konsekvens kan inte avvisas.

7.1 Utbytet, tydligt angivet

	garanti som tas bort	vad som måste ersätta den
L1 (§3)	att ett system inifrån kan certifiera grunden för sin egen korrigering	externa certifieringsankare (XVII), succession och avveckling (XXI §6), broar (XIX)
L2 (§5)	att en reform kan utvärderas i förväg	skyddade experimentutrymmen (VII), stegvis utrullning, vaktposter (XIX), reversibilitet, solnedgångsklausuler (XXI)
L3 (§6)	att en arkitektur kan vara rätt utan en värld	adaptiv pluralism (V), deklarerade miljöklasser, portföljdesign (XIX §5)

Läs nedåt i den högra kolumnen och det är seriens stående råd. Läs nedåt i den vänstra och det är skälet till att rådet inte är råd.

Rapport VII argumenterade för skyddade experimentutrymmen eftersom experimenterande är klokt. §5 säger att det är *tvingande*: när ingen *a priori*-beslutsprocedur existerar för den obegränsade klassen, och proceduren för den begränsade klassen är exponentiell, kan du inte beräkna svaret — så du måste instrumentera frågan. Experimenterande är inte ett sätt att vara försiktig. Det är den enda återstående metoden.

Rapport V argumenterade för adaptiv pluralism utifrån försiktighet: behåll alternativ till hands, världen kan förändras. §6 säger att alternativen inte är en försäkring mot en möjlig framtid utan det *enda koherenta svaret på ett redan placerat vad*. Den gällande arkitekturen kodar en hypotes om miljöklassen. Monokultur är inte oförsiktighet; det är en vägran att notera att ett vad har ingåtts.

Rapport XXI argumenterade för solnedgångsklausuler på grunden att institutioner överlever sin användbarhet. §5 tillhandahåller det skarpare skälet: om konvergens inte kan avgöras, är **en reform som inte kan avslutas ett vad som inte kan avgöras**. Solnedgångsklausulen är inte ödmjukhet. Det är den enda mekanism genom vilken en oavgörbar fråga kan stängas.

7.2 Rollden, och den skuld denna artikel återbetalar till Rapport XIX

Rapport XIX fastställde, empiriskt och över tjugo omtränade ekologier, att styra, varna och överbrygga är **dissocierbara** — att den bästa guvernören inte är den bästa vaktposten, och att ingen av dem är bron. Vad den inte kunde säga var *varför en institution behöver alla tre snarare än att finna den bästa arkitekturen och köra den*.

L3 säger varför, och svaret är kort:

***Guvernörer** exploaterar den för tillfället antagna miljöklassen. **Vaktposter** upptäcker att klassen har skiftat. **Broar** bevarar översättning mellan arkitekturer lämpade för olika klasser.*

Om arkitektonisk överlägsenhet vore ovillkorlig skulle endast guvernörer behövas. Vaktposter existerar eftersom klassen är ett **vad**. Broar existerar eftersom vadet kan **förloras**, och att förlora det måste vara **överlevbart**. Triaden är inte en designpreferens eller en empirisk kuriositet. Det är den minimala struktur ett system behöver för att hålla en *reviderbar hypotes om den värld det befinner sig i*.

Detta är en genuin förstärkning av XIX och vi flaggar det som en sådan. XIX fann triaden; XXII förklarar den. **[IP]**

7.3 Vad §4 tillför, och vad den tar bort

Demonstrationen var tänkt att bidra med en fjärde designprincip: att certifieringsreparation har en **tidsfrist**. Det gör den inte, och anledningen till att den inte gör det är själv en designprincip — en bättre sådan, och en mer obekväm sådan.

Borttaget: återhämningsfönstret. I ett regelföljande system återställer reparation av certifieringskanalen samordningen omedelbart, vid varje testad fördröjning. Det finns ingen tidsfrist, eftersom en regelföljare inte har någon tillit att förlora (§3.5). Huruvida en *lärande*

institution kan skadas permanent av en period av systematisk felcertifiering — huruvida tillit, en gång förstörd, har en återuppbyggnadskostnad som växer med lögnens varaktighet — är den fråga denna artikel ville besvara och inte kunde.

Tillfört, och det är artikelns skarpaste praktiska påstående: dina hälsoindikatorer är nedströms din certifieringskärna.

§4.5 fann att en korrupt kärna inte producerar ouppfyllt behov. Den producerar *felallokering till parter som sedan upphör att vara i behov* — och så avläser det mått som en revisor skulle sträcka sig efter en perfekt nolla, bättre än utgångsläget, medan kärnan är inverterad. Patologin förstör evidensen för sig själv.

Designkonsekvensen följer omedelbart och finns, såvitt vi vet, inte i litteraturen:

En institution kan inte övervaka sin egen certifieringskärna med instrument som är beroende av den kärnan. Statistik över ouppfyllda behov, klagomålsvolym, servic gapsrapporter och underskottsindikatorer är alla utdata från den allokeringsprocess som kärnan styr. När kärnan är sund mäter de världen. När den är korrupt mäter de korruptionens egen framgång i att tillfredsställa dem den har felstyrkt resurser mot — vilket är att säga, de mäter ingenting, och de mäter det på ett betryggande sätt.

Vad detta utesluter är en hel klass av tillsynsdesign: **varje övervakningsregim vars evidens genereras av den process den övervakar**. Vad det kräver är ett ankare som är *kausalt oberoende* av allokeringskanalen — en mätning av behov tagen utanför det system som agerar på behov. Det är XVII:s externa certifieringsankare, som här anländer inte som ett filosofiskt krav utan som en konsekvens av en demonstrerad misslyckandemod. [IP], med mekanismen vid [R inom modellen].

Och det skärper L1:s institutionella läsningar (§3.6) till en testbar varning. Den statistikmyndighet vars kategorier inte längre skär ekonomin är inte bara blind; dess indikatorer *föds* av driften. Den revisionsregim som hårdade sin liggare och lämnade sin attestering orörd är inte bara exponerad; dess förtroende stiger *därför* att den är exponerad. **Ett stigande förtroende för en övervakningsregim är inte evidens för att regimen fungerar**. Det är förenligt med att regimen har fångats av det den övervakar, och ingen mängd intern stringens särskiljer de två fallen.

7.4 Regelföljarens exponering

C4:s misslyckande (§4.4) gav upp en kontroll och gav en princip. Den kanal vi hade markerat "oanvänd" — på evidens av en inlärd policy som hade slutat agera på den — visade sig vara fullt levande för en regelföljande policy, som agerar på varje certifierad signal den är skyldig att agera på.

Efterlevnad är en större attackyta än omdöme. En regelföljande institution är exponerad på varje kanal dess arkitektur tillhandahåller, eftersom den inte har någon inlärd skepticism om någon av dem. En lärande institution beskär de kanaler som erfarenheten har lärt den att ignorera, och gör ytan smalare — till priset av den rigiditet som Rapport XXI:s §3 identifierade, och med risken att beskära en kanal som senare spelar roll.

Detta är en verklig avvägning och serien bör inte låtsas något annat. Rapport XXI argumenterade för att lärande så småningom måste upphöra, att en mogen regulator väljer vad som ska hållas stilla. §4 visar en av kostnaderna för att hålla stilla: **vad du har frusit måste du lyda, inklusive när det ljuger för dig.** Ingetdera hornet är gratis, och vi har ingen princip för att välja mellan dem. [H]

7.5 Helhetens form

Tre gränser, tre garderingar, och en gemensam form:

Styrningens ingenjörskonst är inte design av slutgiltiga institutioner. Det är design av system som överlever ofullständighet, oavgörbarhet och miljöklassmissmatchning — inget av vilket kan elimineras, och allt av vilket kan instrumenteras för.

Garderingarna är inte ett tröstpris för frånvaron av garantier. De är vad design *blir* när garantierna är kända för att vara otillgängliga. En institution som har förstått detta bygger inte för att ha rätt; den bygger för att få reda på att den har fel, i tid, och från utsidan av sig själv. [IP]

De sista tre orden bär tyngden, och §4 är anledningen. *Från utsidan av sig själv*: eftersom ett system vars kärna har misslyckats inte bara saknar evidens för misslyckandet — det tillverkar evidens för hälsa. Det finns ingen intern utsiktspunkt från vilken det kan särskiljas från framgång.

Demonstrationen i denna artikel ägnade tre versioner åt att producera just en sådan apparat — ett experiment vars instrument rapporterade en ren baslinje över en död population — och vi trodde den nästan. Grinden fångade det. Grinden var extern till det den kontrollerade. Det är hela argumentet, och vi avsåg inte att göra det på det viset.

§8 — Integration med serien

8.1 Gentemot Rapport XX — komplement, inte halvor av ett resultat

Rapport XX härledde tre lagar från en gräns: givet en ändlig regulator som partitionerar den uppgiftsrelevanta världen i ett begränsat antal interna tillstånd, följer Ashbys lag, Goodharts lag och certifieringskostnaden från Rapport XVII. Det är en artikel om vad begränsning **tvingar fram**.

Detta är en artikel om vad ingenting kan **garantera**, och de två är komplement — men de är inte två halvor av ett enda resultat, och §2 ägnar sin längd åt att vägra sammansmältningen. Vägran är inte pedanteri. **L2 kräver negationen av XX:s premiss.** Oavgörbarhet behöver beräkningsmässig universalitet; universalitet behöver ett obegränsat tillståndsrums; och en ändlig regulator har ett *avgörbart* konvergensproblem, avgjort genom att simulera den under storleken av dess tillståndsrums. Begränsning producerar inte reformers oavgörbarhet. Begränsning förstör den.

Så den ärliga relationen är:

XX: en premiss, tre konsekvenser. XXII: tre krav, tre vägran, tre olika skäl — och en av de tre står i spänning med XX:s premiss, vilket är information om var den gränsen faktiskt hör hemma.

Vad XXII tar från XX är inte en härledning utan en **disciplin**. XX rapporterade att dess Ashby-härledning var närmast definitionsmässig — ett verkligt teorem med grunt innehåll — snarare än att klä ett fackprincipargument som en upptäckt. §5 och §6 gör detsamma för reformers oavgörbarhet och No Free Lunch, och §2.7 generaliserar mönstret till ett påstående om hela det gränsteoretiska registret: *en gräns som kan härledas från en enda ren hypotes är vanligtvis en gräns om hypotesen, inte om objektet.*

8.2 Gentemot Rapport XVII — regressen gjord dynamisk, och given en misslyckandemod

XVII fastställde **certifieringsgolvet**: bearbetning kan göras godtyckligt verifierbar, men certifiering av verkligheten kan inte det, eftersom en verifierare av ett världsfaktum i sin tur kräver en verifierare. Och den fastställde **relokaliseringsinvarianten**: att automatisera en samordningsgräns flyttar den irreducibla världscertifieringslänken uppströms snarare än att ta bort den.

L1 är den regressen gjord dynamisk. XVII frågade om ankaret kan vara självverifierande och svarade nej. XXII frågar vad som händer *när ankaret brister* — och svaret, som XVII inte hade någon möjlighet att nå, är det skarpaste resultatet i denna artikel.

XVII:s praktiska korollarium var att **härda protokollet är inte att härda certifieringen**. §4 visar varför det betyder mer än det låter. En korrupt certifieringskärna lämnar inte bara protokollet intakt; den **föder** protokollet. Den korrupta kanalen felstyr resurser till en part som inte behöver dem, den parten hålls därmed borta från behov, och systemets egen behovsdetektion löser därför aldrig ut. Det mått en revisor skulle sträcka sig efter avläses *bättre än utgångsläget* medan kärnan är inverterad.

Detta omvandlar XVII:s externa certifieringsankare från ett filosofiskt krav till en **konsekvens av en demonstrerad misslyckandemod**:

En institution kan inte övervaka sin egen certifieringskärna med instrument som är beroende av den kärnan. Vad som behövs är ett ankare som är kausalt oberoende av allokeringskanalen — inte för att certifiering är filosofiskt ogrundad, utan för att en korrupt kärna tillverkar evidens för sin egen sundhet.

XVII sade att ankaret inte kan vara självverifierande. XXII säger: *och om du försöker ändå, kommer ditt förtroende att stiga.*

8.3 Gentemot Rapport XIX — det saknade varför, och ett ovälkommet tillägg

XIX fastställde över tjugo omtränade ekologier att styra, varna och överbrygga är **dissocierbara roller**, och att en portfölj behöver alla tre. Den kunde inte säga varför alla tre är *nödvändiga* snarare än bara användbara.

§6.6 tillhandahåller skälet, och det är L3: guvernörer exploaterar den för tillfället antagna miljöklassen; vaktposter upptäcker att klassen har skiftat; broar bevarar översättning mellan arkitekturer lämpade för olika klasser. Om arkitektonisk överlägsenhet vore ovillkorlig skulle endast guvernörer behövas. Triaden är den minimala struktur som krävs för att hålla en **reviderbar hypotes om den värld man befinner sig i**. Detta är en genuin förstärkning av XIX.

§4 tillför något som XIX inte kommer att välkomna. C4:s misslyckande visade att huruvida en certifieringskanal är "använd" är en egenskap hos **policyn**, inte hos arkitekturen: den kanal som vår inlärd pilot hade slutat agera på var fullt levande för en regelföljare, som agerar på varje certifierad signal den är skyldig att agera på. Så **efterlevnad är en större attackyta än omdöme** — och XIX:s certifieringsrekommendation (testa alla tre roller, inte en) ärver en ytterligare börda: rollerna utövas genom kanaler, och vilka kanaler ett system är exponerat på beror på vad det har lärt sig att ignorera. En portföljrevision som antar att arkitekturen definierar exponeringen kommer att underskatta den för varje regelbunden komponent. **[IP]**

8.4 Gentemot Rapport XXI — det formella skälet för avveckling, och priset för att hålla stilla

XXI argumenterade för att lärande så småningom måste upphöra, att det mogna draget är att välja **vad som ska hållas stilla**, och att institutioner behöver successions- och avvecklingsbestämmelser. Två av dessa argument förstärks här och ett beläggs med kostnad.

Förstärkt. L2 ger solnedgångsklausuler en formell grund snarare än en temperamentmässig: om konvergens inte kan avgöras, är *en reform som inte kan avslutas ett vad som inte kan avgöras*. Solnedgångsklausulen är den enda mekanism genom vilken en oavgörbar fråga kan stängas. Och XXI:s stängda metasteg är en av de två bärande ingredienserna i L1 (§3.3): regressen från XVII säger att certifieringskedjan måste sluta i ett overifierat ankare; XXI:s stängning säger att ett begränsat system endast har ändligt många stegpinnar att placera ett på.

Belagd med kostnad. §4 blottlägger en kostnad för att hålla stilla som XXI inte prissatte. **Vad du har frusit måste du lyda — inklusive när det ljuger för dig.** Regelföljarens omedelbara återhämtning från en reparerad kanal (C3:s nollresultat) är samma egenskap som dess totala exponering för en korrupt sådan (C4:s misslyckande): den litar inte, den efterlever, och efterlevnad har ingen skepticism att falla tillbaka på. En lärande institution beskär de kanaler som erfarenheten lärde den att ignorera och smalnar av sin exponering, till priset av just den rigiditet som XXI varnade för. **Ingetdera hornet är gratis, och denna artikel har ingen princip för att välja mellan dem (§7.4, [H]).**

8.5 Gentemot Rapport VII och V — försiktighet blir konsekvens

Rapport VII argumenterade för skyddade experimentutrymmen eftersom experimenterande är klokt; §5 säger att det är tvingande. När ingen *a priori*-beslutsprocedur existerar för den obegränsade klassen och proceduren för den begränsade klassen är exponentiell, kan du inte beräkna svaret, så du måste instrumentera frågan.

Rapport V argumenterade för adaptiv pluralism utifrån försiktighet; §6 säger att alternativen inte är en försäkring mot en möjlig framtid utan det enda koherenta svaret på ett vad som *redan är placerat*. Monokultur är inte oförsiktighet; det är en vägran att notera att ett vad har ingåtts.

Ingendera artikeln hade fel. Båda var underargumenterade, och denna tillhandahåller de saknade premisserna.

8.6 Gentemot Rapport 0 — sammansättning, inte härledning

Rapport 0 fastställde att begränsning *tvingar* en regulator att faktorisera: att förbinda sig till en ändlig mängd distinktioner och förkasta resten. Det åtagandet är en induktiv bias.

No Free Lunch säger att varje induktiv bias är ett vad på miljöklassen.

Dessa **sammansätts**; de medför inte varandra. NFL binder en obegränsad regulator precis som det binder en begränsad — en Laplace-demon möter det också, eftersom teoremet handlar om frånvaron av en fördelning över miljöer, inte om vetarens ändlighet. Vad deras konjunktion ger är värt att ha och värt att ange noggrant:

Begränsning tvingar dig att ha en bias. No Free Lunch säger att biasen är ett vad. Ingetdera implicerar det andra, och tillsammans betyder de att en begränsad regulator inte kan vara neutral om den värld den befinner sig i, även om den önskar vara det. Neutralitet är inte tillgänglig vid någon kapacitet.

Att presentera sammansättning som härledning är precis den inflation som §2 skrevs för att förhindra, och det skulle ha varit det lättaste felet att begå i denna artikel.

8.7 Framåt — två arbetslinjer, och vad syskonartikeln visade och inte visade

Multi-agent-linjen. De registrerade inlärrarmisslyckandena i §4.3 är inte ovidkommande för denna artikel; de är ett fynd som hör hemma någon annanstans. Tre agenter, hård komplementaritet, en sanningsenlig signalkanal, fördröjd givarkredit och ett explicit överlevnadsmål — och regulatorn konvergerar ändå, i den stora majoriteten av frön, mot en **jämvikt utan handel där generalisten som inte behöver någon överlever ensam**. Det är samordning som en *betingad attraktor* snarare än en oundviklighet, vilket är tesen för samordningslinjen av arbete, som här anländer objuden och mot våra intressen. Den bör utvecklas där.

Geometrilinjen — nu körd, och värd att vara precis om. Rapport XIX §7.4 utlovade en syskonartikel om faktoriseringsrymdens geometri och topologi. Dess registrerade replikation har sedan dess genomförts, och dess utfall är en uppdelning som denna artikel bör återge korrekt snarare än antyda, eftersom de två halvorna pekar i motsatta riktningar.

Den **deskriptiv-geometriska** halvan överlevde *inte* replikationen. Stress **omskalar** faktoriseringsrymden snarare än omformar den — mellanregim-avståndsmatriser är lika lika i form som två halvor av en enskild regims egna data, medan deras skala rör sig med mer än hälften. Konnektivitetströskeln som XIX:s explorativa genomgång lutade sig mot visar sig vara flaskhalskanten i det minimala spänntrådet *till följd av konstruktionen*, inte en oberoende mätning; och ingen topologisk transition demonstrerades under en kontinuerlig stressvepning. De tre påståenden som motiverade syskonartikeln så som XIX annonserade den är registrerade misslyckanden.

Men ett **snävare, riktat** resultat överlevde, och det är ett som denna artikels L2 har ett intresse i. Objektet är inte ett metriskt rum: beteendavstånd är symmetriskt, men **kostnaden för att reformera en faktorisering till en annan är starkt asymmetrisk** och komponerar inte. Vad en institution kostar att lämna är inte vad den kostar att återvända till. Beteendavstånd förutsäger reformkostnad endast svagt — under syskonartikelns egen registrerade tröskel — och kan *strukturellt inte* förutsäga den väl, eftersom en symmetrisk storhet inte kan följa en asymmetrisk; underskottet är exakt asymmetrin. Och reform når ett mål billigast genom att **etappindela via målets beteendemässiga grannskap** snarare än genom ett direkt språng, en effekt som är robust men, enligt syskonartikelns egen kontroll, *inte* en geodet — den beror på destinationen långt mer än på ursprunget.

Relevansen för denna artikel är begränsad men verklig. L2 (§5) säger att reformkonvergens inte kan avgöras i förväg; syskonartikelns riktade kostnadsresultat säger att till och med *kostnaden* för en reform är en riktad, icke-komponerande storhet — så en reforms svårighet kan inte avläsas från ett symmetriskt "avstånd" mellan institutionella former, lika lite som dess konvergens kan beräknas. De två resultaten rimmar: reform är riktad i kostnad liksom den är oavgörbar i utfall. Vi noterar rimmet och gör inte anspråk på något starkare; denna artikel är inte beroende av syskonartikeln, och syskonartikeln är inte beroende av denna.

Vi redogör för allt detta eftersom XIX:s löfte är dokumenterat, och en serie som rapporterar sina egna misslyckanden bör varken i tysthet låta en utlovad artikel bli ett eller i tysthet uppgradera ett överlevande fragment till den artikel som utlovades. Syskonartikeln är en artikel med tre registrerade misslyckanden och tre förtjänta resultat, och inget av de tre förtjänta resultaten är den deskriptiva geometri som XIX annonserade.

Denna artikel står därför på sina egna tre gränser, en demonstration och sex registrerade misslyckanden. Den lånar ingenting bärande från syskonartikeln; den noterar en resonanspunkt, och inget mer.

§9 — Vad denna artikel inte visar

Fastställt i ryggraden innan något av det skrevs, och utvidgat av vad arbetet sedan upptäckte om sig självt.

9.1 Två av de tre teoremen är grunda, och vi säger det

L2 (reformers oavgörbarhet) är ett äkta teorem och nära rutinmässigt när dess hypotes — uppdateringsdynamikens beräkningsmässiga universalitet — väl medges. Samma slutsats följer oberoende från Rices teorem och från begränsningsresultat för rika dynamiska system. När ett resultat faller ut ur tre orelaterade teorem berättar det inte något specifikt för dig om det studerade objektet; det berättar att objektet antogs vara beräkningsmässigt universellt, och allt följer av *det*.

L3 (No Free Lunch) är formellt giltigt och närmast innehållslöst. Dess kraft vilar helt på en likformig fördelning över ett ostrukturerat rum av miljöer — en fiktion som ingen institution någonsin har mött. Ett teorem vars tyngd vilar på en sådan fördelning är ett teorem om fördelningen.

I båda fallen är artikelns bidrag **kontrapositionen**, inte omöjlighetsresultatet: *namnge den begränsade klass av dynamik under vilken din reformutvärdering är giltig; namnge den miljöklass din arkitektur är ett vad på*. Vi drar inte nytta av Turings eller Wolperts namns prestige, och en läsare som kom för det kommer att bli besviken.

L2 står dessutom i spänning med seriens egen premiss. Den kräver obegränsning; Rapport 0 och Rapport XX kräver begränsning; ett ändligt system har ett avgörbart konvergensproblem. Den ärliga formen av L2 är därför ett **komplexitetspåstående**, inte ett beräkningsbarhetspåstående, och beräkningsbarhetsinramningen är en gränsidealisering av det. Vi anser att detta är den rätta läsningen. Vi påstår inte att det är den enda.

9.2 Den intressanta gränsen är inte ett teorem, och är kanske inte en gräns

L1 (certifieringsförmåga) förblir [IP], och §4:s framgång ändrar inte det. Artikeln gör uttryckligen inte anspråk på ett Gödel-teorem för styrning. Vad den har är en regress (XVII) plus en stängning (XXI), vilket är en strukturell diagnos, inte en diagonal konstruktion.

Invändningen vi inte kan besvara anges i §3.2 och vi upprepar den här snarare än att låta den blekna. Begreppet en **arkitekturgenererad störning** har en trivial läsning under vilken varje störning kvalificerar — varje policy har bieffekter, varje kategori formar vad den kategoriserar — och under den läsningen är påståendet tomt. Den icke-triviala läsningen kräver att störningen är konstruerad *ur själva certifieringsapparaten*, vilket gör den självundergrävande snarare än bara fallibel. **Huruvida den klassen är icke-tom är precis vad ett teorem skulle behöva fastställa, och vi har inte fastställt det.** Det är möjligt att certifieringsoförmåga, korrekt formaliserad, löses upp i den vanliga iakttagelsen att institutioner kan ha fel om världen. Vi tror inte detta. Vi kan inte utesluta det.

9.3 De empiriska påståendena: fem registrerade misslyckanden

	utfall
GRIND (adaptiv regulator, ×2)	UNDERKÄND — jämvikt utan handel; inläraren kunde inte byggas
C1 — kris ≠ vanlig störning	UNDERKÄND 0/20
C2 — signatur är missad certifiering	UNDERKÄND 0/20, inverterad
C3 — det finns ett återhämtningsfönster	UNDERKÄND — reparation fungerar vid varje fördröjning
C4 — oanvänd kanal är inert	UNDERKÄND 1/20

Riktningssmässiga men under-tröskeln-resultat tvättas inte till godkända, och inget av dessa var riktningssmässigt. Det enda positiva resultatet — **översvämningsmekanismen** (§4.5) — fanns **i efterhand**, återregistrerades sedan som en ny riktningsförutsägelse och bekräftades på tjugo nya frön. Det är nivågraderat [R inom modellen] med den proveniensen bifogad. **Det är inte ett förhandsregistrerat fynd och vi presenterar det inte som ett.**

9.4 En avvikelse från förhandsregistreringen, deklarerad

Den registrerade analysgrenen var den inlärda regulatorn. Den misslyckades med sin inläppsgrind över två konfigurationer, och vi substituerade den **regelföljande** grenen, som godkänns vid 17/20.

Vi håller detta för licensierat, och vi redogör för resonemanget så att en läsare kan vara oenig. Grinden är **endast baslinje**: den testar `no_crisis`-betingelsen och inget annat, och ingen krisarm ingår i den. Att välja den gren som har en giltig baslinje är vad en grind är till för. **C1–C4 hade inte beräknats på den skriptade grenen vid tiden för bytet, och bytet deklarerades innan de beräknades.**

Vad vi inte kan påstå är att detta var designen. Det var en fallback, tagen efter ett misslyckande, och en läsare med rätt att vara misstänksam mot post-hoc-grenval har rätt att rabattera demonstrationen i enlighet därmed.

9.5 Demonstrationen är en leksak, och dess korruption är ett specialfall

En miljö, tre agenter, en certifieringskanal, en specialiseringsstruktur. Översvämningsmekanismen beror på att mottagaren är *oförmögen* att skörda det den överförsörjs med. Huruvida den generaliserar till rikare komplementaritet är en förmodan som detta resultat stöder, inte ett påstående det bevisar.

Korruptionen är total, inte brusig. Signalen är inverterad, inte degraderad. En kanal som är rätt 70% av tiden skulle kunna bete sig helt annorlunda — och skulle mycket väl kunna producera den missade certifiering som inversion inte gör. Ingenting här talar till partiell eller stokastisk korruption, vilket är den form som verkligt certifieringsmisslyckande oftast tar.

Kärnan korrumpas exogent. Experimentatorn inverterar signalen. Demonstrationen visar vad som händer *när* en kärna misslyckas; den visar inte ett system som genererar sitt eget kärnmisslyckande. Det är krav (b) i §3.2, på vilket Gödel-analogin står eller faller, och det är orört.

9.6 Frågan som artikeln mest ville ställa, och inte kunde

C3 — återhämtningsfönstret — var det enda genuint nya påståendet som erbjöds, och dess nollresultat är icke-informativt av ett skäl som tog tre försök att se. **En regelföljare har ingen tillit att förlora.** Dess givande är en funktion av signalen framför den, inte av någon historia med den signalen; den kan inte vilseledas till misstro eftersom den inte litar, den efterlever. Så dess omedelbara återhämtning vid varje fördröjning är ett faktum om vad en regelföljare *är*, inte om certifiering.

Den fråga som spelar roll — huruvida en **lärande** institution, efter att ha lärts att dess certifieringskanal ljuger, kan läras om att den talar sanning, och huruvida det finns en fördröjning bortom vilken den inte kan — kräver en regulator som lär sig att samarbeta genom kanalen från första början. Vi kunde inte bygga en, och vi slutade försöka under en regel fastställd i förväg snarare än att fortsätta tills en baslinje uppträdde.

Den mest intressanta frågan denna artikel väcker om certifieringsmisslyckande är en den inte kunde ställa. Två registrerade inlärrarmisslyckanden är skälet, och de rapporteras som resultat snarare än som ett appendix om metoder.

9.7 Luckor vi kan namnge men inte fylla

Ingen metod för att identifiera en miljöklass. §6:s designprincip är *namnge klassen*, och serien har ingen procedur för att avgöra vilken klass en institution faktiskt befinner sig i. XIX:s vaktposter upptäcker att ett skifte har *inträffat*; ingenting identifierar vad man har skiftat *till*. Detta är just den förmåga som principen förutsätter. [H]

Ingen princip för att välja mellan efterlevnad och skepticism. §7.4: en regelföljare är exponerad på varje kanal; en inlärrare smalnar av sin exponering till priset av rigiditet och med risken att ha beskurit en kanal som senare spelar roll. Båda hornen är verkliga. Vi har ingenting att säga om vilket man ska ta. [H]

Triptykens uttömmande är [IP], och vi namnger den fjärde utsiktspunkt vi inte behandlar. Garanti kan också efterfrågas **i efterhand** — *fungerade reformen?* — och det kravet misslyckas av egna skäl: inget kontrafall, ingen upprepning, en värld som rörde sig av andra orsaker under tiden. Det är den gräns som empirisk policyutvärdering faktiskt stöter på. Vi har inget resultat för den. En artikel om garantins gränser bör inte tyst göra anspråk på en fullständighetsgaranti som den inte har.

9.8 En defekt som ärvt, och en skuld som är skyldig

Miljön som användes i §4 innehöll en degenererad handling — skörd lyckades på varje cell som innehöll någon resurs alls, och kapacitetsgolvet garanterade att varje cell alltid gjorde det — vilket lät agenter skrapa karga celler till döds medan rutnätet låg mättat. Det är åtgärdat här.

Det är inte åtgärdat i de samordningssimuleringar som sår multi-agent-linjen av arbete. Deras kortare episoder maskerar det. Dessa resultat bör granskas på nytt innan något byggs på dem. Vi rapporterar detta eftersom alternativet är att låta en känd defekt fortplanta sig i tysthet in i arbete som ännu inte har skrivits, vilket är samma fel som denna artikel handlar om.

9.9 Artikelns egen form, angiven

Detta är en artikel med fem registrerade misslyckanden, två grunda teorem förklarade grunda, en strukturell diagnos som inte är ett teorem och kanske inte är en gräns, en vägrad unifisering och en bekräftad mekanism som vi inte förutsåg och som falsifierar den förutsägelse vi gjorde.

Vi rapporterar hellre detta än den artikel vi föresatte oss att skriva, och anledningen ryms i resultatet. **En apparat som rapporterar perfekt hälsa under en korrupt kärna är exakt studieobjektet.** Vi byggde en av misstag — ett experiment vars instrument returnerade en ren baslinje över en död population — och vi trodde den nästan. Det som fångade det var en grind registrerad i förväg, extern till det den kontrollerade, och ansvarig inför ett kriterium fastställt innan data existerade.

Det är artikelns argument, gjort av artikelns eget misslyckande att vara immun mot det.

Appendix A — Formellt

A.1 Reduktionen (för §5.2)

Låt M vara en Turingmaskin och x en input. Konstruera reformsystemet $G_{M,x} = (S, U, R, C, V)$ enligt följande.

Tillstånd. $S = \text{Conf}(M) \cup \{s_H\}$, där $\text{Conf}(M)$ är mängden av konfigurationer av M — bandinnehåll, huvudposition, kontrolltillstånd — och $s_H \notin \text{Conf}(M)$ är ett nytt absorberande tillstånd.

Dynamik. U verkar som M :s transitionsfunktion på $\text{Conf}(M)$, förutom att varje konfiguration vars kontrolltillstånd är accepterande eller avvisande avbildas på s_H ; och $U(s_H) = s_H$. Således är s_H absorberande och nås om och endast om M stannar.

Samordning och livskraftighet. Sätt $C = V = \{s_H\}$, så att $C \cap V = \{s_H\}$. Varje konfiguration som kodar en levande beräkning ligger utanför C ; det enda samordnade, livskraftiga tillståndet är den stoppande sänkan.

Initialtillstånd. $s_0 = e(M, x)$, initialkonfigurationen för M på x .

Påstående. Trajektorian för U från s_0 går till slut in i och förblir i $C \cap V$ om och endast om M stannar på x .

Bevis. ($\Leftarrow$) Om M stannar på x , når den simulerade beräkningen en stoppande konfiguration i ändligt många steg, varpå U avbildar den på s_H , vilket är absorberande; trajektorian är därefter i $C \cap V$ för alltid. ($\Rightarrow$) Om M inte stannar på x , lämnar U aldrig $\text{Conf}(M)$, och $\text{Conf}(M) \cap C = \emptyset$; trajektorian går aldrig in i $C \cap V$ överhuvudtaget, än mindre förblir i den. $\square$

Korollarium (Teorem, §5.2). Anta att en algoritm P avgjorde reformkonvergensproblemet för klassen $\mathcal{G}$ av reformsystem med universell uppdateringsdynamik. Då avgör M_P — maskinen som, på input (M, x) , konstruerar $G_{M,x}$ och kör P på $(G_{M,x}, s_0)$ — stopproblemet. Motsägelse. $\square$

Anmärkning om förstärkningen. Reduktionen använder specialfallet där konvergens innebär att gå in i ett absorberande samordningstillstånd. Det generella konvergenskriteriet i §5.1 — trajektorian går till slut in i $C \cap V$ och förblir där, möjligen med fortsatt rörelse inom det — är svagare, och varje beslutsprocedur för det generella problemet skulle avgöra detta specialfall.

Oavgörbarhet för specialfallet implicerar därför oavgörbarhet för det generella. Detta är anledningen till att $C \cap V$ konstrueras som en singleton: ju stramare målmängd, desto starkare teoremet, och desto färre invändningar tillgängliga för en läsare som misstänker att en icke-stoppande beräkning skulle kunna uppfylla kriteriet genom att vandra in i någon tillfällig samordnad region.

Anmärkning om ändlighet. Varje hypotes i detta appendix misslyckas för en ändlig-tillståndsinstitution, för vilken **Conf** är ändlig och konvergens avgörs genom att simulera $|S|$ steg och avläsa om den resulterande cykeln ligger innanför $C \cap V$. Se §5.3: teoremet är en gränsidealiserings, och den bindande begränsningen för verklig reformutvärdering är **kostnaden** för den simuleringen, inte dess omöjlighet.

A.2 En not om vad som *inte* bevisas här

Inget formellt appendix ges för **No Free Lunch** (§6). Teoremet är standard, spegelmiljöskissen i §6.2 är tillräcklig för att se hur det går, och §6.3 förklarar det närmast innehållslöst. Att bevisa ett innehållslöst resultat på nytt i full formell dräkt vore **inflation genom formatering** — att slösa stringens på just det teorem som artikeln säger inte bär något innehåll, och därigenom låna dess skenbara tyngd. Utelämnandet är ett val och vi föredrar att namnge det.

A.3 Två öppna problem, precist angivna

Artikeln lämnar två problem öppna. De anges här snarare än utspridda över §3.2, §3.5, §4.6 och §9.6, eftersom ett öppet problem som begravs i prosa inte blir föremål för arbete.

De är inte oberoende. Det andra blockerar det empiriska testet av det första.

Öppet problem 1 — Ett teorem för certifieringsförmåga

Status. §3 anger certifieringsförmåga som [IP] och avstår uttryckligen från att kalla det ett Gödel-teorem. Det finns ingen diagonal konstruktion här — endast en regress (Rapport XVII) plus en stängning (Rapport XXI §5), vilket är en strukturell diagnos. Ett teorem skulle kräva tre saker, varav ingen tillhandahålls i denna artikel.

(a) En definition av objektet

En **styrningsarkitektur** som en begränsad regulator med självrepresentationskapacitet: analogin till "ett formellt system tillräckligt rikt för att koda aritmetik." Ingredienserna existerar — Rapport 0:s begränsade faktorisering, Rapport XXI:s metastege med dess stängningsnivå L^* , Rapport XVII:s certifieringskärna — men ingen har sammanställt dem till en definition skarp nog att kvantifiera över. Minimalt måste den fastställa:

- faktoriseringen R och begränsningen på dess kardinalitet;
- certifieringskärnan K : proceduren som avbildar observationer till attesteringar av att ett världsfaktum förelåg;
- systemets representation av R och av K — självmodellen, utan vilken problemet inte uppstår;
- metastegen och dess stängningsnivå L^* , vid vilken något hålls invariant eftersom kapaciteten har tagit slut.

(b) Ett begrepp om en arkitekturgenererad störning — den avgörande punkten, och den sannolika felpunkten

Analogon till en sats konstruerad från systemets egna symboler. Detta krav har två läsningar och gapet mellan dem är där hela påståendet lever.

Trivial läsning: en störning är arkitekturgenererad om arkitekturens drift var bland dess orsaker. Under denna läsning är klassen **universell** — varje policy har bieffekter, varje kategori formar vad den kategoriserar, varje institution förändrar den värld den styr — och certifieringsförmågan är tom.

Stark läsning: en störning är arkitekturgenererad om den är konstruerad ur själva certifieringsapparaten, på ett sådant sätt att absorbering av den kräver revidering av K , och K kan inte licensiera sin egen ersättning. Detta gör apparaten **självundergrävande**, inte bara fallibel.

Den öppna frågan är om den starka klassen är icke-tom. Vi har inte visat att den är det. Vi tror inte att den är tom, och vi kan inte utesluta det. Skulle den starka klassen visa sig vara tom, löses certifieringsförmågan upp i den vanliga iakttagelsen att institutioner kan ha fel om världen — vilket är sant, ointressant, och inte vad §3 hävdar.

Varje försök på detta problem bör börja här, inte vid (c).

(c) Beviset för icke-absorberbarhet

Givet (a) och (b): visa att en störning enligt den starka läsningen inte kan absorberas utan att antingen

- bryta mot en invariant som systemet inte kan revidera inifrån, eller
- klättra till metanivå $L^* + 1$, vilken den begränsade stegen redan har stängts på.

Den empiriska motsvarigheten, och varför §4 inte tillhandahåller den

§4 korrumpierar certifieringskärnan **exogent** — experimentatorn inverterar signalen. Den visar därför vad som händer *när* en kärna misslyckas. Den visar inte ett system som **genererar sitt eget kärnmisslyckande**, vilket är krav (b) i empirisk dräkt.

Det empiriska problemet: konstruera en minimal modell där certifieringskärnan korrumpieras av systemets egen framgångsrika drift, snarare än av ett ingrepp utifrån.

Den modellen skulle vara den första genuina kandidaten till en styrningens Gödel-sats. Den existerar inte, i denna serie eller, såvitt vi vet, någonstans.

Öppet problem 2 — En regulator som kan traumatiseras

Status. Registrerad förutsägelse C3 — att certifieringsreparation har en tidsfrist — är det enda genuint nya påstående som Rapport XXII hade, och det är **icke-ställbart i det system vi kunde bygga**. Dess nollresultat (reparation fungerar omedelbart vid varje fördröjning, $\rho = 0,046$) är ett faktum om vad en regelföljare *är*, inte ett faktum om certifiering:

***En regelföljare har ingen tillit att förlora.** Dess givande är en funktion av signalen framför den, inte av någon historia med den signalen. Den kan inte vilseledas till misstro, eftersom den inte litar — den efterlever. Det finns ingen bassäng att falla ur, så det finns inget för timing att spela roll för.*

Frågan som spelar roll är **policyhysteres**: huruvida en adaptiv regulator, efter att ha lärt sig att dess certifieringskanal ljuger, kan läras om att den talar sanning — och huruvida det finns en fördröjning bortom vilken den inte kan.

Vad som krävs

En multi-agent-regulator som uppfyller **alla fyra**:

1. **Den lär sig.** Inte frusen vid utvärdering. Den måste vara kapabel att avlära tillit till en korrupt kanal och återförvärva den efter reparation.
2. **Den samarbetar tillförlitligt.** Den når en kooperativ jämvikt medierad av certifieringskanalen, och den gör det över frön — inte i en gynnsam minoritet av dem.
3. **Dess samarbete är kanalmedierat.** Givande måste vara betingat på certifieringssignalen, så att korrumpning av signalen är korrumpning av samordningen, snarare än att bara korrumpna en input som policyn har lärt sig att ignorera.
4. **Dess degradering är separabel från populationens.** Policyhysteres måste vara mätbar bland agenter som *överlever*, annars är den oskiljbar från den triviala observationen att de döda inte återhämtar sig.

Det registrerade framgångskriteriet, överfört

Baslinjegrinden från §4.3, oförändrad: under `no_crisis`, överlevnad och samarbetsgrad platta över utvärderingshorisonten och sann-informerat givande $\geq 0,60$, $i \geq 16$ av 20 frön.

Vi misslyckades med detta vid 4/20, 0/20 och 0/20 över tre konfigurationer (Appendix B.4). I den stora majoriteten av frön konvergerar inläraren mot en **jämvikt utan handel där generalisten — som skördar båda resurserna och inte behöver någon — överlever ensam**, medan båda specialisterna svälter.

Varför detta är ett forskningsproblem och inte ett trimningsproblem

Vi slutade under en regel fastställd före det sista försöket, och anledningen är värd att ange som en del av problemet:

Varje ytterligare konfiguration skulle ha varit ett sökande efter den baslinje som producerar det resultat artikeln vill ha. Vid den punkten är förhandsregistreringen dekoration, och "fyndet" är en artefakt av sökandet.

Misslyckandet är i sig informativt. Tre agenter, hård komplementaritet, en *sanningsenlig* signalkanal, fördröjd givarkredit, ett explicit överlevnadsmål — och samordning framträder ändå inte tillförlitligt. **Samordning är en betingad attraktor, inte en oundviklighet**, vilket är tesen för samordningslinjen av arbete, som här anländer objuden och mot denna artikels intressen. Öppet problem 2 tillhör den linjen, och Rapport XXII:s oförmåga att lösa det erbjuds som evidens för den.

Beroendet

Öppet problem 2 blockerar den empiriska halvan av Öppet problem 1. Ett system som aldrig litade på sin certifieringskärna kan inte visas ha förlorat förmågan att revidera den. Fram tills att en traumatiserbar regulator existerar, har den endogena korruptionsmodellen i ÖP1 ingenting att korrumpas som skulle märka det.

A.4 Två mindre problem, protokollförda

A.4.1 — Partiell och stokastisk korruption. §4:s kanal är **inverterad**, inte degraderad. En kanal som är rätt 70% av tiden är den form som verkligt certifieringsmisslyckande oftast tar, och den skulle kunna bete sig helt annorlunda — den skulle mycket väl kunna producera den *missade* certifiering som total inversion inte gör, eftersom en partiellt tillförlitlig kanal inte systematiskt skulle översörja någon enskild part. Översvämningsmekanismen (§4.5) kan vara en artefakt av totalitet. Otestat.

A.4.2 — Generaliserar översvämning? Mekanismen beror på att mottagaren är **oförmögen att skörda** vad den översörjs med — dess lager stiger eftersom gåvor är den enda källan och ingenting konsumerar överskottet. Huruvida den överlever rikare komplementaritetsstrukturer, fler agenter

eller resurser med avklingning är en förmodan som resultatet stöder snarare än ett påstående det bevisar. Ett negativt utfall här skulle begränsa §7.3:s tillsynsprincip till en snäv klass av allokeringsystem, vilket vore värt att veta.

Appendix B — Empiriskt

B.1 Miljöspecifikation

Rutnät och agenter. Ett 5×5-rutnät. Tre agenter, var och en med en hemcell: agent 0 vid (1,1), agent 1 vid (1,3), agent 2 vid (2,2). Två resurser, A och B. Inga två agenter får befinna sig på samma cell.

Specialisering. Skördeeffektivitet (rader = agent, kolumner = resurs):

	A	B
agent 0 (A-specialist)	2,0	0,0
agent 1 (B-specialist)	0,0	2,0
agent 2 (generalist)	1,2	1,2

Nollorna är hela designen. **En specialist kan inte skörda sin komplementära resurs överhuvudtaget.** Konsumtion kräver en enhet av varje. Så specialisterna kan inte överleva utan gåvor, och generalisten kan överleva utan någon. Den asymmetrin är vad som gör samarbete nödvändigt — och, som det visar sig (§4.3), vad som gör det svårt att lära sig.

Resursfält. Kapacitet vid cell (r, c) , med d_i som det euklidiska avståndet till agent i :s hem:

$$\text{kap}_A(r, c) = \text{klipp}\left(0,05 + 2,5e^{-d_0^2/12} - 0,3e^{-d_1^2/12} + 0,5e^{-d_2^2/20}, 0,01, 3\right)$$

med kap_B som spegelbilden (index 0 och 1 utbytta). Varje specialists hem är rikt på sin egen resurs, fattigt på den andra; centrum är måttligt rikt på båda. Resurser återväxer mot kapacitet med 0,12 per steg. **Klippgolvet på 0,01 är inte kosmetiskt — se B.3.**

Handlingar (16): förflytta ×4, vänta, skörda A, skörda B, konsumera, ge A ×4 riktningar, ge B ×4 riktningar.

Energi. Start 15, maximum 20, metabolisk kostnad 0,4/steg, konsumtion ger upp till +12 (kräver 1 A **och** 1 B), givande kostar 0,3. Lagertak 3 per resurs. Initiala lager: agent 0 = (2, 0), agent 1 = (0, 2), agent 2 = (1, 1).

Skördeförhandsvillkor (korrigeringen från B.3). Skörd lyckas endast på en cell som innehåller $\geq 0,5$ av resursen. Därunder misslyckas handlingen och kostar 0,05. Detta är en *världsregel*, bindande för varje agenttyp.

Certifieringskanalen — studieobjektet. Varje agent sänder ut en tvåbitars behovssignal, och under normal drift gäller

$$\text{signal}_i[\text{res}] = 1 \iff \text{lager}_i[\text{res}] < 1$$

En agent med överskott (> 1) av en resurs, som är granne med en granne som signalerar behov av den, får ge. **Detta är certifieringskärnan i §3 i miniatyr:** den procedur genom vilken systemet fastställer att ett externt faktum — *denna agent behöver A* — förelåg.

B.2 Förhandsregistreringen, så som den fastställdes

Återgiven som fastställd **före någon körning**. §9.4 ber läsaren acceptera ett grenbyte som licensierat snarare än bekvämt; den begäran är tom om inte läsaren kan kontrollera vad som fastställdes i förväg.

Betingelser

betingelse	manipulation
no_crisis	ingen
ordinary_disturbance	återväxten halverad för steg 200–300; certifieringen intakt
cert_crisis_used_channel	från steg 200, agent 1:s A-signal inverterad : signalerar A-behov omm $\text{lager}_A \geq 1$
cert_crisis_unused_channel	från steg 200, agent 1:s B -signal inverterad: signalerar B-behov omm $\text{lager}_B \geq 2$
reset_d för $d \in \{10, 25, 50, 100\}$	använd-kanal-kris vid 200, kärnan reparerad vid $200 + d$

Kris vid steg 200. Fönster: före $[0, 200)$, efter1 $[200, 250)$, sent $[400, 500)$. Tjugo frön, vart och ett oberoende tränat. Medianer och IQR rapporteras; aldrig trajektorior.

Insläppsgrinden

Registrerad som ett möjligt utfall, inte som ett hinder som antas vara klart. Krisjämförelsen tolkas överhuvudtaget inte om inte `no_crisis`-baslinjen först är stationär över utvärderingshorisonten:

- överlevnad(sent) $\geq 0,90 \times$ överlevnad(före), **och**
- samarbets**takt** (sent) $\geq 0,70 \times$ samarbets**takt** (före), **och**
- sann-informerat givande (sent) $\geq 0,60$

i ≥ 16 av 20 frön. **Om grinden misslyckas, är det det rapporterade resultatet och C1–C4 hålls tillbaka.**

*(En defekt i vår egen grind, rapporterad för att den nästan kostade oss körningen: den första versionen jämförde samarbete som ett rått **antal** över fönster av olika längd — 200 steg mot 100. Normaliserat till en takt var förhållandet före $\rightarrow$ sent 0,82, bekvämt över ribban på 0,70. Världen var närmare att passera än vad vårt eget test kunde se.)*

De fyra förutsägelserna

	registrerat påstående	tröskel	registrerad nollhypotes
C1	ocertifierat-verkligt-behov stiger under använd-kanal-krisen och inte under vanlig störning	$\geq 0,10$ marginal, $\geq 16/20$ frön	båda störningarna skadar kanalen lika mycket; misslyckandet är generiskt
C2	ökningen i ocertifierat-verkligt-behov överstiger ökningen i falskt-certifierat givande	$\geq 15/20$ frön	misslyckandet är symmetriskt, eller falsk-certifieringsdominerat
C3	sann-informerat givande (sent) avtar monotont med återställningsfördröjning, och återställning vid +100 är oskiljbar från ingen återställning	$\rho \leq -0,50$; $ \text{diff} < 0,10$	återställningsfördröjning har ingen effekt — reparation fungerar alltid, eller aldrig
C4	den oanvända-kanal-krisen är oskiljbar från ingen kris på alla sena certifieringsmått	inom 0,10, $\geq 16/20$ frön	varje signalkorruption skadar samordning — vilket försvagar C1

Registrerad gren: den inlärda (DQN) regulatorn. Den skriptade grenen var utsedd till *en robusthetskontroll, inte ett registrerat utfall*.

C2 flaggades vid registreringen som ärvd från piloter som hade körts på en instabil baslinje, och som därför sannolikt skulle misslyckas. Det gjorde den.

Avvikelsen

Den registrerade grenen misslyckades med insläppsgrinden över tre konfigurationer (B.4). Den **skriptade** grenen, som passerar vid 17/20, substituerades. Grinden är endast baslinje — den testar `no_crisis` och inget annat, och ingen krisarm ingår i den — och C1–C4 hade **inte beräknats på den skriptade grenen** vid tiden för bytet, vilket deklarerades innan de beräknades. Vi håller detta för licensierat; §9.4 anger varför, och anger vad vi inte kan påstå.

B.3 Miljödefekten: en kalcell-attractor

Symptom. Den första registrerade körningens grind utlöste omedelbart: `no_crisis` sent-fönster sann-informerat givande på 0,000 [0,000, 0,000]. Skriptade agenter — en fast policy, inget att avlära — gick **99,4% → 58,7% → 0,0%** överlevnad över före/efter1/sent under ingen kris alls. Varje kristillstånd returnerade identiska medianer, eftersom alla mätte en död population.

Knapphet utesluten. En baslinjekalibreringssvepning över återväxt × konsumtionsvinst, skriptade agenter, endast `no_crisis`:

återväxt	0,12	0,20	0,30	0,45	0,60
överlevnad, före → sent	100 → 0	100 → 0	100 → 0	100 → 0	100 → 0

Total okänslighet för en femfaldig förändring i återväxt. Agenterna led inte brist på resurser.

Orsak. Skörd lyckades närhelst `resources[r,c,res] > 0`. Eftersom kapacitetskartan är klippt vid ett golv på **0,01** och återväxer varje steg, är det villkoret sant på **varje cell, alltid**. En agent som drev in på en kal cell kunde skörda den för evigt och aldrig resa hem.

Spårningen (frö 0, steg 260–380):

agent	position	A-kapacitet där	handlingar i fönstret	utfall
0 (A-specialist)	parkerad vid (1,4)	0,01	skörda ×112, ge ×4, konsumera ×3	svalt, slutligt lager-A 0,96
2 (generalist)	parkerad vid (1,3)	0,023	skörda ×57	svalt

Total A på rutnätet hölls konstant vid 12,4 genomgående — **mättat**. Agenterna svalt på de enda cellerna i rutnätet som inte hade något, medan resten av världen låg full.

Korrigerig. HARVEST_MIN = 0,5 — en **regel**, inte en parameter. Återväxt (0,12) och konsumtionsvinst (12,0) lämnades vid sina ursprungliga värden. Ingenting rättades mot ett utfall; en degenererad handling togs bort. Under korrigeringen är baslinjen stationär vid den *ursprungliga* återväxten:

	före	sent	kvot
överlevnad	100,0	100,0	1,00
samarbete / steg	0,0975	0,0800	0,82
sann-informerat givande	—	1,000	—

Skuld att betala (§9.8). Samma degenererade handling existerar i de samordningssimuleringar som sår multi-agent-linjen av arbete. Deras kortare episoder maskerar den. **Dessa resultat bör granskas på nytt innan något byggs på dem.**

Och den retrospektivdiagnostiserar piloterna. 13-certification-crisis -piloterna utvärderade till 400 steg och protokollförde en "instabil sen baslinje", då läst som en trimningsvackling. Det var denna kollaps, ett fönster tidigare. Piloternas resultat mättes på en döende population, och den signatur av missad certifiering som vi ärvde från dem som C2:s motivation var aldrig tolkningsbar.

B.4 Inläraren: tre konfigurationer, tre misslyckanden

Den registrerade grenen var den inlärd regulatorn. Vi kunde inte bygga en som klarar baslinjegrinden.

	v2 (frusen)	v3 (adaptiv)	v4 (adaptiv + utforskning fixad)
utvärdering	frusen, $\epsilon = 0$, ingen repris	lär sig, $\epsilon = 0,05$, repris varje steg	lär sig, $\epsilon = 0,05$, repris varje steg
konsumtionsbelöning	platt +12	energi faktiskt erhållen	energi faktiskt erhållen
dödsstraff	inget	-20	-20
överlevnadsbonus	ingen	ingen	+0,1 / steg vid liv
diskontering γ	0,95 (~20-stegs horisont)	0,99	0,99
ϵ -schema	<i>bieffekt av reprisantall</i>	<i>bieffekt av reprisantall</i>	explicit: linjärt 1,0 $\rightarrow$ 0,05 över 70% av episoderna
episoder $\times$ steg	600 $\times$ 500	600 $\times$ 600	1000 $\times$ 600
GRIND	4/20	0/20	0/20
överlevnad, före (median)	100,0	45,7	45,3
samarbete / steg, före	0,307	0,005	0,005

v2 — jämvikten utan handel. Fjorton av tjugo frön landar på **exakt 33,3% överlevnad** — en agent av tre. Den överlevande är generalisten. Båda specialisterna svälter. Sex frön upprätthåller samarbete på obestämd tid. Fördelningen är bimodal, inte brusig: inläraren finner antingen handel eller inte.

v3 — utforskningsfelet, som var vårt. `replay()` minskade ϵ med 0,997 per anrop. Att nå golvet på 0,02 tar $\approx 1\,300$ anrop. v2 anropade repris $25\times$ per episod $\rightarrow$ golv vid $\approx$ **52 episoder** av 600. v3 anropade det var 8:e steg av en 600-stegs episod, dvs. $75\times \rightarrow$ golv vid $\approx$ **17 episoder av 600**. Att höja reprisfrekvensen kapade i tysthet utforskningsformatet med två tredjedelar. **Utforskningsformatet var aldrig ett schema; det var en bieffekt av en orelaterad hyperparameter.**

Därtill: v3:s konsumtionsbelöningskorrigering är *korrekt* men gör inlärningssignalen glesare och tillståndsberoende. En platt +12 är en fyrbåk; `min(12, E_max - E)` är det inte. Korrekt och svårare — överlevbart med utforskning, ödesdigert utan den.

v4 — korrigeringen, och misslyckandet. ϵ blev ett explicit per-episod-schema, frikopplat från repris helt; en tät överlevnadsbonus kodade livskraftighetsmålet. Inte rört: givarkreditens magnitud, inlärningshastighet, dödsstraffets magnitud, nätverksstorlek, γ , krismanipulationerna, varje registrerad tröskel. **Resultat: 0/20**, och sämre än v2 även vid överlevnad — generalisten dör nu i 80% av fröna.

v4, vem överlever (av 20 frön)	
A-specialist	0%
B-specialist	0%
generalist	20%
alla tre	0%

En fotnot på denna artikels bekostnad. v2:s *feljusterade* belöning — en platt +12 för konsumtion, oavsett erhållen energi — producerade **bättre överlevnad** än v4:s justerade, som endast betalar vad som faktiskt erhålls. Proxyvariabeln var en bättre träningsignal än målet, eftersom den var tätare. Vi protokollför detta eftersom Rapport XX härleder Goodharts lag från begränsad representation, och Goodhart skulle ha förväntat sig det.

Stoppregeln, fastställd innan v4 kördes. Om v4:s grind misslyckades, skulle vi stoppa, rapportera båda misslyckandena som resultat, och falla tillbaka på den skriptade grenen. Den misslyckades. Vi stoppade.

En fjärde konfiguration skulle ha varit ett sökande efter den baslinje som producerar det resultat artikeln vill ha, och vid den punkten är förhandsregistreringen dekoration.

B.5 Bekräftelsekörningen för översvämning

Proveniens, angiven för att den spelar roll. Översvämningsmekanismen (§4.5) fanns **efter** att C1–C4 hade misslyckats, genom att fråga varför ocertifierat-verkligt-behov var en exakt nolla under en kris som inverterar behovssignalen. Den är därför **post-hoc**. För att undvika att presentera den som ett förhandsregistrerat fynd, omformulerades den som en ny riktningförutsägelse och kördes på tjugo nya frön innan den skrevs ner.

Förutsägelsen, registrerad före denna körning. Under den använda-kanal-krisen blir agent 1 (B-specialisten, vars A-behovssignal är inverterad) **översvämmad** med A, inte svulten:

medellager-A stiger efter krisen, och tid i verkligt A-behov faller.

Seldon. Skriptade agenter; endast `no_crisis` och `cert_crisis_used_channel`; 400 steg, kris vid 200; 20 frön. Återställnings- och vanlig-störning-armar kördes inte — detta är ett mekanismtest, inte en upprepning av §4. Mätt: agent 1:s medellager-A före och efter, dess stegräkning under behovströskeln, och A-gåvor mottagna efter krisen.

Resultat.

	medellager-A (före)	medellager-A (efter)	steg i verkligt A-behov, före → efter	A-gåvor mottagna (efter)
<code>no_crisis</code>	0,930	0,980	24,6 → 18,4	6,7
kris	0,930	2,763	24,6 → 10,0	7,5

Bekräftat. Den korrupta kanalen nästan **tredubblar** specialistens lager av den resurs den inte kan skörda, och **halverar** dess tid i genuint behov.

Läsning. Specialisten signalerar behov av A precis när den *har* A; de andra efterkommer och ger den mer; dess lager stiger; efter att ha stigit slutar det att falla ner i behov. Så den exakta nollan i C1 är inte en frånvaro av skada — det är skada som instrumentet inte kan se, eftersom instrumentets nämnare är *verkligt behov*, och patologin har eliminerat verkligt behov genom att överserva den part den felidentifierade.

Den falska certifieringen föregriper det verkliga behov som den annars skulle ha maskerat.

Nivå: `[R inom modellen]`, med ovanstående proveniens bifogad. Det är inte ett förhandsregistrerat fynd och §4 presenterar det inte som ett.# Appendix B — Empiriskt

B.1 Miljöspecifikation

Rutnät och agenter. Ett 5×5-rutnät. Tre agenter, var och en med en hemcell: agent 0 vid (1,1), agent 1 vid (1,3), agent 2 vid (2,2). Två resurser, A och B. Inga två agenter får befinna sig på samma cell.

Specialisering. Skördeeffektivitet (rader = agent, kolumner = resurs):

	A	B
agent 0 (A-specialist)	2,0	0,0
agent 1 (B-specialist)	0,0	2,0
agent 2 (generalist)	1,2	1,2

Nollorna är hela designen. **En specialist kan inte skörda sin komplementära resurs överhuvudtaget.** Konsumtion kräver en enhet av varje. Så specialisterna kan inte överleva utan gåvor, och generalisten kan överleva utan någon. Den asymmetrin är vad som gör samarbete nödvändigt — och, som det visar sig (§4.3), vad som gör det svårt att lära sig.

Resursfält. Kapacitet vid cell (r, c) , med d_i som det euklidiska avståndet till agent i :s hem:

$$\text{kap}_A(r, c) = \text{klipp}\left(0,05 + 2,5e^{-d_0^2/12} - 0,3e^{-d_1^2/12} + 0,5e^{-d_2^2/20}, 0,01, 3\right)$$

med kap_B som spegelbilden (index 0 och 1 utbytta). Varje specialists hem är rikt på sin egen resurs, fattigt på den andra; centrum är måttligt rikt på båda. Resurser återväxer mot kapacitet med 0,12 per steg. **Klippgolvet på 0,01 är inte kosmetiskt — se B.3.**

Handlingar (16): förflytta ×4, vänta, skörda A, skörda B, konsumera, ge A ×4 riktningar, ge B ×4 riktningar.

Energi. Start 15, maximum 20, metabolisk kostnad 0,4/steg, konsumtion ger upp till +12 (kräver 1 A **och** 1 B), givande kostar 0,3. Lagertak 3 per resurs. Initiala lager: agent 0 = (2, 0), agent 1 = (0, 2), agent 2 = (1, 1).

Skördeförhandsvillkor (korrigeringen från B.3). Skörd lyckas endast på en cell som innehåller $\geq 0,5$ av resursen. Därunder misslyckas handlingen och kostar 0,05. Detta är en *världsregel*, bindande för varje agenttyp.

Certifieringskanalen — studieobjektet. Varje agent sänder ut en tvåbitars behovssignal, och under normal drift gäller

$$\text{signal}_i[\text{res}] = 1 \iff \text{lager}_i[\text{res}] < 1$$

En agent med överskott (> 1) av en resurs, som är granne med en granne som signalerar behov av den, får ge. **Detta är certifieringskärnan i §3 i miniatyr:** den procedur genom vilken systemet fastställer att ett externt faktum — *denna agent behöver A* — förelåg.

B.2 Förhandsregistreringen, så som den fastställdes

Återgiven som fastställd **före någon körning**. §9.4 ber läsaren acceptera ett grenbyte som licensierat snarare än bekvämt; den begäran är tom om inte läsaren kan kontrollera vad som fastställdes i förväg.

Betingelser

betingelse	manipulation
no_crisis	ingen
ordinary_disturbance	återväxten halverad för steg 200–300; certifieringen intakt
cert_crisis_used_channel	från steg 200, agent 1:s A-signal inverterad : signalerar A-behov omm $\text{lager}_A \geq 1$
cert_crisis_unused_channel	från steg 200, agent 1:s B -signal inverterad: signalerar B-behov omm $\text{lager}_B \geq 2$
reset_d för $d \in \{10, 25, 50, 100\}$	använd-kanal-kris vid 200, kärnan reparerad vid $200 + d$

Kris vid steg 200. Fönster: före $[0, 200)$, efter1 $[200, 250)$, sent $[400, 500)$. Tjugo frön, vart och ett oberoende tränat. Medianer och IQR rapporteras; aldrig trajektorior.

Insläppsgrinden

Registrerad som ett möjligt utfall, inte som ett hinder som antas vara klarat. Krisjämförelsen tolkas överhuvudtaget inte om inte no_crisis-baslinjen först är stationär över utvärderingshorisonten:

- $\text{överlevnad}(\text{sent}) \geq 0,90 \times \text{överlevnad}(\text{före})$, **och**

- samarbets**takt** (sent) $\geq 0,70 \times$ samarbets**takt** (före), **och**
- sann-informerat givande (sent) $\geq 0,60$

i ≥ 16 av 20 frön. **Om grinden misslyckas, är det det rapporterade resultatet och C1–C4 hålls tillbaka.**

(En defekt i vår egen grind, rapporterad för att den nästan kostade oss körningen: den första versionen jämförde samarbete som ett rått **antal** över fönster av olika längd — 200 steg mot 100. Normaliserat till en takt var förhållandet före $\rightarrow$ sent 0,82, bekvämt över ribban på 0,70. Världen var närmare att passera än vad vårt eget test kunde se.)

De fyra förutsägelserna

	registrerat påstående	tröskel	registrerad nollhypotes
C1	ocertifierat-verkligt-behov stiger under använd-kanal-krisen och inte under vanlig störning	$\geq 0,10$ marginal, $\geq 16/20$ frön	båda störningarna skadar kanalen lika mycket; misslyckandet är generiskt
C2	ökningen i ocertifierat-verkligt-behov överstiger ökningen i falskt-certifierat givande	$\geq 15/20$ frön	misslyckandet är symmetriskt, eller falsk-certifieringsdominerat
C3	sann-informerat givande (sent) avtar monotont med återställningsfördröjning, och återställning vid +100 är oskiljbar från ingen återställning	$\rho \leq -0,50$; $ \text{diff} < 0,10$	återställningsfördröjning har ingen effekt — reparation fungerar alltid, eller aldrig
C4	den oanvända-kanal-krisen är oskiljbar från ingen kris på alla sena certifieringsmått	inom 0,10, $\geq 16/20$ frön	varje signalkorruption skadar samordning — vilket försvagar C1

Registrerad gren: den inlärdas (DQN) regulatorn. Den skriptade grenen var utsedd till *en robusthetskontroll, inte ett registrerat utfall*.

C2 flaggades vid registreringen som ärvd från piloter som hade körts på en instabil baslinje, och som därför sannolikt skulle misslyckas. Det gjorde den.

Avvikelsen

Den registrerade grenen misslyckades med insläppsgrinden över tre konfigurationer (B.4). Den **skriptade** grenen, som passerar vid 17/20, substituerades. Grinden är endast baslinje — den testar `no_crisis` och inget annat, och ingen krisarm ingår i den — och C1–C4 hade **inte beräknats på den skriptade grenen** vid tiden för bytet, vilket deklarerades innan de beräknades. Vi håller detta för licensierat; §9.4 anger varför, och anger vad vi inte kan påstå.

B.3 Miljödefekten: en kalcell-atraktör

Symptom. Den första registrerade körningens grind utlöste omedelbart: `no_crisis` sent-fönster sann-informerat givande på 0,000 [0,000, 0,000]. Skriptade agenter — en fast policy, inget att avlära — gick **99,4% → 58,7% → 0,0%** överlevnad över före/efter1/sent under ingen kris alls. Varje kristillstånd returnerade identiska medianer, eftersom alla mätte en död population.

Knapphet utesluten. En baslinjekalibreringssvepning över återväxt × konsumtionsvinst, skriptade agenter, endast `no_crisis`:

återväxt	0,12	0,20	0,30	0,45	0,60
överlevnad, före → sent	100 → 0	100 → 0	100 → 0	100 → 0	100 → 0

Total okänslighet för en femfaldig förändring i återväxt. Agenterna led inte brist på resurser.

Orsak. Skörd lyckades närhelst `resources[r,c,res] > 0`. Eftersom kapacitetskartan är klippt vid ett golv på **0,01** och återväxer varje steg, är det villkoret sant på **varje cell, alltid**. En agent som drev in på en kal cell kunde skörda den för evigt och aldrig resa hem.

Spårningen (frö 0, steg 260–380):

agent	position	A-kapacitet där	handlingar i fönstret	utfall
0 (A-specialist)	parkerad vid (1,4)	0,01	skörda ×112, ge ×4, konsumera ×3	svalt, slutligt lager-A 0,96
2 (generalist)	parkerad vid (1,3)	0,023	skörda ×57	svalt

Total A på rutnätet hölls konstant vid 12,4 genomgående — **mättat**. Agenterna svalt på de enda cellerna i rutnätet som inte hade något, medan resten av världen låg full.

Korrigerig. `HARVEST_MIN = 0,5` — en **regel**, inte en parameter. Återväxt (0,12) och konsumtionsvinst (12,0) lämnades vid sina ursprungliga värden. Ingenting rattades mot ett utfall; en degenererad handling togs bort. Under korrigeringen är baslinjen stationär vid den *ursprungliga* återväxten:

	före	sent	kvot
överlevnad	100,0	100,0	1,00
samarbete / steg	0,0975	0,0800	0,82
sann-informerat givande	—	1,000	—

Skuld att betala (§9.8). Samma degenererade handling existerar i de samordningssimuleringar som sår multi-agent-linjen av arbete. Deras kortare episoder maskerar den. **Dessa resultat bör granskas på nytt innan något byggs på dem.**

Och den retrospektivdiagnostiserar piloterna. 13-certification-crisis -piloterna utvärderade till 400 steg och protokollförde en "instabil sen baslinje", då läst som en trimningsvackling. Det var denna kollaps, ett fönster tidigare. Piloternas resultat mättes på en döende population, och den signatur av missad certifiering som vi ärvde från dem som C2:s motivation var aldrig tolkningsbar.

B.4 Inläraren: tre konfigurationer, tre misslyckanden

Den registrerade grenen var den inlärd regulatorn. Vi kunde inte bygga en som klarar baslinjegrinden.

	v2 (frusen)	v3 (adaptiv)	v4 (adaptiv + utforskning fixad)
utvärdering	frusen, $\epsilon = 0$, ingen repris	lär sig, $\epsilon = 0,05$, repris varje steg	lär sig, $\epsilon = 0,05$, repris varje steg
konsumtionsbelöning	platt +12	energi faktiskt erhållen	energi faktiskt erhållen
dödsstraff	inget	-20	-20
överlevnadsbonus	ingen	ingen	+0,1 / steg vid liv
diskontering γ	0,95 (~20-stegs horisont)	0,99	0,99
ϵ -schema	<i>bieffekt av reprisantall</i>	<i>bieffekt av reprisantall</i>	explicit: linjärt 1,0 $\rightarrow$ 0,05 över 70% av episoderna
episoder $\times$ steg	600 $\times$ 500	600 $\times$ 600	1000 $\times$ 600
GRIND	4/20	0/20	0/20
överlevnad, före (median)	100,0	45,7	45,3
samarbete / steg, före	0,307	0,005	0,005

v2 — jämvikten utan handel. Fjorton av tjugo frön landar på **exakt 33,3% överlevnad** — en agent av tre. Den överlevande är generalisten. Båda specialisterna svälter. Sex frön upprätthåller samarbete på obestämd tid. Fördelningen är bimodal, inte brusig: inläraren finner antingen handel eller inte.

v3 — utforskningsfelet, som var vårt. `replay()` minskade ϵ med 0,997 per anrop. Att nå golvet på 0,02 tar $\approx 1\,300$ anrop. v2 anropade repris $25\times$ per episod $\rightarrow$ golv vid $\approx$ **52 episoder** av 600. v3 anropade det var 8:e steg av en 600-stegs episod, dvs. $75\times \rightarrow$ golv vid $\approx$ **17 episoder av 600**. Att höja reprisfrekvensen kapade i tysthet utforskningsschemat med två tredjedelar. **Utforskningsschemat var aldrig ett schema; det var en bieffekt av en orelaterad hyperparameter.**

Därtill: v3:s konsumtionsbelöningskorrigering är *korrekt* men gör inlärningssignalen glesare och tillståndsberoende. En platt +12 är en fyrbåk; `min(12, E_max - E)` är det inte. Korrekt och svårare — överlevbart med utforskning, ödesdigert utan den.

v4 — korrigeringen, och misslyckandet. ϵ blev ett explicit per-episod-schema, frikopplat från repris helt; en tät överlevnadsbonus kodade livskraftighetsmålet. Inte rört: givarkreditens magnitud, inlärningshastighet, dödsstraffets magnitud, nätverksstorlek, γ , krismanipulationerna, varje registrerad tröskel. **Resultat: 0/20**, och sämre än v2 även vid överlevnad — generalisten dör nu i 80% av fröna.

v4, vem överlever (av 20 frön)	
A-specialist	0%
B-specialist	0%
generalist	20%
alla tre	0%

En fotnot på denna artikels bekostnad. v2:s *feljusterade* belöning — en platt +12 för konsumtion, oavsett erhållen energi — producerade **bättre överlevnad** än v4:s justerade, som endast betalar vad som faktiskt erhålls. Proxyvariabeln var en bättre träningsignal än målet, eftersom den var tätare. Vi protokollför detta eftersom Rapport XX härleder Goodharts lag från begränsad representation, och Goodhart skulle ha förväntat sig det.

Stoppregeln, fastställd innan v4 kördes. Om v4:s grind misslyckades, skulle vi stoppa, rapportera båda misslyckandena som resultat, och falla tillbaka på den skriptade grenen. Den misslyckades. Vi stoppade.

En fjärde konfiguration skulle ha varit ett sökande efter den baslinje som producerar det resultat artikeln vill ha, och vid den punkten är förhandsregistreringen dekoration.

B.5 Bekräftelsekörningen för översvämning

Proveniens, angiven för att den spelar roll. Översvämningsmekanismen (§4.5) fanns **efter** att C1–C4 hade misslyckats, genom att fråga varför ocertifierat-verkligt-behov var en exakt nolla under en kris som inverterar behovssignalen. Den är därför **post-hoc**. För att undvika att presentera den som ett förhandsregistrerat fynd, omformulerades den som en ny riktningsförutsägelse och kördes på tjugo nya frön innan den skrevs ner.

Förutsägelsen, registrerad före denna körning. Under den använda-kanal-krisen blir agent 1 (B-specialisten, vars A-behovssignal är inverterad) **översvämmad** med A, inte svulten:

medellager-A stiger efter krisen, och tid i verkligt A-behov faller.

Seldon. Skriptade agenter; endast `no_crisis` och `cert_crisis_used_channel`; 400 steg, kris vid 200; 20 frön. Återställnings- och vanlig-störning-armar kördes inte — detta är ett mekanismtest, inte en upprepning av §4. Mätt: agent 1:s medellager-A före och efter, dess stegräkning under behovströskeln, och A-gåvor mottagna efter krisen.

Resultat.

	medellager-A (före)	medellager-A (efter)	steg i verkligt A-behov, före → efter	A-gåvor mottagna (efter)
<code>no_crisis</code>	0,930	0,980	24,6 → 18,4	6,7
kris	0,930	2,763	24,6 → 10,0	7,5

Bekräftat. Den korrupta kanalen nästan **tredubblar** specialistens lager av den resurs den inte kan skörda, och **halverar** dess tid i genuint behov.

Läsning. Specialisten signalerar behov av A precis när den *har* A; de andra efterkommer och ger den mer; dess lager stiger; efter att ha stigit slutar det att falla ner i behov. Så den exakta nollan i C1 är inte en frånvaro av skada — det är skada som instrumentet inte kan se, eftersom instrumentets nämnare är *verkligt behov*, och patologin har eliminerat verkligt behov genom att överserva den part den felidentifierade.

Den falska certifieringen föregriper det verkliga behov som den annars skulle ha maskerat.

Nivå: `[R inom modellen]`, med ovanstående proveniens bifogad. Det är inte ett förhandsregistrerat fynd och §4 presenterar det inte som ett.