




Varför mångfald motstår formalisering

En tvär-ramverks misslyckandeatlas över utforskningsbevarande under optimeringstryck

Rapport XVI i serien Styrning som ingenjörskonst

Fyra discipliner — reglerteknik, evolutionsbiologi, institutionell ekonomi och beslutsteori — konvergerar oberoende mot en enda förfalls-plus-källtermsstruktur för erosion av alternativ under optimering. Föreslår källtermslokalitet som den korrigerade ordningsparametern. Rapport XVI i serien Styrning som ingenjörskonst.

Björn Kenneth Holmström

Juni 2026

Creative Commons Attribution-ShareAlike 4.0 International

<https://bjorkennethholmstrom.org/working-papers/why-diversity-resists-formalization>

Sammanfattning

Denna artikel undersöker upprepade försök att formalisera en enda intuition: att ett system som optimerar något mål tenderar att förbruka den kapacitet det senare skulle behöva för att upptäcka att målet är felaktigt. Intuitionen återkommer i många domäner – en lärande agent som koncentrerar sina föreställningar, en institution som befäster sig, en population som förlorar variation, en regulator som förlorar den signalrikedom den behöver för att fortsätta identifiera sitt system. Varje domän har ett inhemskt namn för den hotade kapaciteten och en inhemsk formalism för dess nedbrytning.

Den naiva förväntningen är att dessa är lösa analogier som inte överlever kontakt med varandra. Vi testade den förväntningen direkt. Fyra discipliner – reglerteknik, evolutionsbiologi, institutionell ekonomi och beslutsteori – fick samma strukturella fråga i strikt inhemsk vokabulär, med de gemensamma gränsöverskridande termerna förbjudna och det förväntade svaret undanhållet. De minimala formella utsagor som returnerades oberoende av varandra delar en struktur: en storhet som representerar för närvarande oanvända alternativ avtar under det primära målet och består endast genom en *källterm som den optimerande processen inte själv sätter*.

Vi föreslår **inte** en enhetlig teori om ”epistemisk adaptivitet”, ett mätbart index eller ett no-go-teorem. Det strukturella fyndet är avgränsat och taggat därefter **[IP]**. Vad det ger är en korrigerad ordningsparameter: inte en vag föreställning om optimerarens ”räckvidd”, utan **källtermens lokalitet** – huruvida den term som bevarar alternativ ligger innanför eller utanför optimerarens kontrollmängd. Två linser placerar den strikt utanför; två placerar den i ett omstritt område som fältet självt inte har stängt. Artikelns primära bidrag är därför diagnostiskt: en karta över var varje formalism lyckas lokalt, var var och en bryts, och den enda söm längs vilken brytningarna sammanfaller.

1. Objektet som flyttar sig

Fyra litteraturer innehåller en igenkännligt likartad varning.

En **Bayesiansk inlärare** som uppdaterar väl koncentrerar posterior massa på det som evidensen gynnar; ju bättre den lär sig, desto mer evidens kräver en senare rivaliserande hypotes för att rubba den. En **institution** som lyckas bäddar in sig i finansiering, verktyg, utbildning och identitet; ju nyttigare den blir, desto dyrare blir det att hoppa av. En **population** under ihållande riktat selektionstryck förlorar den stående variation som skulle låta den svara på en förändrad miljö. En **regulator** som skärper regleringen undertrycker exakt den insignalrikedom den behöver för att fortsätta identifiera det system den reglerar.

I varje fall finns en storhet som representerar *alternativ som inte för närvarande används* – och i varje fall tycks systemets egen framgång förbruka den. Frestelsen är att namnge den gemensamma storheten en gång för alla (”bestridbarhet”, ”utforskning”, ”mångfald”) och teoretisera den som ett objekt över alla fyra domänerna.

Vi motstår den frestelsen som artikelns grundläggande begränsning. **Huruvida de fyra föreställningarna namnger samma objekt är den fråga som testas, inte en premiss.** Historien om denna undersökning – ärligt redovisad i §2 – är en sekvens av försök att namnge det gemensamma objektet som var och en lyckades lokalt och bröt samman när den pressades en nivå upp. Objektet fortsatte att *flytta sig*: från föreställningar, till modeller, till representationer, till själva selektionsvillkoren. Den rörligheten är det centrala fenomenet. Ett begrepp som förflyttar sig så fort det pressas är antingen mycket djupt eller underbestämt, och de två är svåra att skilja från insidan av den ram som pressar.

2. Metod: motsägelsefull degradering som evidens

Artikeln evidens är av två slag, och det första är ovanligt nog för att anges tydligt.

2.1 Degraderingskurvan

Undersökningen inleddes med ett starkt påstående – *förbättring eroderar bestridbarhet* – som utsattes för ihållande kritik av en panel av avancerade språkmodeller använda som medvetet dekorrelerade observatörer (rollisolerade, olika familjer, integrerade av en människa). Över fem rundor överlevde påståendet inte intakt. Det smalnade av, i ordning:

1. **Universell koppling** – förbättring och bestridbarhet handlas mot varandra, alltid.
2. **Nivårelativ koppling** – avvägningen gäller inom ett fast hypotesrum; konceptuella revolutioner ändrar rummet och undkommer argumentet innanför rummet.
3. **Processprissättbart, inte utfallsprissättbart** – du kan inte prissätta det icke-tänkta alternativet, men du kan parametrisera den *generator* som producerar alternativ; oobserverbarhetsargumentet som först formulerades var fel.
4. **Exogent skyddsbart** – interna beskyddare av mångfald *kan* vara selektionsstabila (mutationshastigheten är vittnet), så beskyddaren behöver inte vara extern; omöjlighetspåståendet var fel.
5. **Källtermens lokalitet** – vad som överlever: alternativ avtar under målet och består endast genom en källterm, och den avgörande variabeln är huruvida den termen ligger innanför eller utanför optimerarens kontrollmängd.

Varje avsmalning tvingades fram av en invändning som förslagsställaren inte kunde absorbera utan att ändra påståendet, och var och en gjorde påståendet mindre, mer användbart och mindre storslaget. Det återkommande felsättet hos *förslagsställaren* är självt data: en tics att befordra ”svårt / kostsamt / nåbart” till ”omöjligt”. Spegelversionen av felsättet hos *panelen* var att befordra varje invändning till en elegantare syntes. Båda är ramar som inte kan överraskas; avsmalningen inträffade endast i luckorna mellan dem, där observatörerna inte delade förslagsställarens ram.

Detta ger det enda påstående som hela övningen inte kunde döda, och det är reflexivt: **ett påstående som hålls bestridbart av genuint dekorrelerade observatörer degraderas graciöst mot något verkligt, och degraderingen fungerar bara så länge observatörerna inte konvergerar mot en gemensam ram.** I samma ögonblick som undersökningen blir en enda syntes som alla nickar åt, slutar den att förbättras. Degraderingskurvan är därmed en levande instans av sitt eget ämne.

2.2 Fyrlins-experimentet

Degraderingskurvan producerade en kandidat till ordningsparameter ("räckvidd") som misstänktes vara inte en variabel utan flera mekanismer som delade ett ord. För att testa om mönstret över domäner var *identitet* (en mekanism) eller *rim* (distinkta mekanismer som bara liknar varandra) genomförde vi en kontrollerad elicitering.

Fyra discipliner fick var och en den identiska strukturella frågan, formulerad helt i den disciplinens inhemska termer. Varje prompt:

- förbjöd all gränsöverskridande vokabulär (*mångfald, utforskning, bestridbarhet, räckvidd, adaptivitet, korrigerbarhet, absorption*);
- undanhöll hypotesen och lät "stiger / faller / hålls" vara lika levande svar;
- krävde ett fast femfälsutdata som avslutades med en **minimal formell utsaga** och en intern oenighet inom fältet.

Två modellfamiljer per lins, dragna från olika leverantörer, gav en replikationskontroll inom linsen före någon jämförelse mellan linserna. Den integrerande modellen exkluderades från att vara en lins, för att undvika att korrelera integrationen med en av dess indata.

Bedömningskriteriet fastställdes *innan* svaren lästes: identitet skulle kräva att de oberoende minimala formella utsagorna (fält 4) delade struktur, medan undantagsvillkoren (fält 3) oberoende namngav samma flyktväg. Rim skulle visa konvergerande intuitioner men strukturellt divergerande formalismer. Prompterna återges i appendixet.

En reservation som styr hela resultatet: dessa observatörer delar betydande träningsoverlapp. **Överensstämmelse mellan dem är stark evidens för att de fyra disciplinära begreppen är formellt isomorfa, och svag evidens för att isomorfin speglar verkligheten [H].** Vad fyra läroböcker kodar i samma form kan vara ett djupt drag hos optimerande system eller ett djupt drag i hur vi lärs att modellera dem. Experimentet kan inte skilja dessa, och artikeln låtsas inte att det kan.

3. De fyra fristående kollapserna

Varje lins rapporteras som ett oberoende formellt objekt. De *förenas inte* i detta avsnitt; föreningen är det separata, svagare påståendet i §4.

3.1 Reglerteknik – persistent excitation

Inhemsk term: persistent excitation (rikedom hos regressorerna $\varphi\varphi^T$).

Riktning: faller. När regulatorn minimerar reglerkostnaden undertrycker den insignalcomponenter som inte behövs för referensföljning, vilket svälter identifieringen av den signalrikedom den kräver.

Flykt: kapaciteten faller inte omm *referenssignalen* $r(t)$ själv är persistent exciting av ordning $\geq$ antalet okända parametrar – dvs. rikedom injiceras utifrån reglerlagen.

Minimal form: under den optimala reglerlagen, om $r(t)$ inte är persistent exciting av ordning n , blir den tids-medelvärdesbildade $\int \varphi\varphi^T$ singular; annars förblir den likformigt positivt definit.

Felsätt: sluten-loop-undertryckning av identifieringskanalen.

Källtermen är $r(t)$. Regulatorn kan inte göra sin egen referens exciting – det är vad som gör den till referensen. **Strikt exogen.**

3.2 Evolutionsbiologi – stående genetisk varians

Inhemsk term: stående additiv genetisk varians, V_A .

Riktning: faller. Riktad selektion driver gynnade alleler mot fixering och tömmer additiv varians i den selekterade egenskapen.

Flykt: faller inte när mutationsinput V_m (och/eller rekombination som frigör dold varians, och/eller fluktuerande selektion) balanserar utarmningen.

Minimal form: $\Delta V_A \approx V_m - (\text{selektionsterm}) \cdot V_A - (\text{driftterm}) \cdot V_A$; varians avtar om inte input eller fluktuation balanserar den.

Felsätt: regimberoende – stabilitet beror på miljövolatilitet.

Källtermen är V_m plus miljöfluktuation. Avgörande är att mutationshastighet själv är en *ärfelig, selekterbar parameter*: optimeraren kan i princip agera på den. **Omstritt endogen.**

3.3 Institutionell ekonomi – hot om inträde

Inhemsk term: hot om inträde, τ .

Riktning: faller. Den vinstmaximerande etablerade aktören höjer barriärerna B , vilket sänker sannolikheten för undanträngning.

Flykt: faller inte när det kostar den etablerade mer att höja B än den vinner ($\partial\pi/\partial B \leq 0$), eller när B är fixerat av teknologi, lag eller trovärdig extern sanktion.

Minimal form: $\partial\tau/\partial B < 0$, gäller om inte $\partial\pi/\partial B \leq 0$ eller B är externt takbegränsat.

Felsätt: bevarandemekanismen är själv en optimerbar variabel – barriärer väljs av samma agent som hotet begränsar.

Källtermen är en *restriktion på B som den etablerade inte sätter*. **Strikt exogen.**

3.4 Beslutsteori – strategi-/posteriorstöd

Inhemsk term: stöd för agentens strategi och posterior (handlingar och hypoteser som bär vikt men inte för närvarande är maximala).

Riktning: faller. EU-maximering med Bayesiansk uppdatering koncentrerar massa på nyttoximerande handlingar och tillstånd med hög posterior; vikten på resten går mot noll.

Flykt: faller inte under icke-stationäritet (posteriorn kan inte sätta sig), under exakta nyttoband, eller – i vissa formaliseringar – när informationsvärdet av en för närvarande suboptimal handling är strikt positivt.

Minimal form: $w_t(a) \rightarrow 0$ för submaximala a i en stationär värld; består om $VOI(a) > 0$, eller band, eller icke-stationäritet fortsätter att omfördela massa.

Felsätt: stödkollaps – men platsen för flykttermen är *inte avgjord inom linsen* (se §4.2).

Källtermen är icke-stationäritet (exogen) *eller* VOI (som i vissa formaliseringar läses som en intern hedge). **Omstritt.**

4. Det gemensamma mönstret, och den korrigerade ordningsparametern

De fyra minimala formerna, skalade till skelett, är samma objekt:

*En storhet **Q** som representerar för närvarande oanvända alternativ – excitationssrikedom, additiv varians, hot om inträde, strategi-/posteriorstöd – **avtar monotont under det primära målet** via ett teckenvillkor, och hålls positiv **endast av en källterm som den optimerande processen inte själv sätter**.*

Det starka testet passerades: fyra oberoende härledda formella utsagor, fyra disjunkta vokabulärer, en struktur. Det svaga testet passerades också: varje lins undantagsvillkor (fält 3) namngav oberoende *icke-stationäritet eller en externt hållen restriktion* som flykten, utan någon koordination. Enligt det kriterium som fastställdes i förväg är detta **identitetsutfallet**, inte rim **[IP]**.

Detta pensionerar det ord som gjorde illegitimt arbete. Ordningsparametern är **inte** optimerarens ”räckvidd” – som alltid var fyra mekanismer (parameterkontroll, institutionell kontroll, representationsutrymme, selektionsomfång) i en enda rock. Den faktiska axeln är **källtermens lokalitet**: ligger den term som bevarar Q innanför eller utanför optimerarens kontrollmängd?

4.1 Två skikt

De fyra linserna delar sig rent, och delningen är resultatet:

Lins	Källterm	Lokalitet	Kollaps
Reglerteknik	referensrikedom $r(t)$	exogen	robust – ingen intern flykt
Institutioner	restriktion på barriärer B	exogen	robust – ingen intern flykt
Evolution	mutationsinput V_m	omstritt endogen	betingad av andra ordningens optimering
Beslut	VOI / icke-stationäritet	omstritt	betingad / ramberoende

När källtermen är **strikt exogen** (reglerteknik, institutioner) är kollapsen robust: optimeraren kan strukturellt inte nå den term som skulle rädda den. En regulator kan inte berika sin egen referens; en etablerad aktör kan inte lyfta det juridiska taket på sina egna barriärer. Q faller och det finns inget

internt drag som stoppar det.

När källtermen är **endogen eller omstritt så** (evolution, beslut) blir kollapsen betingad av en *andra ordningens* fråga: optimerar optimeraren också källtermen? Mutationshastighet är ärftlig, så selektion *kan* agera på den – men den driver den inte alltid till noll, eftersom en låg mutationshastighet i en fluktuerande miljö själv missgynnas. Detta är exakt det vittne som dödade det tidigare omöjlighetspåståendet. Den interna beskyddaren överlever inte för att den är skyddad, utan för att det inte är monotont i fitness att ta bort den *givet en volatil miljö* – dvs. dess överlevnad är parasitär på ett bakgrundsvillkor (volatilitet) som populationen inte heller sätter.

Detta är den precisering experimentet köpte: den verkligt interna källregimen är den *intressanta*, eftersom det är den enda plats där optimerarens egna val avgör utfallet – och även där lutar sig stabiliteten mot en exogen bakgrund. Det exogena skiktet är avgjort och dystert. Det endogena skiktet är där varje designfråga som är värd att ställa nu lever.

4.2 Beslutsteorisömmen (hålls öppen) [H]

Beslutsteori är bistabil, och vi representerar det snarare än att medelvärdesbilda bort det. Över tre familjer: två lokaliserade persistens delvis i **VOI som en intern hedge** – agenten håller suboptimala handlingar viktade *som en del av* maximeringen, vilket gör källtermen endogen i förhållande till målet. En tredje återgav samma problem med **VOI som ett offer** för koncentration – informationsvärdet *faller med* posteriorn, och varje överlevande flykt (icke-stationäritet, en felspecificerad prior, en oinformativ kanal) är strikt extern.

Båda läsningarna är kompetent beslutsteori. Linsen tvingar inte fram en. Så beslutsteori är en *strikt* medlem av schemat under offerläsningen och en *nära-isomorfi* under hedgeläsningen, och fältet har inte avgjort vilken som är korrekt. Denna bistabilitet är inte brus – den är den renaste tillgängliga demonstrationen att **källtermens lokalitet är, för vissa system, ett modelleringsval snarare än ett fast faktum**. Det hör hemma i resultatet med sin osäkerhet intakt.

5. Vad detta inte visar

Disciplinen hos en negativ artikel är att förbjuda befordran av dess eget avgränsade fynd till en lag. Explicit:

- Det visar **inte** att bevarande av mångfald är omöjligt. Evolutionen är ett stående motexempel.
- Det visar **inte** universell kollaps. Två av fyra linser gör kollapsen betingad.
- Det definierar **inte** ett mätbart index. Den bevarande källtermen är, i de fall som betyder mest, inte rent observerbar.
- Det föreslår **inte** en enhetlig teori eller en enda kausal mekanism. Det rapporterar en isomorfi av *formalismer* och en axel längs vilken de skiljer sig.
- Det licensierar **inte** ”räckvidd”, ”epistemisk adaptivitet” eller ”bestridbarhetsindex” som primitiver. Var och en prövades; var och en återinförde en dold global variabel; var och en listas i appendixet som förkastad.

Det tillåtna påståendet är exakt ett: de fyra formalismerna delar en förfall-plus-källterm-struktur, och de skiljer sig längs källtermens lokalitet **[IP]**. Regeln som skiljer denna artikel från de synteser den kritiserar är smal och bärande: *ingen syntes som befördrar ett regimvillkorat mönster till en lag*. De tidigare överdrifterna korsade den linjen mot omöjlighet; den överkorrigerade ”atlasen utan någon syntes alls” skulle korsa den åt andra hållet, genom att förklara de fyra krascherna oberoende när evidensen visar att de inte är det. Fyndet sitter emellan, med sina räckviddsvillkor i texten och inte i en fotnot.

6. Restposten

Två saker förblir genuint öppna, och båda rapporteras som öppna.

Det endogena skiktet. Där källtermen är i optimerarens kontrollmängd (evolution, beslut-under-hedge-läsning) avgörs utfallet av om optimeraren optimerar källtermen, och av ett bakgrundsvillkor (volatilitet, kanalinformativitet) som optimeraren inte heller sätter. Den levande designfrågan – skarpare än något synteserna producerade – är om det existerar en *skyddsklass mellan fysiskt oredigerbart och politiskt upphävningsbart*: en restriktion som är tillräckligt kostsam att upphäva för att överleva vanligt optimeringstryck utan att vara bokstavligt utanför systemet. Biologins invariant är fysisk och oupphävlig; en institutions skyddade slack är en budgetpost som en framtida kostnadsskärare kan skära bort. Huruvida något stabilt lever däremellan är oavgjort, och det är frågan som hela denna arbetslinje nu pekar mot.

Det oprissättbara, korrekt avgränsat. Beslutsteorilinsen namngav sin egen frontlinje opåkallat: inte icke-stationäritet, utan *omedvetenhet om oförutsedda tillstånd* – strukturell ofullständighet hos hypotesrummet, ett tillstånd som priorn tilldelade noll. Detta är det icke-tänkta-alternativ-problemet från den tidiga degraderingskurvan, som återvänder i sitt rätta hem. Det listas av linsen som ett **felsätt**, inte en hanterbar term: du kan inte reservera massa längs en dimension du inte har. Den tidigare undersökningen överdrev detta som en universell omöjlighet och tvingades ta tillbaka det. Dess kalibrerade form är smal: bland de fyra linserna är det endast den som resonerar över föreställningar-om-hypoteser som har ett undantagsvillkor som ingen formalisering i mängden kunde prissätta – och det är där den genuint oobserverbara resten bor, snarare än överallt.

Schemat är tillräckligt avgjort för att anges **[IP]**. Ordningsparametern är korrigerad. De två skikten är rena. Det som förblir öppet är det endogena skiktets skyddsklassfråga och det beslutsteoretiskt oprissättbara – och en artikel som stängde någotdera genom dekret skulle reproducera den exakta ramstängning den satte ut för att kartlägga.

Appendix A — Lins-prompter

Var och en klistrades in fristående, ingen annan kontext. Identiskt femfälts utdataformat över alla fyra. Förbjudna gränsöverskridande termer hölls konstanta. Fullständig text tillgänglig på begäran; strukturen sammanfattas: *svara strikt som en [disciplin]; använd endast [inhemska] begrepp; använd inte [förbjuden lista]; betrakta [ett system som minimerar/maximerar ett mål i en potentiellt icke-stationär miljö]; returnera INHEMSK TERM / RIKTNING / UNDANTAGSVILLKOR / MINIMAL FORMELL UTSAGA / KONFIDENS + intern oenighet inom fältet.*

Modelltilldelning: reglerteknik (två familjer), evolution (två familjer), institutioner (två familjer), beslut (tre familjer – en lades till för att testa §4.2-sömnen). Integratorn exkluderades från linsningen.

Appendix B — Förkastade unifieringar

Var och en prövades under degraderingskurvan; var och en förkastades för att den återinförde en dold global variabel.

- **Epistemisk Adaptivitet (skalär / index)** – den bärande bestridbarhetstermen är konstitutionellt omätbar; indexet kollapsar till en prestationsgrad plus en fudgefaktor.
 - **”Räckvidd” som primitiv** – sönderfaller i fyra icke-ekvivalenta mekanismer; ersatt av källtermens lokalitet.
 - **Bayesiansk unifiering** – giltig endast inom ett fast hypotesrum; konceptuella revolutioner ändrar rummet.
 - **Exogenitet som nödvändigt villkor** – falskt; interna beskyddare kan vara selektionsstabila (mutationshastighet).
 - **Själverosion som universell omöjlighet** – falskt; regimberoende, med stående motexempel.
-

Konfidensetiketter

- **[IP]** – förfall-plus-källterm-schemat och ordningsparametern källtermens lokalitet. Oberoende härlett över fyra disjunkta formalismer; avgränsat; inte befordrat till lag.
- **[H]** – världsrelevansen av isomorfin (korrelerade observatörer), och beslutsteorins bistabilitet.
- **[R]** – inget. Den korrelerade-observatörs-reservationen och den oprissatta resten blockerar båda en robust tagg, avsiktligt.